强化学习

从 Bandit 到 RLHF、RLVR 与 Agentic RL

王自强整理

合订本

2026 年 10 月

仅供个人非商业学习使用

版权与出处说明

本书由王自强整理，供个人学习与非商业交流使用。正文依据公开课程、公开论文与公开教材整理改写；公式、图表和具体论述的来源见正文标注及附录。相关材料的著作权与使用条件归各自权利人所有；Sutton & Barto《Reinforcement Learning: An Introduction》由 MIT Press 免费公开，arXiv 论文按各自许可发布，Spinning Up 文档为 CC BY-SA 4.0。本文件仅供个人非商业学习使用。

主要参考来源

- Sutton R S, Barto A G. Reinforcement Learning: An Introduction[M]. 2nd ed. Cambridge: MIT Press, 2018.（作者免费公开版）
- OpenAI. Spinning Up in Deep Reinforcement Learning[EB/OL]. https://spinningup.openai.com（CC BY-SA 4.0）
- Stanford University. CS224R: Deep Reinforcement Learning[EB/OL]；UC Berkeley. CS285: Deep Reinforcement Learning[EB/OL].
- Wang Z, et al. Reinforcement Learning for LLM Post-Training: A Survey[J]. arXiv:2407.16216
- Ouyang L, et al. Training Language Models to Follow Instructions with Human Feedback[J]. arXiv:2203.02155
- Schulman J, et al. Proximal Policy Optimization Algorithms[J]. arXiv:1707.06347
- Christiano P, et al. Deep Reinforcement Learning from Human Preferences[J]. arXiv:1706.03741
- Rafailov R, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[J]. arXiv:2305.18290
- Shao Z, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[J]. arXiv:2402.03300

排版与工具

本书由 PyMuPDF 排版生成：正文为宋体与 Times New Roman，标题为黑体，公式经 MathJax 转为矢量图形后插入，插图为矢量 SVG。康奈尔版式、页眉页脚、公式编号与书签均由构建脚本自动生成。

使用说明

公式与编号

公式统一用 LaTeX 录入并经 MathJax 渲染为矢量图形，因此任意放大都不失真。需要引用的公式在右侧标注章内编号，例如第 2 章第 7 式写作 (2.7)；书中引用写作「式 (2.7)」。重要结论以定义、定理、命题框给出，算法以带上下粗线的算法框给出，步骤编号形如 1:、2:。每个定理与误差界后面标注 [精确]、[渐近]、[近似] 或 [经验规律]，说明它的理论地位；没有定理支持时，正文不使用无条件的「收敛」「稳定」。

图表

图与表按章编号（图 1-2 表示第 1 章第 2 图），图题在图下方居中，表题在表上方居中，表格使用三线表。插图全部为矢量图，由本书配套脚本按数据重新绘制，不使用截图；数据图的图注给出种子、样本量与评估协议。

全书结构

全书分四部分十二章。第一部分（第 1 – 3 章）建立共同语言：多臂老虎机与探索、马尔可夫决策过程与贝尔曼理论、动态规划与蒙特卡洛、时序差分。第二部分（第 4 – 6 章）是经典与深度强化学习：函数逼近与离策略学习、策略梯度与 PPO、DQN 家族与连续控制。第三部分（第 7 – 9 章）讨论规划与进阶决策：模型与搜索、离线强化学习与策略评估、层次方法与多智能体、安全约束。第四部分（第 10 – 12 章）把这些工具用到语言模型与智能体：RLHF 与偏好优化、RLVR 与推理强化学习、Agentic RL 与持续学习。

三条阅读路线

速查路线：只关心大模型后训练的读者读 2.1 – 2.4、5.1 – 5.3、第 10 章与第 11 章，遇到符号回查附录 A。系统路线：按章顺序读，四部分的桥梁节（2.4、3.2、4.3、5.1、5.6、10.3）不要跳过，它们是把前后章节缝起来的地方。研究路线：先读 4.3（投影贝尔曼与三类误差）、8.5（离策略评估）、10.3 – 10.5（KL 正则到 DPO）、11.2（GRPO），这些是当前讨论最活跃的节点。

符号约定

状态 s、动作 a、奖励 r、折扣 γ、策略 π、行为策略 μ、价值函数 V 与 Q、优势 A、参数 θ（策略）与 ϕ（价值或奖励模型）。期望的下标写明分布，例如 $E_{\pi}[\cdot]$ 表示按策略 π 采样求期望；上标 * 表示最优量，下标 t 表示时刻，k 表示迭代轮次。完整符号表与禁用写法见附录 A。

目　录

王自强整理

第 0 章　全书导论：核心问题、结构与理论边界 13

0.1 强化学习的三个难点 13

0.2 全书地图 14

0.3 六个反复出现的对象 17

0.4 理论分层：判断定理成立的条件 18

0.5 前提知识最小集 20

0.6 符号与命名空间 21

0.7 三条阅读路线 23

0.8 阅读路径与资料使用 24

本章小结 24

关键公式 25

习题 25

延伸阅读 26

第 1 部分　数学与决策基础

第 1 章　Bandit 与探索 28

1.1 问题与形式化 28

1.1.1 K 臂老虎机 28

1.1.2 遗憾的两笔账 29

1.1.3 下界：对数遗憾从哪来 29

1.2 贪心与 ε-贪心 31

1.2.1 从样本平均到动作价值 31

1.2.2 ε-贪心与线性遗憾的精确标价 31

1.2.3 无限次访问与 GLIE 的严格条件 32

1.2.4 Robbins–Monro 条件只约束步长 33

1.3 乐观面对不确定性 34

1.3.1 UCB1 的索引 34

1.3.2 对数遗憾与它的三个前提 34

1.3.3 区间估计：一个可替换的框架 35

1.4 后验与信息 37

1.4.1 Thompson 采样 37

1.4.2 贝叶斯遗憾与信息增益 37

1.4.3 四种探索的分层 38

1.4.4 六种策略在同一张测试台上 38

1.5 上下文老虎机与向 MDP 的过渡 40

1.5.1 上下文老虎机 40

1.5.2 LinUCB：把线性结构变成置信区间 40

1.5.3 缺的那半步：状态、转移与信用分配 41

本章小结 42

关键公式 42

习题 43

延伸阅读 44
第 2 章　MDP 与 Bellman 理论 45
2.1 序贯决策：从老虎机到马尔可夫决策过程 45
2.1.1 上下文老虎机：一次一步的决策 45
2.1.2 状态：让未来只依赖现在 46
2.2 马尔可夫决策过程 48
2.2.1 定义与约定 48
2.2.2 回合、截断与三类目标 48
2.2.3 策略与价值函数的记号 49
2.3 贝尔曼方程与算子视角 51
2.3.1 贝尔曼期望方程 51
2.3.2 矩阵形式与闭式解 52
2.3.3 贝尔曼算子与压缩映射 52
2.4 最优性、策略改进与误差界 55
2.4.1 贝尔曼最优方程 55
2.4.2 残差界：从一个候选价值函数到最优值的距离 56
2.4.3 策略改进：价值差恒等式 58
2.4.4 最优方程与策略改进的关系 60
2.5 部分可观测、状态与奖励设计 61
2.5.1 部分可观测决策过程 61
2.5.2 状态设计的三个陷阱 61
2.5.3 奖励设计与势函数不变性 61
2.5.4 从模型到数据：本章结论的适用边界 62
本章小结 63
关键公式 63
习题 64
延伸阅读 65
第 3 章　动态规划、蒙特卡洛与时序差分 66
3.1 动态规划：有模型时的迭代求解 66
3.1.1 策略评估：把线性方程组变成迭代 66
3.1.2 策略迭代：评估与改进交替 67
3.1.3 值迭代与截断评估 68
3.1.4 原地更新与异步动态规划 69
3.2 蒙特卡洛：把回报当作样本 70
3.2.1 首次访问与每次访问 70
3.2.2 增量均值与随机逼近 70
3.2.3 覆盖：探索起点与 -软策略 71
3.2.4 蒙特卡洛控制 72
3.3 时序差分：用估计更新估计 73
3.3.1 TD(0) 与 TD 误差 73

3.3.2 偏差与方差：自举换来了什么 73
3.3.3 TD 的不动点 74
3.3.4 batch TD 与最大似然 75
3.4 n 步回报与资格迹 77
3.4.1 n 步回报 77
3.4.2 -回报 77
3.4.3 资格迹：前向与后向 78
3.5 控制与收敛条件 80
3.5.1 SARSA 与 Q-learning 80
3.5.2 收敛条件 81
3.5.3 折扣设定与平均奖励设定 82
3.5.4 表格方法的边界 82
本章小结 83
关键公式 83
习题 84
延伸阅读 85

第 2 部分　经典与深度强化学习

第 4 章　函数逼近与离策略学习 87
4.1 从表格到函数逼近 87
4.1.1 表格方法的规模墙 87
4.1.2 参数化值函数与“一次更新影响一片” 88
4.1.3 目标函数与加权范数 88
4.1.4 半梯度TD与完整梯度的区别 89
4.2 致命三要素与离策略 90
4.2.1 三个要素 90
4.2.2 分布偏移： 与 91
4.2.3 覆盖假设，以及它保证不了什么 92
4.2.4 离策略线性函数逼近的发散反例 93
4.3 投影 Bellman 与线性 TD 的不动点 94
4.3.1 线性函数空间与满列秩 94
4.3.2 加权投影与 D-内积 94
4.3.3 投影不动点与法方程 95
4.3.4 期望更新、正定性与收敛条件 95
4.3.5 有不动点，不等于收敛到不动点 98
4.3.6 MSPBE 与三类 Bellman 误差 99
4.3.7 残差界的适用范围 101
4.4 实用的离策略稳定化 102
4.4.1 经验回放 102
4.4.2 目标网络 102
4.4.3 优先采样与双网络 102

4.4.4 致命三要素的两种失败形态 103
4.5 批量 RL 与非线性逼近 104
4.5.1 最小二乘策略评估 104
4.5.2 拟合 Q 迭代 104
4.5.3 神经网络：失去闭式解之后 105
4.5.4 本章的位置，与下一章的问题 105
本章小结 106
关键公式 106
习题 107
延伸阅读 108
第 5 章　策略梯度、信赖域与 PPO 109
5.1 策略梯度定理 109
5.1.1 目标函数与似然比技巧 109
5.1.2 两种等价写法与那个归一化因子 110
5.1.3 REINFORCE 与基线 112
5.2 优势、Actor-Critic 与 GAE 114
5.2.1 两个关于“无偏”的命题 114
5.2.2 Actor-Critic：一份数据，两个学习率 115
5.2.3 广义优势估计 116
5.3 信赖域与 TRPO 118
5.3.1 一步走多远 118
5.3.2 性能差恒等式 118
5.3.3 TRPO 的约束优化 119
5.4 PPO 121
5.4.1 从约束到裁剪 121
5.4.2 裁剪与 KL 惩罚的实测差别 122
5.4.3 十项复现标准 122
5.4.4 熵正则与总损失 124
5.5 实践与诊断 125
5.5.1 五种常见失败 125
5.5.2 评估协议 125
5.5.3 一个小实验：什么在起作用 125
本章小结 127
关键公式 127
习题 128
延伸阅读 128
第 6 章　深度强化学习：从 DQN 家族到连续控制 130
6.1 表格Q-learning的规模与表示限制 130
6.1.1 状态爆炸与“泛化”的代价 130
6.1.2 目标里含有自己的参数 130

6.1.3 离线数据带来的分布偏移 131
6.1.4 两个工程装置各修什么 132
6.2 DQN 与它的改进方法 133
6.2.1 过估计：最大算子的系统性正偏差 133
6.2.2 Double DQN：把选择与评估分开 134
6.2.3 Dueling：把状态价值与动作优势拆开 135
6.2.4 优先经验回放：把预算花在还没学会的地方 135
6.2.5 探索：把随机性放进网络 136
6.2.6 Rainbow 与补丁之间的冲突 137
6.2.7 一个必须澄清的术语：分类型价值学习不等于分布式训练 137
6.3 连续动作与策略梯度方法 139
6.3.1 连续动作下 不再可算 139
6.3.2 DDPG：把 DQN 的三件装备搬到连续空间 139
6.3.3 TD3：三处改动，各修一个失效模式 140
6.3.4 SAC：把熵写进目标 141
6.4 训练诊断与评估 144
6.4.1 三种曲线形态与它们的病因 144
6.4.2 三个容易被调坏的旋钮 144
6.4.3 评估协议 145
6.4.4 一个真算的实验：线性二次调节器上的三种方法 145
6.5 从 Atari 到机器人 147
6.5.1 从像素到状态：观测不是状态 147
6.5.2 仿真到真机：域随机化能补什么，不能补什么 147
6.5.3 分布式采样与大规模训练 148
本章小结 149
关键公式 149
习题 150
延伸阅读 150

第 3 部分　规划与进阶决策

第 7 章　模型、规划与搜索 153
7.1 Dyna：把模型当作加速器 153
7.1.1 三条回路 153
7.1.2 规划步数的真实收益 154
7.1.3 模型误差对规划结果的影响 156
7.2 模型学习与不确定性 157
7.2.1 监督式的模型学习 157
7.2.2 两类不确定性 157
7.2.3 悲观、乐观与短 rollout 158
7.3 从 PETS 到 Dreamer 160
7.3.1 PETS：概率集成加模型预测控制 160

7.3.2 MBPO：短 rollout 与真实数据混合 160
7.3.3 Dreamer：在隐空间里想象 160
7.4 搜索：从 MCTS 到 MuZero 162
7.4.1 MCTS 的四步 162
7.4.2 AlphaZero：先验与计数互相喂养 164
7.4.3 MuZero：预测而非重建 165
7.4.4 规划的边界 166
7.5 基于模型方法的适用条件 168
本章小结 169
关键公式 169
习题 170
延伸阅读 171
第 8 章　离线强化学习与策略评估 172
8.1 离线设定与三个假设 172
8.1.1 数据固定意味着什么 172
8.1.2 覆盖假设与它的松弛 173
8.1.3 三个误差来源与它们的耦合 174
8.2 悲观与保守：BCQ、CQL、IQL 176
8.2.1 悲观原则的一般形式 176
8.2.2 BCQ：把动作选择限制在支持集内 176
8.2.3 CQL：压低数据外动作的价值 177
8.2.4 IQL：不查询数据外动作 178
8.3 序列建模路线：Decision Transformer 181
8.4 模仿学习与交互式数据收集 182
8.4.1 行为克隆与复合误差 182
8.4.2 DAgger：交互式数据聚合 183
8.4.3 与离线设定的关系 184
8.5 离线策略评估 185
8.5.1 评估问题与三条路线 185
8.5.2 重要性采样：无偏，但方差可以无穷 185
8.5.3 直接法与双重稳健 186
8.5.4 同一数据集上的四个估计量 188
8.5.5 离策略评估的可靠性条件 188
本章小结 190
关键公式 190
习题 191
延伸阅读 192
第 9 章　层次、多智能体与安全约束 194
9.1 选项与半马尔可夫决策过程 195
9.1.1 选项的定义与持续时间 195

9.1.2 选项评论家：终止函数也可以求梯度 197
9.1.3 选项的适用条件与实验表现 198
9.1.4 平均奖励下的半马尔可夫形式 200
9.2 马尔可夫博弈与多智能体 201
9.2.1 形式化：当“最优”不再唯一 201
9.2.2 集中训练、分散执行 202
9.2.3 多智能体学习中的非平稳性与收敛条件 203
9.3 约束马尔可夫决策过程与风险敏感 205
9.3.1 约束 MDP 与拉格朗日方法 205
9.3.2 风险度量：VaR 与 CVaR 206
9.3.3 期望约束不能替代尾部约束 208
9.3.4 三种落地做法 209
9.4 元学习与前述决策框架的关系 210
本章小结 211
关键公式 211
习题 211
延伸阅读 212

第 4 部分　语言模型与自主智能体

预备　语言模型作为策略 214
接口：从 token 到策略 214
动作是 token，轨迹是一条序列 214
从 SFT 到策略 216
三个模型：策略、参考与旧策略 216
KL 正则的两种位置 218
奖励与信用分配 220
奖励从哪来 220
从序列奖励到 token 梯度 221
本章小结 223
关键公式 223
习题 224
延伸阅读 224
第 10 章　RLHF 与偏好优化 226
10.1 从人类反馈到奖励模型 226
10.1.1 成对偏好与绝对评分的标注特性 226
10.1.2 Bradley – Terry：把偏好写成奖励差 226
10.1.3 奖励模型的可辨识性与偏好压缩 228
10.2 带 KL 正则的策略优化 230
10.2.1 目标与它的闭式解 230
10.2.2 token 级 PPO 的实现要点 231
10.2.3 结果监督与过程监督 232

10.3 DPO：把奖励重参数化 234
10.3.1 七步推导 234
10.3.2 推导成立的七个条件 236
10.3.3 失效模式 237
10.3.4 工程对比 237
10.4 其他偏好优化路线 239
10.5 评估与失效 241
10.5.1 奖励黑客的三种表现 241
10.5.2 长度偏差的量 242
10.5.3 对齐税、数据泄漏与评估协议 242
本章小结 244
关键公式 244
习题 245
延伸阅读 245
第 11 章　RLVR 与推理强化学习 247
11.1 可验证奖励的定义与判定范围 247
11.1.1 判定器与它的四种形态 247
11.1.2 可验证不等于正确 248
11.1.3 稀疏奖励与信用分配 249
11.1.4 模型评审反馈的可靠性边界 249
11.2 GRPO：组内相对奖励 251
11.2.1 出发点：PPO 的目标 251
11.2.2 组内标准化 251
11.2.3 GRPO 的目标 252
11.2.4 GRPO 的估计性质与适用范围 253
11.2.5 与 PPO 的对照 254
11.3 从 RLVR 到长链推理 256
11.3.1 R1 路线的四个阶段 256
11.3.2 长度膨胀与熵塌缩 257
11.3.3 pass@1 与 pass@k 的错配 258
11.4 稳定性与工程 259
11.4.1 KL 系数与参考策略 259
11.4.2 token 级比率与序列级比率 259
11.4.3 采样温度与组大小 260
11.4.4 奖励黑客 260
11.4.5 评估协议 261
11.5 研究前沿与未解问题 262
11.5.1 三个方向：DAPO、GSPO 与 Dr.GRPO 262
11.5.2 开放问题 263
本章小结 264

关键公式 264
习题 265
延伸阅读 266
第 12 章　Agentic RL 与持续学习 267
12.1 从单次回答到多步交互 267
12.1.1 一次回答与一个回合 267
12.1.2 三条失效的结论 269
12.1.3 terminated 与 truncated：为什么在回合里更要紧 269
12.2 Agentic 循环的形式化 271
12.2.1 状态、动作与转移的分解 271
12.2.2 三条“不能直接套用” 272
12.2.3 两条代表路线 272
12.2.4 把回合放回已有的算法框架 272
12.3 四类“适应”的判别 273
12.3.1 一个统一写法 273
12.3.2 上下文内适应：只改 273
12.3.3 记忆更新：改 274
12.3.4 参数更新：改 274
12.3.5 持续 RL：改 且要求在序列上不退 274
12.4 持续学习与遗忘 276
12.4.1 遗忘从哪里来 276
12.4.2 三类对策 276
12.4.3 任务序列与评估协议 277
12.4.4 一个可复现的遗忘实验 278
12.4.5 稳定性—可塑性权衡 279
12.5 工程与未解问题 280
12.5.1 长时程信用分配 280
12.5.2 可复现性 280
12.5.3 评估：成功率、步数与成本 280
12.5.4 安全：不可逆动作 280
12.5.5 三个没有定论的问题 281
本章小结 282
关键公式 282
习题 283
延伸阅读 284

第 0 章　全书导论：核心问题、结构与理论边界

本章是全书的引言，说明各章要解决的问题、章节之间的衔接，以及阅读“收敛”“无偏”“等于”等结论时需要检查的前提。第0.2节介绍全书结构，第0.4节归纳理论结论的适用范围；相关概念可供后续章节随时查阅。

强化学习结论依赖数据来源、状态与动作表示以及更新方式等条件。同一个更新式在不同数据分布下可能具有不同性质。例如，在有限状态和动作空间中，可以为每个状态或状态—动作对单独存储价值，这种方法称为表格法。若用正在评估的策略采集样本，时序差分（TD）有相应的收敛结论；若样本来自另一策略，类似更新则可能发散，第 4 章将用 Baird 反例说明这一点。第 11 章讨论的语言模型训练也体现了结论强度的差异：可验证奖励训练后回答长度平均增加约三成，这是实验观察，并非定理保证的结果。

方法的分析包括其依赖的假设与结论的适用范围。本书各章都围绕这两点展开。第0.2节介绍十二章的结构和四类结论强度，其余部分汇总核心困难、数学对象、常用工具与符号，方便读者随时回看。

0.1 强化学习的三个难点

常见的监督学习分析通常预设训练样本来自固定分布，并考察相同或相近分布上的预测性能。强化学习中，行为策略可能改变所采集的数据及其后续分布。智能体的行动决定部分观测数据的来源，数据进一步影响策略更新，形成策略与数据分布的相互作用。本书围绕延迟反馈、分布偏移和探索三类困难组织后续章节。

最常见的是延迟反馈。在仅于对局结束时获得胜负奖励的任务中，学习算法需要估计各步行动对最终结果的贡献。第3章讨论使用完整采样回报的蒙特卡洛估计，第5章介绍基于得分函数的策略梯度，第11章讨论按整条回答给出二值反馈的可验证奖励训练。稀疏反馈通常加重信用分配困难；估计方差的变化还取决于奖励分布、基线和具体估计器。

第二个是分布偏移。离策略评估使用行为策略采集的数据估计目标策略的价值，二者的访问分布可能不同。离策略学习因此需要覆盖假设（第 4、8 章），离线强化学习把这条假设推到极限：数据固定，不能再采（第 8 章）。覆盖条件不成立时，依赖该条件的收敛界或误差界无法直接应用。

第三个是探索。始终选择当前估计最优的动作，可能使其他动作缺乏足够的观测数据。第1章使用多臂老虎机刻画探索的遗憾代价，第2章扩展到状

SUMMARY / 总结

态依赖的序贯决策。深度强化学习常通过随机动作、熵正则等机制探索；Gittins指数等精确解依赖特定问题结构。这个落差本身就是第 0.4 节“分层”的一个例子。

交互数据的获取通常受到时间、计算或环境成本约束。样本效率（第 6、7 章）、离线数据复用（第 8 章）、语言模型里“一次 rollout 训多次”（第 10、11 章），都是这条约束的不同应对。

本书按照问题假设和方法所解决的困难组织内容。有限状态、有限动作下的值迭代仍是许多问题的有效解法；DQN 的过估计可通过目标值的选择加以缓解；语言模型训练中仍会使用 PPO，因为奖励不可靠时，其更新方式相对保守。各方法的价值取决于它们适用的条件，以及它们对具体困难提供的解决思路。

因此，本书围绕每种方法的三方面展开：所依赖的假设（数据来源、能否继续交互）、所优化的量（回报、投影误差或偏好似然），以及结论成立的条件。上述三项要素构成后续章节分析算法的共同框架。

0.2 全书地图



图 0-1 全书四部分与十二章。列头是该部分回答的问题，下面三行是这一部分的章。箭头表示依赖：后一部分默认前一部分的内容已经读过。

全书分为四部分，分别从基础决策问题、函数逼近与优化、模型和数据约束、语言模型与智能体系统展开。各部分改变的对象不同：状态与动作表示、可用数据、决策时间结构及奖励来源。

SUMMARY / 总结

第 1—3 章讨论有限状态、有限动作的情形。表格法为每个状态或状态—动作对单独存储一个价值，因此状态规模较小时可以直接分析收敛性、最优性和误差界。第 4 章将价值表示扩展到由特征张成的线性空间；此时，存在不动点并不意味着采样算法一定收敛到该点。第 6 章进一步采用神经网络表示，能够成立的结论大多需要额外条件，许多判断仍来自实验观察。

第三部分讨论模型和数据条件的变化：第 7 章研究环境模型与规划，第 8 章研究固定数据下的策略学习和评估，第 9 章研究层次决策、多智能体与安全约束。最后一部分以语言模型作为策略表示，并用一篇预备章说明接口变化：动作成为 token，奖励落在序列末尾，参考模型与旧策略承担不同作用。这一部分可用的理论保证较少，主要结论属于[经验规律]或[渐近]。

章节顺序体现了概念之间的依赖关系。第 4 章的投影分析建立在期望更新的线性系统表示上；第 8 章的覆盖假设需要行为策略与目标策略的定义；第 10 章的 KL 正则则使用了带约束的目标函数。读者具备相应先修知识后，可以按兴趣选择章节。

表 0-1 汇总各章的四项要素：数据来源、学习对象、优化目标，以及训练过程中能否继续与环境交互。这些要素彼此关联：固定的离线数据限制后续交互；非线性网络通常不具备闭式解；优化投影误差时，MSPBE 的二次型分析才适用。

SUMMARY / 总结

表 0-1 全书对象地图。同一行里的四列互相牵制：数据来源决定了能不能继续交互，“学什么”决定要什么假设，“优化什么”决定能用哪条定理。

章	环境与数据从哪来	学什么	优化什么	能否继续交互
1	多次拉动同一批臂	每个臂的均值与置信界	遗憾（累积损失）	能，且必须选臂
2	已知转移与奖励的 MDP 或采样轨迹	值函数与策略	期望折扣回报	视设定
3	有模型（DP）或采样（MC/TD）	V 或 Q 的表格	与 V^{π}、V^{*} 的误差	能（MC/TD）
4	由行为策略 μ 产生的轨迹	线性或非线性 V_{θ}、Q_{θ}	投影 Bellman 误差 / MSPBE	能，但数据可能离策略
5	当前策略采集的轨迹	策略参数 θ 与基线 V_{ϕ}	期望回报（含 KL 或信赖域约束）	能，策略即采样器
6	回放池中的历史转移	深度 Q 网络或策略网络	采样平方 TD 误差 / 策略目标	能，靠回放复用
7	真实交互 + 学到的模型	模型 P_{ϕ} 与价值	模型误差下的回报下界	能，且可离线规划
8	固定的离线数据集	策略或价值（不与环境交互）	保守化的回报估计	不能
9	多智能体或带约束的环境	选项、联合价值、约束价值	联合回报 / 约束满足	能
10	人类成对偏好	奖励模型 r_{ϕ} 或直接策略	偏好似然（KL 正则）	不必须
11	判定器给出的 0/1 奖励	策略（无 critic）	组内相对奖励	能，需重新采样
12	工具调用与长程任务	策略 + 记忆 + 技能库	任务成功与保留率	能，且环境会变

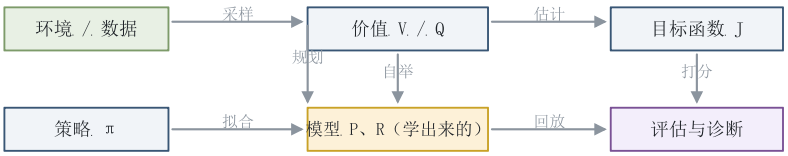
以第 8 章为例，离线强化学习使用固定数据集，训练期间无法继续与环境交互。因此，待评估策略所选择的动作需要得到数据集支持，覆盖条件直接影响价值估计的可靠性。相应地，算法会采用保守的优化目标；第 4 章依赖当前策略采样的收敛结论也不能直接用于这一设定。第 8 章将据此引入相应的分析对象与记号。

数据来源限定学习对象的可观测范围，优化目标决定算法如何更新，适用定理则给出结论成立的条件。这三个方面共同构成每章的分析框架。

SUMMARY / 总结

0.3 六个反复出现的对象

十二章名称各不相同，来来去去只有六个对象。



六个对象在每一章都出现，变的只是「哪些是已知的、哪些要学」

图 0-2 六个对象与它们之间的四条信息流。采样给出数据，拟合把数据变成价值，自举把价值变回目标，规划用模型替代真实交互，打分把目标函数变成可优化的数。

环境与数据。 环境的完整描述是转移 $P(s' \mid s, a)$ 与奖励 $R(s, a)$；能拿到的是采样出来的轨迹。本书用 $\mathcal{D}$ 记数据集，用 d^{π} 记策略 π 下的状态分布（第 4 章起记 d^{π}_{γ}），两者不能混。

策略 π。 一个从状态到动作分布的映射；在第 4 部分，它是一个语言模型，“动作”是下一个 token。

价值 V、Q。 对未来的期望折扣和。凡是带参数的价值函数（V_{ϕ}、Q_{θ}）都是**估计**，本书一律加下标，从不把它当作真值。

模型。 学出来的 P_{ϕ}、R_{ϕ}。有了模型就可以规划，模型的误差会沿规划步长累积，这是第 7 章的主线。

目标函数。 期望回报、带 KL 的回报、带约束的回报。目标函数决定了“能证明什么”：凸的目标有界，非凸的目标只有局部结论。

评估与诊断。 离线设定下（第 8 章）和语言模型训练中（第 10 章），策略表现都需要专门的评估方法。本书将评估作为独立对象系统讨论。

六个对象之间的关系可以用一句话概括：**采样把环境变成数据，拟合把数据变成价值，自举把价值变成目标，规划用模型替代真实交互，而目标函数决定这一切能被证明到什么程度。**

全书反复讨论六类对象，它们各自对应一类**可以独立出错**的环节：数据可能覆盖不足，策略可能探索不足，价值估计可能受到半梯度影响，模型可

SUMMARY / 总结

能积累复合误差，目标可能遭遇奖励黑客，评估可能具有较高方差。每种方法都依赖其中若干环节满足特定条件，并针对其余环节设计处理办法。同一种算法在不同研究中表现不同，往往是因为数据、任务或评价条件有所差异。

0.4 理论分层：判断定理成立的条件

从理论保证最强的情形开始。**表格法**（第 1—3 章）适用于有限状态、有限动作的设定，价值可以逐项存储，因而能够严格证明收敛性、最优性和误差界。例如，当 $\gamma < 1$ 且奖励有界时，值迭代以 γ^k 的速率收敛到 V^*。下一层是**线性函数逼近**（第 4 章）：价值由 $\Phi\theta$ 表示，投影不动点、TD 不动点和 MSPBE 的闭式仍可分析；存在不动点本身并不能保证采样算法收敛到该点。函数表示的变化使结论需要附加条件。

在函数逼近、自举与离策略采样同时存在时，经典 TD 方法可能失稳；梯度 TD 等方法在特定条件下提供收敛保证。语言模型策略优化将动作表示为 token 序列，奖励通常作用于序列级，相关理论保证仍有限，许多结论属于[经验规律]。

SUMMARY / 总结



图 0-3 四级理论分层。越往下假设越少、结论越弱；把上一级的结论直接下移，是本书反复纠正的一类错误。

这种分层用于辨明结论的适用条件。同一结论在表格法中可能是定理，在神经网络中则可能只是经验观察。引用结论时需要保留其前提；省略前提，就可能把“TD 收敛”或“线性函数逼近通常收敛”等表述误用于不满足条件的情形。

为了让这条纪律可检查，本书对每一处实质性断言标注四种状态之一：

表 0-2 四种标签。落在哪一格，决定了这条断言能不能被写进证明。

标签	含义	你能拿它做什么
[精确]	在明确写出的假设下成立，可给出完整推导	可直接引用，但必须连同前提
[渐近]	在某极限（步长趋零、样本趋无穷、$G \to \infty$）下成立	不能当作有限样本下的保证
[近似]	有明确误差来源，量级已知或可估	可用，但要记住偏差从哪来
[经验规律]	有实验支持、无定理支撑	只能当工作假设，不能写进证明

一张断言如果没有标签，默认它是[精确]，但前提必须写在同一页上。本书所有收敛性表述均需注明状态与动作空间、采样分布、步长及必要的算法条件。

SUMMARY / 总结

0.5 前提知识最小集

本书以概率论、线性代数及微积分为数学预备知识，其他工具在使用时补充定义。下面五条是全书反复使用的工具，读后面章节时如果卡住，多半是这里。

期望与条件期望。 记 $\mathbb{E}[X]$ 为随机变量 X 的期望，$\mathbb{E}[X \mid Y]$ 为给定 Y 后的条件期望。反复用到的一条性质是“全期望公式”：$\mathbb{E}[X] = \mathbb{E}\big[\mathbb{E}[X \mid Y]\big]$。时序差分方法之所以能在不知道模型的情况下估计价值，靠的就是把回报拆成“一步奖励 + 下一步价值”再取条件期望：

$$\mathbb{E}\big[R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s\big] = (T^{\pi} V)(s). \tag{0.1}$$

得分函数。 对参数化分布 $\pi_\theta(a \mid s)$，有恒等式

$$\nabla_\theta \log \pi_\theta(a \mid s) = \frac{\nabla_\theta \pi_\theta(a \mid s)}{\pi_\theta(a \mid s)}, \qquad \mathbb{E}_{a \sim \pi_\theta}\big[\nabla_\theta \log \pi_\theta(a \mid s)\big] = 0. \tag{0.2}$$

第二个等号是第 5 章所有基线技巧的来源；它成立的前提是“被求导的分布就是采样分布”，这一点在第 10、11 章的离策略场景里会失效，届时需要重要性比率。

重要性采样。 用行为策略 μ 的数据估计目标策略 π 的期望，需要比率 $\rho = \pi(a \mid s)/\mu(a \mid s)$：

$$\mathbb{E}_{a \sim \pi}\big[f(a)\big] = \mathbb{E}_{a \sim \mu}\Big[\frac{\pi(a \mid s)}{\mu(a \mid s)} f(a)\Big], \tag{0.3}$$

前提是 $\mu(a \mid s) > 0$ 对所有 $\pi(a \mid s) > 0$ 的动作成立——这就是“覆盖假设”，第 4、8 章会反复用到它的各种变体。

KL 与温度。 两个分布之间的 KL 散度定义为

$$D_{\mathrm{KL}}(\pi \,\|\, \pi_{\mathrm{ref}}) = \mathbb{E}_{a \sim \pi}\Big[\log \frac{\pi(a \mid s)}{\pi_{\mathrm{ref}}(a \mid s)}\Big]. \tag{0.4}$$

本书用 $\beta_{\mathrm{KL}} > 0$ 记 KL 正则化系数。在目标 $\max_\pi \mathbb{E}_\pi[r] - \beta_{\mathrm{KL}} D_{\mathrm{KL}}(\pi \,\|\, \pi_{\mathrm{ref}})$ 下，逐上下文的最优解是 $\pi^\star(\cdot \mid x) \propto \pi_{\mathrm{ref}}(\cdot \mid x) \exp\big(r(x, \cdot)/\beta_{\mathrm{KL}}\big)$，前提是 π_{ref} 在每个 x 上全支撑、配分函数有限且为正（第 10 章命题 10.1）。指数上的分母就是 β_{KL}，所以 β_{KL} 本身是这一族的温度，而 $1/\beta_{\mathrm{KL}}$ 才是逆温度——这两个词在文献里经常被反过来用，本书一律按前一种写法，遇到相反的参数化会在首次引用时显式换算。

SUMMARY / 总结

投影。 在加权范数 $\|\cdot\|_D$ 下把向量投到 Φ 的列空间：

$$\Pi_D = \Phi(\Phi^\top D\Phi)^{-1}\Phi^\top D, \tag{0.5}$$

要求 Φ 满列秩、D 正定。第 4 章的全部几何图像都建立在这个算子上。

这五条里最容易低估的是**得分函数**那条恒等式。它看起来只是一次换元，实际上决定了“策略梯度可以只用采样算出来”这件事：正因为 $\mathbb{E}_\pi[\nabla \log \pi] = 0$，任何**不依赖当前动作**的基线都可以减掉而不改变期望，方差才会下降。一旦这个前提破了——采样分布与求导分布不一致、或者基线偷偷依赖了当前动作——“无偏”就不再成立。第 5、10、11 章反复处理的三处错误，全都出在这里。

还有一条不属于公式、但同样必要的准备：**区分“定义”与“近似”**。本书写 $=$ 的地方，指的是在明写的假设下相等；写 $\approx$ 或 $\simeq$ 的地方，指的是有明确误差来源的近似，误差项会在同段或脚注里交代；两者都不是“差不多对”。公式的含义由等号两侧的数学对象、假设与记号约定共同确定。

0.6 符号与命名空间

本书的符号按“作用域”分层，而不是全书一符号一义——那样会写出下标套下标的式子。同一字母在不同章表示不同对象时，该章第一次出现会显式声明，并在这里登记。

举个近的例子。α_{lr} 与 α_{ent} 都读作“步长”或“温度”，一个是优化器的学习率、一个是熵正则的强度，混起来调 PPO 就变成猜谜；A^π 与 $\hat{A}$ 都带一个 A，一个是优势函数的真值、一个是样本量或估计。这两个符号在后面几章会同时出现，靠“一符号一义”根本排不开。

SUMMARY / 总结

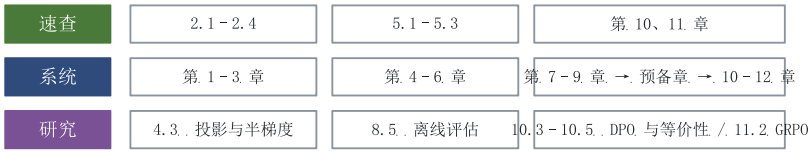
表 0-3 符号与作用域。完整符号表见附录 A，公式索引见附录 B。

符号	含义	出现章节
s, a, r	状态、动作、奖励	全书
π, μ	目标策略、行为策略	全书（μ 一律指行为策略）
V_ϕ, Q_θ	带参数的价值估计（不是真值）	4、5、6、8
A^π, $\hat{A}$	优势函数；带帽的是估计或样本量	5、10、11
d_γ^π, $\bar{d}_\gamma^\pi$	未归一化与归一化的折扣状态分布	4、5
γ, λ	折扣因子；资格迹/GAE 参数（不合并称“衰减系数”）	3、5、8
α_{lr}	学习率（与 α_{ent} 熵温度分开）	全书
β_{KL}	KL 正则化系数（Gibbs 形式下兼作温度）	10、11
$\varepsilon_{\text{clip}}$, ε_{num}	PPO 裁剪阈值；GRPO 的数值保护常数	5、11
ρ	重要性采样比率 π/μ	4、5、8、11
$\mathcal{D}$, D	数据集；加权分布矩阵	4、8
Π_D	投影算子（需声明线性函数空间与满列秩）	4

这张表只登记“跨章会撞车”的符号。像学习率 α_{lr}、资格迹参数 λ 这种各章通用、且在本章内有唯一含义的记号，本书保留领域通行写法，不再加章号下标——否则公式会变成下标套下标，反而更难读。遇到同名不同义时，回查这一表：凡是同一个字母在不同章表示不同对象，这里都会给出该章号。

SUMMARY / 总结

0.7 三条阅读路线



三条路线共用同一套符号与编号；跳读不会遇到未定义的记号

图 0-4 三条阅读路线。速查线只走主干，系统线按章推进，研究线直接跳到方法边界与推导密集的节。

三条阅读路线分别侧重理论证明、算法实现和语言模型优化。

速查（约 60 页）。 第 2.1 – 2.4 节（MDP 与 Bellman）、第 5.1 – 5.3 节（策略梯度与 GAE）、第 10、11 章。适合已经懂 RL、只想补齐语言模型后训练这条线的人。

系统（约 240 页）。 从第 1 章顺序读到第 9 章，读完预备章再读第 10 – 12 章。这是默认路线，也是唯一“每个结论都有前置”的路线。

研究（按题跳读）。 第 4.3 节（投影、半梯度、三类 Bellman 误差）、第 8.5 节（离线策略评估与方差）、第 10.3 – 10.5 节（DPO 推导与等价性条件）、第 11.2 节（GRPO 与组内基线）。这四节是全书推导最密的地方，也是当前研究最活跃的地方。

SUMMARY / 总结

0.8 阅读路径与资料使用

批注栏。 每页右侧留了约 40 mm 的空白栏，底部留了约 35 mm 的总结栏，这是康奈尔笔记的版式：右栏写线索（关键词、疑问、页外引用），底栏写本节一句话总结。正文栏宽度是固定的，任何长度的一行都不会压到右栏。

公式编号。 编号形如 (11.7)，表示第 11 章第 7 式；正文引用写作“式 (11.7)”。公式编号主要保留给后文需要引用的定义、恒等式与主要推导结果。

图与表。 图的编号形如 图 11-2，表的编号形如 表 11-1，按出现顺序排列。每幅实验图都标注了随机种子或样本量与评估协议；没有这些信息的图，只能当示意。

习题。 每章末尾有 5–7 题，其中至少一道是“用一个小规模数值实验验证本节某个结论”。这类题不是装饰：本书有几处错误正是这样做出来的（例如某条收敛条件其实只在常数步长下成立）。

标签。 [精确]、[渐近]、[近似]、[经验规律]分别标明断言的理论地位。理解结论时，应同时核对标签所对应的句子及其前提。

证据。 每条修订都挂着证据卡：书上原话与行号、源页码与原文、正确表述、严重度，存 `review/`；找不到一手来源的一律标“待核验”。

本章小结

本书持续追踪结论与前提之间的关系。延迟反馈、分布偏移和探索分别改变了数据到达方式、数据分布和可选行动。表格表示、线性逼近、非线性逼近与语言模型策略也对应不同的函数表达能力和理论条件。方法从一个表示层次迁移到另一个层次时，需要重新核对结论的适用前提。

全书的阅读路线由章节依赖关系、结论强度和数学工具共同构成。第 0.2 节说明章节安排，第 0.4 节界定结论强度；六类常见对象、五组数学工具与符号表用于定位后文分析中的关键假设。

SUMMARY / 总结

关键公式

全章的主干就是下面五组式子：条件期望形式的 Bellman 备份 (0.1)（T^π 为贝尔曼期望算子，见 2.3 节）、得分函数的两条恒等式 (0.2)、重要性采样与覆盖假设 (0.3)、KL 与 Gibbs 形式 (0.4)、加权投影 (0.5)。它们分别对应后面十二章里反复出现的五个动作——备份、求导、换分布、加约束、投影。

$$\mathbb{E}\big[R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s\big] = (T^\pi V)(s).$$

$$\nabla_\theta \log \pi_\theta(a \mid s) = \frac{\nabla_\theta \pi_\theta(a \mid s)}{\pi_\theta(a \mid s)}, \qquad \mathbb{E}_{a\sim\pi_\theta}\big[\nabla_\theta \log \pi_\theta(a \mid s)\big] = 0.$$

$$\mathbb{E}_{a\sim\pi}\big[f(a)\big] = \mathbb{E}_{a\sim\mu}\Big[\frac{\pi(a \mid s)}{\mu(a \mid s)} f(a)\Big], \quad \mu(a \mid s) > 0 \text{ 当 } \pi(a \mid s) > 0.$$

$$D_{\mathrm{KL}}(\pi \,\|\, \pi_{\mathrm{ref}}) = \mathbb{E}_{a\sim\pi}\Big[\log \frac{\pi(a \mid s)}{\pi_{\mathrm{ref}}(a \mid s)}\Big], \qquad \pi^\star \propto \pi_{\mathrm{ref}} \exp\big(r/\beta_{\mathrm{KL}}\big).$$

$$\Pi_D = \Phi(\Phi^\top D \Phi)^{-1} \Phi^\top D.$$

习题

1. 用全期望公式把式 (0.1) 的左边展开，说明它为什么等于 $r^\pi(s) + \gamma \sum_{s'} P^\pi(s' \mid s) V(s')$，并指出这一步用到了马尔可夫性。
2. 举一个式 (0.2) 第二个等号失效的例子（提示：采样分布不是 π_θ），并写出修正后的表达式。
3. 设 μ 在某状态给动作 a 的概率为 0，而 π 给它正概率。式 (0.3) 还成立吗？此时用重要性采样会发生什么？
4. 在二维线性函数空间里取一组 Φ 与对角 D，手算 Π_D，验证 $\Pi_D^2 = \Pi_D$ 且 $\Pi_D \Phi = \Phi$。
5. 给表 0-1 的第 8 行（离线 RL）补一列“最容易被误用的定理”，说明为什么它不能直接搬过来。
6. 找出本书任意一处带 [经验规律] 标签的断言，写出一个能证伪它的实验设计（只需说明变量与度量）。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 2 版，第 1 章与第 11 章：前者给问题的原始表述，后者把函数逼近的困难讲成“致命三要素”。
- Puterman《Markov Decision Processes》：MDP 与最优性的严格前提，本书第 2 章的定理条件多来自此书。
- Bertsekas《Dynamic Programming and Optimal Control》：值迭代与策略迭代的收敛性证明，比本书第 3 章更细。
- Levine 等《Offline Reinforcement Learning: Tutorial, Review, and Perspectives》：离线设定的覆盖假设与评估困难，对应第 8 章。
- 本书的 `review/cards/`：每一条勘误的证据链，可作为“如何核对一句教材断言”的样例。

SUMMARY / 总结

第 1 部分

数学与决策基础

第 1 章　Bandit 与探索

第 2 章　MDP 与 Bellman 理论

第 3 章　动态规划、蒙特卡洛与时序差分

第 1 章　多臂老虎机与探索

多臂老虎机是研究探索问题的简化模型。标准的 K 臂老虎机包含 K 个可选动作，通常称为臂。每轮选择一个臂并观测其随机奖励；各臂的奖励分布事先未知，未选臂的本轮奖励不可观测。学习者需要估计各臂的平均奖励，并在探索与利用之间分配有限的尝试次数。

例如，设总交互预算为五千次，各臂的奖励分布未知。过早固定选择当前样本均值最高的臂，偶然偏高的估计可能使次优臂长期占据选择；平均分配交互次数，则会把有限预算用于回报较低的臂。算法需要在探索未知奖励与利用已有估计之间分配交互机会。

标 **[精确]** 的结论对每个有限 T 成立，标 **[渐近]** 的只描述 $T \to \infty$ 的曲线形状，其余标 **[经验规律]**；每个界都与它的常数和前提一起出现。遗憾界的常数与分布条件、策略类别及渐近方式相关，引用时须保留相应前提。

读这一章只需会算期望、样本均值，并能读懂概率分布；KL 散度会在它真正派上用场时再解释。最容易混在一起的是两种“好”：一次抽到高奖励是运气，长期平均奖励高才说明臂更好；同样，某个 T 上表现好不等于渐近遗憾界好。不同算法的比较涉及有限时间表现、渐近遗憾与实例类别等多个维度。

1.1 问题与形式化

1.1.1 K 臂老虎机

标准随机老虎机没有随行动转移的状态，也不涉及跨期回报；其奖励分布由选定的臂决定。这三条正是第 2 章要逐条拆掉的东西。

> **定义 1.1（K 臂老虎机与期望遗憾）**
>
> 给定 K 个臂与未知分布 $\nu_1, \dots, \nu_K$，记 $\mu_a = \mathbb{E}_{r \sim \nu_a}[r]$、$\mu^* = \max_a \mu_a$，把 $\Delta_a = \mu^* - \mu_a$ 称为臂 a 的**间隙**。每一轮 t 选 $a_t \in \{1, \dots, K\}$ 并观测独立的 $r_t \sim \nu_{a_t}$，策略选 a_t 时只能用到历史 $h_t = (a_1, r_1, \dots, a_{t-1}, r_{t-1})$。长度为 T 的一局的**期望遗憾**由下式给出，其中 $N_a(T) = \sum_{t=1}^{T} \mathbf{1}\{a_t = a\}$ 是臂 a 被拉动的次数。

$$\mathrm{Regret}(T) = T\mu^* - \mathbb{E}\Big[\sum_{t=1}^{T} r_t\Big] = \sum_{a=1}^{K} \Delta_a \, \mathbb{E}\big[N_a(T)\big], \tag{1.1}$$

式 (1.1) 的最后一步只用了交换求和次序，但这里有一个容易略过的细

节：**遗憾只通过“计数”依赖策略**，分布的信息被压进间隙常数，策略的影响只剩访问次数——后面每个算法分析回答的都是同一个问题：每个次优臂会被访问多少次。遗憾写成“与 $T\mu^*$ 比”是为了让“和最优策略比”显式出现在定义里。

1.1.2 遗憾的两笔账

在明确指定探索与利用判别规则的策略中，拉取次数可按两类决策机制分解；该分解依赖算法内部决策记录。据此把式 (1.1) 拆成

$$\mathrm{Regret}(T) = \sum_a \Delta_a \mathbb{E}\left[N_a^{\mathrm{exp}}(T)\right] + \sum_a \Delta_a \mathbb{E}\left[N_a^{\mathrm{use}}(T)\right]. \tag{1.2}$$

第一项是**探索的代价**，即信息的价格：想做对必须先试错，这笔钱无法避免，只能买得更便宜。第二项是**误判的代价**，含两个来源：**探索不足**——某些臂因从未被认真试过而估值停在噪声上，算法于是永远不去纠正，这部分不随时间衰减，还会被“越选越确信”自我强化；**利用错误**——估计已充分，但抽样噪声仍让人在几乎一样好的臂之间选错，这部分随时间衰减。两笔账此消彼长，“平衡探索与利用”精确地说就是在两项之间选位置。

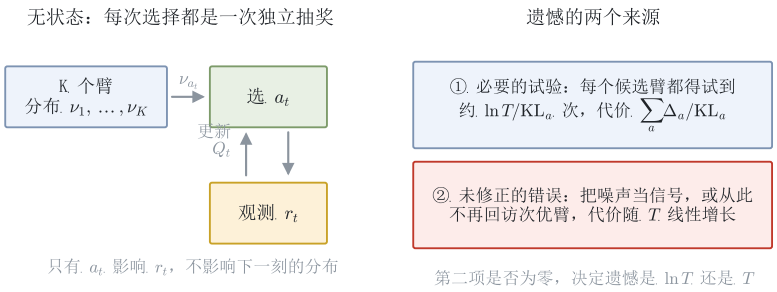


图 1-1 老虎机问题的结构与遗憾的两个来源。左：无状态的一次抽奖，动作只影响当轮奖励，不改变下一轮的分布；右：必要的试验（每个候选臂约需 $\ln T/\mathrm{KL}_a$ 次）与未修正的错误，后者代价随 T 线性增长。

图 1-1 右侧的方框是全章的诊断工具：**先看第二项是否为零**。为零才可能得到 $\ln T$ 型遗憾；为正且不衰减（固定 ε 或纯贪心锁死），遗憾必然是 T 型的。式(1.2)所采用的探索 / 利用分解依赖决策机制的定义，在一般策略下不能仅由奖励轨迹识别。

1.1.3 下界：对数遗憾从哪来

遗憾能否达到亚线性增长，以及它能够达到的最快速度，需要通过下界

来刻画。

> **定理 1.1（Lai – Robbins 下界 [渐近]）**
>
> 设奖励分布属于满足 Lai – Robbins 正则条件的参数族 $\mathcal{D}$。策略须在该族的**每个实例**上都一致有效：对任意 $\alpha > 0$，其期望遗憾为 $o(T^{\alpha})$。对每个次优臂 a，记 $\mathcal{K}_{\inf}(\nu_a, \mu^*, \mathcal{D})$ 为同一分布族内、均值高于 μ^* 的替代分布与 ν_a 之间 KL 散度的下确界。它表示把臂 a 变成一个可能优于当前最优臂的选项，所需的最小信息改变量。
>
> 若该信息量有限且为正，则其期望拉取次数至少为 $\ln T / \mathcal{K}_{\inf} + o(\ln T)$，因此期望遗憾满足下式。

$$\liminf_{T\to\infty} \frac{\mathrm{Regret}(T)}{\ln T} \geq \sum_{a:\,\Delta_a>0} \frac{\Delta_a}{\mathcal{K}_{\inf}(\nu_a, \mu^*, \mathcal{D})}. \tag{1.3}$$

这里不能把条件简化成“每个臂无限访问”。下界针对的是在整类问题上都表现得足够好的算法；只在当前这一局里多拉几次，并不能保证它有能力区分那些看起来相似、但最优臂不同的实例。$\mathcal{K}_{\inf}$ 也不是机械地比较 ν_a 与当前最优分布：它问的是，若想让臂 a 看起来可能比当前最优臂更好，至少要把它的分布改动多少信息量。于是要排除这种替代解释，至少需要约 $\ln T / \mathcal{K}_{\inf}$ 次观测。对数遗憾的来源仍是假设检验的样本复杂度，但信息量必须按这个“最难区分的替代分布”来算。

它还是 [渐近] 的：对 $T = 1000$ 不提供数值。还须分清三种遗憾语言：**实例依赖界**固定 $\{\Delta_a\}$，得 $\sum_a \Delta_a \ln T / \mathrm{KL}_a$；**极小极大界**先在实例类上取上确界：对 $[0,1]$ 有界奖励类，$\sqrt{KT}$ 阶下界与“只差一个 $\log T$ 因子”的上界由 Auer 等（2002）给出，去掉那个因子、得到匹配的 $\Theta(\sqrt{KT})$ 是 Audibert 与 Bubeck（2010）的工作；**贝叶斯界**把实例按先验平均，得 $\sqrt{KT \ln K}$ 量级——三者取 sup 与取期望的顺序不同，数值可差出量级。至于“没有分布假设会怎样”：若连均值是否存在都不保证（如重尾指数不超过 1 的帕累托奖励），$\mathrm{Regret}(T)$ 可能无界，故**有限遗憾是分布类的性质，而不是问题的性质**。

SUMMARY / 总结

1.2 贪心与 ε-贪心

1.2.1 从样本平均到动作价值

最自然的估计是把每次回报存下来求平均，但存储随步数线性增长，每来一个新样本还得整段重算。改写成递推形式，就只需要两个数：

$$Q_{n+1} = Q_n + \frac{1}{n}\big(r_n - Q_n\big). \tag{1.4}$$

重要性不在算术而在形式：估计被写成“旧值 + 步长 × 误差”，于是步长可从 $1/n$ 换成一般的 α_n。$1/n$ 对应样本平均，在平稳奖励下无偏、方差按 $1/n$ 收缩；常数 α 给出指数遗忘的平均，是**非平稳环境最常用的一种**跟踪手段——它永不收敛，只跟随漂移（式 (1.8) 第二条不满足），滑窗平均与无偏常数步长 $\beta_n = \alpha/\bar{o}_n$ 是另两条合法路径。第 3 章会以“时序差分”的名字重现这个形式。

1.2.2 ε-贪心与线性遗憾的精确标价

最直接的动作规则是贪心 $A_t = \arg\max_a Q_t(a)$。贪心没有探索承诺；它可能锁死，但随机奖励下并非每次都会锁死。先看一个不含噪声的反例：

> **例 1.1（贪心可能锁死）**
>
> 两臂的奖励都是确定的：臂 1 每次给 0，臂 2 每次给 1。初始估计均为 0，平局时先选臂 1，估计用样本平均更新。第一轮后臂 1 的估计仍为 0，臂 2 则从未被试过、估计也为 0，所以平局规则再次选臂 1。在给定的平局规则下，臂 2 此后始终不会被选中；每轮少拿 1，累计遗憾正好是 T。

这个反例证明，至少存在一种实例会使纯贪心产生线性遗憾。随机奖励下，早期的高回报可能被后续样本修正，策略也可能转向其他臂；但纯贪心本身不保证探索。显式随机探索或基于不确定度的动作评分可以把探索纳入算法机制。

修正办法是给动作规则加外生随机化：以 $1-\varepsilon$ 贪心、以 ε 在 K 个臂上均匀随机，即 **ε-贪心**。它有下面这个结论——注意是**下界**。

> **命题 1.2（ε-贪心的线性遗憾 [精确]）**
>
> 设 $\varepsilon \in (0,1)$ 固定、探索均匀、探索硬币独立于历史，则对任意 T 与任意 Q_t 有线性下界。

SUMMARY / 总结

$$\mathrm{Regret}(T) \;\geq\; \frac{\varepsilon}{K}\Big(\sum_{a=1}^{K}\Delta_a\Big)T. \tag{1.5}$$

证明：探索时每臂被选中概率恰为 $1/K$，故 $\mathbb{E}[N_a^{\exp}(T)] = \varepsilon T/K$ 对每个 a 成立，代入式 (1.2) 第一项即得，与 Q_t 估得多准无关。□

ε-贪心的遗憾不会因为 Q 变准而消失：策略以 $1-\varepsilon+\varepsilon/K$ 的概率选最优臂（贪心选中，加上探索时恰好抽中），但那 ε 的探索永远在付学费——“最终以概率 1 选最优动作”说的是 $\varepsilon_t \to 0$ 的极限，不是累计代价。

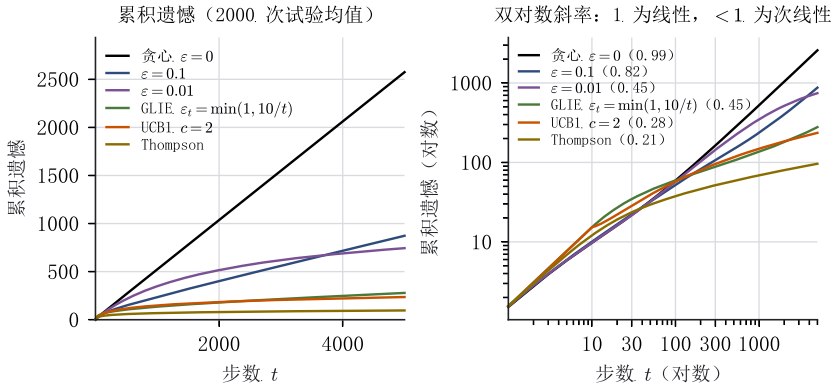


图 1-2 六种策略在 10 臂高斯测试台上的累积遗憾（2000 次独立试验均值，设定见表 1-2）。左：线性坐标，最上面一条（纯贪心）几乎是一条直线；右：双对数坐标，斜率 1 为线性遗憾。斜率判读只给出定性结论，不能验证常数。

图 1-2 后三条曲线分别在第 1.2.3、1.3、1.4 节定义。三条 ε 曲线比纯贪心那条更平，但“更平”不等于“对数”——**有限 T 上斜率小于 1，推不出 $\ln T$ 型遗憾**。

1.2.3 无限次访问与 GLIE 的严格条件

ε-贪心最常被引用的“保证”是“每个动作会被无限次访问”。它成立，但条件必须写全；不写全时它是假的。

> **命题 1.3（探索通道的访问计数 [精确]）**
>
> 设在第 t 轮以概率 ε_t 进入探索、探索时以 $1/K$ 均匀选臂，且探索事件在给定 $\{\varepsilon_t\}$ 时相互独立。则对每个 a 与每个 T，探索通道贡献的期望访问数如下式；并且 $N_a^{\exp}(T) \to \infty$ 以概率 1 成立，当且仅当 $\sum_{t\geq 1}\varepsilon_t = \infty$。

$$\mathbb{E}\big[N_a^{\exp}(T)\big] = \frac{1}{K}\sum_{t=1}^{T}\varepsilon_t. \tag{1.6}$$

证明：给定 $\{\varepsilon_t\}$，$N_a^{\exp}(T)$ 是 T 个条件概率为 ε_t/K 的独立指示变量之和，故期望如式 (1.6)；级数发散时由 Borel–Cantelli 型论证知其以概率 1 发散。□

这已给出**无限次访问的充分条件** $\sum_t \varepsilon_t = \infty$。另一件要单独规定的是极限上要贪心，即 $\varepsilon_t \to 0$，否则式 (1.5) 的线性税永远挂着。两条合起来就是 **GLIE**（Greedy in the Limit with Infinite Exploration），常用的选择是

$$\varepsilon_t = \min\Big\{1,\ \frac{c}{t}\Big\}, \qquad \sum_{t\ge 1} \varepsilon_t = \infty, \quad \varepsilon_t \to 0. \tag{1.7}$$

两条条件各管一件事，缺一不可。反例一：$\varepsilon_t = c/t^2$ 满足 $\varepsilon_t \to 0$ 但 $\sum \varepsilon_t = c\pi^2/6 < \infty$，式 (1.6) 说明探索次数被常数卡住，有限步后探索事实上停止。反例二：$\varepsilon_t = 0.1$ 满足 $\sum \varepsilon_t = \infty$ 但 $\varepsilon_t \not\to 0$，命题 1.2 给出线性遗憾。**“ε-贪心保证收敛”只有在补上这两个条件后才是命题。** 此外 GLIE 的证明还要求 Q 用样本平均、每个动作被无限次访问；函数逼近下前者被死三角破坏、后者变成覆盖性（第 4 章）。

1.2.4 Robbins–Monro 条件只约束步长

式 (1.4) 的收敛性常被一句“只要满足 Robbins–Monro 条件”带过。这在老虎机里是对的，但它管的事窄得多。RM 条件是指

$$\sum_{n=1}^{\infty} \alpha_n = \infty, \qquad \sum_{n=1}^{\infty} \alpha_n^2 < \infty. \tag{1.8}$$

它保证：对 $Q_{n+1} = Q_n + \alpha_n(r_n - Q_n)$ 这样的随机逼近，若目标均值固定、噪声方差有界，则 Q_n 几乎必然收敛到该均值。它**不**保证四件事。一，不保证每臂被访问无穷次：式 (1.8) 里没有策略。二，不覆盖函数逼近——Q_θ 参数化还需表示与稳定性条件（第 4 章死三角）。三，不适用于非平稳目标：目标漂移时 $\sum \alpha_n^2 < \infty$ 使步长趋零，跟踪漂移却要让步长不趋于零，恰好违反第二条——**跟踪与收敛不可兼得**。四，对乐观类与后验类根本不出现：UCB1 与 TS 都没有步长。

因此，**“Robbins–Monro 条件是所有算法收敛的统一充分条件”是错误陈述**：它既不充分（缺探索与逼近），也非所有算法都要满足。

SUMMARY / 总结

1.3 乐观面对不确定性

1.3.1 UCB1 的索引

ε-贪心的探索是“不加选择地花钱”：均匀随机选臂，即使某臂显然不值得再试。更聪明的做法是把探索集中到“不确定且可能有价值”的臂上，统一实现是给每个臂一个**上置信界**：

$$A_t = \arg\max_a \left\{ Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right\}, \qquad c > 0, \tag{1.9}$$

约定 $N_t(a) = 0$ 时索引取 $+\infty$。这就是 **UCB1**：$Q_t(a)$ 是利用项，根号项是**探索奖励**，随 $N_t(a)$ 增大而缩小、随 $\ln t$ 缓慢增大，于是“试得少的臂”自动获得补偿；c 是置信水平的手柄。之所以叫**乐观**：该索引是 μ_a 的上界估计，按上界选择意味着“在证据不足但可能很好的臂上给一次机会”。

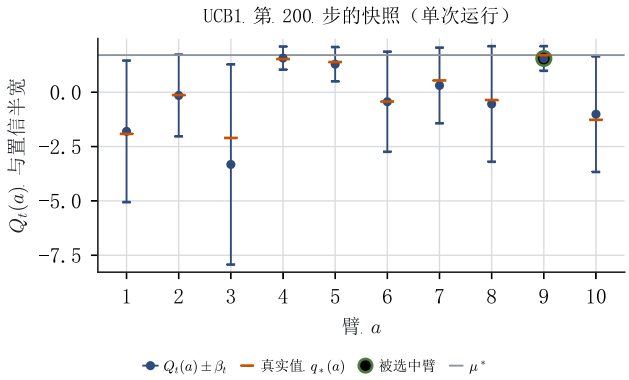


图 1-3 UCB1 在第 200 步的单次运行快照。锯齿线是每个臂的 $Q_t(a) \pm \beta_t$，横线是该臂真实值 $q_*(a)$，虚线是 μ^*，绿圈标出该步被选中的臂。臂 3 的区间宽出一个量级（下界已到 -7.8），却因 Q_t 太低而仍未入选。

1.3.2 对数遗憾与它的三个前提

> **定理 1.2（UCB1 的对数遗憾 [精确]）**
>
> 设 K 个臂的奖励独立同分布、取值于 $[0,1]$（有界支撑已知）、各臂均值与间隙 $\Delta_a > 0$ 固定，且式 (1.9) 的 $c \geq 1$（这里的下界是为让尾部常数 $1 + \pi^2/3$ 有效；若允许 $c \in (1/\sqrt{2}, 1)$，尾部须写成 $1 + 2\zeta(2c^2)$，它在 $c \to 1/\sqrt{2}$ 时发散）。则对每个有限 T，UCB1 的期望遗憾满足下面的界。

$$\mathrm{Regret}(T) \;\le\; 4c^2 \sum_{a:\,\Delta_a>0} \frac{\ln T}{\Delta_a} + \Big(1+\frac{\pi^2}{3}\Big)\sum_{a=1}^{K}\Delta_a. \tag{1.10}$$

首项常数是 $4c^2$，不是与 c 无关的数字：偏差超过 $c\sqrt{\ln t/N}$ 的概率是 t^{-2c^2}，求和要求 $2c^2>1$；“必然情形”的计数约束则给出 $N_t \le 4c^2\ln t/\Delta_a^2$。取 $c=\sqrt{2}$——即 Auer 等（2002）原版置信半径 $\sqrt{2\ln t/N}$——首项常数为 8，尾部项的 $1+\pi^2/3$ 也在这一取值下得到；**第 1.4.4 节的实验取 $c=2$，首项常数因此是 16，不能套用 8**。式 (1.10) 对每个有限 T 成立，所以标 [精确]。两组常数都是证明的产物，换一种置信界就换一组，不是可做数值保证的东西。

三个前提必须逐条写清。**独立同分布**：奖励随时间漂移则失效，且失效是静默的——算法照常运行，界不再成立。**有界奖励且支撑已知**：式 (1.10) 假定 $r\in[0,1]$，真实范围是 $[0,1000]$ 时须先归一化；支撑无界（高斯奖励）需要 sub-Gaussian 假设与另一种界，第 1.4.4 节的高斯实验只能算 [经验规律]。**间隙固定且不为零**：这一条决定界的可用性。

把第三条代入具体数字，就是“界不是保证”最直接的证据。取 $c=\sqrt{2}$（即首项常数 $4c^2=8$）、$K=2$、$T=10^6$、$\Delta=10^{-3}$，右端第一项是 $8\ln(10^6)/10^{-3}\approx 1.1\times10^5$：虽小于 T，但“对数”的好处已被吃掉大半；若 $\Delta=10^{-4}$，该项变成 1.1×10^6，超过 T，界比线性界还松。正确说法是“**UCB1 在间隙不太小的实例上遗憾按 $\ln T$ 增长**”，不是“保证次线性”；要与间隙无关的保证须换第 1.1.3 节的极小极大准则，$\sqrt{KT}$ 与 $\ln T$ 并不矛盾——取 $\sup$ 的顺序不同。

1.3.3 区间估计：一个可替换的框架

UCB1 只是“用上界选择”的一个实例。剥掉具体不等式，框架是：为每个臂维护置信区间，选上端最大者；只要区间有效、宽度随样本收缩，乐观就有效。用 Hoeffding 不等式可直接写出可验算的版本（对全部 $t\le T$ 与全部臂取联合界）：

$$U_t(a) = Q_t(a) + \sqrt{\frac{\ln(2KT/\delta)}{2N_t(a)}}. \tag{1.11}$$

> **命题 1.4（区间估计的对数遗憾 [精确]）**
>
> 设奖励独立同分布、取值于 $[0,1]$，且对每个臂与每个 $t\le T$，式 (1.11) 的区间以 $1-\delta$ 的联合置信度覆盖 μ_a。若策略每步选 U_t 最大的臂，则遗憾满足下面的界。

SUMMARY / 总结

$$\mathrm{Regret}(T) \;\le\; 2\ln\frac{2KT}{\delta}\sum_{a\neq a^*}\frac{1}{\Delta_a} + \sum_{a\neq a^*}\Delta_a \quad \text{以概率至少 } 1-\delta. \tag{1.12}$$

证明：记 $B_t(a)=\sqrt{\ln(2KT/\delta)/(2N_t(a))}$。区间全部有效时，被选中的臂 a 满足 $U_t(a)\ge U_t(a^*)$，即 $\mu_a+2B_t(a)\ge\mu_{a^*}$，故 $B_t(a)\ge\Delta_a/2$，即 $N_t(a)\le 2\ln(2KT/\delta)/\Delta_a^2$；被拉次数不超过该值加一，乘 Δ_a 求和即得式 (1.12)。□

比较式 (1.12) 与式 (1.10)，首项常数由 8（$c=\sqrt{2}$ 时的 $4c^2$）变为 2，差异来自区间形式。两式具有相同的 $\ln T$ 量级和 $\sum_a 1/\Delta_a$ 结构，说明**有效置信区间能够给出同阶的遗憾界**。整个论证依赖区间覆盖真实均值，而这又要求奖励独立、有界且平稳。任一条件不成立，遗憾界便不再适用，即使算法仍可继续运行。乐观方法的失效常源于置信界前提不成立，而非索引计算错误。

δ 的选择本身就是一次兑换：取 $\delta=T^{-1}$ 时 $\ln(2KT/\delta)=\ln(2KT^2)\approx 2\ln T+O(1)$，式 (1.12) 回到式 (1.10) 的量级；δ 取得更小则界更保守。所以“以概率 $1-\delta$ 成立”这句话必须和 δ 一起读，单独引用左端的常数没有意义。

SUMMARY / 总结

1.4 后验与信息

1.4.1 Thompson 采样

前两节都是频率派视角：不设先验，追求最坏情形保证。**Thompson 采样**换视角：设 μ 有先验，每次观测后更新后验，再从后验抽一个“可能的参数实现”，在这个实现里选最优动作：

$$\tilde{\theta}_t \sim \pi_t(\cdot \mid h_t), \qquad A_t = \arg\max_a \tilde{\theta}_t(a). \tag{1.13}$$

它与 UCB 都在“按不确定度配额探索”，机制却相反：UCB 用上界，TS 用抽样。关键性质是 **probability matching**：TS 选中臂 a 的概率恰等于“当前后验下 a 最好”的概率——探索量被自动校准到证据强度上，不必手工设 ε 或 c。可行性完全取决于后验是否好算：Bernoulli 奖励配 Beta 先验有闭式，

$$\pi_t = \mathrm{Beta}\Big(\alpha + \sum_{s\le t} r_s \mathbf{1}\{a_s = a\},\ \beta + \sum_{s\le t}(1-r_s)\mathbf{1}\{a_s = a\}\Big), \tag{1.14}$$

高斯奖励配高斯先验同理；一般情形下后验没有闭式，只能 MCMC、变分或粒子近似。Sutton 与 Barto 说“更新计算可能非常复杂，但对共轭先验则很容易”，并说 TS“往往与本章中最好的无分布方法表现相当”——这就是本节分层的依据。另一条边界：**完整的贝叶斯最优解存在但不可算**，枚举未来观测分支的代价随视野指数增长（1000 步视野下就是 2^{2000} 量级的树）。

1.4.2 贝叶斯遗憾与信息增益

频率派的遗憾是逐实例的，贝叶斯的遗憾是先验平均的：

$$\overline{\mathrm{Regret}}(T) = \mathbb{E}_{\theta\sim\pi_0}\big[\mathrm{Regret}(T)\big]. \tag{1.15}$$

两者不能混用：贝叶斯遗憾小不代表在每个实例上都好，先验不支持的实例可以很差。记瞬时遗憾 $\Delta_t = \mu^* - \mu_{A_t}$、$\mathbb{I}_T = I(A^*; h_{T+1})$ 为历史对**最优动作**的信息量，并定义**信息比** $\Gamma_t = (\mathbb{E}[\Delta_t])^2 / I(A^*; A_t, r_t \mid h_t)$，它衡量“每比特信息换回多少遗憾”。若存在 $\bar{\Gamma}$ 使 $\Gamma_t \le \bar{\Gamma}$ 对所有 t 成立，则由柯西—施瓦茨不等式 $(\sum_t \mathbb{E}\Delta_t)^2 \le T\sum_t (\mathbb{E}\Delta_t)^2$、信息比的定义与互信息的链式法则（$\sum_t I(A^*; A_t, r_t \mid h_t) = I(A^*; h_T)$），得

$$\overline{\mathrm{Regret}}(T) \le \sqrt{\bar{\Gamma}\, T\, \mathbb{I}_T} \le \sqrt{\bar{\Gamma}\, T\, H(A^*)} \le \sqrt{\bar{\Gamma}\, T \ln K}. \tag{1.16}$$

SUMMARY / 总结

这个界把探索效率归结为一个量：每比特信息换多少遗憾。**上界里的熵是最优动作的熵**，不是参数的熵——这正是链式法则那一步能站住的原因。TS 之所以好，是因为共轭情形下它的信息比只有 $O(K)$ 量级，于是得到 $\sqrt{KT\ln K}$；若信息比是与 K 无关的常数，同一推导只给出 $\sqrt{T\ln K}$。“信息增益式”算法则直接最小化这个比值，可比 TS 更紧。式 (1.16) 的每个符号都带前提：**先验必须正确**（$\mathbb{I}_T$ 按先验算，若真值不在先验支撑内，不等式失去意义）、**后验必须可算**、$H(A^*)\le \ln K$ **只在最优动作由参数决定时成立**。其中先验正确性最容易被实验掩盖。

1.4.3 四种探索的分层

按“探索的信息从哪来”分层，得到表 1-1。四层的假设强度依次上升，最弱的假设给出最弱的保证。该表汇总各算法的适用假设与相应的遗憾保证。

表 1-1 探索理论的四层分层。每层的“需要的假设”都是该层结论的一部分，引用时不得省略；最后一列告诉你算法在什么时候会在未显式报告错误的情况下失效。

层	代表	需要的假设	保证的形式	失效方式
贪心式	ε-贪心	几乎无，只要平稳	访问计数（命题 1.3）；ε 固定则遗憾线性（命题 1.2）	ε 太小锁死，太大付税
乐观式	UCB1、区间估计	独立同分布、有界奖励、支撑已知	实例依赖的 $\ln T/\Delta$，常数依赖证明	区间失效：非平稳、无界支撑
后验式	Thompson 采样	正确先验 + 可算后验（共轭）	贝叶斯遗憾 $\sqrt{\bar{\Gamma}T\ln K}$，信息比 $O(K)$ 时即 $\sqrt{KT\ln K}$（式 (1.16)）	先验错配、后验不可算
信息增益式	IDS、Gittins 指数	正确先验 + 信息比可计算	更紧的贝叶斯界，常数可解释	计算不可行，或先验错配

这些方法的适用范围受到奖励平稳性、先验设定、后验计算与信息比估计的限制。奖励非平稳时，可考虑衰减 ε_t 或滑窗 UCB；先验可靠且后验可计算时，贝叶斯方法可能以较少样本达到相近遗憾。

1.4.4 六种策略在同一张测试台上

设定：$K=10$，μ_a 独立取自 $\mathcal{N}(0,1)$，奖励噪声 $\mathcal{N}(0,1)$，2000 次试验，每次 $T=5000$ 步，种子 20261020，Q 用样本平均。六个算法为纯贪心、

SUMMARY / 总结

$\varepsilon=0.1$、$\varepsilon=0.01$、GLIE（式 (1.7) 取 $c=10$）、UCB1（式 (1.9) 取 $c=2$，即首项常数 16 的那一档）、TS（先验 $\mathcal{N}(0,1)$，与生成分布相同）。

表 1-2 六种策略在 10 臂高斯测试台上的累积遗憾（2000 次试验均值）。斜率为双对数斜率，取自 $t\in[1000,5000]$；末段率是最后 100 步的每步遗憾；$T=5000$ 处标准误依次为 66.12、6.60、21.76、12.16、1.73、1.22。

算法	$T=100$	$T=1000$	$T=5000$	斜率	末段率
纯贪心 $\varepsilon=0$	59.1	523.1	2574.3	0.99	0.512
$\varepsilon=0.1$	52.3	236.4	872.9	0.82	0.156
$\varepsilon=0.01$	57.1	348.3	744.0	0.45	0.048
GLIE，$c=10$	59.9	135.8	278.5	0.45	0.030
UCB1，$c=2$	57.6	148.7	235.7	0.28	0.012
Thompson 采样	37.7	68.8	96.3	0.21	0.004

第一行是命题 1.1 的统计体现：步数增 5 倍，遗憾从 523 增到 2574，增 4.9 倍——斜率 0.99，精确地线性。第二、三行是命题 1.2 的核算：理论探索税为 $(\varepsilon/K)\sum_a\Delta_a$，而 $\mathbb{E}[\sum_a\Delta_a]=K\,\mathbb{E}[\mu^*]\approx 10\times 1.54=15.4$，故 $\varepsilon=0.1$ 的税约每步 0.154、$\varepsilon=0.01$ 约 0.0154。实测末段率为 0.156 与 0.048：前者与税几乎重合，后者是税的 3 倍——$\varepsilon=0.1$ 到 $T=5000$ 时“只剩税在付”，而 $\varepsilon=0.01$ 省下的探索被误判吃掉了：它在 $T=1000$ 时遗憾 348、差于 $\varepsilon=0.1$ 的 236，到 $T=5000$ 才反超。ε **这些策略通过探索概率的时间安排控制随机探索所产生的累计遗憾。**

$\varepsilon=0.1$ 的斜率只有 0.82，看似“次线性”，但它有精确的线性下界式 (1.5)：线性项在 $T=5000$ 时已达 $0.154\times 5000=770$，与实测 873 同量级并占主导。后三行是把第二项压到零的路线：GLIE 的末段率 0.030 最低，但 $T=100$ 时遗憾最高，是典型的“先付税、后收益”；UCB1 的末段率 0.012 且标准误仅 1.73（GLIE 为 12.16），说明它既更好又更稳定。对 UCB1 还有一个观察：若遗憾真按 $\ln T$ 增长，$T=5000$ 处的斜率应为 $1/\ln T\approx 0.12$，实测 0.28，故只是定性证据。TS 的领先必须交代原因：本实验的先验与生成分布**完全相同**，是式 (1.16) 最有利的情形；真值落在先验之外时它会偏向先验支持的臂，故“TS 比 UCB1 好”只在表 1-2 下成立。

SUMMARY / 总结

1.5 上下文老虎机与向 MDP 的过渡

1.5.1 上下文老虎机

老虎机最强的假设是“每次抽奖完全一样”。真实的推荐、竞价与临床试验在每次决策前都能看到与当前情形有关的信号。把这类信号称为**上下文** x_t，问题就变成“在不同情形下分别学习哪一臂好”：给定上下文空间 $\mathcal{X}$、动作集 $\mathcal{A}$、上下文分布 ρ 与未知奖励函数 $r:\mathcal{X}\times\mathcal{A}\to[0,1]$，目标是找策略 $\pi:\mathcal{X}\to\Delta(\mathcal{A})$ 使

$$J(\pi)=\mathbb{E}_{x\sim\rho}\,\mathbb{E}_{a\sim\pi(\cdot|x)}\big[r(x,a)\big] \tag{1.17}$$

尽可能大，而遗憾变成“相对于每个上下文的最优动作”的差：

$$\mathrm{Regret}(T)=\mathbb{E}\Big[\sum_{t=1}^{T}\big(r(x_t,\pi^*(x_t))-r(x_t,a_t)\big)\Big],\qquad \pi^*(x)=\arg\max_a r(x,a). \tag{1.18}$$

变化不在符号而在结构：遗憾不再能按“臂”分解，因为每个上下文的最优臂不同，必须按“上下文—动作对”分解。样本效率由此成为核心——一次试验只对一个上下文区域有效；策略不再是一个“选择”而是一个函数，必须泛化到没见过的 x；x 维数高时还需对 r 作结构假设。但有一个结构性事实始终成立：**上下文由环境独立抽样、与所选动作无关**，因此 x_{t+1} 不依赖 a_t，每步仍可独立优化、不需要信用分配。这就是“一步 MDP”——它把探索问题保留下来，把序贯问题推迟了。

1.5.2 LinUCB：把线性结构变成置信区间

若假设 $r(x,a)=x^\top\theta_a+$ 噪声（每臂一组参数），岭回归就给出 $\hat\theta_a$ 与其协方差，进而给出置信上界，乐观原则可原封不动搬过来：

$$A_t=\arg\max_a\Big\{x_t^\top\hat\theta_a+\alpha\sqrt{x_t^\top A_a^{-1}x_t}\Big\},\qquad A_a=\sum_{s:\,a_s=a}x_s x_s^\top+\lambda I. \tag{1.19}$$

式 (1.19) 与式 (1.9) 是同一思想的两个化身：第二项都是“该方向上的不确定度”，只是从“计数 $1/N$”变成“特征协方差的逆”。根号下的 $x_t^\top A_a^{-1}x_t$ 恰是“模型在 x_t 方向上还有多不确定”的度量——试过的方向收缩、没试过的方向保持宽，因此一次试验同时提高一整片方向上的估计，这是它比独立老虎机高效之处。代价是结构假设：线性模型若错，置信区间不再有效，与第 1.3.3 节同一个脆弱点。计算代价：d 维特征下每臂维护 $d\times d$ 矩阵，求逆 $O(Kd^3)$，用 Sherman–Morrison 增量更新可降到 $O(Kd^2)$；d 很

大时不可行。

1.5.3 缺的那半步：状态、转移与信用分配

上下文老虎机与马尔可夫决策过程的差别只有一句话：**在 MDP 里，x_{t+1} 的分布依赖 a_t**。加上这条依赖，问题就从“每步独立”变成“序贯”，三个新现象同时出现。**信用分配**：一次收益可能来自前面若干步，“哪个臂好”是一个数，“这个动作好”却依赖之后怎么走，必须引入价值函数。**跨期探索：现在的次优动作可能是为进入更好的状态**。分布偏移**：数据分布由策略自己决定，换策略就换整条轨迹的分布（第 2 章），它让“评估”与“改进”互相耦合。形式化上，MDP 的价值是式 (1.17) 的序贯版本：

$$V^{\pi}(s) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^{k} r_{t+k+1} \,\middle|\, s_t = s\right]. \tag{1.20}$$

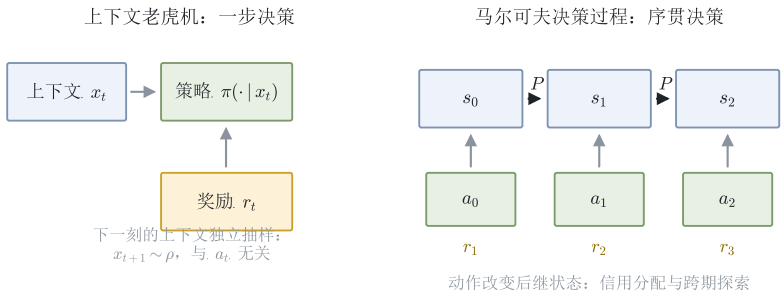


图 1-4 从上下文老虎机到马尔可夫决策过程的半步。左：下一刻的上下文由环境独立抽样，与所选动作无关，因此每步可单独优化；右：动作通过转移 P 改变后继状态，收益沿轨迹累积，于是出现信用分配与跨期探索。

第 2 章从这里接管。 第 2.1 节把上下文 x_t 提升为**状态** s_t，并让 s_{t+1} 的分布依赖 a_t——这就是图 1-4 左右两半的全部区别，也是“上下文”到“状态”的半步：上下文由环境给、与动作无关，状态被动作驱动。第 2.1.2 节给出马尔可夫性，第 2.2 节给出 MDP 定义与三类目标，第 2.3 节证明折扣下的压缩性与贝尔曼方程；本章的遗憾届时变成“相对于最优策略的累积遗憾”，分析它需要置信集与占用测度等新工具。

本章的结论可压缩成一句话：**在不知道收益分布的条件下，用尽量少的试错把动作的价值估准**——少到不浪费（乐观与后验），少到有理论保证（对数与平方根）。第 2 章之后“动作的价值”变成“策略的价值”，但两难本身不会消失，只是换了一个更贵的舞台。

SUMMARY / 总结

本章小结

这一章只处理一种决策：每次选择互不影响。在这个约束下，遗憾恒等式 (1.1) 把策略的作用压成访问计数，于是“谁更好”变成一个可数的问题；式 (1.2) 再把遗憾拆成探索的代价与误判的代价，后者又分成探索不足造成的锁定与抽样噪声造成的误判。Lai – Robbins 下界 (1.3) 说明对数遗憾来自假设检验的样本复杂度，但它标 [渐近]，要求算法在整类实例上一致有效，并要求参数族与 KL 信息满足正则条件；ε-贪心的线性税 (1.5) 则精确到每步 $(\varepsilon/K)\sum_a \Delta_a$，要让它消失，$\varepsilon_t$ 得同时趋于零且级数发散，这就是 GLIE。乐观路线用上界把探索集中到“不确定且可能值钱”的臂上，得到 (1.10)，代价是独立同分布、有界支撑、间隙不为零三条假设；后验路线把遗憾换成最优动作的信息量，得到 (1.16)，代价是先验必须正确。Robbins – Monro 条件 (1.8) 只约束步长，既不保证无限次访问，也不覆盖函数逼近，更不适用于漂移的目标。

这些遗憾界分别依赖奖励平稳性、有界性及先验等假设。三者都能交代，就用后验式；只能声明有界与平稳，就用乐观式；连平稳都保不住，就退回衰减的 ε_t。而它们全都建立在一个前提上——动作不改变下一刻的分布。第 2 章把这个前提拆掉：上下文升为状态，状态被动作驱动，遗憾随之变成沿轨迹累积的量。

关键公式

下面五条是全章的主干：遗憾的定义与它的计数值形式、两个下界、一个上界，以及后验路线的界。常数与前提都写在正文各节，这里只留骨架。

式 (1.1)：

$$\mathrm{Regret}(T) = T\mu^* - \mathbb{E}\Big[\sum_{t=1}^{T} r_t\Big] = \sum_{a=1}^{K} \Delta_a \, \mathbb{E}\big[N_a(T)\big]$$

式 (1.3)：

$$\liminf_{T\to\infty} \frac{\mathrm{Regret}(T)}{\ln T} \;\geq\; \sum_{a:\,\Delta_a>0} \frac{\Delta_a}{\mathrm{KL}(\nu_a, \nu_*)}$$

式 (1.5)：

$$\mathrm{Regret}(T) \;\geq\; \frac{\varepsilon}{K}\Big(\sum_{a=1}^{K}\Delta_a\Big)T$$

式 (1.10)：

$$\mathrm{Regret}(T) \;\leq\; 4c^2 \sum_{a:\,\Delta_a>0} \frac{\ln T}{\Delta_a} + \Big(1+\frac{\pi^2}{3}\Big)\sum_{a=1}^{K}\Delta_a$$

式 (1.16)：

$$\overline{\mathrm{Regret}(T)} \;\leq\; \sqrt{\bar{\Gamma}\,T\,\mathbb{I}_T} \;\leq\; \sqrt{\bar{\Gamma}\,T\ln K}$$

习题

1. 证明式 (1.1) 的第二个等号，并说明它为什么只依赖访问计数、不依赖分布形状；再讨论 $\mathrm{Regret}(T)/(T\sum_a \Delta_a)$ 的极限能否刻画一个算法的好坏。

2. 取 $K=10$、$\sum_a \Delta_a = 15.4$、$\varepsilon = 0.1$，用式 (1.5) 算出 $T=1000$ 与 $T=5000$ 的探索税，与表 1-2 的实测值比较并指出差额属于哪一项；再对 $\varepsilon = 0.01$ 做同样计算，解释它的实测遗憾为何远高于税。

3. 证明命题 1.3。再分别取 $\varepsilon_t = 1/t^2$ 与 $\varepsilon_t = 0.1$，指出各自破坏了哪条条件，说明这两个反例分别对应 GLIE 的哪一半要求。

4. 取 $c=\sqrt{2}$、$K=2$、$\Delta = 10^{-3}$、$T=10^6$，计算式 (1.10) 的右端，说明它为何不再是有信息量的界；再用式 (1.12) 在 $\delta = 0.05$ 时算一次，指出两者常数差异的来源；最后说明把 c 改成 2 时右端如何变化。

5. 推导式 (1.14) 的 Beta 后验更新；再构造一个先验错配的例子（真值 $p=0.9$，先验取 $\mathrm{Beta}(1,9)$），说明 TS 会系统性低估该臂，从而违反式 (1.16) 的哪条前提。

6. 构造一个 2 状态、2 动作的例子，使上下文老虎机意义下的最优动作在 MDP 中不是最优（提示：让某个动作把状态带入价值很低的吸收状态），并用它说明信用分配为何无法靠“每步独立优化”解决。

7. 写出 A_a 的 Sherman–Morrison 增量更新公式，说明每步代价为何能从 $O(d^3)$ 降到 $O(d^2)$；再说明当 d 很大、必须用神经网络替代线性模型时，式 (1.19) 的第二项为何最先失效。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 2 章 §2.1–§2.5 给出 10 臂测试台、ε-贪心与增量式实现的教材式推导，本章第 1.2 节的设定与实验范式直接取自这里；书中指出 $\varepsilon = 0.01$ 长期表现更好但学得更慢，与表 1-2 的交叉点一致。
- 同上 §2.6（乐观初始值）与 §2.7（上置信界动作选择）：§2.6 给出“用乐观初值代替显式随机探索”的最简实现，可与命题 1.1 的锁死机制对照；§2.7 给出式 (1.9) 与关于 c 的经验讨论，但那里没有写出前提。
- 同上 §2.9（关联搜索与上下文老虎机）与 §2.10（Gittins 指数与贝叶斯方法）：§2.10 明确指出 Gittins 方法需要完整先验知识、难以推广到完整的强化学习问题，这正是第 1.4.3 节分层的由来；§2.11 的书目注记给出 Lai–Robbins 与 Auer 等的出处。
- Levine 等的深度强化学习讲义（`source/text/1811.12560_intro-to-deep-rl.txt`）§8.1 讨论探索—利用两难，其中给出 GLIE 的定义（行为策略在极限上变贪心，同时保持无限探索），可与命题 1.3 对照。

第 2 章　马尔可夫决策过程与贝尔曼理论

第1章在随机奖励模型下讨论探索策略与样本分配，分析各动作的未知平均收益。标准老虎机模型中，每次行动的奖励不改变后续环境状态。推荐、竞价与机器人控制都不满足它：此刻选的动作会改变下一刻所处的局面，而下一刻的局面又限制了再下一步能做什么。序贯决策中的动作价值同时取决于当前状态与未来的行动序列。

马尔可夫决策过程以状态转移描述动作对后续决策条件的影响。第 2.3 节与第 2.4 节在这套语言上给出价值函数、贝尔曼方程与最优性理论：压缩映射、残差界、策略改进。第 2.5 节处理它在真实问题里最容易出错的三处接口——部分可观测、状态设计与奖励设计。

本章的结论全部属于**有限马尔可夫决策过程**这一设定：标 [精确] 的结论只在这个设定下成立，向函数逼近与深度网络的推广要等到第 4 章，而本书会在每一处推广时重新声明条件。

本章使用条件概率、期望与有限维矩阵计算；第1章的遗憾分析并非必需的先修内容。状态表示应包含预测后续状态与奖励所需的充分信息。下面的两状态例子会把转移概率、折扣与价值逐项落到数字上。

2.1 序贯决策：从老虎机到马尔可夫决策过程

2.1.1 上下文老虎机：一次一步的决策

上下文老虎机在标准老虎机模型上引入决策前可观测的上下文信息。把这类信号称为**上下文**，就得到老虎机问题最常用的推广。

> **定义 2.1（上下文老虎机）**
>
> 上下文空间 $\mathcal{X}$、动作集 $\mathcal{A}$、上下文分布 ρ 与奖励函数 $r:\mathcal{X}\times\mathcal{A}\to[0,1]$ 构成一个上下文老虎机。学习目标是在不知道 r 的条件下，找一个策略 $\pi:\mathcal{X}\to\Delta(\mathcal{A})$ 使期望奖励
>
> $$J(\pi)=\mathbb{E}_{x\sim\rho}\,\mathbb{E}_{a\sim\pi(\cdot|x)}\big[r(x,a)\big] \tag{2.1}$$
>
> 尽可能大。

上下文老虎机涉及未知奖励的探索与观测反馈。反馈可以即时到达，也

可以根据任务协议延迟或缺失。其一是**探索**：r 未知，只能通过试错估计，而每一次试错都要付出机会成本。其二是**延迟反馈**：动作的收益要等结果回来才能知道，若结果稀疏，估计就慢。它缺少的恰恰是第三个、也是最本质的难点——动作不改变状态。上下文 x 由环境独立抽样，与智能体选了什么动作无关；因此每一步的决策可以单独优化，不存在“今天的选择限制了明天的选项”这种跨期耦合。

把上下文老虎机与真正的序贯决策放在一起对比，可以看清“状态”这个词的分量。上下文老虎机在每轮观测上下文后选择动作，动作不改变后续上下文的生成机制；一般MDP允许动作影响后续状态。

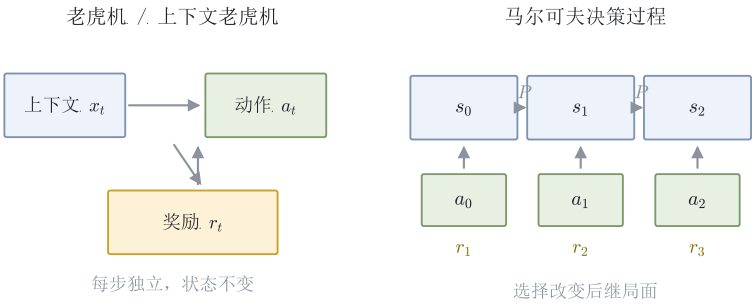


图 2-1 从老虎机到马尔可夫决策过程的推广路径。左侧每一次选择都是独立的抽奖，动作不改变后续情形；右侧动作驱动状态转移，收益沿轨迹累积，决策之间通过状态耦合。

2.1.2 状态：让未来只依赖现在

序贯决策的核心困难在于历史越来越长。若第 t 步的决策要用到整段历史 $h_t = (s_0, a_0, r_1, \dots, s_t)$，则策略的定义域随 t 增长，任何估计方法都会因样本被历史切碎而失效。**状态**的作用就是把这段历史压缩成一个定长的摘要，使得给定摘要之后，历史对未来的预测不再有增量信息。

> **定义 2.2（马尔可夫性）**
>
> 称状态表示 s 对决策过程满足马尔可夫性，若对任意历史 h_t 与任意后续事件 E，
>
> $$\Pr\big(E \mid h_t, a_t\big) = \Pr\big(E \mid s_t, a_t\big). \tag{2.2}$$
>
> 等价地，$\Pr(s_{t+1} \mid h_t, a_t) = \Pr(s_{t+1} \mid s_t, a_t)$。

SUMMARY / 总结

马尔可夫性要求：给定当前状态与动作后，下一步奖励及后继状态的联合分布与更早的历史条件独立。状态不必包含环境的全部信息，但必须对奖励和未来状态具有充分性。含噪传感器读数若无法区分影响未来的真实情形，通常不满足这一条件（第 2.5 节）。工程上把“状态是否够用”称为**状态充分性**问题，它比算法选择更能决定一个强化学习项目能否成功。

由式 (2.2) 可以立刻写出整条轨迹的概率。给定策略 π 与初始分布 ρ_0，

$$\Pr_\pi(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi(a_t \mid s_t)\, P(s_{t+1} \mid s_t, a_t), \tag{2.3}$$

其中 $\tau = (s_0, a_0, s_1, a_1, \dots)$。这条式子是后面所有期望的出发点：策略的价值就是奖励在式 (2.3) 这个分布下的期望。它也说明为什么“数据分布依赖于策略”——改动 π 会同时改动每一个因子。

SUMMARY / 总结

2.2 马尔可夫决策过程

2.2.1 定义与约定

式 (2.3) 把一条轨迹的概率写成连乘，乘里只有三样东西：初始分布、策略与转移核。把它们连同奖励、折扣一起打包，就是本章要反复操作的对象。

> **定义 2.3（马尔可夫决策过程）**
>
> 马尔可夫决策过程由六元组 $(\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho_0)$ 给出：状态集 $\mathcal{S}$、动作集 $\mathcal{A}$、转移核 $P(s' \mid s, a)$、奖励函数 $r : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$、折扣因子 $\gamma \in [0, 1)$ 与初始状态分布 ρ_0。当 $\mathcal{S}$ 与 $\mathcal{A}$ 都是有限集时，称为**有限**马尔可夫决策过程，此时 P 可写成 $|\mathcal{S}| \times |\mathcal{A}|$ 个行随机矩阵。

奖励取期望形式 $r(s,a) = \mathbb{E}[R_{t+1} \mid s_t = s, a_t = a]$ 是一个刻意的简化：它把“同一状态—动作对可能给出不同奖励”这一随机性吸收进期望，从而让价值函数成为确定性的函数。若奖励还依赖后继状态，可写 $r(s,a,s')$ 并令 $r(s,a) = \sum_{s'} P(s' \mid s,a) r(s,a,s')$，两种写法在期望意义下等价；本书统一用 $r(s,a)$，在需要区分时显式写出 $r(s,a,s')$。

在有限设定下，转移与奖励是两个可以完整写下来的对象：前者是 $|\mathcal{S}| \times |\mathcal{A}|$ 个行随机向量，后者是一张实数表。第 2.4 节的算子理论与第 3 章的动态规划都建立在“这两个对象已知且有限”之上；一旦进入函数逼近（第 4 章）或连续控制（第 6 章），这个前提就换成了“从一个采样器里取转移样本”，理论结论也随之改变。

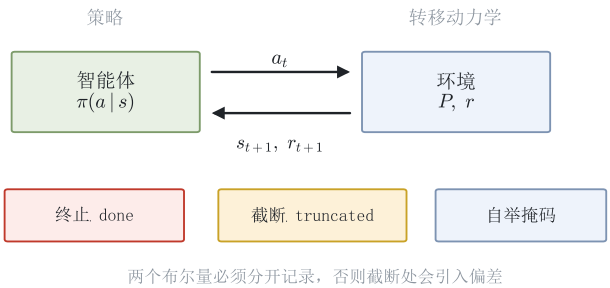


图 2-2 智能体与环境的交互时序。第 t 步智能体据 s_t 选 a_t，环境返回 r_{t+1} 与 s_{t+1}；截断（时间上限）与终止（吸收状态）在实现上必须分开记录。

2.2.2 回合、截断与三类目标

SUMMARY / 总结

有限马尔可夫决策过程的结束方式有两种，工程实现里极易混淆，而它们对自举的影响完全不同。**终止**表示任务按其定义结束；在标准吸收终止设定下，后续价值为零。**截断**表示时间上限或外部干预结束了当前采样，但任务本身仍可能继续。有限时域任务若将剩余步数纳入状态，其时间上限属于任务定义的一部分。二者在数据里都表现为“回合结束”，但对自举的处理相反：终止处应当切断自举，目标就是该步奖励；截断处若直接切断自举则引入系统偏差——把“还有未来”当成“没有未来”，正确的做法是保留对后继价值的自举，或用掩码把截断步的回报补上。这一区别在第 5 章与第 11 章的实现细节中反复出现，本书在符号上统一用终止位与截断位两个独立的布尔量记录，两者的处理不得合并。

目标的写法取决于任务是否自然终止。三类目标的并列对比如表 2-1。

表 2-1 三类目标的并列对比。折扣与平均奖励目标的贝尔曼方程都是不动点方程，有限时域目标则是递推式，不存在无穷远的不动点。

目标	价值定义	贝尔曼形式	适用场景
折扣回报	$\mathbb{E}_\pi[\sum_{k\ge 0}\gamma^k r_{t+k+1} \mid s_t=s]$	$V^\pi = r^\pi + \gamma P^\pi V^\pi$	无限时域、需保证有界
平均奖励	$\mathbb{E}_\pi[\sum_{k\ge 0}(r_{t+k+1}-\bar r^\pi) \mid s_t=s]$	$V^\pi + \bar r^\pi = r^\pi + P^\pi V^\pi$	无限时域、长期吞吐
有限时域	$\mathbb{E}_\pi[\sum_{k=0}^{h-1} r_{t+k+1} \mid s_t=s]$	$V_h^\pi = r^\pi + P^\pi V_{h-1}^\pi$	回合长度固定

表 2-1 的第三种情形最容易漏掉：有限时域下价值函数额外依赖剩余步数 h，因此最优策略可以是**非平稳**的——同一状态在剩余步数不同时选择不同动作。本书主要采用折扣回报目标，因为在有界奖励且折扣因子小于1 时，折扣目标具有回报有界及贝尔曼算子压缩等性质。平均奖励目标需要遍历性假设，其算子不再是压缩映射，理论处理要复杂得多。

折扣因子常被误解为“越远的奖励越不重要”这一经济学解释。在实现层面它还有两个数值作用：其一，若 $|r| \le r_{\max}$，则回报满足 $|G_t| \le r_{\max}/(1-\gamma)$，方差同样被这个因子约束，因此 γ 直接决定了估计目标的尺度；其二，$\gamma<1$ 是压缩映射成立的前提（第 2.4 节），$\gamma=1$ 时价值可能发散，除非任务本身有限时域或满足平均奖励的遍历条件。更准确地说，$\gamma<1$ 是式 (2.9) 有唯一解的充分条件之一，另一条是该策略下从所有状态必然终止（定理 2.1）。

2.2.3 策略与价值函数的记号

> **定义 2.4（策略）**
>
> 策略是

SUMMARY / 总结

> $\pi : \mathcal{S} \to \Delta(\mathcal{A})$ 的映射。称策略**马尔可夫**当且仅当它只依赖当前状态；称其**平稳**当且仅当它与时间无关。确定性策略是随机策略的退化情形，记作 $a = \pi(s)$。

本书默认策略马尔可夫且平稳。这一限制并不损失一般性：在有限马尔可夫决策过程中，只要状态满足马尔可夫性，就存在最优的平稳马尔可夫策略（定理 2.2）。若状态不满足马尔可夫性，最优策略可能需要记忆，问题升级为部分可观测（第 2.5 节）。

策略的价值函数与动作价值函数定义为

$$V^{\pi}(s) = \mathbb{E}_{\pi}\Big[\sum_{k=0}^{\infty} \gamma^{k} r_{t+k+1} \,\Big|\, s_t = s\Big], \tag{2.4}$$

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}\Big[\sum_{k=0}^{\infty} \gamma^{k} r_{t+k+1} \,\Big|\, s_t = s, a_t = a\Big], \tag{2.5}$$

两者通过 π 相互联系；称二者之差为**优势函数**

$$A^{\pi}(s,a) = Q^{\pi}(s,a) - V^{\pi}(s). \tag{2.6}$$

式 (2.6) 的含义是“在状态 s 比其他动作平均好多少”。它满足一个恒等式，后面所有策略改进的证明都要用到：

$$\mathbb{E}_{a \sim \pi(\cdot\mid s)}\big[A^{\pi}(s,a)\big] = 0. \tag{2.7}$$

即对当前策略而言，优势的期望为零——这是“没有更好的动作”的精确表述，也是第 5 章策略梯度里“基线不引入偏差”的代数根源。

价值函数与策略之间还有一层对偶关系：给定 V^{π} 可以恢复 Q^{π}，给定 Q^{π} 则贪婪策略就是最自然的改进方向。第 2.4 节把这一观察变成定理。除 V 与 Q 之外，本书还会用到**状态占用测度**：

$$d_{\gamma}^{\pi}(s) = (1-\gamma)\sum_{t=0}^{\infty} \gamma^{t}\, \Pr(s_t = s \mid \pi), \tag{2.8}$$

它把“按策略 π 走时各状态被访问的频率”写成一个概率分布（对 s 求和为 1），从而把策略的价值写成 $J(\pi) = \frac{1}{1-\gamma}\mathbb{E}_{s\sim d_{\gamma}^{\pi}, a\sim\pi}[r(s,a)]$。式 (2.8) 里的 $1-\gamma$ 归一化因子不可省略：不归一化的版本总质量为 $1/(1-\gamma)$，用作分布会算错梯度尺度。**符号在这里分叉**：本章式 (2.8) 的 d_{γ}^{π} 已归一化（总质量 1），第 5.1.2 节则用 d_{γ}^{π} 记**未归一化**版本、$\bar{d}_{\gamma}^{\pi}$ 记归一化版本，两者差常数因子 $1/(1-\gamma)$；跨章引用以“总质量是否为 1”为准。

SUMMARY / 总结

2.3 贝尔曼方程与算子视角

2.3.1 贝尔曼期望方程

价值函数的定义含有一条无穷长的轨迹，直接按定义计算是不可能的。把它拆成“当前一步的奖励”加“余下部分的价值”，无穷级数就变成一个方程。

> **定理 2.1（贝尔曼期望方程 [精确]）**
>
> 设 $\mathcal{S}$ 与 $\mathcal{A}$ 有限、奖励有界、$0 \le \gamma < 1$，且策略为平稳策略。则价值函数满足
>
> $$V^{\pi}(s) = \sum_{a} \pi(a \mid s) \Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^{\pi}(s') \Big], \tag{2.9}$$
>
> $$Q^{\pi}(s,a) = r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) \sum_{a'} \pi(a' \mid s') Q^{\pi}(s',a'). \tag{2.10}$$
>
> 两条方程互为正反向的同一关系：把式 (2.10) 右边对 π 取期望即得式 (2.9)。

证明. 由定义 2.4 与式 (2.4)，将第一个奖励从回报级数中分离，余项按马尔可夫性在后继状态处重新开始，即得式 (2.9)；式 (2.10) 同理。折扣因子 $\gamma < 1$ 与有界奖励保证回报绝对收敛。□

把方程算一遍，比再读一遍定义更能看出每一项在做什么。设只有状态 A, B：在 A 立即得 1，以概率 $1/2$ 留在 A、以概率 $1/2$ 到 B；B 吸收且之后奖励为 0。取 $\gamma = 0.9$，于是 $V(B) = 0$，而

$$V(A) = 1 + 0.9\big[0.5 V(A) + 0.5 V(B)\big],$$

解得 $V(A) = 1/0.55 \approx 1.82$。这里的 1 是眼前奖励，方括号是下一状态价值的均值，0.9 折扣未来。若误把 A 当成必定自环，答案会变成 10；错误在转移概率，不在代数。

式 (2.9) 是**线性**方程组：给定 π，它对 V^{π} 是线性的。这一线性性是第 3 章动态规划与第 4 章投影理论的全部起点；一旦价值函数被参数化，线性性就变成非线性的最小二乘问题，这是后面所有麻烦的来源。

SUMMARY / 总结

2.3.2 矩阵形式与闭式解

把式 (2.9) 写成向量形式。设 $V^\pi \in \mathbb{R}^{|\mathcal{S}|}$，$r^\pi(s) = \sum_a \pi(a \mid s) r(s,a)$，$P^\pi(s' \mid s) = \sum_a \pi(a \mid s) P(s' \mid s,a)$，则

$$V^\pi = r^\pi + \gamma P^\pi V^\pi \tag{2.11}$$

于是

$$V^\pi = (I - \gamma P^\pi)^{-1} r^\pi. \tag{2.12}$$

式 (2.12) 说明价值函数是矩阵求逆的结果，而 $I - \gamma P^\pi$ 一定可逆：由 $\gamma < 1$ 与 P^π 行随机，

$$(I - \gamma P^\pi)^{-1} = \sum_{k=0}^{\infty} \gamma^k (P^\pi)^k, \tag{2.13}$$

右端是收敛的诺伊曼级数（第 k 项范数不超过 γ^k）。式 (2.13) 有一个直观读法：$(P^\pi)^k$ 的第 (s,s') 元是“从 s 出发按 π 走 k 步落在 s' 的概率”，于是价值等于把第 k 步的期望奖励按 γ^k 加权求和。这条级数也解释了折扣因子的第二个作用：它让无穷求和收敛。

对有限状态的问题，式 (2.12) 提供了精确解。但它的代价是 $O(|\mathcal{S}|^3)$ 的矩阵求逆，且要求完整知道 P^π 与 r^π。动态规划（第 3 章）用迭代避开求逆，蒙特卡洛与时序差分（第 3 章后半）用采样避开模型，函数逼近（第 4 章）用参数化避开 $|\mathcal{S}|$ 个未知量。四条路线都从式 (2.11) 出发，只是各自换掉了其中一件东西。

2.3.3 贝尔曼算子与压缩映射

把式 (2.9) 的右端看作作用在价值函数上的算子，就能用不动点理论讨论“迭代会不会收敛”。定义

$$(T^\pi V)(s) = \sum_a \pi(a \mid s) \Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V(s') \Big], \tag{2.14}$$

则式 (2.9) 就是 $V^\pi = T^\pi V^\pi$。以 $\|\cdot\|_\infty$ 记上确界范数。

SUMMARY / 总结

命题 2.1（贝尔曼算子的压缩性 [精确]）

对任意 $V_1, V_2 \in \mathbb{R}^{|\mathcal{S}|}$，

$$\|T^\pi V_1 - T^\pi V_2\|_\infty \le \gamma \|V_1 - V_2\|_\infty. \tag{2.15}$$

因此 T^π 是 γ-压缩映射，在 $\mathbb{R}^{|\mathcal{S}|}$ 中存在唯一不动点，且该不动点就是 V^π。

证明. 记 $\Delta(s) = |V_1(s) - V_2(s)|$。对任意 s，

$$\begin{aligned} \left|(T^\pi V_1)(s) - (T^\pi V_2)(s)\right| &\le \gamma \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) \Delta(s') \\ &\le \gamma \|\Delta\|_\infty. \end{aligned} \tag{2.16}$$

取上确界即得式 (2.15)。由巴拿赫不动点定理，压缩映射在完备度量空间上有唯一不动点，且从任意初值迭代都收敛到它。 □

由证明可以看出压缩性完全来自 $\gamma < 1$，与状态数、动作数无关，也与奖励的大小无关。**折扣因子的第一功能是保证算子压缩**，而非“让远期奖励不重要”。若 $\gamma = 1$，式 (2.15) 退化为非扩张（≤ 1），不动点可能不存在或不唯一，第 9 章的平均奖励目标正是这种情况。

命题 2.1 还直接给出收敛速度：

$$\|V_k - V^\pi\|_\infty \le \frac{\gamma^k}{1-\gamma} \|V_1 - V_0\|_\infty, \tag{2.17}$$

即误差按 γ^k 几何衰减。第 3 章的值迭代就是“反复作用 T^π”，其迭代轮数由式 (2.17) 决定；这解释了为什么 γ 接近 1 时收敛极慢——那正是长时程信用分配困难在数值上的表现。

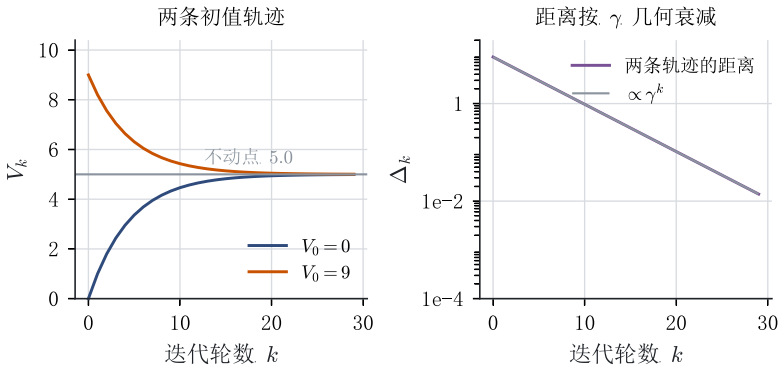


图 2-3 压缩映射的几何直观。两个初值在一维价值空间里反复作用压缩算子，距离按 γ 衰减并共同收敛到唯一不动点；γ 越接近 1，收缩越慢。

SUMMARY / 总结

2.4 最优性、策略改进与误差界

2.4.1 贝尔曼最优方程

在所有策略中取逐点最大，得到**最优价值函数** $V^*(s)=\sup_\pi V^\pi(s)$。它满足的方程不再是线性的，因为最大值与求和交换了位置。

> **定理 2.2（贝尔曼最优方程 [精确]）**
> 在有限马尔可夫决策过程中，V^* 是如下方程的唯一解：
>
> $$V^*(s)=\max_a\Big[r(s,a)+\gamma\sum_{s'}P(s'\mid s,a)V^*(s')\Big], \tag{2.18}$$
>
> 且存在**确定性平稳**策略 π^* 达到该最优值。它的逐状态取值由最优动作价值函数给出，即 $\pi^*(s)\in\arg\max_a Q^*(s,a)$，而
>
> $$Q^*(s,a)=r(s,a)+\gamma\sum_{s'}P(s'\mid s,a)V^*(s'). \tag{2.19}$$

证明要点. 定义最优贝尔曼算子

$$(T^*V)(s)=\max_a\Big[r(s,a)+\gamma\sum_{s'}P(s'\mid s,a)V(s')\Big]. \tag{2.20}$$

它与 T^π 满足同一压缩不等式：$\|T^*V_1-T^*V_2\|_\infty\le\gamma\|V_1-V_2\|_\infty$，因为逐点取最大不放大差距。故 T^* 有唯一不动点 V_∞。对任意 π 有 $T^\pi V_\infty\le T^*V_\infty=V_\infty$，两边反复作用 T^π 并令其次数趋于无穷，得 $V^\pi\le V_\infty$，即 $V_\infty\ge V^*$。另一方面，以 V_∞ 为评价函数取贪婪动作得到确定性策略 π_∞，可以验证 $T^{\pi_\infty}V_\infty=T^*V_\infty=V_\infty$，故 $V^{\pi_\infty}=V_\infty$，于是 $V_\infty\le V^*$。两式合并即得 $V_\infty=V^*$，且取到最优的策略确实存在。 □

定理 2.2 有两点容易被过度推广。第一，它依赖 $\mathcal{S}$ 有限且 $\max$ 可达；在无限状态空间或连续动作空间里，“逐点最大值”可能不可达，此时只能保证上确界，最优策略的存在性要另行论证。第二，它假定转移与奖励已知——这正是动态规划的前提，而强化学习的主线恰恰是没有模型。第 3 章说明如何在没有模型时用采样逼近 V^*，但那时得到的只是收敛到 V^* 的估计，不再是式 (2.18) 的精确解。

SUMMARY / 总结

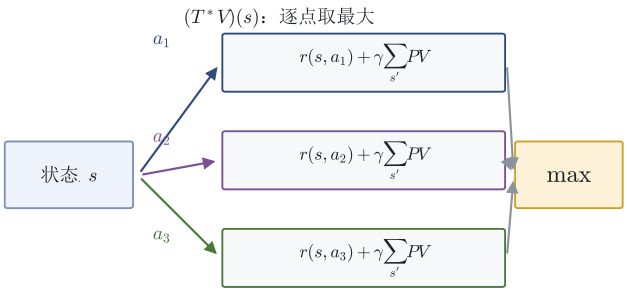


图 2-4 最优贝尔曼算子的逐点取最大结构。同一个状态上，不同动作给出不同的「即时奖励 + 折扣后续价值」，最优方程的右端取其中的最大值，因此不再是线性方程。

2.4.2 残差界：从一个候选价值函数到最优值的距离

在计算或采样受限时，通常只能得到近似价值函数 V，因此需要估计它与 V^* 的距离。若 V 是对应算子的不动点，两者之差为零；一般情形下，以下不等式给出残差与价值误差之间的联系。

> **定理 2.3（残差界 [精确]）**
>
> 设 $\mathcal{S}$ 有限、$|r| \le r_{\max}$、$0 \le \gamma < 1$。若 $V : \mathcal{S} \to \mathbb{R}$ 有界，则
>
> $$\|V - V^*\|_\infty \le \frac{\|V - T^*V\|_\infty}{1-\gamma}. \tag{2.21}$$

证明. 记 $\delta = \|V - T^*V\|_\infty$，即 T^*V 与 V 的差距。由 T^* 的压缩性与 $T^*V^* = V^*$，

$$\|T^*V - V^*\|_\infty = \|T^*V - T^*V^*\|_\infty \le \gamma \|V - V^*\|_\infty.$$

于是

$$\|V - V^*\|_\infty \le \|V - T^*V\|_\infty + \|T^*V - V^*\|_\infty \le \delta + \gamma \|V - V^*\|_\infty,$$

移项即得式 (2.21)。 □

三个贝尔曼误差不是同一个量

式 (2.21) 右端的分子是**最优算子的上确界残差** $\|V - T^*V\|_\infty$，它只对表格情形、以 $\|\cdot\|_\infty$ 度量、且算子为 T^* 时成立。常见文献中的另外两个量与之不同，不能相互替换。

贝尔曼误差（Bellman error）是逐状态的向量 $\bar{\delta}(s) = (T^\pi V)(s) - V(s)$，未平方；它的期望形式就是 TD 误差的期望。**均方贝尔曼误差**（MSBE）是它的 D-加权**平方**范数，即 $\mathrm{MSBE} = \|\bar{\delta}\|_D^2 = \mathbb{E}_{s\sim D}[\bar{\delta}(s)^2]$，平方与权重都必须写明。**均方投影贝尔曼误差**（MSPBE）是 $\|\Pi_D T^\pi V_\theta - V_\theta\|_D^2$，多了一层到函数空间的投影与一个加权分布 D。三者的投影、分布与优化性质都不同，相互之间只有单向不等式，没有等式。

具体地说，(a) 在函数逼近下，投影步使 T^π 不再是压缩算子，式 (2.21) 的推导不成立，此时只能得到 $\|V - V^\pi\|_D$ 与投影残差之间的关系；(b) 深度强化学习实际最小化的是**采样平方 TD 误差**：DQN 的损失是 $\mathbb{E}_{s\sim D}[(r + \gamma \max_{a'} Q_{\bar{\theta}}(s', a') - Q_\theta(s, a))^2]$。它既不是 MSBE——因为“先平方再取期望”比“先取期望再平方”恰好多一个 $\mathrm{Var}(\bar{\delta} \mid s)$ 项，两者只在奖励与转移对该状态无噪声时相等——也不是 MSPBE，因为它没有投影；目标网络 $\bar{\theta}$ 与 $\max_{a'}$ 又使回归目标随训练变化，而 MSBE 与 MSPBE 都是对固定 π 定义的；(c) 因此“Bellman loss 很小”不能推出“价值函数接近最优”——这是深度强化学习里最常见的一类错误论断，第 4 章会给出反例与正确的替代结论。

定理 2.3 的价值在于它把“离最优有多远”化归为“算子残差有多大”，后者可以在数据上估计。它的局限同样清楚：上确界范数要求逐状态检查，实际只能采样估计；而当价值函数被参数化后，投影算子的介入使压缩性不再成立（第 4 章命题 4.2）。使用时必须同时写出条件与范数，否则这条不等式会被误用成“训练损失小即价值准”。

SUMMARY / 总结

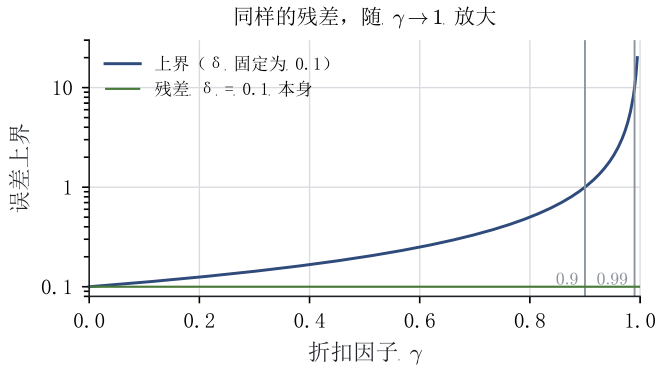


图 2-5 残差界随折扣因子的放大效应。同样的算子残差 δ，在 $\gamma=0.9$ 与 $\gamma=0.99$ 下对应完全不同的价值误差上界；$\gamma\to 1$ 时该界趋于发散，这正是长时程任务难以评估的原因。

2.4.3 策略改进：价值差恒等式

有了 Q^π，最自然的改进是“在每个状态上都选 Q^π 最大的动作”，得到贪婪策略 $\pi'(s)=\arg\max_a Q^\pi(s,a)$。要证明这样改不会变差，需要把“两个策略的价值之差”精确写出来。本节以下默认 π,π' 都是平稳马尔可夫策略；式 (2.22) 对历史依赖策略同样成立，但本节不展开。

> **定理 2.4（价值差恒等式 [精确]）**
>
> 对任意两个策略 π,π' 与任意状态 s，
>
> $$V^{\pi'}(s)-V^{\pi}(s)=\mathbb{E}_{a\sim\pi'(\cdot|s)}\big[A^{\pi}(s,a)\big] +\gamma\,\mathbb{E}_{s'\sim P^{\pi'}(\cdot|s)}\big[V^{\pi'}(s')-V^{\pi}(s')\big]. \tag{2.22}$$

证明. 两边都按 π' 的一步分解展开。由式 (2.5)，

$$V^{\pi'}(s)=\mathbb{E}_{a\sim\pi'}\big[Q^{\pi'}(s,a)\big],\qquad V^{\pi}(s)=\mathbb{E}_{a\sim\pi'}\big[V^{\pi}(s)\big],$$

后者只是把常数 $V^\pi(s)$ 写成对 π' 的期望。两式相减，把 π' 选出的每个动作拆成“相对 π 的优势”加“基线”：

$$V^{\pi'}(s)-V^{\pi}(s)=\mathbb{E}_{a\sim\pi'}\Big[\underbrace{Q^{\pi'}(s,a)-Q^{\pi}(s,a)}_{\text{后继价值的差}}\Big] +\mathbb{E}_{a\sim\pi'}\Big[\underbrace{Q^{\pi}(s,a)}_{A^\pi(s,a)}-V^{\pi}(s)\Big]. \tag{2.23}$$

第一项中，由式 (2.10) 展开后继价值之差（即时奖励相同，相消）：

$$Q^{\pi'}(s,a)-Q^{\pi}(s,a)=\gamma\sum_{s'}P(s'\mid s,a)\big[V^{\pi'}(s')-V^{\pi}(s')\big],$$

SUMMARY / 总结

再对 $a \sim \pi'$ 与 $s' \sim P$ 依次取期望，即得式 (2.22) 的第二项；式 (2.23) 的第二项就是式 (2.22) 的第一项。 □

式 (2.23) 的第一个等号没有使用“$\mathbb{E}_{a\sim\pi'}[Q^\pi(s,a)] = V^\pi(s)$”——那个等式一般**不成立**，只在 $\pi' = \pi$ 时成立。正确的分解是把 $V^\pi(s)$ 写成对 π' 的常数期望，从而把差距精确地分成“后继价值差”与“优势”两块。

式 (2.22) 将价值差分为当前状态的一步优势期望和后继状态上的折扣价值差。该递推式说明策略改进的收益如何沿后续状态传播；策略价值仍需通过贝尔曼方程或相应评估过程求得。

> **定理 2.5（策略改进定理 [精确]）**
>
> 若对所有状态 s 都有 $\mathbb{E}_{a\sim\pi'(\cdot|s)}[Q^\pi(s,a)] \geq V^\pi(s)$，则对所有 s 有 $V^{\pi'}(s) \geq V^\pi(s)$。若其中某个状态严格不等，则**该状态的**价值严格增大；若所有状态都严格不等，则 $V^{\pi'} > V^\pi$ 逐点成立。

证明. 设 $D(s) = V^{\pi'}(s) - V^\pi(s)$，并记 $A(s) = \mathbb{E}_{a\sim\pi'(\cdot|s)}[A^\pi(s,a)]$。由式 (2.22) 有 $D(s) = A(s) + \gamma\mathbb{E}_{s'\sim P^{\pi'}}[D(s')]$，而假设给出 $A(s) \geq 0$，故 $D(s) \geq \gamma\mathbb{E}_{s'\sim P^{\pi'}}[D(s')]$。下一步必须对**最小值**取极值：设 $s_{\min}$ 使 D 达到最小（有限状态保证取到），则 $D(s_{\min}) \geq \gamma\mathbb{E}_{s'\sim P^{\pi'}}[D(s')] \geq \gamma D(s_{\min})$，即 $(1-\gamma)D(s_{\min}) \geq 0$；由 $\gamma < 1$ 得 $D_{\min} \geq 0$，也就是 $V^{\pi'} \geq V^\pi$ 逐点成立。若某状态 s 上 $A(s) > 0$，则 $D(s) \geq \gamma D_{\min} + A(s) > 0$，该状态的价值严格增大。反过来，若错误地对**最大值**取极值，只能得到 $D_{\max} \geq \gamma\mathbb{E}[D(s')]$，它与 $\mathbb{E}[D(s')] \leq D_{\max}$ 联立推不出 $D_{\max} \geq \gamma D_{\max}$——这正是本条证明最容易写错的地方。

这段证明常被简化为“差距写成 γ 乘后续差距、沿轨迹归纳”，但那样会漏掉当前状态的一步优势项；即便两项写全，若在取极值的方向上出错（该用最小值的场合用了最大值的不等式），严格性仍推不出来。式 (2.22) 才是完备的出发点：它明确区分了两项，“非劣”与“严格改进”分别对应两项的条件，而严格性只是一步代入。

定理 2.5 比较的是同一状态下的价值，且要求所有状态的一步优势非负。这条「全状态」要求不能放宽成“在部分状态改进即可”：若 π' 在改进的同时于另一状态退化（一步优势为负），就会出现“一处变好、另一处变坏”（习题 5）；反过来，若 π' 在其余状态与 π 相同，那些状态的一步优势恰为 0，定理仍给出全局非劣——这正是第 3 章策略迭代“逐状态更新、整体单调”的根据。

SUMMARY / 总结

2.4.4 最优方程与策略改进的关系

把定理 2.2 与定理 2.5 放在一起，可以看出最优性的两条等价刻画：其一是**方程刻画**——V^* 是 T^* 的唯一不动点；其二是**改进刻画**——不存在一个策略在某个状态上严格更好，即 $V^{\pi} = T^* V^{\pi}$ 当且仅当 π 最优。前者导出值迭代，后者导出策略迭代（评价 + 改进交替）。第 3 章将证明二者都有限步收敛，并给出计算量对比。

最后需要强调本节结论的理论地位。定理 2.1 – 2.5 全部是 [精确] 的，但它们的精确性建立在四个前提上：状态有限、转移与奖励已知、$\gamma < 1$、价值用表格存储。这四条中任意一条被放弃，结论都要重写：有限状态换成连续状态，$\max$ 可能不可达；未知模型换成采样，得到的是收敛性而非等式；$\gamma = 1$ 换成平均奖励，算子不再压缩；表格换成函数逼近，投影破坏压缩性。本书余下各章正是在这四条上逐条放宽，并在每次放宽时重新标注结论的地位。

表 2-2 本章核心结论的前提与失效方式。表中每一行的前提都是定理的一部分，引用时不得省略。

结论	前提	理论状态	失效方式
贝尔曼期望方程	期望有限，$+$（$\gamma < 1$ 或必然终止）	[精确]	$\gamma = 1$ 且不终止时 V^{π} 可能发散，方程不再给出有限解
矩阵闭式解	$\mathcal{S}$ 有限、$\gamma < 1$	[精确]	求逆 $O(n^3)$，模型未知时不可用
算子压缩与不动点	$\gamma < 1$、上确界范数	[精确]	函数逼近下压缩性失效
最优方程与最优策略存在	有限 MDP	[精确]	连续动作时 $\max$ 不可达
残差界	表格、∞-范数、T^*	[精确]	换范数或换算子即不成立
策略改进定理	全状态一步优势非负	[精确]	某状态优势为负时可能一处变好、另一处变坏

表 2-2 也解释了本书的写作方式：每给出一个结论，就同时写出它的适用条件与失效方向；后续章节放宽某一条前提时，会说明是哪一条、结论因此从 [精确] 降为 [渐近] 还是 [近似]。只记公式不记前提，就会反复遇到“书上说收敛、实际不收敛”的困惑。

SUMMARY / 总结

2.5 部分可观测、状态与奖励设计

2.5.1 部分可观测决策过程

真实系统的状态往往不可直接观测，只能看到含噪的观测。把观测显式写进模型，就得到部分可观测马尔可夫决策过程（POMDP），其元组在定义 2.3 之外增加观测集 $\mathcal{O}$ 与观测核 $O(o \mid s', a)$。

POMDP 的处理办法是把“对状态的信念”当作新状态。设 b_t 是 s_t 上的分布，则

$$b_{t+1}(s') \;\propto\; O(o_{t+1} \mid s', a_t) \sum_{s} P(s' \mid s, a_t)\, b_t(s), \tag{2.24}$$

归一化常数使 b_{t+1} 成为概率分布。以信念为状态、(2.24) 为转移的决策过程是一个**连续状态**的马尔可夫决策过程，理论上完全适用本章的框架，但它的状态空间是单纯形，不再是有限集，因此表 2-2 中依赖有限性的结论（矩阵闭式解、精确 **max**）都不再直接成立。工程上更常见的做法是放弃显式信念，改用循环网络把历史压成隐状态（第 6 章、第 7 章），代价是理论保证从 [精确] 降为 [经验规律]。

2.5.2 状态设计的三个陷阱

状态表示决定马尔可夫性是否成立，而马尔可夫性决定“用当前状态做决策是否足够”。三个陷阱反复出现。

第一是**别名**（aliasing）：两个实质不同的情形被映射到同一个状态向量，于是任何确定性策略在这两种情形下只能做同一件事。传感器量化、降采样、把连续量离散成粗格子都会引入别名。第二是**非平稳特征**：把时间、计数器或回合内序号放进状态，会让“同一个状态”在不同时刻意味着不同的事，价值函数随之依赖时间，平稳策略假设失效。第三是**未来信息泄漏**：把决策之后才能知道的信息编码进状态，会得到虚高的离线评估，线上部署立刻失效——这是第 8 章离线评估与第 10 章奖励模型中最隐蔽的错误来源。

2.5.3 奖励设计与势函数不变性

奖励是任务目标的唯一载体，改动奖励等于改动问题。一个常见的做法是在原奖励上叠加“引导项”以加速学习。问题在于引导项会不会改变最优策略。下面的结论给出一个安全的构造。

SUMMARY / 总结

定理 2.6（势函数奖励塑形 [精确]）

设折扣因子 $\gamma < 1$、$\Phi : \mathcal{S} \to \mathbb{R}$ 有界，定义塑形奖励

$$\tilde{r}(s, a, s') = r(s, a, s') + \gamma \Phi(s') - \Phi(s). \tag{2.25}$$

则对任意策略 π，塑形后的价值满足 $\tilde{V}^{\pi}(s) = V^{\pi}(s) - \Phi(s)$，因此两者的最优策略集合相同。$\gamma = 1$ 的终止型问题里望远镜和的尾项 $\gamma^{T}\Phi(s_T) = \Phi(s_T)$ 一般不消失，结论要另行处理。

证明. 沿轨迹望远镜求和：

$$\sum_{k \geq 0} \gamma^{k} \left[\gamma \Phi(s_{k+1}) - \Phi(s_k) \right] = \left(\gamma \Phi(s_1) - \Phi(s_0) \right) + \left(\gamma^{2} \Phi(s_2) - \gamma \Phi(s_1) \right) + \cdots = -\Phi(s_0),$$

其中相邻两项的 $\gamma\Phi$ 逐项相消，末项在 $\gamma < 1$ 且 Φ 有界时趋于零。故塑形回报等于原回报减去 $\Phi(s_0)$，与动作无关，最优策略不变。 □

定理 2.6 的实用价值是：任何形如“$\gamma\Phi(s') - \Phi(s)$”的引导项都不会改变最优解，因此可以放心用来加速。反之，不满足该形式的引导项（例如固定的步数惩罚、按距离线性递减的奖励）会改变最优策略，实践中大量“奖励塑形导致学出奇怪行为”的案例都源于此。

2.5.4 从模型到数据：本章结论的适用边界

本章的所有推导都假定 P 与 r 已知。强化学习真正面对的是“只能通过交互获得样本”的设定，此时式 (2.11) 不能直接使用。第 3 章给出两条替代路线：动态规划在已知模型时迭代式 (2.11)，蒙特卡洛与时序差分在未知模型时用采样估计式 (2.11) 的两端。两条路线都以本章的方程为目标，区别只在于“怎么得到方程右边的数”。

因此，本章对各项结论的适用条件作出明确限定。后续章节里出现的每一个算法，本质上都是某个本章方程的近似求解方案；当算法表现异常时，回到本章检查“它到底在解哪个方程、那个方程的前提是否成立”，通常比调参更有效。

SUMMARY / 总结

本章小结

这一章只做一件事：把“动作会改变下一刻的局面”写成数学。状态是历史的定长摘要，马尔可夫性要求条件独立而非信息完备——这条要求一旦不成立，问题就升级为部分可观测，最优策略可能需要记忆。在这个设定下，价值函数满足贝尔曼期望方程 (2.9)；有限状态下它等价于线性方程组 (2.11)，闭式解 (2.12) 只是一个诺伊曼级数的和，成立的前提是 $\gamma < 1$。把方程右端看成一个算子，压缩性（命题 2.1）立刻给出不动点唯一与几何收敛 (2.17)；把求期望换成逐点取最大，得到最优方程 (2.18) 与确定性平稳最优策略（定理 2.2）。残差界 (2.21) 把“离最优有多远”化成“算子残差有多大”，但它只对表格、上确界范数与最优算子成立——残差、MSBE、MSPBE 是三个不同的量，训练损失小推不出价值准。策略改进的出发点是价值差恒等式 (2.22)：一步优势与后继价值差必须同时写出，非劣来自两项的非负，严格性来自第一项。

这六条结论共享四个前提：状态有限、模型已知、$\gamma < 1$、价值用表格存。第 3 章换掉第二条，用采样替掉模型，于是有了蒙特卡洛与时序差分；第 4 章换掉第四条，投影破坏压缩性，精确的等式退化成带常数的误差界。第 2.5 节的 POMDP、状态设计与奖励塑形，则是这四条前提在工程里最先被违反的地方。

关键公式

这六条是全章主干：期望方程、矩阵闭式解、最优方程、残差界、价值差恒等式，以及把价值写成占用测度的那个恒等式。条件写在定理里，这里只留骨架。

式 (2.9)：

$$V^{\pi}(s) = \sum_{a} \pi(a \mid s) \Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^{\pi}(s') \Big]$$

式 (2.11) 与式 (2.12)：

$$V^{\pi} = r^{\pi} + \gamma P^{\pi} V^{\pi}, \qquad V^{\pi} = (I - \gamma P^{\pi})^{-1} r^{\pi}$$

式 (2.18)：

$$V^*(s) = \max_a \Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^*(s') \Big]$$

式 (2.21)：

$$\|V - V^*\|_\infty \le \frac{\|V - T^* V\|_\infty}{1-\gamma}$$

式 (2.22)：

$$V^{\pi'}(s) - V^{\pi}(s) = \mathbb{E}_{a\sim\pi'}\big[A^{\pi}(s,a)\big] + \gamma \mathbb{E}_{s'\sim P^{\pi'}}\big[V^{\pi'}(s') - V^{\pi}(s')\big]$$

式 (2.8)：

$$d_\gamma^\pi(s) = (1-\gamma)\sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s \mid \pi)$$

习题

1. 证明式 (2.7)：对任意策略 π 与状态 s，$\mathbb{E}_{a\sim\pi}[A^\pi(s,a)] = 0$。并说明这条恒等式在策略梯度中“减去基线不引入偏差”的作用。

2. 设 $\mathcal{S} = \{1, 2\}$，$\mathcal{A} = \{a, b\}$，转移与奖励给定。写出 P^π 与 r^π 的显式矩阵，用式 (2.12) 求 V^π，再用值迭代（反复作用 T^π）求近似解，比较两者误差随迭代轮数的衰减是否与式 (2.17) 一致。也可用 2.3.1 节的 A, B 例子，截成五步求回报并与 1.82 比较。

3. 对 $\gamma = 0.9, 0.99, 0.999$ 分别计算残差界 (2.21) 在 $\delta = 0.1$ 时的数值，并说明为什么“γ 越接近 1，价值评估越难”这一经验说法在数学上是有根据的。

4. 构造一个反例，说明式 (2.21) 在把 $\|\cdot\|_\infty$ 换成加权二范数 $\|\cdot\|_D$ 后不成立。提示：考察投影算子 Π_D 与 T^* 的交换性。

5. 用式 (2.22) 说明定理 2.5 的“全状态非劣”为什么不能省。构造两状态 MDP，使 π' 在 s_0 上改进、同时在 s_1 上退化（一步优势为负），从而 $V^{\pi'}(s_0) > V^{\pi}(s_0)$ 而 $V^{\pi'}(s_1) < V^{\pi}(s_1)$（提示：$s_0$ 的改进给出 $+10$ 的即时奖励，s_1 的退化每步 -0.5，两者都自环或直通 s_1，取 $\gamma = 0.9$，可算得价值差 $(+5.5, -5)$）。再说明相反的情形：若 π' 在其余状态与 π 完全相同，则那些状态的一步优势恰为 0，定理给出全局非劣，不会出现“别处变差”。

6. 验证定理 2.6：对

$\Phi(s) = -\|s - s_{\text{goal}}\|_1$ 的势函数塑形，证明塑形前后的最优策略相同，并解释为什么“每步固定惩罚”形式的塑形不满足该结论。

7. 说明为什么在截断（而非终止）的回合末尾直接切断自举会引入偏差，并给出一种正确的掩码写法。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 3 章给出马尔可夫决策过程与贝尔曼方程的教材式推导，其记号与本书基本一致，可作为对照阅读；该章末尾关于“状态聚合”的一节是状态设计问题最好的入门材料。
- Puterman《Markov Decision Processes》是有限与无限时域马尔可夫决策过程的经典参考，平均奖励目标、非平稳策略与灵敏度分析的标准处理都在其中；本书第 9 章的平均奖励部分以此为依据。
- Ng、Harada 与 Russell 关于奖励塑形的工作（Policy invariance under reward transformations, ICML 1999）给出了定理 2.6 的完整形式，并讨论了“潜在函数必须由专家给出”这一实践限制。
- Stanford CS234 的马尔可夫决策过程与贝尔曼方程讲义，以及 CS285 第 1–2 讲，提供了从控制论视角出发的另一种讲法，可与本章互补。
- 若想看清“压缩映射—不动点—收敛速度”这条线索在函数逼近下如何断裂，可先读第 4 章的投影贝尔曼误差一节，再回读本章命题 2.1 的证明，注意证明中哪一步用到了“表格”这一前提。

第 3 章　动态规划、蒙特卡洛与时序差分

第2章给出了贝尔曼方程，本章讨论相应价值函数的数值求解。给定策略，贝尔曼期望方程是一个线性系统，闭式解 (2.12) 要求完整知道 $\boldsymbol{P}$、$\boldsymbol{r}$，再做一次求逆。10^6 个状态时，仅存下稠密的 $\boldsymbol{P}^{\boldsymbol{\pi}}$ 就要 10^{12} 个双精度数，约 8 TB；求逆是 10^{18} 次浮点运算量级。本章研究在环境模型未知或直接求解成本较高时估计价值函数的方法。

本章以第 2 章的价值函数 $\boldsymbol{V},\boldsymbol{Q}$、贝尔曼方程及折扣回报为先修知识。全章围绕策略评估与策略改进展开：给定策略后估计其价值，再据此改进策略。另一个贯穿主题是偏差、方差与自举：动态规划利用已知模型计算期望，蒙特卡洛使用完整回报，时序差分则将下一状态的价值估计接入更新目标。

本章的结论仍限定在**表格设定**：状态与动作有限，每个状态-动作对有一个独立估计值，不共享参数。标 [精确] 的结论只在这个设定下成立；涉及采样收敛的结论标 [渐近]，意思是样本量趋于无穷且步长满足一定条件，而不是“跑起来就会收敛”。

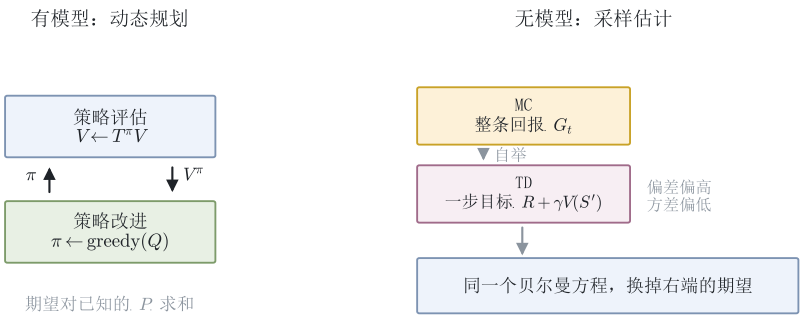


图 3-1 两条求解路线。左侧有模型时，动态规划在“评估”与“改进”之间循环，期望对已知的转移求和；右侧无模型时，采样估计用观测到的回报替代期望，蒙特卡洛用整条回报，时序差分用一步目标，后者把自身的估计放进了目标。

3.1 动态规划：有模型时的迭代求解

模型已知，式 (2.9) 的右端就能直接算出来，求解退化为对价值表的反复扫描。当环境模型未知时，动态规划的期望备份难以直接计算，需要使用采样方法估计。

3.1.1 策略评估：把线性方程组变成迭代

SUMMARY / 总结

给定策略 π，求 V^π 是一个线性方程组问题。闭式解 (2.12) 在数学上干净，在计算上却几乎不可用：求逆的复杂度是 $O(|\mathcal{S}|^3)$，而状态数动辄以百万计。10^6 个状态时，存下稠密的 P^π 就要 10^{12} 个双精度数（约 8 TB），求逆是 10^{18} 次浮点运算量级。

迭代法把同一个方程改写成不动点迭代：

$$V_{k+1}(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a)\big[r(s, a, s') + \gamma V_k(s')\big]. \tag{3.1}$$

一次扫描对每个状态做一次**备份**：用当前价值表算出右端，写回去。右端是贝尔曼期望算子 T^π 作用在 V_k 上，于是 $V_{k+1} = T^\pi V_k$。命题 2.1 已证明 T^π 在 $\gamma < 1$ 时压缩，式 (2.17) 给出几何衰减 $\|V_k - V^\pi\|_\infty \le \gamma^k \|V_0 - V^\pi\|_\infty$。取 $|r| \le 1$、$V_0 = 0$，初误差不超过 $1/(1-\gamma)$；要从 10 量级降到 10^{-3}，$\gamma = 0.9$ 约需 100 次扫描，$\gamma = 0.99$ 约需 1000 次。折扣因子在此体现出数值代价：它既保证收敛，也决定收敛多慢。

迭代法的真正优势在于只碰真实存在的转移。若每个状态平均有 d 个可达后继，一次扫描的工作量是 $O(|\mathcal{S}||\mathcal{A}|d)$；$10^6$ 个状态、4 个动作、平均 3 个后继时，一次扫描约 1.2×10^7 次运算，不到一秒，而闭式解需要的 10^{18} 次运算不可完成。**利用稀疏性**是动态规划胜过闭式解的全部理由，也是它后来被函数逼近取代时最先丢掉的性质。

3.1.2 策略迭代：评估与改进交替

有了评估，控制就是两步交替：把当前策略评估到足够准，再在每个状态上换成对当前价值最贪心的动作：

$$\pi'(s) = \arg\max_a \sum_{s'} P(s' \mid s, a)\big[r(s, a, s') + \gamma V^\pi(s')\big]. \tag{3.2}$$

在讨论正确性之前，先记一下成本。一轮策略迭代等于 k 次评估扫描加 1 次改进扫描，每次扫描 $O(|\mathcal{S}||\mathcal{A}|d)$，总成本约为 $(k+1)|\mathcal{S}||\mathcal{A}|d$。这里的 k 由评估阈值与折扣共同决定：把误差压到 θ 所需的扫描次数约为 $\log(\theta / \|V_0 - V^\pi\|_\infty) / \log\gamma$（式 (2.17)）。$\gamma$ 越接近 1，k 越大，单轮成本越高。

定理 2.5 保证 π' 在每个状态上不劣于 π，且只要有一个状态的动作改变，该状态的价值就严格上升。有限状态下确定性策略只有 $|\mathcal{A}|^{|\mathcal{S}|}$ 个，严格单调的改进序列必然在有限步内停在“改进后策略不变”处，那里每个状态都满足贝尔曼最优方程。这条论证标 [精确]，代价是“评估到足够准”在实现上只能是近似。算法 3-1 给出完整循环。

SUMMARY / 总结

算法 3-1 策略迭代（表格型）

```
输入：P(s'|s,a)、r(s,a,s')、折扣 γ、评估阈值 θ
V(s) ← 0，π(s) ← 任意（如均匀随机）
循环（外层）：
  重复（评估）：Δ ← 0
    对每个 s：v ← Σ_a π(a|s) Σ_s' P(s'|s,a)[r + γ V(s')]
    Δ ← max(Δ, |v - V(s)|)；V(s) ← v
  直到 Δ < θ
  对每个 s：π(s) ← argmax_a Σ_s' P(s'|s,a)[r + γ V(s')]
直到 π 不再变化；返回 π, V
```

成本还有第二个来源：评估可能要用几十次扫描，改进只需一次。于是出现一个自然的旋钮——评估不必做到收敛，做 m 次扫描就够了。下一节讨论不同评估深度下的策略迭代与值迭代。

3.1.3 值迭代与截断评估

取 $m=1$，即评估一次就改进一次，且改进后的策略立刻用于下一步，得到值迭代：

$$V_{k+1}(s)=\max_a \sum_{s'} P(s'\mid s,a)\big[r(s,a,s')+\gamma V_k(s')\big], \tag{3.3}$$

即 $V_{k+1}=T^{*}V_k$。T^{*} 同样 γ-压缩，故 $V_k\to V^{*}$，式 (2.17) 的界照旧成立。值迭代、策略迭代与截断策略评估均可从广义策略迭代框架理解，但其更新算子和实现流程应分别定义。中间情形是截断评估：

$$V_{k+1}=(T^{\pi_k})^{m}V_k,\qquad \pi_{k+1}=\mathrm{greedy}(V_{k+1}), \tag{3.4}$$

$m=1$ 是值迭代，$m\to\infty$ 是策略迭代。图 3-2 在 40 状态、4 动作的随机 MDP 上实测了这三种设置（$\gamma=0.9$，初始策略相同），左图按轮数计、右图按累计备份数计。

SUMMARY / 总结

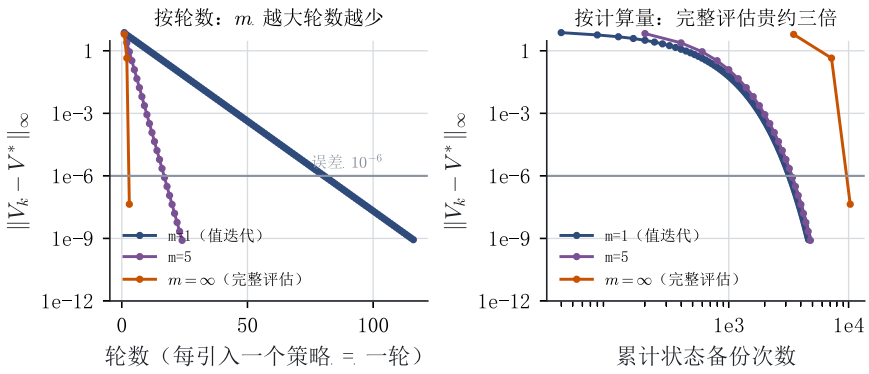


图 3-2 同一个广义策略迭代家族在三种评估深度下的收敛。40 状态随机 MDP，γ =0.9，seed=7，初始策略取 seed=3 的随机策略；左图为误差随轮数的变化，右图为同一误差随累计状态备份次数的变化，两图纵轴均为对数刻度，虚线为 10^{-6} 参考线。

以 $\|V_k - V^*\|_\infty \le 10^{-6}$ 为达标线：$m=1$ 需要 81 轮、3240 次备份；$m=5$ 需要 17 轮、3400 次备份；评估到收敛只需 3 轮，却要 10320 次备份。轮数被压掉 27 倍，备份数几乎没变，完整评估甚至贵了 3.2 倍。原因在于策略改进只关心“哪个动作的右端更大”这个**排序**，把价值算到 10^{-6} 远超排序所需，多出来的精度全部被丢掉。所以“轮数少”与“计算量少”是两件事：教材里常见的“策略迭代更快”只在轮数这个坐标上成立，换到备份数坐标就未必——这个例子里它反过来更贵。m 能改变两者的分配，不能同时压低两者。

3.1.4 原地更新与异步动态规划

式 (3.1) 的写法暗示一次扫描使用上一轮的整张表（同步更新）。实现时通常按状态顺序逐个更新，后面的状态立刻用上前面的新值（原地更新，Gauss-Seidel 风格）。这不改变不动点，却改变收敛速度：同一个 40 状态 MDP 上，同步值迭代要 149 轮才降到 10^{-6}，原地更新只要 81 轮——信息顺着顺序在一轮扫描里就能走完一整条链。

推到底就是**异步动态规划**：不要求每轮更新所有状态，只挑一部分更新，且每次都用当前最新的值。收敛条件明确：只要每个状态被无限次更新且 $\gamma<1$，价值表就收敛到 V^π 或 V^* [渐近]。这条结论把“更新顺序”从正确性条件里解脱出来：可以任意顺序扫，可以只用一部分状态，也可以由误差驱动（优先更新残差最大的状态）。第 7 章把这类做法与“从数据学模型”结合，得到 Dyna 一类的规划方法。

SUMMARY / 总结

3.2 蒙特卡洛：把回报当作样本

模型未知时，式 (3.1) 右端的求和无法计算，能拿到的是轨迹。既然价值是回报的期望，最直接的做法就是用观测到的回报当作期望的样本——这就是蒙特卡洛方法：目标就是真实回报，只是它本身带随机性。

3.2.1 首次访问与每次访问

蒙特卡洛预测的核心更新只比式 (3.1) 少一个求和：

$$V(S_t) \leftarrow V(S_t) + \alpha\big[G_t - V(S_t)\big], \tag{3.5}$$

其中 $G_t = \sum_{k\geq 0} \gamma^k R_{t+k+1}$ 是实际观测到的回报。**首次访问**只在状态于本回合第一次出现时更新，**每次访问**在每个时间步都更新。无偏的理由不在“独立”上，而在回报的构造：G_t 沿 π 走完一条回合累加而成，期望就是 $v^\pi(S_t)$，

$$\mathbb{E}\big[G_t \mid S_t = s\big] = v^\pi(s) \tag{3.6}$$

[精确]，期望同时对动作与转移取。独立性用在别处：跨回合样本独立同分布，才使式 (3.7) 的 σ^2/N 与大数定律可用。**每次访问**的单个样本同样无偏，每个 G_t 的期望仍是 $v^\pi(s)$；多出的偏差来自 N_s 随机且与回报相关的比值结构，量级很小；两类估计在样本量趋于无穷时都收敛 [渐近]。若用 N 条独立回合的平均值作估计，误差按

$$\mathrm{Var}\Big(\frac{1}{N}\sum_{i=1}^{N} G^{(i)}\Big) = \frac{\sigma^2}{N} \tag{3.7}$$

衰减，σ^2 是单条回报的方差。$1/\sqrt{N}$ 与动态规划的几何速度完全不同：样本量翻倍只把误差降到 0.71 倍。

> **无偏不等于收敛**
>
> 式 (3.6) 只说明“能采到样本时单个样本的期望等于真值”：它不保证采得到（某状态几乎不被访问时估计就停在初值），不保证有限样本下误差小（方差可任意大），也不保证式 (3.5) 收敛（见 3.2.2 的步长条件）。把“MC 无偏”读成“MC 收敛”，是本节最常见的错误。

3.2.2 增量均值与随机逼近

若一条回合只访问一次状态，取 $\alpha = 1/N$ 的式 (3.5) 恰好等于算术平

SUMMARY / 总结

均，写成递推就是增量均值：

$$V_{n+1} = V_n + \frac{1}{n}\big(G_n - V_n\big), \qquad V_n = \frac{1}{n}\sum_{i=1}^{n} G_i. \tag{3.8}$$

形式值得单独记：**估计 = 旧值 + 步长 × 误差**。把 $1/n$ 换成一般步长，就得到随机逼近的标准形式

$$\theta_{k+1} = \theta_k + \alpha_k\big(Y_k - \theta_k\big), \tag{3.9}$$

其中 Y_k 是 θ 的无偏样本。Robbins–Monro 条件给出几乎必然收敛的充分条件：$\sum_k \alpha_k = \infty$ 且 $\sum_k \alpha_k^2 < \infty$ [渐近]。第一条保证步长不会小到走不完剩下的距离，第二条保证噪声累积方差有限，$1/n$ 恰好同时满足两者。常数步长违反第二条，只收敛到真值附近宽约 $O(\alpha)$ 的邻域——这不是缺陷：非平稳时“追上变化”比“收敛到一点”更重要。

式 (3.8) 与式 (3.9) 是本章的枢纽：后面所有算法的更新式都是这个形状，差别只在 Y_k 取什么。

3.2.3 覆盖：探索起点与 ε-软策略

控制要用 $Q(s,a)$ 而不是 $V(s)$：没有模型时，用 V 做贪心改进需要知道动作把状态带到哪里，而这正是缺失的信息；于是只有被访问过的动作对才有可靠估计。

最直接的办法是**探索起点**：每回合从随机选定的状态-动作对出发。这在数学上干净，在工程上几乎不可行。可行的是让行为策略自带探索，要求它在每个状态上对每个动作至少保留 $\varepsilon/|\mathcal{A}|$ 的概率：

$$\pi(a \mid s) \geq \frac{\varepsilon}{|\mathcal{A}|} \quad \text{对所有 } (s,a). \tag{3.10}$$

称满足式 (3.10) 的策略为 **ε-软策略**：它把覆盖变成策略自身的性质，代价是最终学到的只是最优的 ε-软策略 π^*_ε，而它的价值损失满足

$$V^*(s) - V^{\pi^*_\varepsilon}(s) \;\leq\; \frac{\varepsilon\,(R_{\max} - R_{\min})}{1-\gamma}$$

[精确]（每步以不超过 ε 的概率偏离贪心、偏差按 $1-\varepsilon$ 折扣累积，级数求和即得）：损失对 ε 线性，对 γ 则放大了 $1/(1-\gamma)$ 倍——折扣越接近 1，同样的探索率要付出越大的价值代价。把这一项简写成 $O(\varepsilon)$ 会丢掉折扣因子，在 $\gamma \to 1$ 时严重低估损失。

SUMMARY / 总结

3.2.4 蒙特卡洛控制

装配起来就是蒙特卡洛控制：每回合结束后用式 (3.5) 更新访问过的 Q，再用 ε-贪心改进策略：

$$\pi(a \mid s) = \frac{\varepsilon}{|\mathcal{A}|} + (1-\varepsilon)\,\mathbf{1}\{a = \arg\max_{a'} Q(s,a')\}, \tag{3.11}$$

收敛要求每个状态-动作对被访问无限次、步长满足式 (3.9)、奖励有界[渐近]。GLIE（“在极限中贪心”）常被当作万能充分条件，这是误读：它只是让 ε 衰减到零同时保持覆盖的一类策略，关键始终是覆盖与步长（3.5.2 节详述）。

实现中涉及两个影响估计稳定性的细节。第一，**更新顺序无关**：蒙特卡洛控制只要求“回合结束后把访问过的每个 (s,a) 按首次或每次访问的规则各更新一次”，先更新谁不影响结果；这与后面 TD 的在线更新形成对照，那里的顺序会改变数据分布。第二，**探索必须由策略保证，而不能指望初值**：若用确定性贪心加乐观初值，只能撑过前几个回合，一旦所有动作都试过一次、估计已经接近真值，探索就停了；这正是 3.2.3 节把 ε-软策略作为标准配置的原因。

SUMMARY / 总结

3.3 时序差分：用估计更新估计

蒙特卡洛等到回合结束才更新，在长回合任务上代价很大。时序差分把目标换成一个可以立即算出的量：一步奖励加上对后继状态的当前估计。这个替换引入偏差，换来方差的大幅下降——本章余下内容基本都在处理这笔交易的后果。

3.3.1 TD(0) 与 TD 误差

TD(0) 的更新是

$$V(S_t) \leftarrow V(S_t) + \alpha\big[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)\big], \tag{3.12}$$

方括号里的量称为**时序差分误差**：

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t). \tag{3.13}$$

时序差分误差 δ_t 同时承担两项作用：它是一步优势的样本估计；对后继状态取条件期望后，$\mathbb{E}[\delta_t \mid S_t = s] = (T^\pi V)(s) - V(s)$，对应策略评估的期望更新方向。因此，第 5 章的演员—评论家方法可以用 δ_t 驱动策略与价值函数的更新。

3.3.2 偏差与方差：自举换来了什么

把式 (3.12) 的目标取期望，得到

$$\mathbb{E}_\pi\big[R_{t+1} + \gamma V(S_{t+1}) \,\big|\, S_t = s\big] = (T^\pi V)(s). \tag{3.14}$$

式 (3.14) 说明 TD 目标**不是** $v^\pi(s)$ 的无偏样本：只有 $V = v^\pi$ 时 $(T^\pi V)(s)$ 才等于 $v^\pi(s)$，在此之前偏差恰为 $(T^\pi V)(s) - v^\pi(s)$，大小与 V 离 v^π 的距离同阶；把这份偏差沿时间往前传时每步被 γ 乘一次（$T^\pi V - v^\pi = \gamma P^\pi (V - v^\pi)$），所以它是**收缩**而不是放大。定理 2.3 的 $1/(1-\gamma)$ 放大讲的是“残差大小与离 v^π 多远”的关系，对象不同，不能混。蒙特卡洛目标 G_t 没有这个问题，它是无偏的。

代价换来了方差。整条回报 G_t 含 $T - t$ 个随机奖励与随机状态，方差随视野长度增长；一步目标只含一个随机奖励与一个随机状态，$\gamma < 1$ 还把它压缩了一次。图 3-3 在 19 状态随机游走上实测了两种估计的差别。

SUMMARY / 总结

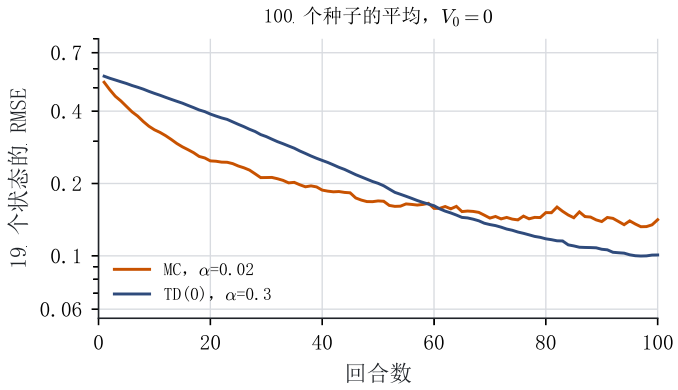


图 3-3 蒙特卡洛与时序差分的误差曲线。19 状态随机游走，γ =1，V0=0，100 个随机种子各跑 100 回合，纵轴为 19 个状态的 RMSE（对数刻度），两条曲线各取使最终误差最小的步长；100 回合后 MC 的 RMSE 为 0.141、种子间标准差 0.057，TD(0) 为 0.101、标准差 0.020。

这张图不能读成“TD 处处更好”。前 60 个回合里蒙特卡洛明显更好（第 10 回合时 MC 的 RMSE 为 0.335，TD(0) 为 0.474）：此时价值表还远离真值，自举目标建立在错误估计上，偏差占主导。约第 60 回合两条曲线交叉，此后 TD 持续下降，而 MC 在 0.14 附近抖动——它的方差没有随样本积累消失，只按 $1/\sqrt{N}$ 缩小。这张图真正显示的是**偏差在早期主导、方差在后期主导**。TD 的种子间标准差只有 MC 的 0.35 倍，与“自举降低方差”一致；它早期更差，与“自举引入偏差”一致。

> **自举不是'无偏的低方差估计'**
>
> 自举以价值估计替代未知的真实后续回报，通常会引入偏差并降低目标方差（式 (3.14)）。TD 与蒙特卡洛方法的相对表现取决于数据分布、估计视野、步长及偏差—方差权衡。

3.3.3 TD 的不动点

把式 (3.12) 的更新写成期望形式（对后继状态取期望，保留当前状态）：

$$V(s) \leftarrow V(s) + \alpha\big[(T^{\pi}V)(s) - V(s)\big]. \tag{3.15}$$

式 (3.15) 说明 TD(0) 的**平均**更新就是一次策略评估备份，因此不动点满足 $V = T^{\pi}V$，即 $V = V^{\pi}$——TD(0) 解的是**给定策略的贝尔曼方程**，不是最优方程。这一点决定了控制问题的算法结构：单靠 TD(0) 只能评估，要找最优策略必须与策略改进交替，回到 3.1.2 的广义策略迭代框架。

蒙特卡洛的不动点也是

SUMMARY / 总结

v^π（样本量趋于无穷时），区别在到达路径：TD 每步把估计拉向 $T^\pi V$，MC 每步把估计拉向一个无偏样本；TD 方法常具有较低方差，但具体收敛速度取决于步长、动力学和函数表示；蒙特卡洛估计使用完整回报。偏差要分两处说：**自举偏差**来自用自身估计当目标，量级 $O(\gamma\|V - v^\pi\|)$，与步长无关；**步长残余偏差**只在常数步长下出现，量级 $O(\alpha)$。用 Robbins–Monro 步长（$\sum_t \alpha_t = \infty$、$\sum_t \alpha_t^2 < \infty$）时 TD 与 MC 一样以概率 1 收敛到 v^π，所以“TD 有偏”这个说法只对常数步长成立（[精确]，见定理 3.1 的条件）。

3.3.4 batch TD 与最大似然

固定一个数据集后反复扫描。此时式 (3.12) 的 S_{t+1} 与 R_{t+1} 都来自数据集。只要每个状态-动作对在数据中出现过，反复扫描的 TD(0) 收敛到由数据**估计出的模型**下的精确解

$$\hat{V} = (I - \gamma \hat{P})^{-1} \hat{R}, \tag{3.16}$$

其中 $\hat{P}, \hat{R}$ 是从数据统计得到的经验模型 [精确]。这个结果称为**确定性等价**：batch TD 的解等于“先估模型、再用闭式解求值”的结果。

同样的数据集上，batch 蒙特卡洛最小化训练集上的平方误差 $\sum_t (G_t - V(S_t))^2$，它拟合已见回报，而不是任何一个模型的精确解。两者差别在数据充分时消失，在数据不充分时很关键：确定性等价在估计模型下精确，最小二乘解只是对已见样本的平均。

表 3-1 把前四节的四种估计放在一起对比。

表 3-1 四种价值估计的对比。偏差与方差两列只在“估计 v^π”这一目标下可比；动态规划一行没有方差，因为它不采样，但它的“精确”依赖模型正确。TD 一行的偏差是**两种不同来源之和**：自举偏差（换步长不会消失）与常数步长的残余偏差（换成衰减步长就消失），复习时不要把两者合并成一个数。

方法	更新目标	偏差	方差	是否需要模型
动态规划	$(T^\pi V)(s)$	无（除截断误差）	无	需要
首次访问 MC	整条回报 G_t	无	大，$\propto \sigma^2$	不需要
每次访问 MC	整条回报 G_t	小（样本相关）	大	不需要
TD(0)	$R_{t+1} + \gamma V(S_{t+1})$	自举偏差 $O(\gamma\|V - v^\pi\|)$；常数步长另有 $O(\alpha)$ 残余	小，单步	不需要

表 3-1 的最后两行是本章的主线：从 MC 到 TD，方差下降、偏差上

升；从 TD 到 DP，偏差消失，但模型重新变成必需品。三者的排列是“用多少真实样本、用多少自身估计”这一比例的三种取值。

读这张表时还要避免两个常见误读。其一，“TD 方差小”的条件是**同一状态被反复访问**：它把整条回报的随机性换成了单步随机性，代价是每步都要用当前估计，而估计本身带着偏差；若各状态只出现一次，单步方差未必更小。其二，“DP 无偏差”的前提是**模型正确**。模型错时 DP 会稳定地收敛到一个错的答案——误差不会表现为抖动，因此也无法靠多看几条轨迹发现；这是把 DP 用到近似模型（第 7 章）时最危险的一点。

SUMMARY / 总结

3.4 n 步回报与资格迹

TD(0) 与 MC 各取一个端点：只往前看一步，或一直看到回合结束。中间是一整条连续的选择。n 步回报给出离散的中间点，资格迹把整条谱压缩成一次更新。

3.4.1 n 步回报

把 TD 的目标往前推 n 步：

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n V(S_{t+n}), \tag{3.17}$$

$V(S_{t+n})$ 是剩下尾巴的估计。$n=1$ 退化为 TD(0) 的目标，n 超过回合长度时退化为 MC 回报。中间取值的偏差与方差介于两端，但两者地位不同。偏差一侧是定理：用到的真实奖励越多、自举成分越少，偏差按 γ^n 收缩 [精确]（与式 (2.21) 同一机制）。方差一侧只是趋势：方差**通常**随 n 增大，实际取决于奖励与后继价值估计的相关性 [经验规律]——若二者负相关，$\mathrm{Var}(G^{(n)})$ 可以随 n 先降后升，所以“方差随视野单调增”不能当定理用。若回合在第 $t+n$ 步之前**终止**，就令 n 截短到终止处，尾部不再自举；而时间上限造成的**截断**处应当继续自举。两者的处理恰好相反，实现时必须用两个独立的布尔量分别记录。

3.4.2 λ-回报

取几何权重 $(1-\lambda)\lambda^{n-1}$ 把各 n 步回报混合：

$$G_t^{\lambda} = (1-\lambda)\sum_{n\geq 1} \lambda^{n-1} G_t^{(n)}, \tag{3.18}$$

$\lambda \in [0,1)$。权重和恒为 1：$\sum_{n\geq 1}(1-\lambda)\lambda^{n-1}=1$，这是下面每一条判断的判据。$\lambda=0$ 时只剩 $n=1$ 的项；$\lambda=1$ 是公式的**端点**而不是它的取值——直接代入得主和为零，只剩残余项 $\lambda^{T-t-1}G_t \to G_t$，于是退化为完整回报，这个退化必须单独讨论。$\lambda$ **增大**的效果是权重 λ^{n-1} 衰减变慢，长 n 步回报的相对权重变大，而不是“各项权重趋于相等”：以 $\lambda=0.5$ 与 0.9 对比，前者 $w_1=0.5,\ w_5=0.031$，后者 $w_1=0.1,\ w_5=0.066$——短项权重下降，长项涨到前者的 2.1 倍，分布变平缓；又因为权重和恒为 1，λ 增大只能把质量从短项移到长项，不可能让各项趋于相等。后者 $w_{12}=0.031$，恰好与前者第 5 项相当。

SUMMARY / 总结

式 (3.18) 有一个等价递推，把整条谱变成一次更新：

$$G_t^{\lambda} = R_{t+1} + \gamma\big[(1-\lambda)V(S_{t+1}) + \lambda G_{t+1}^{\lambda}\big]. \tag{3.19}$$

图 3-4 在同一条 19 状态随机游走上扫描了 λ，三条曲线对应三个步长。

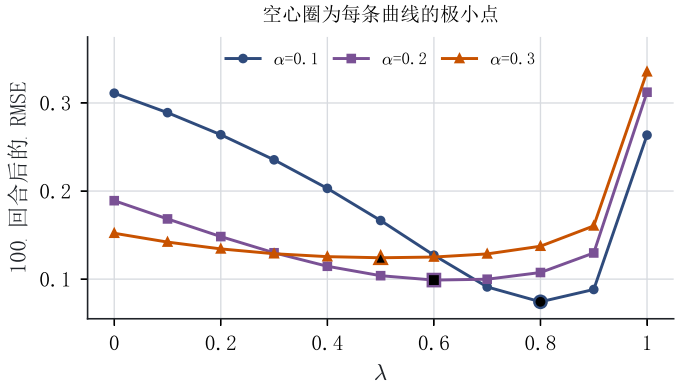


图 3-4 误差随 λ 的变化。19 状态随机游走，γ=1，V0=0，100 个种子各跑 100 回合，离线 λ-回报；三条曲线的极小点用空心标记标出：α=0.1 时在 λ=0.8（0.074），α=0.2 时在 λ=0.6（0.099），α=0.3 时在 λ=0.5（0.124）。

三条曲线都是 U 形，极小点却随步长移动：$\alpha = 0.1$ 时 $\lambda = 0$ 与 $\lambda = 1$ 两端分别是 0.311 与 0.264，中间 $\lambda = 0.8$ 处降到 0.074；$\alpha = 0.3$ 时两端是 0.152 与 0.335，极小点移到 $\lambda = 0.5$。这说明**不存在普遍最优的 λ**（[经验规律]：这是实测规律，不是定理），它必须与步长一起调：步长大时靠较小的 λ 抑制方差，步长小时可以靠较大的 λ 减小偏差。两端更差的理由也不一样——$\lambda = 0$ 端受偏差拖累，$\lambda = 1$ 端受方差拖累，这正是 3.3.2 节那笔交易在不同 λ 上的重演。

3.4.3 资格迹：前向与后向

式 (3.18) 要向未来看很多步，在线场景必须等回合结束。资格迹给出不需要等待的实现：给每个状态配一个**迹**，记录它最近被访问的程度，更新时按迹分配误差。累积型迹是

$$E_t(s) = \gamma\lambda E_{t-1}(s) + \mathbf{1}\{S_t = s\}, \tag{3.20}$$

替换型迹在被访问时直接把迹置为 1 而不是累加：

$$E_t(s) = \begin{cases} 1, & S_t = s, \\ \gamma\lambda E_{t-1}(s), & \text{其他}. \end{cases} \tag{3.21}$$

有了迹，TD(λ) 的更新对所有状态一次完成：

SUMMARY / 总结

$$V(s) \leftarrow V(s) + \alpha\delta_t E_t(s) \quad \text{对所有 } s, \tag{3.22}$$

其中 δ_t 仍是式 (3.13)。离线情形下（回合结束后统一更新），后向视角的式 (3.22) 与前向视角的式 (3.18) 给出**完全相同**的更新总量 [精确]。在线情形下两者只差 $O(\alpha)$，而且这个差不会被朴素实现消掉：要逐时刻精确复现式 (3.18) 的权重序列，需要用真在线 TD(λ) 的迹修正形式（Sutton 与 Barto 第 12 章 12.5 节）[渐近]。这条等价性是资格迹的全部价值：它让“往未来看 λ 加权多步”变成“每步一次全局衰减加一次局部更新”，计算量与一步 TD 相同。

这里还要强调 γ 与 λ 的区别，二者在式 (3.20) 中相乘，角色完全不同。γ 定义在回报里，决定未来的奖励值多少；λ 定义在目标的混合里，决定用多少自举、用多少真实奖励。把两者合并成一个“衰减系数”会在第 4 章立刻出问题：函数逼近下两者的稳定性性质不同，γ 影响算子的压缩性，λ 影响迹的长度。

SUMMARY / 总结

3.5 控制与收敛条件

把 TD 的估计装进广义策略迭代，就得到表格型控制的两个标准算法。SARSA 评估当前行为策略，Q-learning 则使用最优性算子构造更新目标。两者的目标定义不同，因此收敛结论和行为性质也不同。

3.5.1 SARSA 与 Q-learning

SARSA 用实际执行的下一个动作构造目标：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)] \tag{3.23}$$

Q-learning 用下一个状态上的最大值构造目标：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)] \tag{3.24}$$

差别只在目标：用 $Q(S_{t+1}, A_{t+1})$ 还是用 $\max_a Q(S_{t+1}, a)$。SARSA 的目标依赖行为策略（正是 ε-贪心的探索动作），评估的是“正在执行的这个 ε-软策略”；Q-learning 的目标对行为策略不作假设，直接朝最优算子的方向更新，因而可以学最优策略而行为策略保持探索。

这个差别在悬崖边上变得可见（图 3-5）：5×5 网格，踏入三格悬崖得 -100 并回起点，其余每步 -1。

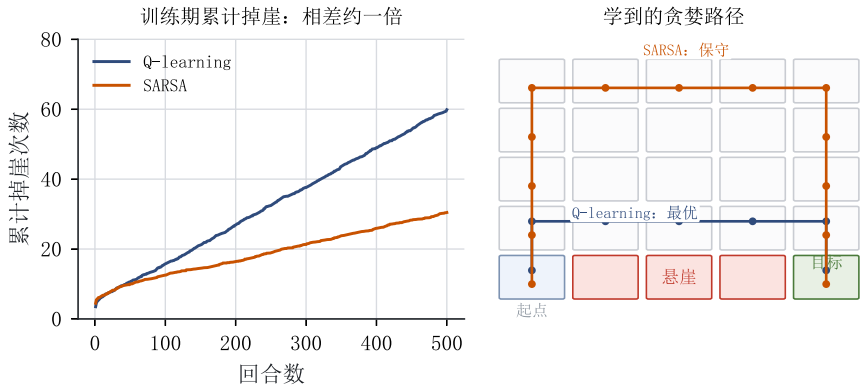


图 3-5 悬崖任务上两个控制算法的差别。5×5 网格，起点 (4,0)、目标 (4,4)、悬崖为 (4,1)–(4,3)，每步 -1、掉崖 -100 并回起点；20 个种子各 500 回合，ε=0.1、α=0.5、γ=1。左图为训练期累计掉崖次数，右图为训练结束后的贪婪路径。

20 个种子、每个 500 回合的实测结果：Q-learning 全过程掉崖 1197 次（平均每回合 0.120 次），SARSA 掉崖 609 次（0.061 次），前者是后者的两倍。学到的贪婪路径相反：Q-learning 找到沿第三行的 6 步最优路径，紧贴悬崖走；SARSA 学到绕到最上面一行再下来的 12 步路径，远离悬崖。原

因就在两式的差别：SARSA 的目标含探索动作，把“贴崖行走时被随机探索推下去”的风险计入了价值；Q-learning 永远假设之后走最优动作，看不见这份风险。两者的平均回报很接近（最后 100 回合：-17.80 对 -16.78）：前者以训练期掉崖换更短的路径，后者以更长的路径换更少的掉崖。表 3-2 并列两种算法。

表 3-2 SARSA 与 Q-learning 的对照。两行更新式只差目标里的取值方式，其余性质都由这一处差别派生。

性质	SARSA	Q-learning
更新目标	$R+\gamma Q(S',A')$，A' 来自行为策略	$R+\gamma\max_a Q(S',a)$
目标策略与行为策略	相同（on-policy）	可以不同（off-policy）
解的是什么	当前 ε-软策略的价值	最优价值 Q^*
训练期风险	低（把探索风险计入价值）	高（贴着最优路径走）
收敛条件	覆盖 + Robbins–Monro + 有界奖励	同左，但覆盖针对行为策略

表 3-2 的最后一行列出关键覆盖条件。Q-learning 要求行为策略对每个相关状态—动作对都有正的访问概率；覆盖不足时，无法保证相应的 $Q(s,a)$ 会被更新，最大化步骤可能选中缺乏数据支持的动作。第 4 章 4.2 节讨论数据分布与目标策略不同的情形，以及函数逼近下由此产生的稳定性问题。

3.5.2 收敛条件

把 3.3.2 节的偏差分析与 3.2.2 节的步长条件合起来，就是表格型 Q-learning 的收敛定理。

> **定理 3.1（Q-learning 的收敛性 [渐近]）**
>
> 设状态与动作有限、奖励有界（$|R|\le R_{\max}$）、每个状态-动作对被访问无限次，且步长满足 $\sum_k \alpha_k=\infty$、$\sum_k \alpha_k^2<\infty$。则式 (3.24) 产生的 Q_k 以概率 1 收敛到 Q^*。

三个条件各管一件事：覆盖保证每个 $Q(s,a)$ 都被数据修正过；步长条件保证噪声被平均掉又不会过早停止；有界奖励保证目标方差有限，从而让第二条条件起作用。去掉任何一个结论都不成立——覆盖不足时未被访问的动作对停在初值上，$\max$ 会选中它并给出错误的最优值；常数步长时估计只在 Q^* 的邻域内游走；奖励无界时目标方差可能发散，步长再合适也无法平

均。

关于探索衰减要谨慎两句。第一，GLIE 不是唯一的充分条件，它只是把“覆盖”与“收敛到贪心”打包在一起的一种方式；只要覆盖与步长条件成立，收敛性并不需要 ε 单调衰减。第二，“ε-贪心 + 随时间衰减”不是可以照抄的通用配方：衰减太快会在覆盖尚未建立时停止探索，太慢则最终策略离贪心太远，衰减表依赖于状态规模与回合长度。

3.5.3 折扣设定与平均奖励设定

本章所有结论都在折扣设定下。平均奖励设定不问折扣后的总和，而看单位时间的平均收益，

$$\rho(\pi) = \lim_{T\to\infty} \frac{1}{T}\,\mathbb{E}_{\pi}\Big[\sum_{t=0}^{T-1} R_{t+1}\Big], \tag{3.25}$$

对应的贝尔曼方程把平均收益与相对价值分开写：

$$V(s) + \rho = \sum_{a} \pi(a \mid s) \sum_{s'} P(s' \mid s, a)\big[r(s,a,s') + V(s')\big]. \tag{3.26}$$

与第 2 章表 2-1 的折扣形式相比，式 (3.26) 多了 ρ 这一项，价值函数只刻画“相对平均水平的偏离”。代价是理论前提变强：马尔可夫链必须不可约（否则不同初始状态给出不同的长期平均），对应算子不再是压缩映射，不动点不唯一，本章用到的收缩论证全部失效。因此在表格设定之外，折扣仍是默认选择：它让算子保持压缩，所有估计方法于是共享同一套收敛语言。

3.5.4 表格方法的边界

表格方法的能力边界由两个数决定：状态-动作对的数量与信息的传播距离。前者是内存与每次更新的扫描成本，后者更隐蔽：价值只能沿实际访问过的转移逐步扩散，从目标传到距离 L 步的状态至少需要 L 个回合。

两个后续方向因此在第 4 章自然出现。其一是**函数逼近**：$|\mathcal{S}|$ 一旦大到写不下，就只能用共享参数表示价值函数、让没见过的状态也有估计，代价是 3.3.3 节的不动点结构全部改变（4.1 节）。其二是**离策略的分布偏移**：Q-learning 允许行为策略与目标策略不同，但价值一旦由参数表示，数据分布（行为策略决定）与目标期望（目标策略决定）就不再匹配，3.5.2 节的覆盖假设不再充分（4.2 节）。

SUMMARY / 总结

本章小结

动态规划、蒙特卡洛与时序差分解的是同一个贝尔曼方程，差别只在右端怎么算出来。模型已知时右端可以直接求和，把线性方程组改写成不动点迭代就行：式 (3.1) 每扫一遍收敛因子是 γ（式 (2.17)），闭式解 (2.12) 的 $O(|\mathcal{S}|^3)$ 代价在大状态空间上做不起，迭代法真正的优势是只碰真实存在的转移。策略迭代、截断评估与值迭代是同一个家族按评估深度 m 参数化的三个点；图 3-2 的实测里 m 从 1 增到 ∞ 把轮数压掉 27 倍，备份数却几乎不变甚至更多。轮数少与计算量少是两件事，教材里那句“策略迭代更快”只在轮数这个坐标上成立。

模型未知时右端算不出来，只能拿回报当样本。蒙特卡洛用整条回报作目标，无偏，误差按 $1/\sqrt{N}$ 衰减；但无偏不等于收敛，收敛还要覆盖（式 3.10）与步长条件（式 3.9），这也解释了增量均值 (3.8) 为什么把 $1/N$ 写成步长。时序差分把目标换成一步奖励加自举估计，偏差进来了、方差降下去了（式 3.14），不动点仍是 V^π（式 3.15）；图 3-3 上偏差在早期主导、方差在后期主导。n 步回报与 λ-回报把两端连成一条谱，λ 增大只是让长 n 步回报的相对权重变大，$\lambda = 1$ 退化为完整回报而不是“权重摊平”；图 3-4 里极小点随步长移动，不存在普遍最优的 λ。控制层面，SARSA 与 Q-learning 的差别只在目标里取行为动作还是取最大值：前者评估当前 ε-软策略因而保守，后者学最优策略因而冒险（图 3-5），两者收敛都要覆盖、Robbins–Monro 步长与有界奖励（定理 3.1）。第 4 章把这些更新搬到参数化函数上，“每个状态独立”这条前提一消失，覆盖与稳定性就得重新交代；第 5 章的演员-评论家则把这里的 δ_t 直接拿去当驱动信号。

关键公式

这几组式子是全章的主干，顺序与正文一致：策略评估、策略改进、值迭代、蒙特卡洛预测、TD 预测与 TD 误差、n 步与 λ-回报、累积型资格迹、SARSA、Q-learning。推导、条件与实测都在对应小节里，这里只留式子本身。

$$V_{k+1}(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a)\big[r(s, a, s') + \gamma V_k(s')\big]$$

$$\pi'(s) = \arg\max_a \sum_{s'} P(s' \mid s, a)\big[r(s, a, s') + \gamma V^\pi(s')\big]$$

SUMMARY / 总结

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' \mid s,a)\big[r(s,a,s') + \gamma V_k(s')\big]$$

$$V(S_t) \leftarrow V(S_t) + \alpha\big[G_t - V(S_t)\big]$$

$$V(S_t) \leftarrow V(S_t) + \alpha\delta_t, \qquad \delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$$

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n V(S_{t+n}), \qquad G_t^{\lambda} = (1-\lambda)\sum_{n\geq 1} \lambda^{n-1} G_t^{(n)}$$

$$E_t(s) = \gamma\lambda E_{t-1}(s) + \mathbf{1}\{S_t = s\}$$

$$Q(S_t,A_t) \leftarrow Q(S_t,A_t) + \alpha\big[R_{t+1} + \gamma Q(S_{t+1},A_{t+1}) - Q(S_t,A_t)\big]$$

$$Q(S_t,A_t) \leftarrow Q(S_t,A_t) + \alpha\big[R_{t+1} + \gamma \max_a Q(S_{t+1},a) - Q(S_t,A_t)\big]$$

习题

1. 对 3.1.1 节的例子（$|\mathcal{S}| = 10^6$、$|\mathcal{A}| = 4$、平均 3 个后继），分别估计闭式解与一次迭代扫描的运算量，并说明在什么条件下迭代法的优势最大、在什么条件下它会消失。

2. 证明截断评估 (3.4) 在固定 m 时等价于一个评估算子的 m 次幂，并说明为什么 $m \to \infty$ 时策略迭代的单调性来自定理 2.5，而 $m = 1$ 时值迭代的收敛性来自 T^* 的压缩性。这两种论证能否互换？

3. 用图 3-2 的数字验证“轮数 × 每轮计算量”的守恒近似：算出三种 m 下达到 10^{-6} 的总备份数，解释为什么 $m = 5$ 与 $m = 1$ 几乎相同、而 $m \to \infty$ 明显更贵。

4. 在 19 状态随机游走上重做图 3-3 的实验，但把 V_0 从 0 改成 0.5。预测两条曲线交叉的位置会向哪个方向移动，并解释原因（提示：偏差的初值与 $V_0 - v^\pi$ 成正比）。

5. 构造一个 2×2 的 MDP，使得 ε-软策略集内的最优策略不是贪心策略，并计算两者价值差的常数因子。

6. 说明为什么式 (3.18) 中 $\lambda \to 1$ 是“长项相对权重增大”而不是“各项权重趋于相等”。用 $\lambda = 0.9$ 与 $\lambda = 0.99$ 权重序列的前 10 项给出说明（$\lambda = 0.9$ 时 $w_5 = 0.0656$、$\sum_{n\le 10} w_n = 0.6513$），并指出 $\sum_{n} (1-\lambda)\lambda^{n-1}$ 等于多少、为什么式 (3.18) 在 $\lambda = 1$ 处只能作为极限而不能直接代入。

7. 在 5×5 悬崖任务上把 ε 从 0.1 改成 0.01，预测 SARSA 与 Q-learning 的

掉崖次数与最终路径如何变化，并用实验验证。若把悬崖的惩罚从 -100 改成 -1，结论是否还成立？

8. 证明 batch TD(0) 的不动点 (3.16) 等于最大似然模型下的精确解，并说明为什么 batch MC 的解一般不等于它。提示：写出经验模型 $\hat{P}, \hat{R}$ 的最大似然形式，再代入 (2.12)。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》（第 2 版）第 4 章是动态规划的标准讲述，4.1 – 4.4 节给出策略评估、策略改进、值迭代与异步 DP 的完整推导，4.5 节讨论效率的度量，可与 3.1.3 节的实测数字对照；第 5 章处理蒙特卡洛方法，5.1 – 5.5 节覆盖首次访问与每次访问、覆盖机制与控制算法。
- 同书第 6 章是时序差分的核心章节，6.1 – 6.4 节给出 TD(0)、偏差-方差讨论与确定性等价，6.5 节讨论收敛性；第 7 章把 n 步方法系统化；第 12 章专门处理资格迹，12.1 – 12.5 节给出前向与后向视角的等价性证明，是理解迹与在线实现的必读材料。
- Bertsekas《Dynamic Programming and Optimal Control》第 1 卷对值迭代与策略迭代的收敛速度有更细的分析，包括收缩速率与误差界的具体常数；第 2 卷讨论大规模问题上的近似与异步实现，可与 3.1.4 节配合阅读。
- Robbins 与 Monro 1951 年的原始论文（A stochastic approximation method）给出式 (3.9) 的条件与证明，是理解“为什么需要两条步长条件”最短的入口。
- Sutton 与 Barto 第 11 章（Off-policy Methods with Approximation）的 11.1 – 11.3 节是“致命三要素”的经典讨论，可作第 4 章 4.2 节的预习。

第 2 部分

经典与深度强化学习

第 4 章　函数逼近与离策略学习

第 5 章　策略梯度、信赖域与 PPO

第 6 章　深度强化学习：从 DQN 家族到连续控制

第 4 章　函数逼近与离策略学习

前述表格法为每个状态或状态—动作对存储独立的价值估计。棋盘、机械臂和游戏画面中的状态数量很大，无法逐一存储。一个七自由度机械臂若将每个关节离散为十档，就有 10^7 种状态组合；Atari 单帧图像包含 210×160 个像素位置和三个颜色通道；连续控制的状态空间则不可数。本章用有限维参数表示价值函数。表示能力扩大后，表格法中的压缩映射论证不再自动适用，收敛结论需要重新建立并明确条件。

被放弃的东西可以精确指出来。表格情形下 T^π 把值函数映到值函数，压缩性足以保证迭代收敛；参数化之后 $T^\pi V_\theta$ 一般落在参数族外，必须先把它的像投影回来，投影与算子不可交换，不动点的位置随之改变。再叠上自举（用估计更新估计）与离策略采样（用行为策略 b 的数据评估目标策略 π），更新式可能**根本没有不动点**。

本章依次讨论参数化值函数与半梯度更新、离策略采样对稳定性的影响、线性函数逼近下的投影贝尔曼方程与收敛条件，以及工程稳定化方法和神经网络扩展。Baird 反例说明特定离策略更新可能发散。

> 导读
>
> **问题**：状态数无法承受时，如何用有限参数估计 V^π；在离策略采样下，这套估计为什么会失效，失效的条件又是什么。
>
> **先修**：第 2 章的贝尔曼期望方程、压缩映射与残差界；第 3 章的 TD(0)、步长条件与随机逼近的基本语言。
>
> **主要来源**：Sutton & Barto《Reinforcement Learning: An Introduction》(2nd ed.) 第 9–11 章；Baird (1995)；Tsitsiklis & Van Roy (1997)；Sutton, Maei, Precup, Bhatnagar, Silver, Szepesvári, Wiewiora (2009a, 2009b)。
>
> **资料截止日**：2026-10-19。此后出现的方法只进研究框，不作定理依据。

4.1 从表格到函数逼近

4.1.1 表格方法的规模墙

表格方法的内存与样本复杂度都正比于状态数。在有限且不大的 MDP 上这是最优选择：每个状态一个自由参数，没有任何近似误差。但绝大多数

实际问题里 $|\mathcal{S}|$ 大到无法枚举。一个七自由度机械臂，每个关节离散成十档就有 10^7 个状态；Atari 的一帧画面是 210×160 的三通道图像；连续控制任务里状态根本不可数。

把连续状态离散化只是把墙推远一点。若每个维度需要 k 格才能达到可接受的精度，则 n 维状态需要 k^n 个格子——维数灾难。更根本的是，离散化丢掉了最该利用的结构：相邻状态的取值几乎相同，物理上连续，一个状态学到的东西理应立刻惠及邻居。表格方法把每个状态当作互不相干的独立参数，学到第 10^6 个状态时，第 1 个状态的经验一点也帮不上忙。

4.1.2 参数化值函数与“一次更新影响一片”

用有限个参数表示全部状态的值：

$$V_\theta(s) \approx V^\pi(s), \qquad \theta \in \mathbb{R}^d,\ d \ll |\mathcal{S}| \tag{4.1}$$

参数化方式决定泛化如何发生。最常用的是线性参数化 $V_\theta(s) = \phi(s)^\top \theta$ 这种内积形式，其中 $\phi(s) \in \mathbb{R}^d$ 是由状态算出的**特征向量**；也可以是神经网络 $V_\theta(s) = f(s;\theta)$，此时参数与状态的关系是非线性的。无论哪种，参数都是共享的：更新 $V_\theta(s)$ 会同时改变所有与 s 特征重叠的状态的估计。这既是函数逼近的全部价值，也是它全部麻烦的来源。

价值在于样本效率。一次转移 (s, r, s') 提供的信息不再只作用于一个格子，而是作用于整个特征方向；若 ϕ 设计得当，少数几条轨迹就能把大片状态的估计拉到合理范围。麻烦在于**干扰**：改变一个状态的估计必然改变别的状态的估计，而这个改变未必是我们想要的。在表格情形下，更新只沿坐标轴方向移动，不同状态的误差互不干扰；在参数化情形下，更新沿特征方向移动，一个方向的修正会在别的状态上留下投影分量，当采样分布与目标分布不一致时，这些分量累积起来可以把本来正确的估计推离轨道（第 4.2 节）。

4.1.3 目标函数与加权范数

有了参数化，就需要一个衡量“估得准不准”的量。取加权平方误差：

$$\mathrm{VE}(\theta) = \|V_\theta - V^\pi\|_\mu^2 = \sum_{s \in \mathcal{S}} \mu(s)\big(V_\theta(s) - V^\pi(s)\big)^2 \tag{4.2}$$

其中 μ 是状态空间上的概率分布，称为**加权分布**或**评估分布**。它决定各状态误差在目标函数中的权重，并影响最优参数。均匀分布为每个状态赋予相同权重；策略 π 的访问分布则提高常访问状态的权重。本章第 4.3 节的收

SUMMARY / 总结

敛结论以 μ 为 on-policy 访问分布为前提，即样本由待评估策略产生。

必须强调 (4.2) 与监督学习损失的结构差异：目标 V^π 是未知的，甚至随 θ 不可分离——它满足 $V^\pi = T^\pi V^\pi$，而 T^π 里含有我们正在估计的量。监督学习里标签与参数无关，梯度下降是在固定目标上找最小值；这里目标本身是参数的函数，直接对 (4.2) 求梯度会多出“目标随参数变化”的一项，而这一项无法用样本无偏估计。

4.1.4 半梯度TD与完整梯度的区别

把 TD(0) 移植到参数化值函数上，得到**半梯度 TD(0)**：

$$\theta_{t+1} = \theta_t + \alpha\,\delta_t\,\nabla_\theta V_\theta(S_t), \qquad \delta_t = R_{t+1} + \gamma V_\theta(S_{t+1}) - V_\theta(S_t) \tag{4.3}$$

δ_t 仍是 TD 误差，只是把 $V(S)$ 换成 $V_\theta(S)$；步长 $\alpha > 0$。当 $\phi(s) = e_s$（one-hot 特征）时，(4.3) 逐分量退化为表格 TD(0)，所以表格方法是它的特例，而不是另一种算法。

现在说明“半梯度”这个名称的来历。若把 δ_t^2 当作瞬时损失并对 θ 求梯度，由链式法则得

$$\nabla_\theta \tfrac{1}{2}\delta_t^2 = -\delta_t\Big(\nabla_\theta V_\theta(S_t) - \gamma\nabla_\theta V_\theta(S_{t+1})\Big) \tag{4.4}$$

(4.4) 才是这个瞬时损失的**真梯度**，它含两项：对当前估计的梯度，以及对自举目标 $R_{t+1} + \gamma V_\theta(S_{t+1})$ 的梯度（带负号）。半梯度 (4.3) 只保留第一项，把 $\gamma V_\theta(S_{t+1})$ 当作常数——它假装目标不依赖参数。用 (4.4) 的完整形式做随机梯度下降的方法叫**残差梯度法**（residual gradient），它是真梯度，收敛更稳健，但收敛点往往明显劣于半梯度 TD 的不动点。

半梯度 TD 忽略自举目标对当前参数的导数，因此通常不等于采样平方 TD 误差的完整梯度。它具有自己的不动点；一般情形下，该更新也不对应这一固定损失函数的负梯度，因而不能直接套用标准梯度下降的收敛论证。

SUMMARY / 总结

4.2 致命三要素与离策略

4.2.1 三个要素

Sutton 与 Barto 把不稳定的来源归纳为一句话，值得逐字引用：

> the danger of instability and divergence arises whenever we combine all of the following three elements, making up what we call the deadly triad: Function approximation, Bootstrapping, Off-policy training.

译作：只要**函数逼近**、**自举**、**离策略训练**三者同时出现，不稳定与发散的危险就存在。原文紧接着排除了几种常见的归因：危险不是控制或广义策略迭代造成的，也不是学习过程或环境不确定性造成的。

需要注意措辞的三个层次。“危险存在”不等于“必然发散”：三者齐备给出的是**可能性**，Baird 反例（第 4.3.5 节）是构造出来的存在性证据，说明这种可能性真的会被触发；而第 4.3 节的定理说明，在 on-policy 分布下同一套更新式仍然可以证明收敛。把“三者齐备必然发散”当作结论是错的：它只是经验规律，严格版本是“缺少额外条件时没有保证收敛的一般性定理”。

在若干典型设定中，单独出现函数逼近、自举或离策略采样仍可获得稳定算法；具体结论取决于表示与更新规则。表格方法 + 离策略可以收敛（前提是每个状态-动作对被无限次访问、且步长满足 Robbins–Monro）；函数逼近 + on-policy 有收敛保证（第 4.3 节的定理，前提是线性 Φ、满列秩、Robbins–Monro 步长）；函数逼近 + 自举但不离策略：若函数逼近是线性的，可以落在第 4.3 节定理的范围内，**非线性逼近则没有一般结论**（第 4.5.3 节）。据 S&B 的措辞，任意两者同时存在时“不稳定性可以被避免”——那是“可以避免”，不是“保证收敛”。函数逼近、自举与离策略的结合可能导致发散；三者同时存在并不意味着算法必然不稳定。

SUMMARY / 总结

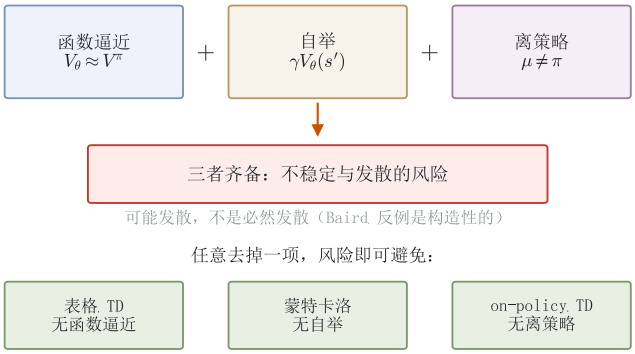


图 4-1 致命三要素的结构。三个要素各自单独出现时不破坏收敛性；两两组合仍可分析；三者同时出现时，更新式的线性化矩阵可能失去正定性，此时发散是可能的结果而非必然结果。图中虚线标注了本章给出保证的位置。

4.2.2 分布偏移：d^π 与 μ

记号必须先分清。给定策略 π，它在状态上的折扣访问分布定义为

$$d^\pi(s) = (1-\gamma)\sum_{t\geq 0}\gamma^t \Pr\big(S_t = s \mid S_0 \sim \rho_0, \pi\big) \tag{4.5}$$

系数 $1-\gamma$ 使各状态的权重之和为 1，即 $\sum_s d^\pi(s) = 1$；ρ_0 是初始状态分布。这是“按 π 行动时，状态被访问的相对频率”。on-policy 学习里，采样分布恰是 d^π，于是 $\mu = d^\pi$，(4.2) 的最优解与 (4.3) 的不动点可以对齐到同一个 μ 下讨论。off-policy 学习里，数据由行为策略 b 产生，更新分布变成 d^b，而目标策略仍是 π。此时

$$d^b(s) = (1-\gamma)\sum_{t\geq 0}\gamma^t \Pr\big(S_t = s \mid S_0 \sim \rho_0, b\big), \qquad d^\pi(s) = (1-\gamma)\sum_{t\geq 0}\gamma^t \Pr\big(S_t = s \mid S_0 \sim \rho_0, \pi\big) \tag{4.6}$$

这两个分布一般并不相等（式 4.6 把两者并列摆出来正是为了对比），这个差就是**分布偏移**。它不是估计噪声，不会随样本量增大而消失：即使有无穷多数据、用精确期望代替采样，只要更新分布是 d^b，最小化的对象就变成了“在 d^b 权重下的误差”，而不是我们关心的 d^π 下的误差。修正的手段是重要性采样，把每条样本按其在新旧分布下的概率比加权：

$$\rho_t = \frac{\pi(A_t \mid S_t)}{b(A_t \mid S_t)}, \qquad \mathbb{E}_b\big[\rho_t\,\delta_t\,\nabla_\theta V_\theta(S_t)\big] = \mathbb{E}_{S_t\sim d^b,\,A_t\sim\pi}\big[\delta_t\,\nabla_\theta V_\theta(S_t)\big] \tag{4.7}$$

注意等号两端的状态分布都是 d^b：单步比率 ρ_t 只换**动作**的分布，不换状态的分布——状态仍由行为策略的轨迹决定。右端**不是某个目标的梯度**：等号只是把动作的期望从 b 换回 π，半梯度仍是半梯度——换掉的是分布，不是更新式的性质。要得到真梯度必须另换目标（残差梯度，或在投影贝尔

SUMMARY / 总结

曼误差上做 GTD，见第 4.3.5 节）。

(4.7) 能把期望配平，但解决不了稳定性：配平的是**一阶矩**，而 TD 迭代的稳定性由更新算子的**谱**决定。加权可以改变算子的特征值符号，这一点在第 4.3.5 节会看得非常清楚。

4.2.3 覆盖假设，以及它保证不了什么

表格情形下的标准条件是：每个状态-动作对被访问无限次，且步长满足 Robbins–Monro（$\sum_t \alpha_t = \infty$，$\sum_t \alpha_t^2 < \infty$）。这条条件在函数逼近下必须换成更强的说法，因为参数是共享的，“访问一个状态”不再等价于“确定一个参数”。

常用的替代是**覆盖假设**：$\text{supp}(\pi) \subseteq \text{supp}(\mu)$，即目标策略可能选的动作，行为策略也以正概率选到；否则 ρ_t 的分母为零，重要性采样无定义，任何方法都无法评估 π 在该动作上的价值。但覆盖只是**必要条件**。它保证“该看见的都看得见”，却完全不管“看见之后更新式会不会把参数推向无穷”。Baird 反例满足覆盖（所有动作在所有状态下都有正概率），仍然发散。因此本节的正确表述是：覆盖保证可辨识性，不保证稳定性；稳定性另外需要分布与谱的条件。

下面的受控实验直接展示分布偏移的代价。考虑 19 个状态的双动作链，状态 i 的右移概率由所选动作决定，链条两端吸收、吸收时给 $+1$ 或 0 这两种结果；取 $\gamma = 0.99$，六维 Legendre 特征，目标策略 π 以 0.8 的概率右移，行为策略 b 以 0.5 右移，两者都保持覆盖。用 b 采样、用 ρ 修正、每个配置跑 $n = 5000$ 步、20 个种子（on-policy 用种子 6000–6019，off-policy 用 7000–7019，步长 $\alpha = 0.05$），评估时以 d^π 为权重计算 (4.2)。

结果分两半，都是真算出来的。**偏差**：on-policy 的更新分布下不动点处的误差为 5.66×10^{-3}，off-policy 的更新分布下为 9.97×10^{-3}，而最优投影只能到 4.61×10^{-3}——分布偏移把不动点本身推远了 1.76 倍，这一部分是不可消除的系统偏差。**方差**：20 个种子终点误差，on-policy 为 $1.45 \times 10^{-2} \pm 3.97 \times 10^{-3}$，off-policy 为 $4.16 \times 10^{-2} \pm 2.80 \times 10^{-2}$（最大 1.30×10^{-1}）；标准差增大到 7 倍，说明重要性权重的乘性噪声让不同种子的收敛速度差异极大。两个分布的总变差距离为 0.2588，并不算大，偏差与方差的代价却已经如此明显。还须说明一点：这两组的算子 A 特征值实部都为正（on：0.007 至 0.055；off：0.010 至 0.026，各含一对共轭复根），所以此处并没有发散，只有偏差与方差。分布偏移是发散的**背景**，不是发散的充分条件——这一点在第 4.3.5 节会看到反面的例子。

SUMMARY / 总结

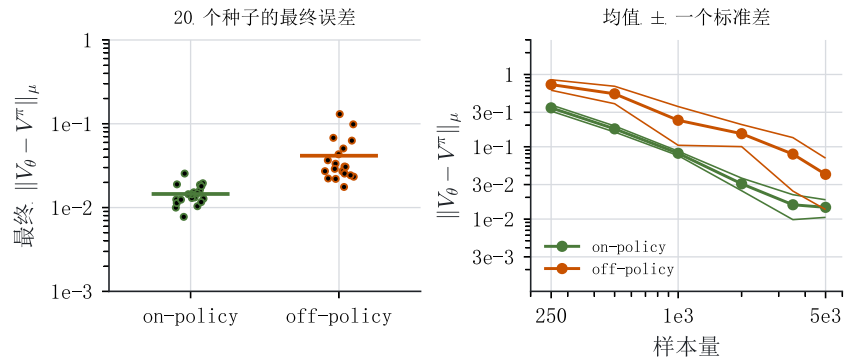


图 4-2 分布偏移的偏差与方差（实验 2b）。左：on-policy 与 off-policy 两种采样下 20 个种子的误差曲线，阴影为 ± 1 个标准差；off-policy 在每一个检查点上都更高且更散。右：终点误差的分布，off-policy 的尾部延伸到 1.3×10^{-1}。同一更新式、同一特征、同一目标策略，唯一的差别是数据从哪个分布来。

4.2.4 离策略线性函数逼近的发散反例

审查中最常见的错误表述是“线性函数逼近通常仍然收敛”：它的错误不在结论方向，而在抹掉了**分布**这个决定性参数。第 4.3 节将证明，半梯度 TD 的期望更新是线性系统 $\theta \leftarrow \theta + \alpha(b - A\theta)$，收敛与否取决于 A 的谱：

- 若 A 正定（对称部分正定），则对 $\alpha < 2/\lambda_{\max}(A)$ 迭代收敛；
- 若 A 的谱含负实部特征值 λ，则 $\rho(I - \alpha A) \geq |1 - \alpha\lambda| > 1$ 对**任意** $\alpha > 0$ 成立，迭代必然发散，且发散速度由 $|\lambda|$ 决定。

A 是否正定不由“是不是线性”决定，而由三元组 (Φ, D, P^π) 共同决定。on-policy 时 D 取 d^π，可以证明 A 正定（这正是第 4.3.4 节定理的核心）；换成行为分布 D_b，正定性就不再成立。把“通常”换成“在 on-policy 分布下”，代价是把含糊的经验说法变成可检验的定理前提——这正是本书要求的标准。

两状态反例最容易记住：A, B 由同一行为策略等概率出发，分别以概率 1 与 0 转到终止态；B 无奖励，A 的奖励使 $V(A) = 2V(B)$ 成为真值关系。取一维特征 $\phi(A) = 1, \phi(B) = 2$（真值可精确表示），离策略更新只更新 A、丢弃 B 的更新，可得

$$\delta_t = (2\gamma - 1)w_t, \qquad w_{t+1} = \big(1 + \alpha(2\gamma - 1)\big)w_t \tag{4.8}$$

当 $\gamma > 0.5$ 时，递推系数大于 1，w_t 指数增长，且增长率不依赖 α。on-policy 分布下，状态 A 的估值通过状态 B 的后继价值得到支持；这一耦合会限制误差的放大。离策略采样破坏了该分布关系，误差可能持续增长。

SUMMARY / 总结

4.3 投影 Bellman 与线性 TD 的不动点

本节将离策略稳定性问题写成可分析的线性系统：先定义投影，再求不动点，并给出迭代收敛的条件。第 4.3.6 节汇总这些条件及其边界。

4.3.1 线性函数空间与满列秩

设状态集有限，$|\mathcal{S}| = N$，特征矩阵 $\Phi \in \mathbb{R}^{N\times d}$ 的第 s 行为 $\phi(s)^\top$。值函数是该矩阵列空间中的一个向量：

$$V_\theta = \Phi\theta, \qquad \operatorname{rank}\Phi = d\ (d \le N) \tag{4.9}$$

满列秩是必须明写的假设。若 $\operatorname{rank}\Phi < d$，则存在非零 ν 使 $\Phi\nu = 0$，参数 θ 与 $\theta+\nu$ 表示同一个值函数；此时 $A = \Phi^\top D(I-\gamma P^\pi)\Phi$ 必然奇异（$\Phi\nu = 0 \Rightarrow A\nu = 0$），$A\theta^* = b$ 或者无解、或者有无穷多解，“不动点”就不再唯一。Baird 反例的特征矩阵是 7×8、秩为 7，恰好违反这条假设——这是它能把水搅浑的一半原因，另一半在 (4.15) 之后关于可逆性的讨论。

实践中满列秩往往不成立（特征数超过状态数、特征之间线性相关），标准的补救是正则化（在 A 上加 λI）或用伪逆，代价是最优解被轻微偏移。

4.3.2 加权投影与 D-内积

把 μ 写成对角矩阵 $D = \operatorname{diag}(\mu)$，则 (4.2) 可写成二次型

$$\|v\|_D^2 = v^\top D v = \sum_s \mu(s) v(s)^2 \tag{4.10}$$

这是在 $\mathbb{R}^N$ 上的一个内积（要求 $\mu(s) > 0$）。在这个内积下，把任意值函数投影到 Φ 的列空间上的投影矩阵为

$$\Pi_D = \Phi(\Phi^\top D\Phi)^{-1}\Phi^\top D \tag{4.11}$$

它具备投影的三个特征：

$$\Pi_D^2 = \Pi_D, \qquad \Pi_D\Phi = \Phi, \qquad \langle v - \Pi_D v,\ \Phi u\rangle_D = 0 \ \text{对任意 } u \tag{4.12}$$

第三条是几何意义所在：残差 $v - \Pi_D v$ 与整个列空间在 D-内积下正交，因此 $\Pi_D v$ 是列空间中距 v 最近的点（最近性由 (4.10) 的范数定义）。注意 (4.11) 只对**线性**函数空间成立：Φ 的列空间是线性子空间，投影才有闭式的正交结构。神经网络参数化不是线性子空间，V_θ 的像是弯曲的流形，Π_D 无从定义——本章第 4.5 节会看到，这正是非线性逼近失去理论保证的技术根

源。

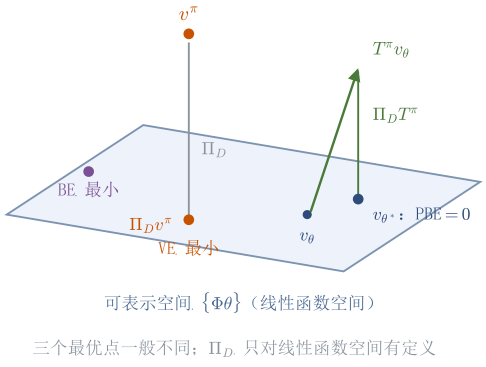


图 4-3 线性函数逼近的投影几何。$\boldsymbol{v^\pi}$ 一般不在特征张成的平面内；$\boldsymbol{\Pi_D v^\pi}$ 是平面内距 $\boldsymbol{v^\pi}$ 最近的点（$\boldsymbol{D}$-范数意义）；半梯度 TD 的收敛点是 $\boldsymbol{\Phi\theta^* = \Pi_D T^\pi \Phi\theta^*}$，即“投影后的贝尔曼算子”的不动点，一般既不是 $\boldsymbol{\Pi_D v^\pi}$ 也不是 $\boldsymbol{v^\pi}$。

4.3.3 投影不动点与法方程

线性情形下，迭代稳定时收敛到由“投影”与“贝尔曼算子”交替作用所定义的不动点：

$$\boldsymbol{\Phi\theta^* = \Pi_D T^\pi \Phi\theta^*} \tag{4.13}$$

该方程来自半梯度更新的期望值。更新方向为 $\boldsymbol{\delta_t \phi(S_t)}$；期望更新为零意味着残差在特征方向上与数据分布正交，即残差经投影后为零。由式 (4.13) 两边减去 $\boldsymbol{\Phi\theta^*}$，并利用 $\boldsymbol{\Pi_D}$ 的自伴性，得

$$0 = \Phi^\top D\big(T^\pi \Phi\theta^* - \Phi\theta^*\big) \tag{4.14}$$

把 $\boldsymbol{T^\pi v = r^\pi + \gamma P^\pi v}$ 代入，注意 $\boldsymbol{\Phi^\top D T^\pi \Phi\theta^* = \Phi^\top D r^\pi + \gamma \Phi^\top D P^\pi \Phi\theta^*}$ 这条等式，整理得到**法方程**：

$$\boldsymbol{A\theta^* = b}, \qquad \boldsymbol{A = \Phi^\top D\big(I - \gamma P^\pi\big)\Phi}, \quad \boldsymbol{b = \Phi^\top D r^\pi} \tag{4.15}$$

$\boldsymbol{A}$ 是 $\boldsymbol{d \times d}$ 矩阵，可以由特征与转移概率精确算出，不需要枚举全部状态（实际算法用采样估计）。可逆性需要两个条件：$\boldsymbol{\Phi}$ 满列秩（否则 $\boldsymbol{A}$ 奇异，见 (4.9) 后的讨论），以及 $\boldsymbol{I - \gamma P^\pi}$ 可逆（$\boldsymbol{\gamma < 1}$ 时成立，因为 $\boldsymbol{P^\pi}$ 是随机矩阵，谱半径不超过 1）。两条合起来保证 $\boldsymbol{A}$ 可逆，不动点唯一。

4.3.4 期望更新、正定性与收敛条件

半梯度 TD(0) 的一步期望更新可以直接算出。设 $\boldsymbol{S_t \sim \mu}$、$\boldsymbol{S_{t+1} \sim P^\pi(\cdot \mid S_t)}$，则

SUMMARY / 总结

$$\mathbb{E}\big[\theta_{t+1}-\theta_t \mid \theta_t\big]=\alpha\big(b-A\theta_t\big) \tag{4.16}$$

这里 μ 就是采样分布：只有当数据由 π 自己产生（on-policy）时才有 $\mu=d^{\pi}$。数据来自行为策略 b 时，加重要性权重 ρ_t 只能把**动作**分布纠正为 π，状态分布仍是 d^{b}，所以 (4.16) 仍不成立；此时最小化的是 d^{b} 加权的误差（4.2.2 节），要恢复 (4.16) 必须 $b=\pi$。

其中 b, A 即 (4.15) 中样本矩阵的期望形式，半梯度更新在期望意义下就是在做 $A\theta=b$ 的定点迭代；于是它是一个带噪声的线性动力系统，关键性质是 A 的谱。当 $\mu=d^{\pi}$（on-policy 分布）时，对任意 $u\neq 0$，令 $v=\Phi u$，则

$$\begin{aligned} u^{\top}Au &= \sum_{s}\mu(s)v(s)\big[v(s)-\gamma(P^{\pi}v)(s)\big]=\|v\|_{\mu}^{2}-\gamma\langle v,P^{\pi}v\rangle_{\mu} \\ &\geq \|v\|_{\mu}^{2}-\gamma\|v\|_{\mu}\|P^{\pi}v\|_{\mu} \;\geq\; \big(1-\gamma\big)\|v\|_{\mu}^{2}>0, \end{aligned} \tag{4.17}$$

第一个等号按 s 展开、第二个把 $\sum_s \mu(s)v(s)(P^{\pi}v)(s)$ 写成内积；两个不等号分别来自 Cauchy–Schwarz 与 P^{π} 在 μ-范数下的非扩张性 $\|P^{\pi}v\|_{\mu}\le\|v\|_{\mu}$——后者用到了 μ 是 π 的平稳分布。**等号一般取不到**：它要求 $P^{\pi}v=v$，即 v 是 P^{π} 的特征函数；平稳性 $\mu^{\top}P^{\pi}=\mu$ 只给出质量守恒 $\sum_s \mu(s)(P^{\pi}v)(s)=\sum_s \mu(s)v(s)$，对乘积项 $\langle v,P^{\pi}v\rangle_{\mu}$ 没有任何约束。因此式 (4.17) 是**不等式**，右端严格为正。由此 **on-policy 分布下 A 正定**，进而可逆，且 $\theta_{t+1}=(I-\alpha A)\theta_t+\alpha b$ 在 $\alpha<2/\lambda_{\max}(A)$ 时收敛到 $\theta^{*}=A^{-1}b$。

这条论证的前提在实验里往往只近似成立。第 4.3.4 节的数值实验用的是回合制吸收链，μ 取归一化折扣访问分布，它不是严格平稳分布，非扩张性只是近似成立——这正是式 (4.17) 写成不等式的意义；实测 $d=6$ 时 A 的六个特征值落在 0.0144 到 0.0218 之间（两端分别是极小与极大特征值），全为正实数，迭代稳定。这提示一个务实的判据：定理要的是“谱在右半平面”，而不是“某条恒等式成立”。前者可以用数值验证，后者往往不能。

把这套论证升级为随机逼近需要额外的概率条件。**收敛命题**（[渐近]）：若 (i) 采样分布为 on-policy 分布 $\mu=d^{\pi}$ 且采样链遍历，(ii) Φ 满列秩，(iii) 步长满足 $\sum_t\alpha_t=\infty$、$\sum_t\alpha_t^{2}<\infty$，则 $\theta_t\to\theta^{*}$ 几乎必然，其中 θ^{*} 是 (4.15) 的唯一解。证明是 Robbins–Monro 定理的直接应用：更新可写成 $\theta_{t+1}=\theta_t+\alpha_t(b-A\theta_t+\varepsilon_t)$，噪声项 ε_t 的条件期望为零、条件方差有界。注意 (iii) 与“常步长”不相容——常步长只保证收敛到不动点的一个邻域，邻域半径正比于 α，这一点在数值实验里会清楚地看到。

由式 (4.17) 可推出不动点误差的经典上界（[精确]，有限 MDP、$\gamma<1$、当前策略采样分布）：

SUMMARY / 总结

$$\|V_{\theta^*} - V^\pi\|_\mu \;\le\; \frac{1}{\sqrt{1-\gamma}}\,\min_{\theta}\|V_\theta - V^\pi\|_\mu \tag{4.18}$$

两边平方即得 $\mathrm{VE}(\theta^*) \le \frac{1}{1-\gamma}\min_\theta \mathrm{VE}(\theta)$。因子 $1/(1-\gamma)$ 来自投影：投影不动点在列空间里最“靠近”贝尔曼算子的像，而这个像并不在列空间内。

界是紧的，但当特征族已经能很好地表示 V^π 时，界远松于实际。数值实验可以验证这一点。考虑第 3 章用过的 19 状态随机游走，$\gamma = 0.99$，μ 取 on-policy 访问分布，特征为归一化状态上的 Legendre 多项式（$d = 2$ 到 10），采样 $n = 3000$ 步，20 个种子。先看精确量：

表 4-1 实验 1：19 状态随机游走上的两种策略评估，表中为 $\mathrm{VE} = \|V_\theta - V^\pi\|_\mu^2$（$\gamma = 0.99$，$n = 3000$，$\alpha = 0.05$，各 20 个种子，TD 用种子 1000–1019、LSTD 用 2000–2019）。“最优投影”为 $\mathrm{VE}(\Pi_D v^\pi)$，“不动点”为 TD 的精确不动点 $\mathrm{VE}(\theta^*)$，末两行为 20 个种子的均值（标准差见图 4-4）；$d = 3, 5$ 等其余点见该图左。

d	2	4	6	8	10
cond	5.1	21.0	64.9	223.4	1125.6
最优投影	5.62×10^{-2}	2.04×10^{-3}	2.93×10^{-5}	2.11×10^{-7}	8.40×10^{-10}
不动点	5.87×10^{-2}	2.26×10^{-3}	3.19×10^{-5}	2.24×10^{-7}	8.73×10^{-10}
TD 实测	8.09×10^{-2}	6.54×10^{-2}	6.49×10^{-2}	6.48×10^{-2}	6.47×10^{-2}
LSTD 实测	7.01×10^{-2}	3.51×10^{-2}	3.56×10^{-2}	3.59×10^{-2}	3.60×10^{-2}

表中包含两项比较。第一项是**不动点位置**：TD 不动点与最优投影只差 1.039 到 1.108 倍，而式 (4.18) 给出的界为 $1/(1-\gamma) = 100$ 倍，说明该界对这组特征较为保守。第二项是**实测误差**：当 $d \ge 4$ 时，TD 误差稳定在约 6.5×10^{-2}，不再随特征数下降。常步长 $\alpha = 0.05$ 使迭代在 θ^* 附近波动，误差半径与 α 同阶；增加特征数不会消除这一噪声地板。LSTD 不含步长参数，误差则随样本量增加而下降。图右侧展示了两种误差随样本量变化的差异。

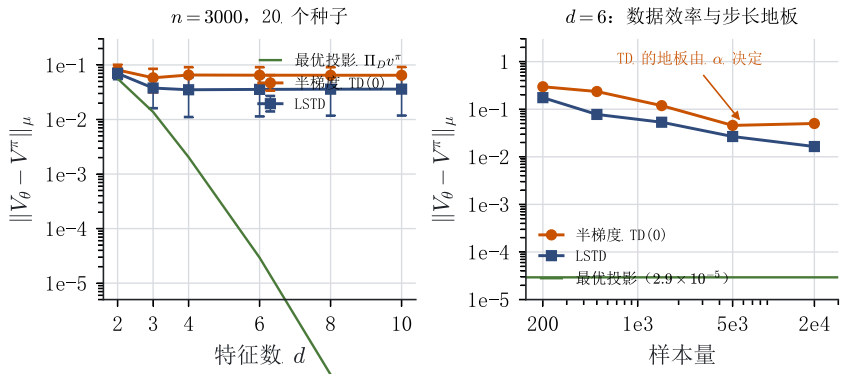


图 4-4 实验 1：半梯度 TD 与 LSTD 的误差对比。左：固定

SUMMARY / 总结

$n = 3000$，误差随特征数的变化（误差棒为 20 个种子的标准差）；$d \geq 4$ 后 TD 被步长地板挡住，LSTD 与最优投影同步下降。右：固定 $d = 6$，误差随样本量的变化；TD 单调下降后停在约 5×10^{-2}，LSTD 按 $1/\sqrt{n}$ 逼近最优投影（虚线，2.9×10^{-5}），两者在 $n = 200$ 之后始终相差一个量级。

4.3.5 有不动点，不等于收敛到不动点

这是本章最重要的一段，也是审查报告点出的那个错误最容易被写出来的地方：**存在投影不动点 $\neq$ 任意 TD 采样算法稳定收敛到它**。(4.13) 只说明“若迭代收敛，则收到这里”；它没有、也无法说明迭代会收敛。稳定性取决于 A 是否正定，而 (4.17) 的正定性证明用了两处：μ 是 π 的平稳分布、Φ 满列秩。任一处失效，结论就失效。

Baird 反例是构造性的反证。七个状态，两个动作；从任一状态选“虚线”动作，以 $1/6$ 的概率均匀转到前六个状态之一；选“实线”动作，转到第七个状态。奖励恒为零，$\gamma = 0.99$，真值 $v^\pi \equiv 0$。特征为八维：前六个状态的值为 $2w_i + w_8$，第七个状态的值为 $w_7 + 2w_8$，零向量可精确表示。目标策略恒选实线，行为策略以 $1/7$ 选实线、$6/7$ 选虚线，于是更新分布是**均匀分布**，而目标策略的 on-policy 分布集中在第七个状态。初始 $w_0 = (1, 1, 1, 1, 1, 1, 10, 1)^\top$。

跑 3000 步，步长 0.005、0.01、0.02 各一组（种子分别为 1400、1900、2900），on-policy 一组用种子 700。结果是 $\|w\|_2$ 在 $t = 200, 1000, 3000$ 三处分别长到 $1.65 \times 10^1 / 8.79 \times 10^1 / 1.28 \times 10^3$、$2.88 \times 10^1 / 3.43 \times 10^2 / 4.13 \times 10^4$ 与 $4.89 \times 10^1 / 3.95 \times 10^3 / 6.07 \times 10^7$ 这三组数，每一组都无界增长，而且步长越小增长越慢、从不停下。把同一更新式的采样分布换成 on-policy，$\|w\|_2$ 全程在 9 到 10 之间徘徊，最后 v_θ 缓慢趋向零。

发散条件可以由矩阵谱直接计算。取 D 为均匀分布，P^π 的每一行都是第七个状态的 one-hot 向量（因为 π 恒选实线，一步必到第七状态），于是 $A = \Phi^\top D(I - \gamma P^\pi)\Phi$ 可以精确求出。它的谱是

$$\lambda(A) = \{-0.2393,\ -0.0222,\ 0,\ 0.5714\ (\text{五重})\} \tag{4.19}$$

两个负实部特征值说明 A 不是正定的。更准确地说，A 非对称，判正定性要看它的**对称部分** $(A + A^\top)/2$：该矩阵的最小特征值为 -1.02，故存在 u 使 $u^\top A u < 0$，二次型变号；而“实部为负”与“二次型变号”并不等价。于是 $I - \alpha A$ 的谱半径至少是 $1 - \alpha(-0.2393) = 1 + 0.2393\alpha > 1$，对**任何** $\alpha > 0$ 都成立：迭代必然发散，发散速率由 α 与 0.2393 决定。$\alpha = 0.01$ 时每步放大 1.0024 倍，3000 步累计 $e^{7.17} \approx 1.3 \times 10^3$，与实测的

$4.13 \times 10^4 / 2.88 \times 10^1 \approx 1.4 \times 10^3$ 倍吻合。这就是“对任意步长发散”的算术内容，也是半梯度不是任何函数梯度这一事实的后果：没有势函数下界，参数可以沿一个“看起来在下降”的方向一路走到无穷。

两个补充事实让这个反例更有说服力。第一，它的特征矩阵是 7×8、秩为 7，违反 (4.9) 的满列秩假设，所以 A 有一个零特征值、不动点不唯一；但秩亏只影响“收到哪里”，不影响“能否收到”——发散由负特征值造成，补一个状态使其满秩并不改变发散。第二，覆盖假设成立（每条动作都有正概率），所以“多采点数据”救不了它：问题不在数据量，而在更新算子的谱。这类失败在实践中表现为 $\|w\|$ 缓慢漂移了很久之后突然爆炸，因此更隐蔽。

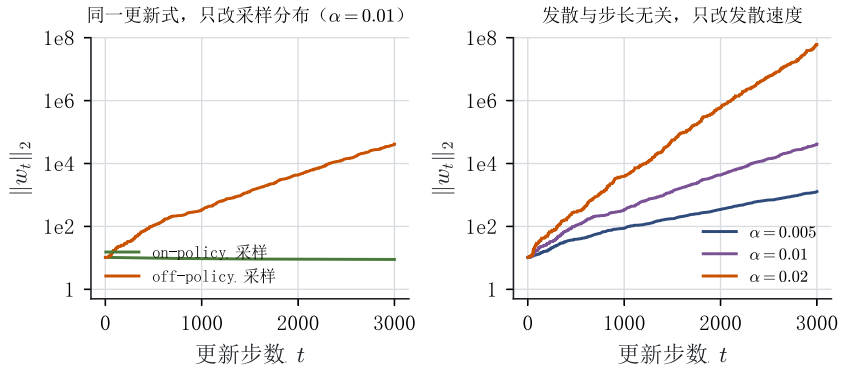


图 4-5 实验 2a：Baird 反例。左：同一更新式，on-policy 采样的 $\|w\|_2$ 有界（约 9），off-policy 采样则指数增长（$\alpha = 0.01$，纵轴对数）。右：三个步长下都发散，步长只改变斜率、不改变结论；A 的负特征值 -0.2393 给出理论斜率 $\ln(1 + 0.2393\alpha)$。

梯度 TD（GTD）系列的动机正来自这里。既然半梯度的病根是“缺少一个真梯度”，那就构造一个真梯度来最小化某个可学习的、投影后的目标。取

$$\overline{\mathrm{MSPBE}}(\theta) = \|\Pi_D T^\pi V_\theta - V_\theta\|_D^2 \tag{4.20}$$

GTD(0) 与 TDC 使用辅助参数构造 MSPBE 的可采样梯度更新，并采用双时间尺度步长。在线性函数逼近、覆盖条件、Φ 满列秩及相应步长条件下，可以证明这些算法的离策略渐近收敛。相较于半梯度 TD，这类方法增加了计算与步长设置要求；收敛保证也仅适用于其明确的假设范围。

4.3.6 MSPBE 与三类 Bellman 误差

(4.20) 给出的是**投影贝尔曼误差的均方**（mean squared projected Bellman error，MSPBE；文献中亦称投影贝尔曼误差 PBE，两者是同一个量）。线

性情形下它可以化成参数的二次型。记 $C = \Phi^\top D\Phi$（特征的二阶矩矩阵），并注意 $A\theta - b = \Phi^\top D(T^\pi V_\theta - V_\theta)$，把 (4.11) 代入 (4.20) 直接展开：

$$\overline{\mathrm{MSPBE}}(\theta) = (A\theta - b)^\top C^{-1}(A\theta - b) \tag{4.21}$$

这个式子解释了两件事。第一，MSPBE 的最小值点正是 $A\theta = b$ 的解 θ^*——所以 TD 的不动点就是 MSPBE 的最小点，第 4.3.3 节的法方程不是随手写的，它是一个明确的优化问题的最优性条件。第二，C^{-1} 的存在要求 Φ 满列秩，与 (4.15) 的可逆性条件同源。LSTD 与 GTD 都在解同一个目标，前者用闭式解，后者用随机梯度。

MSPBE 与贝尔曼残差不是同一个量，这一点必须在公式层面说清。**贝尔曼残差**（Bellman residual）是不投影的残差范数：

$$\mathrm{BE}(\theta) = \|T^\pi V_\theta - V_\theta\|_\mu^2 \tag{4.22}$$

它衡量“贝尔曼方程被违反了多少”，与参数化无关，是值函数本身的性质。**采样平方 TD 误差**（MSBE）则是把 TD 误差的平方按数据分布取期望，即 $\mathbb{E}_\mu[\delta_t^2]$，它可以在线估计，也是深度强化学习实际最小化的对象。三者可以相差很大：MSPBE 先投影再取范数，把“特征表达不了的那部分残差”提前抹掉，因此它总是小于等于 BE，而且它的最小点与 BE 的最小点一般不同。

> **三个 Bellman 误差不是同一个量**
>
> **Bellman 残差** $\|T^\pi V - V\|_\mu$（或 $\|\cdot\|_\infty$）不投影、不采样，衡量的是方程被违反了多少；最小化它需要真梯度（残差梯度法），可学习性很差。**MSBE**（采样平方 TD）是 $\mathbb{E}_\mu[\delta_t^2]$，不投影但有采样，DQN 实际优化的就是它（配目标网络），既不是 MSPBE，也不是 sup-范数残差。**MSPBE** 先投影再取 μ-范数，线性情形等于 $(A\theta - b)^\top C^{-1}(A\theta - b)$，它的零点是 TD 不动点，只在线性函数空间中有定义。三者的投影对象、加权分布与优化性质都不同，所以“某个误差小”不能直接翻译成“价值接近 V^π”，也不能互相替代；把 Π_D 用到非线性函数空间没有定义——那不是一个线性子空间的投影。

SUMMARY / 总结

表 4-2 三类 Bellman 误差的对照。引用其中任何一个都必须同时说明投影、分布与函数空间，缺一项就不可比。

名称	定义	是否投影	加权	能否直接优化
Bellman 残差	$\|T^\pi V_\theta - V_\theta\|_\mu$	否	μ	仅残差梯度（真梯度，收敛点较差）
MSBE	$\mathbb{E}_\mu[\delta_t^2]$	否	数据分布	是，DQN 的实际目标
MSPBE	$\|\Pi_D T^\pi V_\theta - V_\theta\|_D^2$	是	$\mu = d^\pi$	是，线性情形有闭式解与随机梯度

三者中只有 MSPBE 有“投影”这一步，而投影恰恰是最容易被悄悄绕过的一步。只要值函数不是线性的，Π_D 就没有定义，MSPBE 随之失去意义；此时能写的只有 MSBE 或 BE。第 4.5节讨论神经网络时会回到这一点：深度强化学习用 MSBE 代替 MSPBE，是因为 MSPBE 在非线性情形下无法定义。

4.3.7 残差界的适用范围

第 2 章证明过的残差界在这里仍然成立，但它的条件必须原样搬运：

$$\|V - V^*\|_\infty \le \frac{\|V - T^*V\|_\infty}{1-\gamma} \tag{4.23}$$

适用条件是：有限 MDP、$0 \le \gamma < 1$、上确界范数，且压缩性来自最优贝尔曼算子 T^* 本身。它说的是“若一个函数在 sup-范数下离最优不动点很近，则它离 V^* 也近”，因子是 $1/(1-\gamma)$。这条界之所以可靠，是因为 T^* 在 sup-范数下是 γ-压缩，压缩性不依赖任何分布。

它**不能**在未加证明时替换成 MSE、MSBE 或 MSPBE 的界。原因有三。其一，范数不等价：μ-范数只看见 μ 支撑上的误差，若某个状态 $\mu(s) = 0$，那里可以错得任意离谱而 MSE 不变；sup-范数不允许这种漏洞。其二，压缩性来源不同：(4.23) 靠的是 T^* 的压缩性，而 MSBE/MSPBE 的界要靠“投影算子的非扩张性 + 采样误差 + 分布匹配”，每一环都需要单独的条件（投影非扩张只在 D-范数下成立，采样误差要遍历性，分布匹配要覆盖）。其三，最优性对象不同：MSPBE 的零点是最小化投影残差的点，(4.18) 才是它与 V^π 的正确桥梁，且因子是 $1/\sqrt{1-\gamma}$ 而不是 $1/(1-\gamma)$。

正确做法是按“要什么范数、什么分布、什么函数空间”三件事分别陈述：要 sup-范数界就用 (4.23) 并承认它要求 T^*；要 μ-范数界就用 (4.18) 并写明 $\mu = d^\pi$；要非线性逼近的界，就得引入拟合误差项（如 (4.28)）。

SUMMARY / 总结

4.4 实用的离策略稳定化

4.4.1 经验回放

第 4.3.5节的教训是“分布与谱决定稳定性”，但从采样过程看，连续采集的相邻转移通常高度相关，相应的 TD 误差也会呈现相关性；此时半梯度更新方向会随数据分布缓慢变化。**经验回放**（experience replay）将转移存入缓冲区，并在训练时随机抽取小批量，以减弱相邻样本的时序相关性，使更新所用数据更接近独立同分布的假设；样本被多次使用也提高了数据利用率。

回放的代价是“数据陈旧”：缓冲区里的转移由旧策略产生，当前策略已经变了，于是回放本身就是一种离策略——分布偏移重新出现，而且随着训练进行而加剧。这意味着回放不是免费的稳定器，它只是把“相关样本”换成“分布偏移”，两者都需要额外机制处理。真正让回放可用的是它与目标网络、小批量平均的组合。

4.4.2 目标网络

第二个手段直指“追自己”。半梯度更新的目标是 $R_{t+1}+\gamma V_{\theta}(S_{t+1})$，其中含同一个 θ；参数一动，目标跟着动，迭代等于在追一个同时移动的靶子。**目标网络**把靶子暂时钉住：用一份滞后参数 θ^{-}（每隔 C 步从 θ 复制，或按 τ 做指数平均）计算自举目标，只对当前参数求梯度。以平方损失为例，目标函数变成

$$L(\theta)=\left(R_{t+1}+\gamma V_{\theta^{-}}(S_{t+1})-V_{\theta}(S_t)\right)^2,\qquad \theta^{-}\ \text{每}\ C\ \text{步同步一次} \tag{4.24}$$

在两次同步之间，(4.24) 是一个目标固定的回归问题，梯度下降有明确的下降保证；θ^{-} 的滞后把“目标随参数漂移”的反馈回路切断了一个时间尺度。代价是偏差：θ^{-} 落后于 θ，自举目标是旧参数的函数，收敛点因此被拉偏；C 越大越稳、偏差越大，这是一个必须显式调参的折中，不存在“选对 C 就两全”的说法。

4.4.3 优先采样与双网络

优先经验回放按 TD 误差的大小决定采样概率，误差大的样本被多抽，相当于把有限的更新预算投到“还没学会”的地方：

SUMMARY / 总结

$$P(i) = \frac{p_i^\omega}{\sum_k p_k^\omega}, \qquad p_i = |\delta_i| + \epsilon \tag{4.25}$$

$\omega \in [0,1]$ 控制优先级的使用强度，$\epsilon > 0$ 保证每条样本都有非零概率。代价是引入采样偏差（改变了数据分布），需要重要性权重修正；同时“误差大”也可能是噪声，优先级会把噪声样本反复抽出来放大。

双网络针对的是 $\max$ 算子的系统性高估：用同一个网络既选动作又评估动作，最大值噪声被反复利用，估计向上偏。用两套参数，一套选动作、另一套评估，可以把这个偏差压下来；**延迟更新**则让目标网络的同步频率低于策略网络，进一步稳住自举。这两项属于深度值方法的工程层，具体机制与实现差异留到第 6 章讨论 Q 学习家族时展开，此处只交代它们各自在“三要素”里动了哪一根杠杆：回放动的是分布（让数据不再严格 on-policy，反而更危险），目标网络动的是自举的时间尺度，双网络动的是自举目标的偏差结构。三者都不能消除致命三要素，只是把发散的风险换成了可控的偏差与方差。

4.4.4 致命三要素的两种失败形态

在本章实验里出现的失败可以归成两类，识别它们有助于判断“调参能不能救”。

值爆炸。参数范数指数增长，值函数被推到远离任何合理范围的地方。第 4.3.5 节的 Baird 实验是原型：$\|w\|_2$ 从 2.9×10^1 涨到 4.1×10^4，增长速率与 A 的负特征值精确对应（前一组取 $\alpha = 0.01$，共 3000 步）。这类失败的特征是**持续性**：损失可能在某几步看起来在下降，但参数范数单调上升，最终溢出。诊断办法是直接监控 $\|w\|$ 与 TD 误差的量级，而不是只看损失曲线。

策略退化。值函数没有爆炸，但策略在几个动作之间来回跳，或者收敛到一个明显次优的确定性策略。离策略下这个失败更常见：行为策略带来的数据覆盖了目标策略不会去的区域，这些区域的值估计被反复更新却缺少约束，$\arg\max$ 于是在噪声上做选择。它的特征是**振荡**而非发散，学习曲线呈现平台与突降交替。

两类失败的共同点是不出现在 on-policy 表格方法里，因为那里每个状态的价值都由自身的更新单独支撑；参数一旦共享，一个区域的错误就会通过特征重叠传染给别处。所以工程上的稳定化手段必须同时管理分布（回放、优先采样）与谱（目标网络、真梯度）。

SUMMARY / 总结

4.5 批量 RL 与非线性逼近

4.5.1 最小二乘策略评估

(4.15) 的法方程是线性的，这提示一个直接解法：把 A 与 b 用样本累加估计出来，然后解方程。**最小二乘策略评估**（LSTD）正是这样做的：

$$A_t = \sum_{k<t} \phi_k \big(\phi_k - \gamma \phi_{k+1}\big)^\top, \quad b_t = \sum_{k<t} R_{k+1} \phi_k, \quad \theta_t = A_t^{-1} b_t \tag{4.26}$$

实现上给 A_t 加一个数值正则项 λI，防止早期样本不足时矩阵奇异。A_t^{-1} 可用 Sherman–Morrison 公式增量维护，每步代价 $O(d^2)$，不必求逆。LSTD 没有步长，误差只来自采样，按 $1/\sqrt{n}$ 衰减。

表 4-1 与图 4-4 右图给出对比：同样的 n，LSTD 在每个特征数下都比常步长 TD 准一个量级（$d = 6$、$n = 3000$ 时 3.56×10^{-2} 对 6.49×10^{-2}）；样本量从 200 增到 20000 时 LSTD 从 1.75×10^{-1} 降到 1.64×10^{-2}，而 TD 停在 5×10^{-2} 附近。代价有三条：每步 $O(d^2)$ 比 TD 的 $O(d)$ 贵；“永不遗忘”，环境非平稳时失效；λ 没有像步长那样直观的调节手段。

LSTD 与 TD 解的是**同一个不动点** $A\theta = b$，区别只在闭式解与随机迭代：“LSTD 比 TD 准”是估计效率之争，不是理论之争；“两者在离策略下都可能发散”也一样——(4.19) 的负特征值对 LSTD 同样致命，只是把发散变成“矩阵近奇异、解剧烈震荡”。

4.5.2 拟合 Q 迭代

把策略评估换成最优控制，得到**拟合 Q 迭代**（fitted Q iteration，FQI）：

$$Q_{k+1} = \arg\min_{Q \in \mathcal{F}} \sum_{i=1}^{n} \Big(r_i + \gamma \max_{a'} Q_k(s_i', a') - Q(s_i, a_i) \Big)^2 \tag{4.27}$$

$\mathcal{F}$ 是假设空间。FQI 是**批量**的：每轮用整个数据集解一个回归，不涉及步长；表格情形退化为值迭代，参数化情形则是“带投影的值迭代”。因此误差界与 (4.18) 同族，但多一项拟合误差。若每轮的回归误差在 sup-范数下不超过 ϵ，则（[近似]，有限 MDP、$\gamma < 1$、足够多轮迭代、$\mathcal{F}$ 在 sup-范数下有界）

$$\limsup_{k \to \infty} \|V_k - V^*\|_\infty \le \frac{2\gamma}{(1-\gamma)^2} \epsilon \tag{4.28}$$

SUMMARY / 总结

(4.28) 是 Munos–Szepesvári 型结果，因子 $1/(1-\gamma)^2$ 比 (4.23) 差一个 $1/(1-\gamma)$：每轮投影都引入新误差并被压缩映射放大一次。它同样要求 sup-范数，不能换成 MSE。

FQI 的困难都在回归上：目标依赖上一轮的 Q，轮与轮之间漂移；$\max$ 使目标向上偏；数据来自固定行为策略时，(4.27) 解出的只是该分布下的最优近似——这与第 4.2 节的分布偏移是同一件事的批量版本。

4.5.3 神经网络：失去闭式解之后

把 $\mathcal{F}$ 换成神经网络，三条保证同时消失。第一，**没有闭式解**：非线性下 (4.27) 只能用 SGD 迭代，写不成 $A\theta = b$。第二，**没有投影矩阵**：网络的值函数像不是线性子空间，Π_D 无定义，MSPBE 与 (4.21) 随之失效，能写的只有 MSBE 或 BE。第三，**没有正定性论证**：(4.17) 依赖 $v = \Phi u$ 的线性结构，非线性时 A 这个矩阵不存在，稳定性只能靠架构设计（目标网络、梯度裁剪、层归一化）维持。

于是深度值方法的实际目标退回到采样平方 TD 误差：

$$\theta \leftarrow \theta - \alpha\big(V_\theta(S_t) - y_t\big)\nabla_\theta V_\theta(S_t), \qquad y_t = R_{t+1} + \gamma V_{\theta^-}(S_{t+1}) \tag{4.29}$$

(4.29) 与 (4.3) 形式相同，上下文全变了：θ^- 让目标滞后，回放让数据近 i.i.d.，两者都不是理论保证，只是把“三要素齐备”的危险压到可接受的程度。这里存在明确的能力-稳定性权衡：网络越强越能逼近复杂的 V^π，但越容易在自举反馈下失稳；把网络改小、目标更新变慢都能换来稳定，代价是 (4.28) 的 ϵ 变大——第 6 章会看到这条权衡在每个工程选择里反复出现。

4.5.4 本章的位置，与下一章的问题

回到出发点。第 3 章用表格把“给定策略、估计价值”做到精确；本章换成共享参数，换来泛化与样本效率，代价是三层：目标不可直接计算、分布可能不匹配、算子可能不正定。

这三层困难有共同根源：我们一直在**估计价值**，而价值只是由策略与环境共同决定的中间量。评估得再准，也只回答“这个策略值多少”，不回答“哪个策略最好”；在连续动作空间里 $\arg\max_a Q(s,a)$ 本身就是优化问题，每步内层再套一层，代价与不稳定性叠加。第 5 章因此换问题：直接对策略参数求梯度。本章的结论不会丢弃——策略梯度仍要价值函数做基线，而基线仍由本章方法估计，分布偏移会以“行为策略与目标策略之差”的形式回来。

SUMMARY / 总结

本章小结

函数逼近把“一个状态一个数”换成共享参数的 d 维表示，换来泛化与样本效率，代价是三件事同时发生：贝尔曼算子的像落在参数族外（目标不可直接算）、采样分布可能与目标策略不匹配（分布偏移）、更新算子可能不正定（稳定性）。前半章把这三件事拆开讲：目标函数 $\mathrm{VE}(\theta)=\|V_\theta-V^\pi\|_\mu^2$ 必须先说清 μ，它决定最优参数也决定收敛性，本章所有收敛结论都以 $\mu=d^\pi$ 为前提；半梯度 TD 丢掉了自举目标对参数的依赖项，因此不是任何标量函数的负梯度，也就不继承梯度下降的稳定性保证，但它有自己的不动点。致命三要素（函数逼近、自举、离策略）给出的是**发散的可能**而非必然，Baird 反例是构造出来的存在证据，而 on-policy 分布下的定理说明同一更新式换个分布仍然可证。

后半章把直觉变成定理，再划出定理的边界。线性情形的不动点由法方程 $A\theta^*=b$ 刻画，其中 $A=\Phi^\top D(I-\gamma P^\pi)\Phi$；$\mu=d^\pi$ 时 A 正定，再加上满列秩、遍历性与 Robbins–Monro 步长，随机迭代才渐近收敛到 θ^*——这是随机逼近定理的应用，不能压缩成“TD 收敛”。存在不动点不等于收敛到它，$\mathrm{VE}(\theta^*)\le\frac{1}{1-\gamma}\min_\theta\mathrm{VE}(\theta)$ 是最优性界而不是收敛性定理，三个 Bellman 误差（残差、MSBE、MSPBE）的投影、分布与可优化性各不相同，不能互相替代。第 5 章从这里换问题：不再估价值再取最大，而是直接对策略参数求梯度；第 6 章则与第 4.4 节合流——回放、目标网络与双网络都不是理论保证，只是把三要素齐备的风险压到可以接受的程度。

关键公式

下面六组式子是本章的主干，顺序与正文一致：目标与半梯度更新、投影、法方程、正定性与最优性界、MSPBE 与 sup-范数残差界、LSTD 与拟合 Q 迭代。前提（线性空间、满列秩、$\mu=d^\pi$）写在各自小节里，这里只留式子。

$$\mathrm{VE}(\theta)=\|V_\theta-V^\pi\|_\mu^2,\qquad \theta_{t+1}=\theta_t+\alpha\delta_t\nabla_\theta V_\theta(S_t)$$

$$\|v\|_D^2=v^\top Dv,\qquad \Pi_D=\Phi(\Phi^\top D\Phi)^{-1}\Phi^\top D$$

$$\Phi\theta^*=\Pi_D T^\pi\Phi\theta^*,\qquad A\theta^*=b,\quad A=\Phi^\top D(I-\gamma P^\pi)\Phi,\quad b=\Phi^\top Dr^\pi$$

$$u^\top Au\ \ge\ (1-\gamma)\|\Phi u\|_\mu^2>0,\qquad \mathrm{VE}(\theta^*)\le\frac{1}{1-\gamma}\min_\theta\mathrm{VE}(\theta)$$

SUMMARY / 总结

$$\overline{\mathrm{MSPBE}}(\theta) = (A\theta - b)^\top C^{-1}(A\theta - b), \quad C = \Phi^\top D \Phi, \qquad \|V - V^*\|_\infty \le \frac{\|V - T^*V\|_\infty}{1-\gamma}$$

$$\theta_t = A_t^{-1} b_t, \qquad Q_{k+1} = \arg\min_{Q \in \mathcal{F}} \sum_i \big(r_i + \gamma \max_{a'} Q_k(s_i', a') - Q(s_i, a_i)\big)^2$$

习题

4.1（推导法方程）从投影不动点方程 $\Phi\theta^* = \Pi_D T^\pi \Phi\theta^*$ 出发，不引用任何结论，逐步推出 $A\theta^* = b$ 及 A、b 的表达式。你的推导必须说明每一步用了 Π_D 的哪条性质，并指出 A 可逆所需的条件。

4.2（投影矩阵）验证 (4.11) 定义的 Π_D 满足 $\Pi_D^2 = \Pi_D$ 与 $\Pi_D \Phi = \Phi$，并证明它在 D-内积下自伴。进一步证明：残差 $v - \Pi_D v$ 与列空间正交，从而 $\Pi_D v$ 是列空间中的最近点。

4.3（MSPBE 的二次型）利用 $A\theta - b = \Phi^\top D(T^\pi V_\theta - V_\theta)$ 与 Π_D 的表达式，证明 (4.21)。再用它说明：MSPBE 的最小点唯一且等于 $A^{-1}b$。

4.4（正定性的两处前提）重读 (4.17) 的证明，指出它用到“μ 是 π 的平稳分布”与“Φ 满列秩”的哪一步。若把 μ 换成均匀分布，构造一个两状态反例使 $u^\top A u < 0$。

4.5（表格是特例）取 $\phi(s) = e_s$（$d = N$），写出 A 与 b 的具体形式，验证 $A\theta = b$ 的解就是表格 TD(0) 的不动点 V^π。再说明此时 (4.18) 的界退化成什么。

4.6（Baird 的谱）在 Baird 反例中，π 恒选实线，故 P^π 的每一行都是第七个状态的 one-hot 向量，D 为均匀分布。写出 $A = \Phi^\top D(I - \gamma P^\pi)\Phi$ 的 8×8 形式，验证它有一个负特征值，并由此给出“对任意 $\alpha > 0$ 都发散”的论证。

4.7（步长地板）常步长 TD 收敛到 θ^* 的邻域而非 θ^* 本身。设 A 的特征值为 $\lambda_i > 0$，把误差 $e_t = \theta_t - \theta^*$ 的递推写成 $e_{t+1} = (I - \alpha A)e_t + \alpha \varepsilon_t$，给出稳态误差方差与 α 的关系，并解释表 4-1 中 $d \ge 4$ 后误差不再随特征数下降的现象。

4.8（分布偏移的界）设 $\mathrm{TV}(d^\pi, d^b) = \delta$，值函数有界 $\|V\|_\infty \le V_{\max}$。给出用 δ 与 $V_{\max}$ 表示的两个分布下 VE 之差的界，并用实验 2b 的数值（$\delta = 0.2588$）检验这个界是否紧。

延伸阅读

下列文献的原文都在 source/text 目录中，Sutton & Barto 的教材全文也在其中。先读第 9 章的半梯度与误差界，再读第 11.3 – 11.7 节，那是本章后半的直接来源。

- Sutton & Barto, Reinforcement Learning: An Introduction (2nd ed.)，第 9 章讲半梯度方法与线性情形的不动点和误差界，第 11 章讲致命三要素、Baird 反例、投影几何与 GTD。
- Baird (1995), Residual Algorithms: Reinforcement Learning with Function Approximation：反例的原始出处，也是“残差梯度收敛但收敛点差”这一现象的最早系统讨论。
- Tsitsiklis & Van Roy (1997), An Analysis of Temporal-Difference Learning with Function Approximation：线性 TD 收敛性的严格分析，本章第 4.3.4 节定理的经典来源。
- Sutton, Maei, Precup, Bhatnagar, Silver, Szepesvári, Wiewiora (2009a), Fast Gradient-Descent Methods for Temporal-Difference Learning with Linear Function Approximation：GTD2 与 TDC，MSPBE 的真梯度构造。
- Sutton, Maei, Precup (2009b), A Convergent O(d) Algorithm for Off-policy Temporal-Difference Learning with Linear Function Approximation：GTD(0)，离策略收敛的第一个 $O(d)$ 算法。
- Lagoudakis & Parr (2003), Least-Squares Policy Iteration；Ernst, Geurts, Wehenkel (2005), Tree-Based Batch Mode Reinforcement Learning：LSTD 与 FQI 的原始文献，批量方法的工程细节。
- Munos & Szepesvári (2008), Finite-Time Bounds for Fitted Value Iteration：本章 (4.28) 的来源，也是“拟合误差如何被 $1/(1-\gamma)^2$ 放大”的标准陈述。

第 5 章　策略梯度、信赖域与 PPO

前面几章都在想办法把价值估准：知道了 Q，决策就是取最大。这一手在动作离散、估值可靠时够用，却有两处绕不过去。动作是连续的（力矩、关节角、下一个 token）时，$\arg\max_a Q(s,a)$ 没有闭式解，每一步都要另解一个优化；最优行为本身就随机时（对手博弈、部分可观测），“取最大”根本表达不出来。策略直接表示给定状态下的动作分布，价值函数主要用于评估和优化。

策略梯度直接对带参数的策略分布 $\pi_\theta(a \mid s)$ 进行优化，目标是提高高回报动作的概率。难点在于动作价值未知，学习者只能获得采样回报；同一条轨迹中的多个动作共享回报信号，不同随机轨迹的回报也会变化。本章将说明如何用采样回报估计策略梯度，并控制估计的方向和更新幅度。

若已熟悉第 3 章的回报、蒙特卡洛与 TD 目标，并能求标量函数的导数，就有了读本章所需的数学。三条线索依次是：策略梯度定理把“调概率”写成可采样的梯度（须 on-policy）；5.2 节把“这条轨迹总分高”换成“这个动作比平均好多少”，再用 GAE 平衡偏差与方差；5.3、5.4 节用信赖域与裁剪控制更新幅度，但两者保证强度不同。

本章分别标明理论恒等式、条件性近似与经验算法的证明强度。策略梯度定理、基线恒等式、性能差恒等式都是 **[精确]** 的恒等式；TRPO 拿性能差恒等式做优化时，把 $d^{\pi'}$ 换成了 $d^{\pi_{\text{old}}}$，于是只剩 **[近似]**；PPO 的裁剪目标连近似都算不上，它是 **[经验规律]** 层面的工程启发式。PPO的训练稳定性还取决于优势估计、采样分布、学习率、裁剪参数及实现细节。

5.1 策略梯度定理

5.1.1 目标函数与似然比技巧

先把“好”写成数字。策略跑出一条轨迹 $\tau = (s_0, a_0, s_1, a_1, \ldots)$，把轨迹上的折扣回报加起来记作 G_τ，目标是它的期望

$$J(\theta) = \mathbb{E}_{\tau\sim p_\theta}\Big[G_\tau\Big], \qquad G_\tau = \sum_{t\ge 0}\gamma^t R_{t+1}. \tag{5.1}$$

这一步没有新东西，只是把第 2 章的 $J(\pi) = \mathbb{E}_{s_0\sim\rho_0}[V^\pi(s_0)]$ 按轨迹展开，两者逐项相等。写成轨迹形式的好处是参数的依赖被集中到一处；麻烦也在这里，因为 p_θ 同时含策略与转移核，

SUMMARY / 总结

$$p_\theta(\tau) = \rho_0(s_0) \prod_{t \ge 0} \pi_\theta(a_t \mid s_t)\, P(s_{t+1} \mid s_t, a_t). \tag{5.2}$$

直接求导会得到 $\nabla_\theta J = \sum_\tau G_\tau \nabla_\theta p_\theta(\tau)$，而 $\nabla_\theta p_\theta(\tau)$ 里含 $\nabla_\theta P$——模型未知时这个量算不出来，此路不通。

绕过去的办法是似然比技巧（也叫得分函数技巧）：$\nabla_\theta p_\theta = p_\theta \nabla_\theta \log p_\theta$。取对数之后连乘变求和，而式 (5.2) 里只有策略项含 θ，转移核与初始分布求导即消失，

$$\nabla_\theta \log p_\theta(\tau) = \sum_{t \ge 0} \nabla_\theta \log \pi_\theta(a_t \mid s_t), \tag{5.3}$$

代回去，梯度变成“轨迹上各步得分函数之和，用整条轨迹的回报加权”：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta}\Big[G_\tau \sum_{t \ge 0} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \Big]. \tag{5.4}$$

式 (5.4) 已经可以采样：按当前策略跑若干回合，把每条轨迹的回报乘上各步得分函数求和，取平均就是无偏估计。但它的方差大到不好用，原因很具体——整条轨迹共用一个 G_τ。第 0 步与第 100 步的动作被同一个数放大或缩小，回合越长，这个数越接近“整局运气”，梯度就越像噪声。后面几节做的事本质相同：把这个粗粒度的权重换细。先只算 t 之后的回报，再减掉一个基线，最后把基线换成学出来的价值函数。

5.1.2 两种等价写法与那个归一化因子

同一个梯度有两种写法：一种把期望写在轨迹上，一种拆成“先按状态分布取 s、再按策略取 a”。它们是同一个梯度的两副面孔，但归一化因子不同，混用会直接错掉一个 $1/(1-\gamma)$ 的尺度。

先约定记号。未归一化的占用测度

$$d_\gamma^\pi(s) = \sum_{t \ge 0} \gamma^t \Pr_\pi(s_t = s \mid s_0 \sim \rho_0), \qquad \sum_s d_\gamma^\pi(s) = \frac{1}{1-\gamma}, \tag{5.5}$$

未归一化测度的总质量为 $1/(1-\gamma)$，这是折扣访问次数的几何级数之和；γ 越接近 1，总质量越大。归一化版本记作 $\bar{d}_\gamma^\pi = (1-\gamma) d_\gamma^\pi$，其总质量为 1，因此是概率分布。第 2 章的式 (2.8) 使用归一化版本，但仍记作 d_γ^π；本章按 `_CONVENTIONS.md` 区分两种记号。因子 $1/(1-\gamma)$ 对应两种占用测度之间的换算，不改变目标函数。

有了

SUMMARY / 总结

d_γ^π，策略梯度定理把式 (5.4) 改写成对状态与动作的两重求和：

$$\begin{aligned}\nabla_\theta J(\theta) &= \sum_s d_\gamma^{\pi_\theta}(s) \sum_a \nabla_\theta \pi_\theta(a \mid s)\, Q^{\pi_\theta}(s,a) \\ &= \sum_s d_\gamma^{\pi_\theta}(s) \sum_a \pi_\theta(a \mid s)\, \nabla_\theta \log \pi_\theta(a \mid s)\, Q^{\pi_\theta}(s,a).\end{aligned} \tag{5.6}$$

若改用归一化测度，同一个梯度必须写成

$$\nabla_\theta J(\theta) = \frac{1}{1-\gamma}\, \mathbb{E}_{s\sim \bar{d}_\gamma^{\pi_\theta},\, a\sim\pi_\theta}\Big[\nabla_\theta \log \pi_\theta(a \mid s)\, Q^{\pi_\theta}(s,a)\Big]. \tag{5.7}$$

两式严格相等：把 $\log$ 的梯度换回 $\nabla\pi/\pi$，π 与 $1/\pi$ 相消，再用 $\sum_s d_\gamma^\pi = \frac{1}{1-\gamma}\sum_s \bar{d}_\gamma^\pi$ 即可。常见的错误是取了 $\bar{d}$ 却漏掉因子，这等价于把目标悄悄换成了 $(1-\gamma)J$：梯度方向没变，但步长的含义变了，学习率、裁剪阈值、KL 阈值的标定随之全部错位。要省掉这个因子，唯一正当的做法是显式声明“以下优化 $(1-\gamma)J$”。

再把轨迹形式也写成占用测度形式，以便看清三者关系。把 G_τ 拆成从 t 时刻起的折扣回报 G_t，注意轨迹分布下 s_t 的边际概率是 $\Pr_\pi(s_t = s)$，于是

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau\Big[\sum_{t\ge 0} \gamma^t G_t\, \nabla_\theta \log \pi_\theta(a_t \mid s_t)\Big], \tag{5.8}$$

其中 γ^t 这个权重不能省。它来自 $\sum_t \gamma^t \Pr(s_t = s) = d_\gamma^\pi(s)$：只有带上 γ^t，把式 (5.8) 对 t 求和才能还原成式 (5.6)。把 γ^t 写成“每步等权”，优化的是未折扣目标；在 γ 接近 1 的任务上两者差别不大，但它们是两个不同的目标，不能当作同一条式子互换。

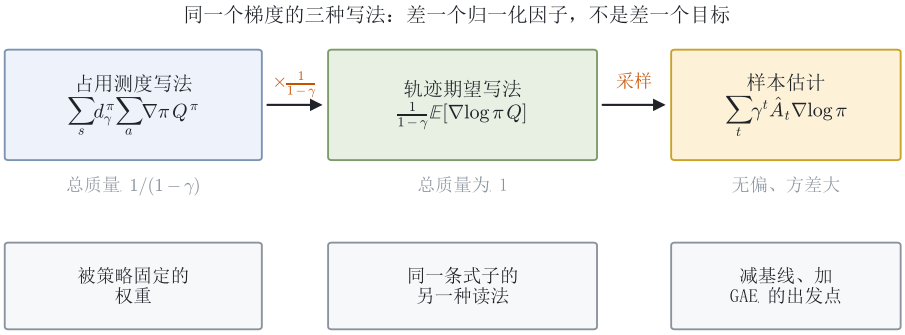


图 5-1 同一个策略梯度的三种写法。占用测度、对归一化分布的期望、样本平均，三者只差归一化因子与采样方式，不是三个不同的目标。

图 5-1 对照了策略梯度的三种写法：改变的是期望的表示和估计方式，

目标保持不变。样本估计的方差通常较大。第 5.2 与 5.4 节介绍的基线、优势和裁剪分别通过降低方差或以有限偏差换取较低方差改善估计。

> **定理 5.1（策略梯度定理 [精确]）**
>
> 设策略 $\pi_\theta(a \mid s)$ 对 θ 可微，且 $\nabla_\theta \pi_\theta$ 有界。则对折扣目标 (5.1)，式 (5.6) 成立：梯度等于占用测度加权的优势方向之和，其中 $d_\gamma^{\pi_\theta}$ 取式 (5.5) 的未归一化版本；若改用归一化测度，右端必须乘 $1/(1-\gamma)$。该式中的 $d_\gamma^{\pi_\theta}$ 本身依赖 θ，但它的**梯度**不出现在结果里——这是定理的全部内容。

式 (5.6) 写的是 Q^π 而不是 A^π：两者只差一项与动作无关的基线，由基线恒等式 (5.10) 其梯度从 Q^π 换成 A^π 不改变结果，所以定理陈述里的“优势”与式中的“动作价值”是同一件事的两种写法。

定理 5.1 最容易被读成“梯度与状态分布无关”。精确的说法是：分布 $d_\gamma^{\pi_\theta}$ 依赖 θ，但它对 θ 求导的那一项与其余项恰好抵消。Sutton 与 Barto 的证明走的是先对 V^π 用乘积法则、再对 ∇Q^π 反复展开的路线，展开后每一步的 P^π 与 π 重新组合，最终坍缩成一句“从 s 出发、按 π 走 k 步到达 x 的概率乘以 γ^k”，求和即得占用测度（Sutton & Barto, 2018, 第 13.2 节）。

离策略策略梯度估计可能需要重要性权重或其他校正，其方差与轨迹长度及分布差异有关。定理里的 $d_\gamma^{\pi_\theta}$ 是目标策略自己的占用测度，用行为策略 μ 采到的数据估计它，必须乘上重要性比率 π_θ/μ 的连乘；连乘的方差随回合长度指数增长，这是第 4 章离策略学习困难的另一种面孔。PPO 通常使用当前策略采集的数据，以避免长轨迹重要性比率连乘带来的高方差。

5.1.3 REINFORCE 与基线

把式 (5.8) 的期望换成样本平均，就得到最古老的策略梯度算法。对一条完整轨迹，用 G_t 代替 G_τ——只用 t 之后的回报，因为 t 之前的奖励与 a_t 无关——得到 REINFORCE 的更新

$$\theta \leftarrow \theta + \alpha\, \gamma^t G_t\, \nabla_\theta \log \pi_\theta(a_t \mid s_t), \tag{5.9}$$

其中 α 是学习率。相对于基线的正优势会使策略梯度倾向于提高相应动作的概率，负优势则倾向于降低该概率。回报 G_t 的方差可能随回合长度增加；零基线不能扣除不同状态的共同回报部分，因此估计方差可能较高。

减基线就是给权重减去一个只依赖状态的量 $b(s)$。它不改变期望，理由是一行代数：

SUMMARY / 总结

$$\mathbb{E}_{a\sim\pi_\theta}\big[\nabla_\theta \log \pi_\theta(a\mid s)\, b(s)\big] = b(s)\sum_a \nabla_\theta \pi_\theta(a\mid s)$$
$$= b(s)\,\nabla_\theta \underbrace{\sum_a \pi_\theta(a\mid s)}_{=1} = 0. \tag{5.10}$$

最后一步是关键：策略对动作求和恒为 1，常数的梯度为零。这个恒等式对**任意**只依赖 s 的 b 成立，不要求 b 与策略有关：b 可以是任何不随动作变化的量，甚至随机变量。于是

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau\Big[\sum_{t\ge 0}\gamma^t\big(G_t - b(s_t)\big)\nabla_\theta \log \pi_\theta(a_t\mid s_t)\Big] \tag{5.11}$$

对任意**只依赖状态**的 b 都是无偏的。取 $b(s)=V^\pi(s)$ 时权重正好是优势 $A^\pi(s,a)$，方差最小；取学出来的 $b(s)=V_\phi(s)$ 在实践中几乎一样好——它**不改变梯度的期望**，代价只是优势估计带上 critic 的误差。这两句要分清楚：无偏性只要求基线不依赖动作，不要求 critic 准（命题 5.1 与命题 B 的分工见 5.2.1 节）。还有一条边界：上面全部结论只对式 (5.11) 的**蒙特卡洛权重** G_t 成立。把 G_t 换成自举的 δ_t 后，$V_\phi(s_{t+1})$ 的误差会经转移核变成动作相关项，梯度就不再无偏，分界见 5.2.3 节末。

算法 5-1 REINFORCE（带基线）

输入：可微策略 π_θ，基线 $b(s)$（可为 0、V^π 或 V_ϕ），学习率 α
for 每条轨迹 **do**
  按 π_θ 从 $s_0\sim\rho_0$ 采样，得 $(s_0,a_0,r_1,\dots,s_T)$
  计算 $G_t=\sum_{k\ge t}\gamma^{k-t}r_{k+1}$，$t=0..T-1$
  for $t=0..T-1$ **do**
    $\theta\leftarrow\theta+\alpha\,\gamma^t\,(G_t-b(s_t))\,\nabla_\theta\log\pi_\theta(a_t\mid s_t)$
  end for
end for
注：b 只依赖状态；$b(s)=0$ 即原始 REINFORCE

算法 5-1 里有一个实现细节：γ^t 这个因子在多数开源实现中被省略，因为学习率可以吸收它——但只有在“所有轨迹等长”或“目标本来就是未折扣”时，这种省略才不改变优化对象。本书的写法保留它，以便与式 (5.8) 严格对应。

SUMMARY / 总结

5.2 优势、Actor-Critic 与 GAE

5.2.1 两个关于“无偏”的命题

实践中流传一句话：“减去基线不引入偏差，所以用学出来的 V_ϕ 也没问题。”这句话的结论是对的，推理却常常是错的：人们把“策略梯度无偏”当成了“优势估计无偏”。两者是不同层次的对象，条件也不同，混在一起会得出两种相反的错误结论——要么以为 critic 一错梯度就偏，于是不敢用学出来的价值；要么以为优势无偏就万事大吉，于是拿一个错得离谱的 critic 去做诊断。

先看优势估计。给定 V_ϕ 与从 (s_t, a_t) 出发的真实回报 G_t，

$$\mathbb{E}\big[G_t - V_\phi(s_t) \mid s_t, a_t\big] = Q^\pi(s_t, a_t) - V_\phi(s_t). \tag{5.12}$$

只要 G_t 是真实的折扣回报，右端就精确等于 $Q^\pi - V_\phi$，与 V_ϕ 准不准无关。它等于优势 $A^\pi = Q^\pi - V^\pi$ **仅当** $V_\phi = V^\pi$；否则它是一个“半真半假”的量：动作那一半是准的，状态那一半带着 critic 的误差。所以命题 A 的正确表述是“优势估计在给定 V_ϕ 时无偏地估计 $Q^\pi - V_\phi$”，而不是“A 无偏”。

> **命题 5.1（优势估计的无偏性 [精确]）**
>
> 对任意函数 V_ϕ 与任意状态—动作对 (s, a)，式 (5.12) 成立。因此 $G_t - V_\phi(s_t)$ 是 $A^\pi(s, a)$ 的无偏估计，当且仅当 $V_\phi = V^\pi$。当 $V_\phi \neq V^\pi$ 时，误差为 $V^\pi(s) - V_\phi(s)$，只依赖状态、不依赖动作。

再看策略梯度。把 $b = V_\phi$ 代入式 (5.10)——那个恒等式对任意 $b(s)$ 都成立，包括错的 b。于是即便 V_ϕ 完全不准，

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau\Big[\sum_{t\geq 0} \gamma^t \big(G_t - V_\phi(s_t)\big) \cdot \nabla_\theta \log \pi_\theta(a_t \mid s_t)\Big] \tag{5.13}$$

求和之后仍然成立（在 on-policy 采样、G_t 无偏这两个条件下）。**这就是命题 B**：策略梯度估计无偏，只要求基线不依赖动作，不要求 critic 精确。两者条件不同、结论也不同：把它俩混成一句“GAE 无偏所以策略梯度无偏”，既低估了命题 B 的适用范围（它对任意基线都成立），也高估了命题 A 的适用范围（它对错误的 critic 不成立）。

两个命题合起来给出一条准则：critic 的作用是**降方差**，不是**保无偏**。只要基线只依赖状态，偏差就进不了梯度；反过来，任何让基线依赖动作的改动都会立刻引入偏差。

SUMMARY / 总结

5.2.2 Actor-Critic：一份数据，两个学习率

式 (5.11) 仍然要等回合结束才能算 G_t。把 G_t 换成自举形式，就能每步更新：用一步 TD 误差

$$\delta_t = R_{t+1} + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) \tag{5.14}$$

代替 $G_t - V_\phi(s_t)$，得到

$$\theta \leftarrow \theta + \alpha_\theta \, \delta_t \nabla_\theta \log \pi_\theta(a_t \mid s_t), \qquad \phi \leftarrow \phi + \alpha_\phi \, \delta_t \nabla_\phi V_\phi(s_t). \tag{5.15}$$

两个更新共用一个 δ_t，这是 Actor-Critic 的结构性特征：一个误差信号同时驱动两个学习器，actor 用它调节动作概率，critic 用它修正价值估计（Sutton & Barto, 2018，第 13.5 节）。critic 需要随策略变化跟踪 V^{π_θ}，actor 则沿策略梯度更新参数，因此两者的学习率可以不同。

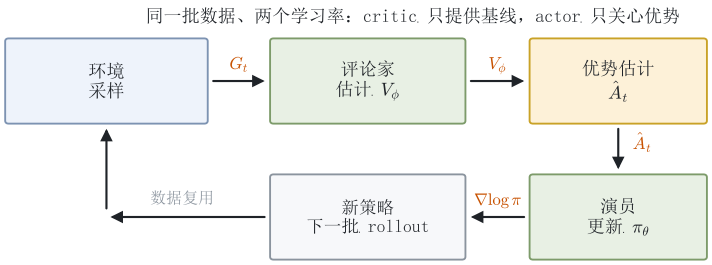


图 5-2 画的就是这个闭环。注意图中“critic 的梯度”与“actor 的梯度”走同一条箭头：δ_t 既是 critic 的回归残差（对 $V_\phi(s_t)$ 的平方误差求导恰好得 $-\delta_t$），也是 actor 的权重。一份误差两用是效率的来源，也是偏差的来源：命题 B 只对式 (5.11) 的 MC 权重成立，δ_t 版本带来的是偏差，不只是方差。

critic 的目标有两种写法。第一种是蒙特卡洛回归，目标取 G_t，无偏但方差大；第二种是自举回归，目标取 $R_{t+1} + \gamma V_\phi(s_{t+1})$，方差小但目标本身依赖 ϕ（半梯度），并且引入偏差。PPO 原文用的是后者，损失是平方误差

$$L^{VF}(\phi) = \mathbb{E}_t\left[\left(V_\phi(s_t) - V_t^{\text{targ}}\right)^2\right], \tag{5.16}$$

其中 V_t^{targ} 由采样时的旧参数算出、在整轮更新中保持不变（stop-gradient），否则 critic 会追着自己的尾巴跑（Schulman 等, 2017, 式 (9)）。这一点在实现中极易出错：若把 V^{targ} 当成可微的量一起优化，平方误差可

以被“把两边一起拉大”这种退化解压低。

5.2.3 广义优势估计

单步 TD 误差偏差大（它只看一步），蒙特卡洛回报方差大（它看完整回合），两者之间的插值是 n 步回报，而 GAE 是它的指数加权版本。写成递推形式，计算方便，也便于看清 λ 的作用：

$$\hat{A}_t = \delta_t + \gamma\lambda\,\hat{A}_{t+1}, \qquad \hat{A}_t = \sum_{l\geq 0}(\gamma\lambda)^l\,\delta_{t+l}, \qquad \lambda \in [0,1]. \tag{5.17}$$

$\lambda = 0$ 时 $\hat{A}_t = \delta_t$，退化为单步 TD 误差；$\lambda = 1$ 时把递推展开，相邻项中的 γV_ϕ 逐项相消（望远镜消去），回到蒙特卡洛权重 $G_t - V_\phi(s_t)$，只剩

$$\hat{A}_t\big|_{\lambda=1} = G_t - V_\phi(s_t), \tag{5.18}$$

这个消去要用到一个隐含条件：尾部项必须归零，即 $\lim_{L\to\infty}(\gamma\lambda)^L V_\phi(s_{t+L}) = 0$。回合在终止处令 $V(\text{terminal}) = 0$ 时它自动成立；无限时程则需 $\gamma < 1$ 且 V_ϕ 有界。少了这一条，级数是发散的和，(5.18) 就只是一条近似。

与 5.2.1 节的蒙特卡洛优势估计完全相同。这个望远镜求和有一个重要推论：**$\lambda = 1$ 时偏差与 critic 的精度无关**。无论 V_ϕ 多离谱，$G_t - V_\phi(s_t)$ 都只差一个状态函数，而状态函数进不了梯度（命题 B）。反过来，$\lambda < 1$ 时自举把 V_ϕ 的误差乘进了优势，误差不再是一个纯粹的状态函数，偏差就出现了。

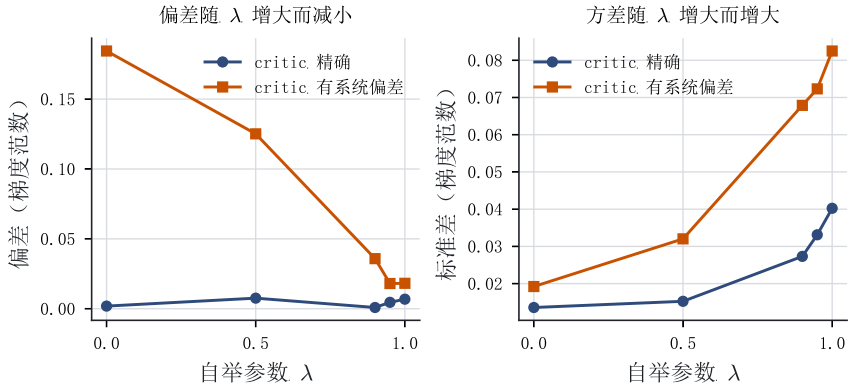


图 5-3 偏差与方差随 λ 的变化（4 状态链式 MDP，γ=0.9，30 次重复、每次 80 条轨迹）。左图偏差随 λ 从 0.18 降到 0.02，右图标准差从 0.014 升到 0.040。

图 5-3 是这个说法的实验版。任务仍是那个可精确求解的 4 状态链式 MDP（$\gamma = 0.9$，初始策略为均匀 softmax，真值由占用测度解析算出），用

30 次独立重复、每次 80 条轨迹估计梯度，与解析梯度比范数。左图两条线对应两种 critic：精确的 V^{π}，以及被放大 1.6 倍的错误 critic。结果与理论一致：错误 critic 的偏差随 λ 从 0.18 单调降到 0.02（$\lambda = 1$ 时只剩采样噪声），精确 critic 的偏差始终在噪声量级；方差则随 λ 单调上升（0.014 升到 0.040）。这也是 $\lambda \approx 0.95$ 成为默认值的理由：偏差已经很小，方差还没到不可接受。

式 (5.17) 的第二行是无限和，实践中按轨迹段截断：段末为终止状态时余项为零；为截断（时间上限）时必须保留对 $V_{\phi}(s_T)$ 的自举，否则把“还有未来”当成“没有未来”。这一偏差与动作无关，会被基线吸收一部分，因而更难察觉。

到这里，“偏差”这个词已经出现了三次，必须分开：**自举偏差**来自 $\lambda < 1$，与 V_{ϕ} 的精度绑定；**折扣偏差**来自 $\gamma < 1$——原文明确指出，只要 $\gamma < 1$，梯度估计相对**未折扣**目标本身就带偏差，与 V 准不准无关；**截断偏差**来自时间上限，见上段。本章从头到尾优化的是折扣目标 (5.1)，所以只把第一种计入“偏差”；换到未折扣任务时，第二种就是第一位的误差源，加多少基线都消不掉。

还有一条分界线值得单独写清楚，因为它决定命题 B 能用在哪里。命题 B 的对象是式 (5.11) 的**蒙特卡洛权重** $G_t - b(s_t)$：把 b 换成任意状态函数，权重只差一个 s_t 的函数，乘上 $\nabla \log \pi$ 后对动作求和为零。一旦把 G_t 换成自举的 $\delta_t = R_{t+1} + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)$，$V_{\phi}(s_{t+1})$ 带的是**下一个状态**的估值误差；经转移核 $P(s_{t+1} \mid s_t, a_t)$ 平均后它依赖 a_t，不再是与动作无关的状态函数，求和不为零——**一步 Actor-Critic 的 δ_t 版本因此确有偏**。这正是 GAE 原文说 δ^V 只在 $V = V^{\pi,\gamma}$ 时是 γ-just、否则会给出有偏梯度估计的意思，与命题 B 并不矛盾：命题 B 说的是带状态基线的梯度**期望**不变，原文说的是**优势估计量**本身有偏。

SUMMARY / 总结

5.3 信赖域与 TRPO

5.3.1 一步走多远

策略梯度只规定了方向，没规定步长。方向对而步长过大，目标会先升后降：参数走出局部近似有效的区域后，Q^{π_θ} 已经不能代表新策略的价值。用一个可精确求解的小任务把这件事量化：4 状态链式 MDP，$\gamma = 0.9$，softmax 表格策略，每轮采 6 条轨迹、用 GAE($\lambda = 0.95$) 估计梯度，只跑一个 epoch，扫描学习率。

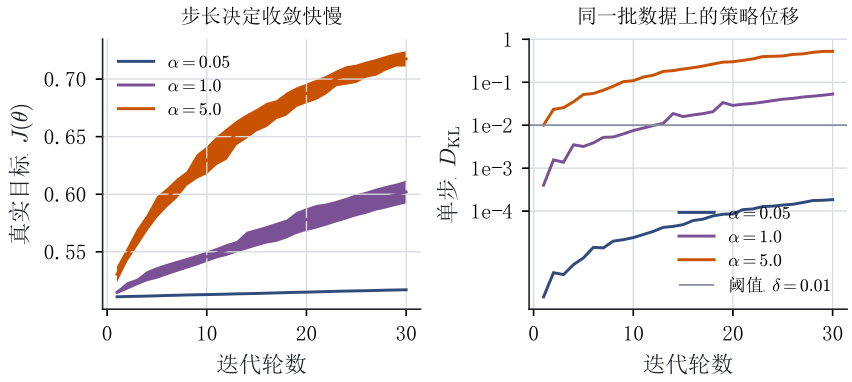


图 5-4 步长与单步策略位移。左图：三种步长下的真实目标 J(θ)（阴影为 8 个种子的标准差，每个种子 30 轮、每轮 6 条轨迹）。右图：同一批数据上相邻两轮策略的 KL 散度，虚线是常见信赖域阈值 δ=0.01。步长放大 100 倍，单步位移放大约三个数量级，而目标只多涨了 0.2。

结果见图 5-4：$\alpha = 0.05$ 时 30 轮后 $J = 0.517$、KL 中位数 5.6×10^{-5}；$\alpha = 1.0$ 时 $J = 0.597$、KL 1.5×10^{-2}，已越过 $\delta = 0.01$；$\alpha = 5.0$ 时 $J = 0.713$、KL 0.22。该实验还显示：在这个单峰任务上，即使最大的步长也没有让 J 塌陷，目标始终单调上升。原因是该任务的最优策略是角点解，朝正确方向走多远都是改进。真实任务不是这样——网络参数共享、奖励带噪声、优势估计有偏，一次过大的更新会把策略推到“事后看来很差”的区域，并且由于后续数据全部由新策略产生，这种错误很难被纠正回来。PPO 原文的出发点是同一句话：步长过大时“策略很可能移动到旧策略很远的地方，导致性能塌陷”（Schulman 等, 2017, 第 1 节）。

图 5-4 右图的 KL 是比“参数变化量”更好的位移度量：参数空间的距离与行为差异并不成正比，某些方向参数改动很小而策略天翻地覆（softmax 饱和区、网络最后一层），另一些方向改动很大而输出几乎不变。TRPO 的出发点正是改用行为空间的距离（Spinning Up, TRPO 文档）。

5.3.2 性能差恒等式

SUMMARY / 总结

要谈“更新是否安全”，得知道新策略的价值与旧策略差多少。这个差可以精确写出来，而且形式出人意料地简单：差值等于旧策略的优势在新策略访问分布下的期望。

> **定理 5.2（性能差恒等式 [精确]）**
>
> 对任意两个策略 π, π'（π' 为任意策略，不要求与 π 接近），折扣目标之差等于旧策略的优势在“新策略访问分布”下的期望，即式 (5.19)。其中 $d_\gamma^{\pi'}$ 是从 ρ_0 出发、按 π' 走出的未归一化占用测度，$A^\pi = Q^\pi - V^\pi$ 用旧策略算；若改用归一化测度，右端要乘 $1/(1-\gamma)$。

$$J(\pi') - J(\pi) = \sum_s d_\gamma^{\pi'}(s) \sum_a \pi'(a \mid s)\, A^\pi(s,a), \tag{5.19}$$

证明只需一步：把 $J(\pi') - J(\pi) = \mathbb{E}_{s_0\sim\rho_0}[V^{\pi'}(s_0) - V^\pi(s_0)]$ 沿 π' 的轨迹展开，每一项写成“当前奖励加后继价值”，再用 $A^\pi = Q^\pi - V^\pi$ 把差值逐项配对，望远镜求和即得。它的意义在于：**新策略的价值完全由旧策略的优势在新分布下的期望决定**。如果 $A^\pi(s,a) \ge 0$ 对所有被 π' 访问的 (s,a) 成立，则 $J(\pi') \ge J(\pi)$，等号只在优势处处为零时取得——这就是策略改进定理的另一种写法。

恒等式虽然精确，却不可直接优化：右端的分布 $d_\gamma^{\pi'}$ 依赖待求的 π'，而它正是我们不知道的量。TRPO 的做法是把 $d_\gamma^{\pi'}$ 换成 d_γ^{π}（旧策略的占用测度），得到一个只依赖采样数据的代理目标：

$$L_\pi(\pi') = J(\pi) + \sum_s d_\gamma^{\pi}(s) \sum_a \pi'(a \mid s) A^\pi(s,a). \tag{5.20}$$

这一步替换是整个信赖域方法的核心近似，必须标 **[近似]**：$L_\pi(\pi')$ 与 $J(\pi')$ 在 $\pi' = \pi$ 处一阶相等（梯度相同），二阶及更高阶不同。因此“最大化 L_π”只在 π' 离 π 不远时才近似等于“最大化 $J(\pi')$”；离得越远，代理目标越乐观，优化它反而可能降低真实目标。这正是 5.3.1 节实验里“代理目标涨、真实目标未必涨”的数学表述。

5.3.3 TRPO 的约束优化

既然近似只在局部有效，就把“局部”写成显式约束。先用重要性比率把式 (5.20) 写成对样本友好的形式：设数据由 π_{old} 采得，

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}, \qquad L^{\text{CPI}}(\theta) = \hat{\mathbb{E}}_t\big[\rho_t(\theta)\, \hat{A}_t\big], \tag{5.21}$$

SUMMARY / 总结

其中 $\hat{\mathbb{E}}_t$ 表示对采样时间步取经验平均，$\hat{A}_t$ 是 5.2.3 节的 GAE 估计（用 π_{old} 算）。TRPO 求解

$$\max_{\theta} \hat{\mathbb{E}}_t\left[\rho_t(\theta)\hat{A}_t\right] \quad \text{s.t.} \quad \hat{\mathbb{E}}_t\Big[D_{\text{KL}}\big(\pi_{\text{old}}(\cdot\mid s_t)\,\big\|\,\pi_\theta(\cdot\mid s_t)\big)\Big] \le \delta. \tag{5.22}$$

δ 的典型取值在 10^{-2} 量级；约束用的是平均 KL，方向是 $\pi_{\text{old}}\|\pi_\theta$（Schulman 等, 2015, 式 (3)(4)）。这里有一个常被忽略的细节：理论上的单调改进保证用的是**最大** KL 而不是平均 KL，平均 KL 的版本只是它的一个更松、因而更省算力的替代。所以即便约束被满足，“改进”也只在下述意义上成立：在代理目标与真实目标之差被 KL 一致控制的区域内，最大化代理目标不会降低真实目标。这个“一致控制”本身是近似，故定理 5.3 标 **[近似]**。

> **定理 5.3（TRPO 的单调改进 [近似]）**
>
> 设 π_{old} 与 π_θ 之间的平均 KL 不超过 δ，且在该邻域内代理目标与真实目标之差被 $C\delta$ 一致界定（$C = 4\varepsilon\gamma/(1-\gamma)^2$，Schulman 等, 2015, 第 3 节）。则最大化式 (5.22) 的代理目标不会使 $J(\pi_\theta)$ 降低超过 $C\delta$ 的量级。该结论依赖两个近似：用 $d^{\pi_{\text{old}}}$ 替代 d^{π_θ}，以及用平均 KL 替代最大 KL；因此它是**近似意义下的**改进，不构成无条件的单调性保证。

求解式 (5.22) 的实用路线是三步（Schulman 等, 2015, 第 5 节；Spinning Up, TRPO 文档）。第一步，对代理目标取一阶近似、对 KL 约束取二阶近似，解出 $\sqrt{2\delta/(g^\top F^{-1} g)}\,F^{-1}g$，其中 g 是代理目标的梯度、F 是平均 Fisher 信息矩阵；第二步，用共轭梯度法解 $Fx = g$，避免显式构造 $|\theta|^2$ 规模的矩阵；第三步，沿该方向做回溯线搜索，取满足 KL 约束的最大步长，

$$\theta = \theta_{\text{old}} + \alpha^j F^{-1} g, \qquad j = 0, 1, 2, \dots \tag{5.23}$$

直到约束满足为止。这三步的代价是二阶方法：每次更新要多次“矩阵—向量”乘积、每次乘积要一遍数据。TRPO 因此在工程上偏重，这也是 PPO 出现的直接动机。用 Fisher 而不用 Hessian，是因为它只依赖策略分布、不依赖奖励，而 KL 约束在局部等价于参数方向上的 Fisher 二次型（二阶展开的 [近似]）。

SUMMARY / 总结

5.4 PPO

5.4.1 从约束到裁剪

TRPO 要解线性系统、要做线搜索，实现复杂，也难以与参数共享、分布式采样这类训练设施共存。PPPPO通过一阶优化与裁剪替代显式的二阶信赖域约束，尝试控制策略更新幅度。步是把约束变成惩罚。KL 惩罚版的目标是

$$L^{\mathrm{KLPEN}}(\theta)=\hat{\mathbb{E}}_t\Big[\rho_t(\theta)\hat{A}_t-\beta\,D_{\mathrm{KL}}\big(\pi_{\mathrm{old}}(\cdot\mid s_t)\,\big\|\,\pi_\theta(\cdot\mid s_t)\big)\Big], \tag{5.24}$$

β 可以固定，也可以按观测到的 KL 自适应调整（KL 偏大就增大 β，偏小就减小）。这个形式在数学上更接近 TRPO 的约束，但 β 极难标定：它对奖励尺度、策略更新的频率都敏感，同一组超参在不同任务上差几个数量级（Schulman 等, 2017, 第 4 节）。

第二步是干脆不惩罚，改在目标函数里直接“掐掉”越界的收益。这就是裁剪目标：

$$L^{\mathrm{CLIP}}(\theta)=\hat{\mathbb{E}}_t\Big[\min\big(\rho_t(\theta)\hat{A}_t,\ \mathrm{clip}(\rho_t(\theta),1-\varepsilon,1+\varepsilon)\,\hat{A}_t\big)\Big], \tag{5.25}$$

ε 默认取 0.2。式 (5.25) 的行为可以分四种情形读出来，图 5-5 把它们画成了曲线。

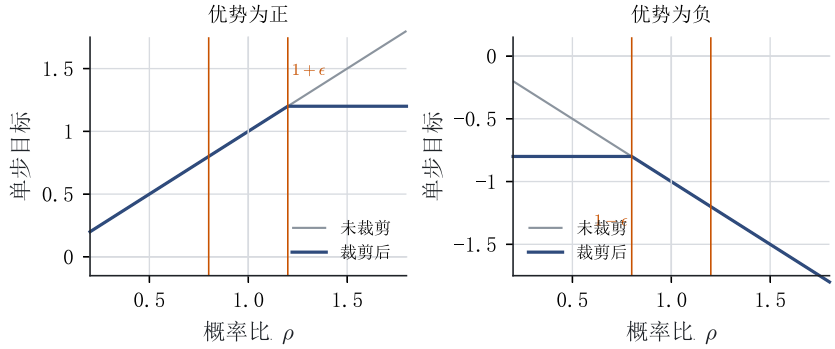


图 5-5 裁剪目标作为概率比的函数。左图优势为正：ρ 超过 1+ ε 后目标被压成水平线，继续增大 ρ 不再有收益；右图优势为负：ρ 低于 1- ε 后同样被压平。虚线是未裁剪的 ρ Â，两条竖虚线标出裁剪区间。

读图 5-5 时注意两点。第一，裁剪只截断“继续朝同一方向走”的收益，不阻止反方向的移动：当 $\hat{A}_t>0$ 且 $\rho_t<1-\varepsilon$ 时，$\min$ 取的是未裁剪项，梯度照常存在。第二，$\min$ 的存在使目标成为未裁剪目标的下界，因而是一个“悲观”估计——这正是 PPO 原文称之为 pessimistic bound 的原因

（Schulman 等, 2017, 第 3 节）。

适用边界如下：**裁剪不是信赖域**。它没有约束 KL，也不保证 $J(\pi_\theta)$ 不下降；它只在一件事上做了惩罚——比率离开区间后不再给额外奖励。单个样本的比率被限制在 $[1-\varepsilon, 1+\varepsilon]$ 附近有收益，但整个策略的 KL 可以远超这个量级：图 5-6 右图会给出实测，即使在 $\varepsilon = 0.2$、每批数据只复用 8 轮的温和设置下，单步 KL 的中位数仍然达到 0.15，是常见阈值 $\delta = 0.01$ 的十五倍。所以 PPO 的稳定性来自工程组合（多轮复用 + 小批量 + KL 早停 + 梯度裁剪），不来自裁剪的数学性质。PPO 用裁剪换掉的只是 TRPO 的二阶求解，没有换来任何约束保证；把这一条写成“PPO 的 clip 保证信赖域”是错误表述。

5.4.2 裁剪与 KL 惩罚的实测差别

PPO 原文做过一组直接对照：同样 7 个连续控制环境、每个设置 21 次运行，比较“不裁剪”、“裁剪（三种 ε）”与“KL 惩罚（固定与自适应）”。

表 5-1 PPO 原文对裁剪与 KL 惩罚的对照。7 个连续控制环境、每设置 21 次运行的平均归一化得分；裁剪 ε =0.2 最高，不裁剪时在半猎豹上出现比随机策略还差的负分。（Schulman 等, 2017, 表 1）

处理方式	归一化得分	备注
不裁剪、不惩罚	-0.39	半步就崩，个别环境低于随机策略
裁剪，$\varepsilon = 0.1$	0.76	区间偏窄，更新保守
裁剪，$\varepsilon = 0.2$	0.82	原文默认值
裁剪，$\varepsilon = 0.3$	0.70	区间偏宽，稳定性下降
自适应 $_{\mathrm{KL}}$，$\delta = 0.01$	0.74	需标定，对尺度敏感
固定 $_{\mathrm{KL}}$，$\beta = 1$	0.71	β 难选，最优值随任务漂移

表 5-1 的两个读法都重要：横向看不裁剪最差，说明“多轮复用同一批数据而不加限制”确实会毁掉策略，这是 5.3 节“代理目标只在局部有效”的直接证据；纵向看 ε 的最优值在 0.2 附近，太窄则几乎不更新，太宽则退化成不裁剪。这类“中间最好”的曲线是经验规律，没有定理给出最优 ε。

5.4.3 十项复现标准

PPO 的论文只有两页算法描述，而复现它需要十个具体决定。把它们写成伪代码，是因为这一节的争议几乎全部来自“漏掉了其中某一项”。算法

5-2 中标注 ① 到 ⑩ 的十项，前六项决定目标函数的形式，后四项决定优化的调度。

算法 5-2 PPO 的十项复现标准

```
1: 输入：策略 π_θ，价值 V_φ，裁剪范围 ε=0.2，GAE 参数 λ=0.95，轮数 K，批大小 M
2: for iteration = 1, 2, ... do
3:    用 π_old = π_θ 采样 N 个并行环境 × T 步                # ① rollout 由 π_old 生成
4:    记录 terminated 与 truncated 两个标志，分别处理          # ② 截断处保留自举
5:    δ_t = r_t + γ V_φ(s_{t+1})·(1 - terminated_t) - V_φ(s_t)   # ③ TD 误差
6:    for t = T-1..0: Â_t = δ_t + (γλ)(1-done_t)·Â_{t+1}     # ③ GAE（跨回合切断）
7:    Â_t ← (Â_t - mean Â) / (std Â + 1e-8)                  # ④ 优势批内归一化（可选）
8:    V^targ_t ← V_φ(s_t)，在本轮内固定                       # ⑧ 目标值 stop-gradient
9:    for epoch = 1..K do                                    # ⑦ 多轮复用
10:      for 每个 mini-batch do                               # ⑦ 小批量
11:         ρ_t = π_θ(a_t|s_t) / π_old(a_t|s_t)               # ⑤ 概率比
12:         L^CLIP = mean(min(ρÂ, clip(ρ, 1-ε, 1+ε)Â))        # ⑥ 裁剪目标
13:         L = L^CLIP - c1·mean((V_φ - V^targ)²) + c2·mean(H(π_θ))  # ⑧⑨ 值损失与熵
14:         θ, φ ← θ, φ + η grad L                            #    梯度上升
15:      end for
16:      若 mean KL(π_old‖π_θ) > 1.5·δ_KL 则提前结束本轮      # ⑩ 早停（工程实践）
17:   end for
18:   θ_old ← θ，φ_old ← φ                                   # ⑩ 何时更新旧策略
19: end for
```

这十项不是同一种东西，来源必须分层：①③⑤⑥⑦⑧ 与 “$\theta_{\text{old}} \leftarrow \theta$” 出自原文算法 1；⑧ 的值损失形式与 ⑨ 的熵奖励见原文式 (9)；② 终止/截断分开记录是本书第 2 章的约定；④ 优势批内归一化与 ⑩ 的 KL 早停属工程实践——原文第 4 节处理 KL 用的是自适应惩罚系数 β（$d < d_{\text{targ}}/1.5$ 则 $\beta \leftarrow \beta/2$，$d > 1.5 d_{\text{targ}}$ 则 $\beta \leftarrow 2\beta$），不是提前结束本轮。分清来源，才不至于把“某个开源实现的调参”当成“论文的算法”。

十项里最容易被忽略的是第 ② 项与第 ⑩ 项。第 ② 项：终止（terminated）与截断（truncated）必须分开记录。终止处自举为零，截断处必须保留 $V_\phi(s_T)$ 的自举；把两者都当成 done 会让价值系统性偏低。**终止步与截断步都必须切断跨回合递推**：否则前一段回合的错误优势会按 $(\gamma\lambda)^k$ 衰减着污染后一段。第 ⑩ 项：旧策略 π_{old} 只在轮次开始时更新一次，整轮 K 个 epoch 内保持不变；比率 ρ_t 的分母若跟着刷新，“比率偏离 1 多少”这个度量就失去意义，裁剪也就无从判断。

SUMMARY / 总结

第 ④ 项与第 ⑧ 项最常引发争议。优势归一化把 $\hat{A}_t$ 除以批内标准差，使 ε 的含义与奖励尺度解耦，代价是优势的绝对尺度改变，用它做诊断时读数会失真。值损失方面 c_1 必须与策略项量级匹配：奖励尺度为 10^3 时平方误差会压过策略项，表现为“策略不动、价值损失下降”；标准做法是归一化回报或调小 c_1，两者都是 [经验规律]。

5.4.4 熵正则与总损失

探索与利用的平衡在策略梯度里由熵来调节。加熵奖励后的目标是

$$J_{\text{ent}}(\theta) = \mathbb{E}_{\tau\sim p_\theta}\big[G_\tau\big] + \alpha_{\text{ent}}\,\mathbb{E}_s\big[H(\pi_\theta(\cdot\mid s))\big], \tag{5.26}$$

其中 $H(\pi) = -\mathbb{E}_{a\sim\pi}[\log\pi(a\mid s)]$ 是策略熵，α_{ent} 是熵温度。这个符号必须与学习率 α 分开写：两者都是标量、都叫“alpha”，但一个控制探索强度，一个控制步长，混用会让超参表不可读，也会在调参时互相掩盖。α_{ent} 越大策略越随机，任务奖励越稀疏越需要它；它过大会让策略永远停在不做决策的均匀分布上。

把三项合起来，就得到 PPO 实际优化的损失：

$$L^{\text{CLIP+VF+S}}(\theta) = \hat{\mathbb{E}}_t\Big[L_t^{\text{CLIP}}(\theta) - c_1 L_t^{VF}(\theta) + c_2\,S[\pi_\theta](s_t)\Big], \tag{5.27}$$

其中 S 是熵奖励，c_1, c_2 是两个系数，L^{VF} 是式 (5.16) 的平方误差（Schulman 等, 2017, 式 (9)）。三项的符号容易记混：策略项与熵项要最大化，价值误差要最小化，所以式 (5.27) 里价值项带负号。实现中通常对 L^{CLIP} 取负号后与其余两项一起做梯度下降；只要符号一致，写成上升或下降都可以，但报告结果时必须说清用的是哪一种。

SUMMARY / 总结

5.5 实践与诊断

5.5.1 五种常见失败

复现 PPO 时反复复现 PPO 时反复出现的失败有五种，它们的共同点是“标定错了”。励尺度又大，是最常见的一种：$\hat{A}_t$ 的量级上到 10^2 以上时，比率稍有偏离就产生巨大目标值，梯度跟着爆炸；诊断信号是熵骤降、KL 剧烈震荡。

价值损失压过策略损失时，曲线看起来像“学会了，但没变强”：价值损失平滑下降、回合回报不涨。原因通常是 c_1 过大或回报没归一化，处置办法是把回报除以运行标准差，或者把价值网络与策略网络解耦。

梯度裁剪缺失是另一种：目标被裁剪并不限制参数更新，少量极端样本仍可造成大位移。把全局梯度范数裁到 0.5 左右是 [经验规律]。

多轮复用的实现里常出 KL 爆炸而不早停：没有“KL 超过阈值就提前结束本轮”的保护，一批数据可以被优化到与旧策略完全不同的策略上，而这一批数据的优势估计早已失效。

还有一种更隐蔽——奖励尺度根本没处理。奖励乘 10 与学习率乘 10 近似等价，但对裁剪阈值、熵系数、价值损失的影响并不等价，这是“换个任务就调不动”的最常见原因。

五条指向同一件事：策略梯度类方法对尺度极其敏感，因为它的更新量同时依赖回报的尺度（进入优势）、概率的尺度（进入比率）与参数的尺度（进入 KL）。诊断时先查这三处的标定，比换算法有效。

5.5.2 评估协议

策略梯度方法的评估比价值方法更容易出错：策略是随机的，采样本身带方差；训练过程不稳定，最终性能依赖“取哪一次快照”；超参敏感，单次运行的结果不能代表算法。

因此报告结果时至少给出四项：**确定性评估与随机评估分开报**，两者的差距反映策略的随机程度；**多个种子**，至少 3 个、最好 5 个以上，报均值与标准差而非最好的一次；**训练曲线而非只看终点**，策略梯度常早期快升、后期回落；**样本效率与墙钟时间分开报**，并行环境数会同时改变两者。

5.5.3 一个小实验：什么在起作用

SUMMARY / 总结

本节在一个可精确求解的 4 状态链式 MDP 上做两组对照。设置：$\gamma = 0.9$，表格 softmax 策略，每轮采 6 条轨迹，GAE(λ) 用旧策略的精确价值函数，每批数据复用 8 轮、小批量 64、学习率 0.5，6 个种子，30 轮迭代。第一组扫描裁剪范围 ε 与自举参数 λ。

表 5-2 裁剪范围与自举参数的对照。数值为最后 8 轮真实目标 $J(\theta)$ 的种子均值，种子标准差在 0.003 到 0.009 之间；同一列内的差异全部落在标准差之内。

裁剪范围	$\lambda = 0$	$\lambda = 0.95$	$\lambda = 1$
不裁剪	0.692	0.691	0.691
$\varepsilon = 0.1$	0.692	0.688	0.693
$\varepsilon = 0.2$	0.692	0.688	0.692
$\varepsilon = 0.3$	0.692	0.688	0.690

表 5-2 是一个“零结果”，而零结果本身有信息量：在这个任务上，最优策略是角点解（每个状态都选前进），策略梯度朝正确方向走多远都是改进，因此裁剪与 λ 都无从发挥。这说明**裁剪的价值依赖任务结构**，不能指望它在任何任务上都带来提升；表 5-1 里裁剪的优势来自连续控制任务中策略需要精细配比、奖励带噪声的情形。

第二组对照换一个变量：每批数据的复用轮数。

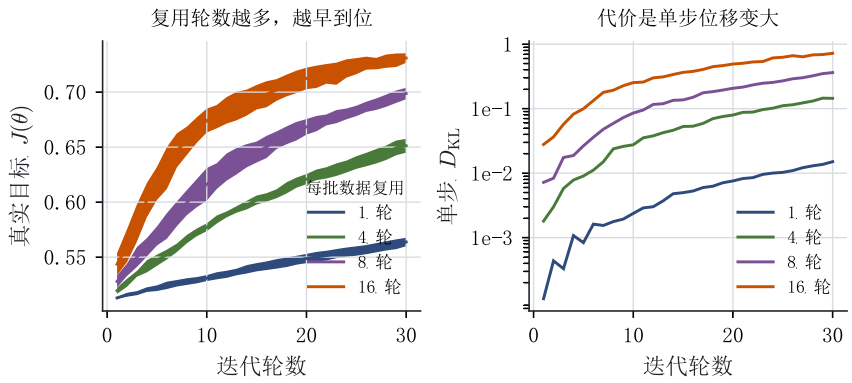


图 5-6 复用轮数的作用。左图：每批数据复用 1、4、8、16 轮时的真实目标（阴影为 6 个种子的标准差）。右图：同一批数据上相邻两轮策略的 KL 散度（对数刻度）。复用越多，到达同一性能所需的迭代越少，代价是单步位移按数量级增长。

图 5-6 的数字：复用 1、4、8、16 轮时 J 从 0.560 单调升到 0.728，KL 中位数从 4.9×10^{-3} 升到 0.36。性能与位移同步上升，这正是 PPO 的设计张力：复用提高样本效率，裁剪与早停压住位移。**预算固定时，成败取决于“每批数据用几次、每步走多远”，而不是裁剪阈值。**

SUMMARY / 总结

本章小结

本章从一个具体的本章研究如何通过采样估计策略梯度，并控制估计误差与策略更新幅度。。第一步把“调概率”写成可采样的梯度——得分函数技巧把转移核的求导消掉，代价是必须 on-policy 采样，而且整条轨迹共享一个回报，方差大到几乎不可用。第二步把这个粗权重换细：reward-to-go 只看 t 之后，基线减掉“这个状态本来就不错”的部分，优势再把它压成“比平均好多少”。基线的合法性来自一个恒等式，它只要求基线不随动作变化；也正因为它只保证期望不变，critic 的精度问题被降级成方差问题，而不是无偏性问题——这两件事分开，5.2.1 节的两个命题各管一头。

第三步管幅度。代理目标只在旧策略附近等于真实目标，于是 TRPO 把它写成 KL 约束下的优化，代价是二阶方法；PPO 用裁剪换掉二阶求解，换来的是实现简单，不是任何约束保证。这三条线索在第 6 章合流：同样的策略梯度接上函数逼近、经验回放与双 critic，就成了连续控制里的 DDPG、TD3 与 SAC；第 10 章的语言模型偏好优化用的是同一套东西，那里的 KL 正则与本篇的约束是一件事的两种写法。

关键公式

下面九条是全章的主干，从目标的三种写法出发，经基线与优势，到信赖域与裁剪；它们之间的推导顺序就是 5.1 到 5.4 节的顺序。

$$J(\theta) = \mathbb{E}_{\tau\sim p_\theta}\Big[\sum_{t\ge 0}\gamma^t R_{t+1}\Big]$$

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau}\Big[\sum_{t\ge 0}\gamma^t G_t\,\nabla_\theta \log \pi_\theta(a_t\mid s_t)\Big]$$

$$\nabla_\theta J(\theta) = \sum_s d_\gamma^{\pi_\theta}(s)\sum_a \nabla_\theta \pi_\theta(a\mid s)\,Q^{\pi_\theta}(s,a), \qquad \sum_s d_\gamma^{\pi}(s) = \frac{1}{1-\gamma}$$

$$\nabla_\theta J(\theta) = \frac{1}{1-\gamma}\,\mathbb{E}_{s\sim \bar d_\gamma^{\pi},\,a\sim\pi}\big[\nabla_\theta \log \pi_\theta(a\mid s) Q^{\pi}(s,a)\big]$$

$$\mathbb{E}_{a\sim\pi}\big[\nabla_\theta \log \pi_\theta(a\mid s) b(s)\big] = 0$$

$$\hat A_t = \sum_{l\ge 0}(\gamma\lambda)^l \delta_{t+l}, \qquad \hat A_t\big|_{\lambda=1} = G_t - V_\phi(s_t)$$

$$J(\pi') - J(\pi) = \sum_s d_\gamma^{\pi'}(s)\sum_a \pi'(a\mid s) A^{\pi}(s,a)$$

SUMMARY / 总结

$$\max_{\theta} \ \hat{\mathbb{E}}_t\big[\rho_t(\theta)\hat{A}_t\big] \quad \text{s.t.} \quad \hat{\mathbb{E}}_t\big[D_{\mathrm{KL}}(\pi_{\mathrm{old}}\|\pi_\theta)\big] \le \delta$$

$$L^{\mathrm{CLIP}}(\theta) = \hat{\mathbb{E}}_t\Big[\min\big(\rho_t\hat{A}_t,\ \mathrm{clip}(\rho_t, 1-\varepsilon, 1+\varepsilon)\hat{A}_t\big)\Big]$$

习题

1. 证明基线恒等式 (5.10)：对任意状态函数 b，$\mathbb{E}_{a\sim\pi}[\nabla_\theta \log \pi_\theta(a \mid s) b(s)] = 0$。并说明为什么 b 依赖动作时该等式失效，给出一个依赖动作的反例。
2. 推导 $\lambda = 1$ 时的望远镜求和：从式 (5.17) 的递推出发，证明 $\hat{A}_t\big|_{\lambda=1} = G_t - V_\phi(s_t)$，并指出这一步不要求 $V_\phi = V^\pi$。
3. 设 $V_\phi = 2V^\pi$，其余设置正确。分别判断：(a) $G_t - V_\phi(s_t)$ 是否是 A^π 的无偏估计；(b) 用它构造的策略梯度估计是否无偏。对两个结论各给一句理由。
4. 用式 (5.6) 与式 (5.7) 验证：若把归一化形式中的 $1/(1-\gamma)$ 丢掉，得到的梯度与真实梯度相差一个常数因子。说明这个因子为什么不能“吸进学习率”而不改变优化对象。
5. 对式 (5.25)，分 $\hat{A}_t > 0$ 与 $\hat{A}_t < 0$ 两种情形，写出 ρ_t 在 $(0, 1-\varepsilon)$、$(1-\varepsilon, 1+\varepsilon)$、$(1+\varepsilon, \infty)$ 三段上的梯度表达式，并说明哪些段梯度为零。
6. 说明为什么 TRPO 用平均 KL 约束时只能得到近似意义下的单调改进，而“最大 KL”版本才有严格界。给出一个平均 KL 很小、最大 KL 很大的例子。
7. 在 4 状态链式 MDP 上复现图 5-4 与图 5-6：改变学习率与复用轮数，记录真实目标与单步 KL。说明为什么在本任务上大步长没有导致目标下降，而在连续控制任务上会。
8. 设某个实现把截断步当成终止步处理（自举置零）。说明这一错误如何经 GAE 传到优势估计，并使哪些状态的动作概率被系统性压低。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 13 章：策略梯度定理的完整证明（13.2 节）、REINFORCE 的推导（13.3 节）、基线与 Actor-Critic（13.4、13.5 节）；本章记号与之一致，可逐节对照。
- Schulman 等《Trust Region Policy Optimization》（ICML 2015）：约束优

化的原始形式、单调改进定理与共轭梯度的实现细节；其保证建立在“最大 KL”与近似误差可控之上。

- Schulman 等《Proximal Policy Optimization Algorithms》（2017）：裁剪目标的定义（第 3 节）、KL 惩罚与自适应的对比（第 4 节）、表 1 的消融数据与算法 1 的伪代码。本章十项复现标准据此与工程实践整理。
- Spinning Up 的 VPG、TRPO、PPO 三篇文档：公式与代码的对应写得最清楚，尤其是“用 KL 而不是参数距离”与“线搜索”的工程动机。
- GAE 的偏差—方差分析见 Schulman 等《High-Dimensional Continuous Control Using Generalized Advantage Estimation》（ICLR 2016）第 4 节；本章 5.2.3 节的结论与该文一致。

SUMMARY / 总结

第 6 章　深度强化学习：从 DQN 家族到连续控制

深度 Q 学习可能出现训练回报突然下降、估计值异常升高，或损失下降而策略性能退化等现象。这些现象可能与参数共享、自举目标变化及经验回放造成的数据分布差异有关，具体原因需要结合训练曲线和评估结果诊断。参数化后，一次梯度更新会同时改变多个状态的估值；自举目标 $r+\gamma \max_a Q_\phi(s',a)$ 又依赖待更新的参数；回放数据则来自多个历史策略，而优化目标对应当前策略的访问分布。这三种因素共同改变了表格 Q-learning 的分析条件。

本章按照函数逼近后 Q-learning 面临的四类困难组织内容：目标不断变化、价值过估计、样本利用效率有限，以及连续动作难以优化。每种改进都从可观察到的训练现象入手，再说明相应公式和代价。图 6-1 汇总了六种改进及其针对的问题；它们分别处理不同的失效原因，也各自带来不同代价。理解表格 Q-learning 的一步更新即可开始本章，神经网络知识会在相关位置补充。本章依次讨论目标移动、价值过估计、样本效率和连续动作优化。回放池用于降低连续样本的相关性，目标网络用于减缓学习目标的变化；二者各自缓解特定问题，但都不提供收敛保证。

需要先说明本章结论的性质。除了少数关于估计偏差的命题（例如最大算子的系统性正偏差），本章讨论的算法都没有“收敛到最优”的证明：它们是在特定任务、特定超参数、特定评估协议下被经验验证的工程方法。本章系统介绍DQN系列方法、DDPG、TD3和SAC的目标函数、实现机制及评估要求。

6.1 表格Q-learning的规模与表示限制

6.1.1 状态爆炸与“泛化”的代价

表格方法的存储量随状态数增长。Atari 的一帧是 210×160 的彩色图像，围棋的合法局面数在 10^{170} 量级，逐状态存储因此难以扩展。函数逼近使用共享参数表示动作价值 $Q_\phi(s,a)$，使相似状态能够共享信息，并对未见状态进行泛化。这一表示方法已在第 4 章介绍。

6.1.2 目标里含有自己的参数

更麻烦的还不是存储量：目标本身含有自己的参数，表格 Q-learning 的更新写成

SUMMARY / 总结

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha\Big[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)\Big], \tag{6.1}$$

这里的目标项和被更新的价值属于同一张表中的不同条目。换成 Q_ϕ 后，目标项也依赖同一组参数；每次梯度更新都在拟合一个会随参数变化的目标。若训练中损失平稳下降而 Q 值持续增大，可能反映目标漂移，需结合价值估计与策略表现诊断。把它写成损失函数就是

$$L(\phi) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\Big[\big(r + \gamma\,(1 - d_t)\max_{a'} Q_{\bar{\phi}}(s', a') - Q_\phi(s, a)\big)^2\Big], \tag{6.2}$$

其中 $\mathcal{D}$ 是经验回放缓冲区，$\bar{\phi}$ 是延迟更新的目标参数，$d_t \in \{0, 1\}$ 是**终止指示**：$d_t = 1$ 当且仅当 S_{t+1} 终止（转移形式记作 d）。这个因子出现在本章每一个目标式里，值得单独说清。

终止与**截断**是两件事，必须分开记录。终止是 MDP 的性质：S_{t+1} 之后没有后续回报，终止状态的价值恒为 0，所以目标里的自举项必须被掩掉、只剩 r。截断是采样协议的性质：回合因时间上限、预算耗尽或外部中断而结束，状态本身并不终止，目标仍是 $r + \gamma \max_{a'} Q_{\bar{\phi}}(S_{t+1}, a')$——**自举必须保留**。

把截断当终止会让每个回合末尾的价值估计被系统性压低，截断越频繁、低估越重。实现上这是两个字段（terminated 与 truncated），不能合成一个 done。

式 (6.2) 与监督学习的形式一样，区别在于标签是由上一步的估计算出来的。在函数逼近、自举和离策略同时存在时，某些更新规则可能不稳定或发散，但这一组合并不意味着必然失稳。深度 Q-learning 恰好三样齐全，因此不能指望它像监督学习那样单调下降。

6.1.3 离线数据带来的分布偏移

第三个问题来自数据。经验回放让样本可以重复使用，代价是缓冲区里的转移由许多历史策略产生，当前策略可能无法保证会走到那些状态。式 (6.2) 的期望是对 $\mathcal{D}$ 取的，而我们要优化的对象是对当前策略的占用测度取的，两者不一致。第 4 章讨论过这种离策略偏差：要么用重要性采样修正，要么保证目标策略的支持集落在行为策略之内，要么接受“优化的是另一个目标”这一事实。

经验回放通过打乱缓冲区中的转移，减弱相邻样本的时序相关性并提高数据复用率。小批量梯度估计仍受缓冲区分布、采样方式与目标策略分布差异影响；回放本身不会自动消除这种偏差。

SUMMARY / 总结

6.1.4 两个工程装置各修什么

DQN 的做法是把上述问题拆成两个装置分别处理（Mnih et al., 2015；Sutton & Barto, 2018, 第 16.5 节）。**经验回放**把在线产生的相关样本变成近似独立的训练集，同时让每条经验被多次使用；**目标网络**每隔 C 次更新把参数拷贝一份并冻结，用冻结的参数计算式 (6.2) 中的标签，从而在 C 步之内把“追自己”变成“拟合一个移动缓慢的目标”。此外 DQN 还把 TD 误差裁剪到 $[-1,1]$，防止个别样本产生过大的梯度。

这两个装置修的不是同一个问题：回放针对样本相关与数据利用率，目标网络针对自举目标的不稳定。Mnih 等在 5 个游戏上的消融实验显示，两者单独使用都能显著提升，合用时提升更大（Sutton & Barto, 2018, 第 16.5 节）[经验规律]。这预示了后面所有补丁的共同形态：每个补丁针对一个具体的失效模式。

即便如此，DQN 的表现也远非全面：按“达到人类得分 75% 以上即算人类水平”的判据，它在 46 个可比游戏中的 29 个达到该界，真正超过人类得分的是 22 个（Sutton & Barto, 2018, 第 16.5 节；Nature 版按 49 个游戏报告，分母口径不同，不要混用）。在需要长程规划的《蒙特祖玛的复仇》上它几乎只有随机玩家的水平。这些失败案例正是改进方法的起点。

> **定义 6.1（经验回放缓冲区）**
>
> 经验回放缓冲区是一个容量有限的集合 $\mathcal{D}$：每交互一步存入一条转移，满则丢弃最旧的；训练时从中随机抽小批量。它打断样本的时间相关性，并让每条经验被多次使用。

SUMMARY / 总结

6.2 DQN 与它的改进方法

DQN 之后的一批方法，大多可以读成同一句话的不同补法：某个量被估偏了，或者某部分计算被浪费了。本节按“故障现象、公式改动、代价”三件事逐个过一遍，最后给出补丁表（表 6-1）。

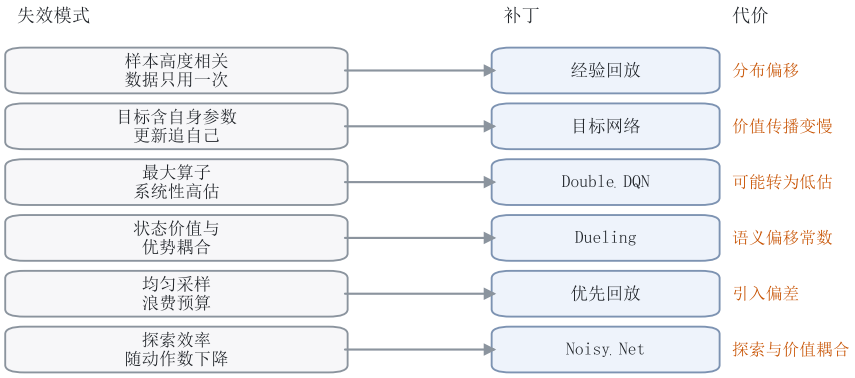


图 6-1 DQN 家族的补丁地图。左列为失效模式，中列为对应补丁，右列为其代价

6.2.1 过估计：最大算子的系统性正偏差

Q 值可能在训练中持续升高，超过任务可实现的折扣回报，并伴随策略性能下降。带噪声的动作价值估计经最大化选择后会产生向上的偏差；学习率、目标网络和数据分布也会影响实际训练动态。

假设对每个动作的真实价值 $Q^\star(s,a)$，我们只有一个带噪声的估计 $\hat{Q}(s,a) = Q^\star(s,a) + \epsilon_a$，且噪声均值为零。取最大时，被选中的往往是噪声为正的那个动作，于是

$$\mathbb{E}\Big[\max_a \hat{Q}(s,a)\Big] \;\geq\; \max_a \mathbb{E}\big[\hat{Q}(s,a)\big], \tag{6.3}$$

$\max$ 是凸函数，因此 Jensen 不等式给出式 (6.3)。不等式在某些条件下可以取等号，例如某个固定动作几乎处处达到最大值。

> **定理 6.1（最大算子的正偏差 [精确]）**
>
> 设 $\hat{Q}_1, \dots, \hat{Q}_m$ 均具有有限期望，且均值分别为 $Q_1, \dots, Q_m$。则 $\mathbb{E}[\max_i \hat{Q}_i] \geq \max_i Q_i$。该不等式不要求各估计量独立；当某个固定动作几乎处处达到最大值时可以取等号，一般情形下则为严格不等式。

Thrun 与 Schwartz 的上界是 $\gamma\epsilon(m-1)/(m+1)$，前提是误差在 $[-\epsilon,\epsilon]$ 上均匀分布、ϵ 是半宽而非标准差（转引自 van Hasselt et al., 2016）：动作越

多、噪声越大，过估计越重，且偏差会经自举逐层累积。DQN 在 49 个 Atari 游戏上都观察到过估计，幅度不一（van Hasselt et al., 2016）。

图 6-2 把这条机制量出来：对 m 个真实价值相同的动作各取独立高斯噪声估计，重复 40 万次，统计最大值与真值之差。动作数从 2 增到 32，过估计增到约四倍；噪声从 0.1 增到 0.5，过估计几乎等比增大——这是式 (6.3) 的定量版本。图里用的是高斯噪声，**不满足**均匀分布的前提，因此只说明随动作数与噪声单调增，不能当作该上界的定量验证。

接下来看第二个补丁。

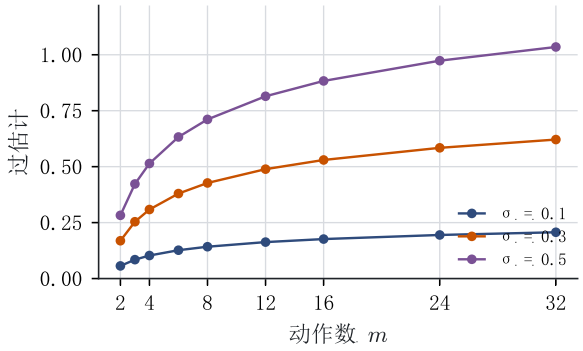


图 6-2 最大算子的过估计随动作数与噪声增长。40 万次蒙特卡洛，噪声为独立高斯

6.2.2 Double DQN：把选择与评估分开

过估计的麻烦在于它会被自举放大：每一轮的目标都比真实值高一点，下一轮在高出来的基础上再高一点。Double Q-learning 的思路很简单——用一套估计选动作，用另一套估计评估这个动作，让“选”和“评”用两份独立噪声。DQN 里恰好已经有两个网络，在线网络与目标网络可以分别扮演这两个角色，于是目标变为

$$y^{\text{Double}} = r + \gamma\,(1 - d_t)\,Q_{\bar{\phi}}\Big(s', \arg\max_{a'} Q_{\phi}(s', a')\Big). \tag{6.4}$$

与式 (6.2) 相比只改了一处：**max** 拆成“选”与“评”两步。当两个网络的误差不相关时，被选中的动作不再系统性偏向高估的一侧。但这并不能消除过估计：若两个估计器误差同向，偏差会保留；某些情形下反而低估。原始论文的措辞是“reduce overestimation”，而非“eliminate”——诊断曲线也能看出来：Q 值仍然偏高，只是不再逐轮抬高。

在 5 分钟游戏时长、49 个游戏的统一评估下，DQN 的归一化得分中位数是 93.5%、均值 241.1%，Double DQN 分别为 114.7% 与 330.3%；在 Human Starts 协议、30 分钟时长下，中位数从 47.5% 升到 88.4%（van

Hasselt et al., 2016, 表 1、表 2）[经验规律]。两算法的超参数完全相同，唯一差别是目标式。

6.2.3 Dueling：把状态价值与动作优势拆开

很多状态里选哪个动作并不重要——赛车游戏里前方没有车时，左右微调几乎等价，网络却在为每个动作重复学同一件事：这个状态本身值多少。Dueling 把这一观察写进结构：一个网络同时输出 $V(s)$ 与 $A(s,a)$，再聚合回 Q，状态价值只学一次，优势只学相对好坏。

最直接的聚合方式是

$$Q(s,a;\theta,\alpha,\beta)=V(s;\theta,\beta)+A(s,a;\theta,\alpha), \tag{6.5}$$

这里 α,β 只是优势支路与价值支路的参数（与学习率 α 同名不同义，仅在本小节有效）。但式 (6.5) 不可辨识：给 V 加常数 c、给 A 减同一个 c，Q 不变，网络无法确定该由哪一路承担它；原论文报告直接用式 (6.5) 训练表现很差（Wang et al., 2016）。两种修法都强制优势在某处归零：

$$Q(s,a)=V(s)+\Big(A(s,a)-\max_{a'}A(s,a')\Big), \tag{6.6}$$

或者减去优势的均值：

$$Q(s,a)=V(s)+\Big(A(s,a)-\frac{1}{|\mathcal{A}|}\sum_{a'}A(s,a')\Big). \tag{6.7}$$

式 (6.6) 恢复语义：最优动作优势为零，$Q(s,a^\star)=V(s)$。式 (6.7) 放弃语义（V 与 A 各偏移一个常数）但优化更稳：优势只需跟上均值，不必补偿最优动作优势的变化。原论文全部实验用式 (6.7)，因为它不改变 A 的相对次序，因而不改变任何贪心或 ϵ-贪心策略（Wang et al., 2016）。

代价是结构更复杂，优势的绝对值也不再直接可解释；评测规模为 57 个 Atari 游戏（Wang et al., 2016）[经验规律]。

6.2.4 优先经验回放：把预算花在还没学会的地方

均匀采样把同样的计算分给所有转移，而多数转移的 TD 误差已接近零，继续回放几乎无益。优先经验回放（PER）改为按优先级采样：第 i 条转移的优先级 $p_i=|\delta_i|+\epsilon$，$|\delta_i|$ 是 TD 误差绝对值，ϵ 防止零误差转移永不再采。采样概率为

SUMMARY / 总结

$$P(i) = \frac{p_i^\alpha}{\sum_k p_k^\alpha}, \tag{6.8}$$

其中 α 是**优先级指数**（与学习率同名不同义），$\alpha = 0$ 退化为均匀采样；另一变体取 $p_i = 1/\mathrm{rank}(i)$，对离群值更稳健（Schaul et al., 2016）。

改变采样分布就改变了更新的期望，于是引入偏差；修正靠重要性采样权重

$$w_i = \left(\frac{1}{N} \cdot \frac{1}{P(i)}\right)^\beta, \tag{6.9}$$

$\beta = 1$ 时完全补偿非均匀采样，实践中把 β 从 β_0 线性退火到 1，并把权重除以 $\max_i w_i$ 使其只缩小、不放大更新。原本的更新用 $w_i\delta_i$ 代替 δ_i。

原论文比较 DQN 与 DQN+优先回放：49 个游戏中 41 个提升，中位数从 48% 升到 106%（Schaul et al., 2016）[经验规律]；基准 Double DQN 为 100%，106% 只略高于它，两者叠加后又高一档。常用配置：比例型 $\alpha = 0.6$、$\beta_0 = 0.4$，秩型 $\alpha = 0.7$、$\beta_0 = 0.5$。代价三项：$\beta < 1$ 时的偏差、实现复杂、新样本优先级未知。

算法 6-1 Double DQN + **比例型优先回放**

输入：网络 Q_ϕ、**目标网络** Q_ϕ-、**缓冲区大小** N、**批大小** k、**指数** α, β、**步长** η
初始化：缓冲区为空，ϕ- ← ϕ，p_i ← 1
重复（每个回合）：
1: **观察** S，**按** ε-**贪心（或** Noisy Net**）选** A **执行，观察** R, S'
2: **以优先级** p = max_i p_i **把** (S, A, R, S', terminated, truncated) **存入缓冲区**
3: **若缓冲区未满则继续收集，否则：**
4: **按** P(i) ∝ p_i^α **抽** k **条转移**
5: **计算** w_j = (N · P(j))^(-β) / max_i w_i
6: **计算** δ_j = R_j + γ(1 - terminated_j) Q_ϕ-(S'_j, arg max_a Q_ϕ(S'_j, a)) - Q_ϕ(S_j, A_j)
7: **累积梯度** Δ ← Δ + w_j δ_j grad_ϕ Q_ϕ(S_j, A_j)
8: **更新** ϕ ← ϕ + η Δ，p_j ← |δ_j| + ε；**每隔** C **步复制** ϕ- ← ϕ **并退火** β
输出：ϕ

6.2.5 探索：把随机性放进网络

ϵ-贪心在动作空间大时效率很低：随机动作几乎不可能有用，而“几乎不可能”意味着探索的样本绝大多数是纯浪费——在 18 个动作的 Atari 上还能靠运气，在连续力矩控制里就完全无效。Noisy Nets 换一个位置加噪声：不再随机挑动作，而是在网络的权重上加可学习噪声，于是同一个状态下的

动作选择本身带随机性，且噪声幅度随梯度一起被训练。这样探索依赖状态，也在训练后期自动收缩，不必手工退火 ϵ。计数式探索走的是另一条路：用访问次数构造内在奖励，把“没去过的地方”变成可优化的目标，代价是在高维状态上“次数”本身很难定义。

6.2.6 Rainbow 与补丁之间的冲突

Rainbow 把 Double、Dueling、PER、多步回报、分布式价值与 Noisy Nets 合成一个智能体（Hessel et al., 2018），常被当作补丁互不矛盾的证据。更准确的说法是多数组合可共存、少数需额外处理：多步回报加深偏差，PER 只修正采样分布、不修正自举偏差，叠加时 β 的退火要重算；Noisy Nets 取代 ϵ-贪心后探索噪声与价值耦合，优先级估计也随之改变。

表 6-1 DQN 家族补丁表：失效模式、公式改动与代价

补丁	失效模式	公式改动	代价
目标网络	目标含自身参数，更新追自己	用冻结的 $\bar{\phi}$ 算标签	价值传播被延迟
经验回放	样本相关、利用率低	期望改对缓冲区取	数据分布与当前策略不一致
Double	最大算子系统性高估	选择与评估分离（式 6.4）	可能转为低估
Dueling	状态价值与优势耦合	两路输出再加均值聚合（式 6.7）	结构复杂、语义偏移常数
PER	均匀采样浪费预算	按 p_i^α 采样、w_i 修正	引入偏差、实现复杂
Noisy Net	ϵ-贪心探索低效	权重上加可学习噪声	探索与价值耦合

补丁是否值得用，取决于任务里那个失效模式是否真的存在——动作空间很小时，Double 的收益可能被它的额外方差抵消。

6.2.7 一个必须澄清的术语：分类型价值学习不等于分布式训练

“分布式”在深度强化学习文献里指两件完全不同的事，混着说会让读者以为 6.5 节的并行采样是“分布式价值”的推论。**分类型价值学习**（distributional value learning）把回报当随机变量、学它的分布而不是期望，动作价值是该分布的均值，即 $Q^\pi(s,a)=\mathbb{E}[Z^\pi(s,a)]$。它的贝尔曼备份作用在分布上，其中 $S'\sim P(\cdot\mid s,a)$、$A'\sim\pi(\cdot\mid S')$：

$$Z^\pi(s,a)\overset{D}{=}R(s,a)+\gamma Z^\pi(S',A'), \tag{6.10}$$

C51 离散化分布、QR-DQN 回归分位数——改变的是**被估计的对象**；分

布式训练（6.5 节）指并行采样与异步更新，改变的是**计算的组织方式**。

SUMMARY / 总结

6.3 连续动作与策略梯度方法

6.3.1 连续动作下 max 不再可算

DQN 家族的每一个目标式里都有一个 $\max_a$ 或 $\arg\max_a$。动作是离散的少数几个时，逐个算一遍就行；动作是 $[-2,2]$ 上的力矩时，这个最大化变成一个连续优化问题，每步都要解一次，代价无法接受。连续控制的方法因此换了一个对象：不学 Q 再取最大，而是直接学一个策略 $\mu_\theta(s)$，再用链式法则把 Q 的梯度传回策略参数。

这就是确定性策略梯度（deterministic policy gradient, DPG）的思路（Silver et al., 2014）。它的梯度是（式中的 d_γ^μ 沿用第 5 章 (5.5) 的**未归一化**约定 $\sum_s d_\gamma^\mu(s)=1/(1-\gamma)$（第 2 章 (2.8) 给的是归一化版本，两者差 $1/(1-\gamma)$）。本章的 $J(\theta)$ 是 $\mathbb{E}[\sum_t \gamma^t r]$，与未归一化测度配套；若用归一化测度而不补前因子，等于优化 $(1-\gamma)J$，梯度整体小 $1/(1-\gamma)$——第 5 章 (5.7) 把这一定性为常见错误）

$$\nabla_\theta J(\theta)=\mathbb{E}_{s\sim d_\gamma^\mu}\Big[\nabla_\theta \mu_\theta(s)\,\nabla_a Q^\mu(s,a)\big|_{a=\mu_\theta(s)}\Big], \tag{6.11}$$

它要求 Q 对动作可微，且策略是确定性的。式 (6.11) 的期望只对状态取，不需要对动作采样，因此方差比随机策略梯度小；代价是探索必须由外部噪声提供，因为确定性策略本身不含随机性。

6.3.2 DDPG：把 DQN 的三件装备搬到连续空间

深度确定性策略梯度（deep deterministic policy gradient, DDPG）就是把式 (6.11) 与 DQN 的两个装置拼起来（Lillicrap et al., 2016）。它有一个确定性 actor μ_θ 和一个 critic Q_ϕ，critic 的损失与式 (6.2) 同形，只是把目标里的 $\max$ 换成目标策略的输出：

$$\begin{aligned} y &= r+\gamma\,(1-d_t)\,Q_{\bar\phi}\big(s',\mu_{\bar\theta}(s')\big),\\ L(\phi) &= \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\Big[\big(y-Q_\phi(s,a)\big)^2\Big]. \end{aligned} \tag{6.12}$$

actor 按式 (6.11) 更新，梯度经 critic 传回。目标网络不采用 DQN 的“每 C 步硬拷贝”，而是软更新：

$$\bar\theta\leftarrow\tau\theta+(1-\tau)\bar\theta,\qquad \bar\phi\leftarrow\tau\phi+(1-\tau)\bar\phi, \tag{6.13}$$

$\tau\ll 1$ 时目标每步只挪动一点，等价于一个很长的平均窗口。原论文用 $\tau=0.001$、$\gamma=0.99$、10^6 容量的回放池，actor 与 critic 的学习率分别为 10^{-4}

SUMMARY / 总结

与 10^{-3}，探索噪声用 Ornstein–Uhlenbeck 过程（$\theta = 0.15$、$\sigma = 0.2$）而不是独立高斯（Lillicrap et al., 2016）。

DDPG 的问题写在它的成功里：它在许多任务上有效，但结果对超参数、奖励尺度与随机种子都相当敏感 [经验规律]。式 (6.12) 的目标仍含 $\max$ 的连续版本，而 critic 的过估计会经 actor 放大：actor 主动寻找被高估的动作，越找越偏。机制与 6.2.1 相同，只是发生在连续空间，也没有 ϵ-贪心式的试错来纠偏。

6.3.3 TD3：三处改动，各修一个失效模式

DDPG 训练中常见的故障有三个具体的现象：critic 的 Q 值一路走高而回报不涨（过估计被 actor 主动利用）、策略在动作边界附近来回抖（critic 在外推区域给出尖峰）、以及训练后期突然崩一次（actor 追着噪声走）。TD3 对这三个现象各改一处（Fujimoto et al., 2018）。

针对第一个，最小化双 critic：训练两个独立的 Q_{ϕ_1}, Q_{ϕ_2}，目标取较小值：

$$y = r + \gamma\,(1 - d_t)\,\min_{i=1,2} Q_{\bar{\phi}_i}\big(s', \tilde{a}'\big). \tag{6.14}$$

取最小值相当于对过估计做保守修正：若两个 critic 的误差独立，则 $\min$ 更可能落在低估一侧，从而抵消式 (6.3) 的正偏差。代价是可能转为系统性低估，而低估同样会经 actor 传播；两个 critic 若高度相关，修正力度随之下降。

针对第二个，目标策略平滑。在目标动作上加截断噪声：

$$\tilde{a}' = \mu_{\bar{\theta}}(s') + \mathrm{clip}\big(\epsilon, -c, c\big), \qquad \epsilon \sim \mathcal{N}(0, \sigma^2). \tag{6.15}$$

动机是：确定性策略的 critic 只在数据覆盖的窄带上有可靠估计，若目标动作恰好落在带外，critic 的估计就是外推，误差很大。加噪声等于要求 Q 在动作的小邻域内都给出相近的值，从而平滑掉这些尖峰。

针对第三个，延迟策略更新：critic 每步更新，actor 与目标网络每 d 步更新一次（典型取 $d = 2$）。理由是 critic 的误差需要先降下来，actor 才不至于追着噪声走。这三处改动的共同点是“先让 critic 可靠，再让 actor 跟上”，这也是 TD3 相对 DDPG 更稳的主要来源（Fujimoto et al., 2018）[经验规律]。

SUMMARY / 总结

算法 6-2 TD3 的四件套

输入：actor μ_θ、两个 critic Q_φ1, Q_φ2、目标网络、回放池 D、延迟周期 d、噪声 σ, c、软更新率 τ
初始化：φ1, φ2, θ 随机；φ-1 ← φ1，φ-2 ← φ2，θ- ← θ
重复（每一步）：
1: 选动作 a = clip(μ_θ(s) + ε_explore, a_min, a_max)，执行，存 (s, a, r, s', terminated, truncated) 到 D
2: 从 D 抽一个小批量
3: 目标动作 ã' = clip(μ_θ-(s') + clip(ε, -c, c), a_min, a_max)，ε ~ N(0, σ²)
4: y = r + γ (1 - terminated) · min(Q_φ-1(s', ã'), Q_φ-2(s', ã'))
5: 两个 critic 各做一次梯度下降，最小化 (Q_φi(s, a) - y)²
6: 若 步数 mod d == 0：
7: actor 更新：grad_θ J = -grad_a Q_φ1(s, a)|_{a=μ_θ(s)} · grad_θ μ_θ(s)
8: 软更新：θ- ← τθ + (1-τ)θ-，φ-i ← τφi + (1-τ)φ-i（i = 1, 2）
输出：θ

6.3.4 SAC：把熵写进目标

soft actor-critic（SAC）换了一个优化对象。它不最大化期望回报，而是最大化“回报加策略熵”：

$$J(\pi)=\sum_t \mathbb{E}_{(s_t,a_t)\sim\rho_\pi}\Big[r(s_t,a_t)+\alpha_{\text{ent}}\,H\big(\pi(\cdot\mid s_t)\big)\Big], \tag{6.16}$$

其中 $H(\pi(\cdot\mid s))=-\mathbb{E}_{a\sim\pi}[\log\pi(a\mid s)]$，$\rho_\pi$ 指策略与环境交互产生的状态—动作联合分布（$s_t\sim d_\gamma^\pi$、$a_t\sim\pi(\cdot\mid s_t)$），与 (6.11) 的 d_γ^μ 同源。α_{ent} 是熵温度，控制熵项相对于奖励的权重；$\alpha_{\text{ent}}\to 0$ 时退化为普通的期望回报目标（Haarnoja et al., 2018a）。

这个目标的贝尔曼备份也要改。定义软价值函数

$$\begin{aligned} Q(s,a)&=r(s,a)+\gamma(1-d)\,\mathbb{E}_{s'}\big[V(s')\big],\\ V(s)&=\mathbb{E}_{a\sim\pi}\big[Q(s,a)-\alpha_{\text{ent}}\log\pi(a\mid s)\big], \end{aligned} \tag{6.17}$$

也就是说，价值里扣掉了“为了保持随机性而付出的代价”。策略的改进不再是取 $\arg\max$，而是向 $\exp(Q/\alpha_{\text{ent}})$ 做 KL 投影；对高斯策略用重参数化 $a=\tanh\big(f_\phi(\epsilon;s)\big)$，$\epsilon\sim\mathcal{N}(0,I)$，策略损失写成

$$J_\pi(\phi)=\mathbb{E}_{s\sim\mathcal{D},\,\epsilon}\Big[\alpha_{\text{ent}}\log\pi_\phi\big(a\mid s\big)-Q_\theta\big(s,a\big)\Big]\Big|_{a=\tanh(f_\phi(\epsilon;s))}. \tag{6.18}$$

工程上还有两件事：训练两个 Q 网络并取较小值（与 TD3 同理），再维护它们的目标网络做软更新；原文另有一个价值网络 V_ψ，实现里通常由

SUMMARY / 总结

critic 直接算出，本章按实现写法处理。原始论文的 α_{ent} 是手工设定的超参数，且 SAC 对奖励尺度特别敏感——奖励尺度在这里**充当温度**，所以不同任务的最优取值不同（Haarnoja et al., 2018a）；由式 (6.16) 可读出「奖励乘 c 等价于把 α_{ent} 除以 c」，这是推论而非原文措辞。

后续版本把 α_{ent} 也变成优化变量：给定目标熵 $\bar{H}$，解对偶问题

$$\min_{\alpha_{\text{ent}}>0} \mathbb{E}_{a\sim\pi}\Big[-\alpha_{\text{ent}}\big(\log\pi(a\mid s)+\bar{H}\big)\Big], \tag{6.19}$$

其中 $\bar{H}>0$ 是**目标熵**（文献里也写作 $\bar{H}=-H_{\text{target}}$）。对 α_{ent} 求导得 $H(\pi)-\bar{H}$：熵低于目标时导数为负、梯度下降把温度推高，熵高于目标时导数为正、温度下降（Haarnoja et al., 2018b）。把这里的负号漏掉，更新方向会整个反过来——这是改写这一段时最容易犯的错。这是约束优化的拉格朗日形式，理论地位是 [近似]：收敛性依赖策略类与 critic 的准确性，实践中通常只当自适应步长用。

这几组“温度 / 步长”符号作用域不同，混用会直接写错公式：α 是学习率，既出现在第 5 章的策略梯度里，也出现在式 (6.1) 的表格更新里；α_{ent} 是 SAC 的熵温度，单位与奖励相同，只出现在式 (6.16)—(6.19) 中；β_{KL} 是第 10 章 RLHF 目标里对参考策略的 KL 正则系数，约束策略偏移而非熵。三者都是权衡系数，只是对象不同：α 权衡新旧估计，α_{ent} 权衡回报与随机性，β_{KL} 权衡偏离参考策略的代价。

算法 6-3 SAC 与温度自动调节

输入：策略 π_ϕ、两个 Q 网络 Q_θ1, Q_θ2、目标 Q 网络、α_ent（或可学习 log α_ent）、目标熵 H_target
重复（每一步）：
1: a ~ π_ϕ(·|s)，**执行，存** (s, a, r, s', terminated, truncated) **到** D
2: **从** D **抽一个小批量，采样** a' ~ π_ϕ(·|s')
3: y = r + γ (1 - terminated) (min_i Q_θ-i(s', a') - α_ent log π_ϕ(a'|s'))
4: **两个** critic **各做梯度下降，最小化** (Q_θi(s, a) - y)²
5: **用重参数化** a = tanh(f_ϕ(ε; s)) **更新策略：**
grad_ϕ (α_ent log π_ϕ(a|s) - min_i Q_θi(s, a))
6: **若自动调节温度：**
α_ent ← α_ent - η · grad(-α_ent (log π_ϕ(a|s) + H_target))，**并截断到** α_ent > 0
7: **软更新目标网络**
输出：ϕ, θ

SUMMARY / 总结

表 6-2 三种连续控制算法的结构对比

算法	策略与探索	critic 与更新节奏	额外机制
DDPG	确定性；外加 OU / 高斯噪声	单 critic，每步更新	目标网络软更新
TD3	确定性；外加高斯噪声	双 critic 取 min，每 2 步更新 actor	目标动作平滑、延迟更新
SAC	随机（高斯）；探索来自策略熵	双 critic 取 min，每步更新	熵温度 α_{ent}、目标价值网络

表 6-2 最值得注意的一行是 critic 数量：TD3 与 SAC 都取两个 critic 的最小值，这几乎成了连续控制的标准做法，原因已在前两节说明——单个 critic 的过估计会被 actor 主动利用，而连续空间没有 ϵ-贪心式的试错来纠偏。选哪种方法则看动作的性质：确定性策略适合精度要求高、噪声主要来自执行器的任务，随机策略适合存在多个近优解、需要保持探索的任务。

SUMMARY / 总结

6.4 训练诊断与评估

深度强化学习的实验结果极易被误读：同一个算法在不同实现、不同随机种子、不同评估口径下可以差出数倍，而论文里报告的通常是精心挑选过的配置。本节先把常见的学习曲线形态对应到具体病因，再给出评估协议的最低要求，最后用一个真算的连续控制实验演示这套协议。

6.4.1 三种曲线形态与它们的病因

早崩指训练初期回报冲高、随后急剧塌陷。最常见的原因是 critic 的估计失控：TD 误差的量级突然增大，actor 追着这些错误的目标走，把策略推向更差的区域，形成正反馈。诊断时不要只看回报，要同时记录 TD 误差的分位数与 Q 值的均值——如果 Q 的均值在崩塌前出现数量级上的抬升，基本可以确定是过估计或数值问题，而不是探索不足。

平台指曲线长时间水平。原因可能是探索不足、网络容量不够、奖励过于稀疏或学习率过小。判断的关键是有没有已知上界：接近上界即收敛，否则曲线形状无法区分“学会了”与“卡住了”。

缓慢下降指回报随训练推进而下降。它通常是估计偏差在起作用：actor 逐渐学会利用 critic 的高估区域，而这些区域在真实环境中并不存在。奖励尺度不当、目标网络更新过频、优先级设置过激都会加速这一过程。

这三种形态共享一个前提：图上画的是**训练回报**，而训练时的行为策略含有探索噪声。策略变好与探索变少都会改变训练回报，两者混在一起，曲线就不能直接读成策略质量。

6.4.2 三个容易被调坏的旋钮

奖励尺度。它同时影响价值量级、TD 误差、梯度大小与熵温度的有效值。SAC 的原始论文指出奖励尺度在该目标里充当温度；由式 (6.16) 可见把奖励乘以 c 等价于把 α_{ent} 除以 c，因此“调温度”与“调奖励尺度”在**这个目标里**是同一件事（Haarnoja et al., 2018a）[近似]。实践上先把奖励归一化到固定量级，再调温度。

梯度裁剪。DQN 把 TD 误差裁剪到 $[-1,1]$，SAC 与 TD3 常用范数裁剪。裁剪太松等于没有，太紧会让学习停滞——奖励尺度较大时，裁剪后的梯度几乎不含信息。判断办法是记录被裁剪样本的比例。

目标更新频率。DQN 每 C 步硬拷贝，DDPG 与 TD3 用 $\tau \ll 1$ 的软更

新：τ 越小目标越稳但越滞后，越大越接近“追自己”。

6.4.3 评估协议

一套可用于比较的评估协议至少包含五项。第一，**固定评估种子集**，且与训练种子分离，保证不同算法面对同一批初始条件。第二，**评估时关闭探索噪声**：DDPG 的原始论文明确说明评估时不加探索噪声（Lillicrap et al., 2016），SAC 用策略均值而非采样动作。第三，**至少 5 个训练种子**并报告**中位数与四分位距**：回报分布常有重尾，均值会被一两个崩溃的种子拉偏，“最好种子”更不是对性能的估计。第四，**足够的评估回合**：DQN 用 100 个回合、$\epsilon = 0.05$ 的 ϵ-贪心增加起点多样性（van Hasselt et al., 2016），回合太少会让回合间方差盖过算法差异。第五，**不用训练回报代替评估回报**。

还应报告**方差来源**：种子间方差衡量算法对初始化的敏感性，回合间方差衡量策略在初始状态分布上的稳定性，合并成一个“标准差”会丢失信息。

6.4.4 一个真算的实验：线性二次调节器上的三种方法

为了让比较可复现，这里用一个解析可解的任务：一维双积分器（小车的位置控制），状态 $s = (p, v)$，动作是加速度 $a \in [-2, 2]$，动力学为 $p_{t+1} = p_t + 0.1\, v_t$、$v_{t+1} = v_t + 0.1\, a_t$，每步代价 $c = 0.1\,(p^2 + 0.1\, v^2 + 0.01\, a^2)$，回合长度 100 步，折扣 $\gamma = 0.99$。初始状态 $p \sim U(-2, 2)$、$v \sim U(-1, 1)$。这个任务的无限时域最优策略是线性反馈，可由离散代数 Riccati 方程解出；把它作用在同一批评估初始状态上，得到参考回报 -0.83（20 个固定评估种子）。后文所有回报都除以这个参考值，1.0 表示达到 LQR 最优。

三种算法用同一套骨架：两层 32 单元的全连接网络、批大小 64、学习率 3×10^{-4}、软更新率 $\tau = 0.005$、回放池 5×10^4、每个训练种子 15000 步环境交互。DDPG 与 TD3 用标准差 0.15 的高斯探索噪声，TD3 的延迟更新周期为 2；SAC 的温度固定为 0.05。每个算法训练 5 个种子，评估时关掉噪声，在 20 个固定初始状态上各跑一个完整回合，取均值作为一个种子的成绩。

五个种子的归一化回报（越大越接近 LQR 最优）如下，括号内为四分位区间：DDPG 中位数 0.39（0.34 – 0.42），TD3 0.45（0.42 – 0.54），SAC 0.73（0.65 – 0.76）。三种方法都没有触及 LQR 最优：最好的单次成绩是 SAC 的 0.78，最差的种子只有 0.19。SAC 在这个任务上中位数最高，分布

也最紧（除一个 0.42 的种子外，其余四个都落在 0.65 以上）；DDPG 的分布最宽，一个种子拿到 0.81，另一个只有 0.19。

图 6-4 给出同一批训练过程的学习曲线：SAC 在 2000 步左右开始抬升，DDPG 稍晚，TD3 最晚；但三条曲线在 15000 步内始终在 0.2 到 0.8 之间震荡，单看曲线很难判断优劣。训练回报混合了探索噪声与初始状态的随机性，不能代替评估回报。

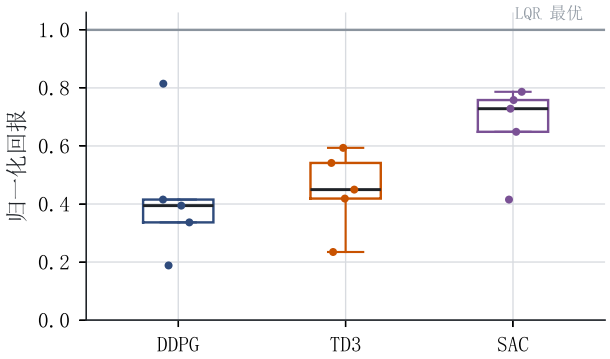


图 6-3 DDPG、TD3、SAC 在 LQR 任务上的归一化回报。箱线为 5 个训练种子的分布，散点为单个种子，虚线为 LQR 最优

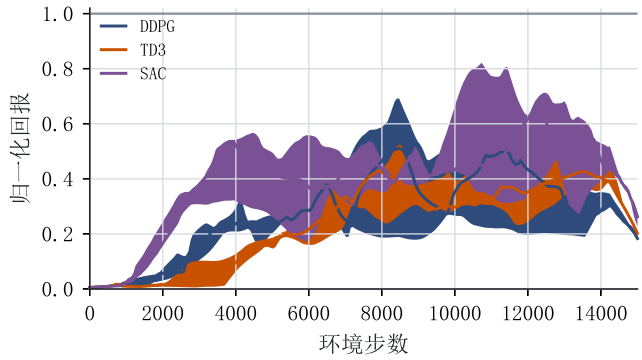


图 6-4 三种方法的学习曲线。实线为 5 个种子的中位数，阴影为四分位区间，横轴为环境交互步数

这组数字的解读要谨慎。任务太简单——状态只有两维、动力学线性、最优策略已知，任何能拟合线性反馈的网络都能接近最优，差距主要体现在**收敛速度与种子间方差**。15000 步是刻意设定的短预算，critic 远未收敛，差别被初始化噪声放大；三个算法也没有各自调参，学习率、网络宽度、批大小完全相同。因此差距不能完全归因于算法本身。结论应当表述为：**在这个任务、这个预算与这套共享超参数下**，三种方法的回报分布如此；不能外推成“SAC 一定比 DDPG 稳”这类无条件判断。

SUMMARY / 总结

6.5 从 Atari 到机器人

6.5.1 从像素到状态：观测不是状态

Atari 的输入是图像帧，单帧并不构成马尔可夫状态——球的速度无法从一张图里读出。DQN 的做法是堆叠最近 4 帧作为观测，把“历史”塞进输入（Mnih et al., 2015）。这是一个廉价的部分可观测性补丁，代价是网络必须自己学会从帧差里推断速度，样本效率因此下降。

真实机器人上还有两个 Atari 不存在的问题。其一是**观测延迟**：相机曝光、传输、推理加起来常有几十毫秒，而控制频率可能是 100 Hz，策略看到的永远是“过去”。其二是**动作频率与控制器的层级**：底层是力矩或速度环，上层策略输出的目标位置要经过滤波与限幅，实际执行的动作为策略输出的滞后版本。把仿真里学到的策略直接搬到真机，这两条都会让“同一个策略”看到不同的状态转移。图 6-5 把这三处差距画在一起。



图 6-5 仿真到真机的三处差距。观测延迟、动作频率与安全约束都会改变策略实际面对的状态转移

6.5.2 仿真到真机：域随机化能补什么，不能补什么

sim-to-real 的常见做法是域随机化：训练时随机化质量、摩擦、延迟、观测噪声、甚至动力学参数，让策略见到足够宽的分布，从而对真实环境的偏差不敏感。它的逻辑与 6.2.5 的探索类似：把不确定性放进训练分布，而不是寄希望于真机上的微调。

需要明确它的边界。域随机化不提供任何泛化保证 [经验规律]：它只是把训练分布撑大，真机若落在分布之外（地面材质、负载、磨损），策略仍会失效；它也不能替代安全约束——随机化会鼓励策略试探危险区域，而真机上一次碰撞不可逆。因此实务上常见的组合是“仿真预训练 + 真机小幅微调 + 硬性安全层”。

SUMMARY / 总结

6.5.3 分布式采样与大规模训练

当任务从单个 Atari 游戏变成几十个游戏或上亿步的机器人数据时，瓶颈从算法变成吞吐。IMPALA 的 actor-learner 架构把采样与学习解耦：多个 actor 各用本地策略跑轨迹、把经验送进队列，中心 learner 异步消费（Espeholt et al., 2018）。actor 的策略可能落后 learner 若干次更新，数据天然离策略，于是需要一个修正项——V-trace，它按截断的重要性比率把离策略的 n 步回报修正回目标策略：

$$v_s = V(s) + \sum_{t=s}^{s+n-1} \gamma^{t-s} \Big(\prod_{i=s}^{t-1} c_i \Big) \delta_t V, \qquad \delta_t V = \rho_t \big(r_t + \gamma V(s_{t+1}) - V(s_t) \big), \tag{6.20}$$

其中 μ 是 actor 的行为策略，$\rho_t = \min(\bar{\rho}, \pi(a_t \mid s_t)/\mu(a_t \mid s_t))$ 是重要性比率，$c_i = \min(\bar{c}, \pi(a_i \mid s_i)/\mu(a_i \mid s_i))$ 把同类比率截断到 $\bar{c}$；两个截断常数把方差压在可控范围内，代价是引入偏差。这与 6.2.7 的“分类型价值学习”无关：改变的是并行度与数据的新鲜度，不是被估计的对象。

另一条路是提高单机利用率：更大的回放池、更多并行环境。它们不改变样本复杂度，只把墙钟时间压下来；评估时要把这类改进与算法改进分开报告，否则“更快的实现”会被误读成“更好的算法”。

SUMMARY / 总结

本章小结

本章从一个具体的失败出发：把 Q 表换成神经网络，曲线会先涨后崩。三个洞口解释了崩的原因——参数化让一次更新改动所有状态，目标里含着自己的参数所以越追越远，回放数据与当前策略的分布不一致。DQN 用经验回放与目标网络分别堵住后两个，但过估计、样本效率与探索仍然敞着，这正是改进方法的起点。每个补丁都对应一个能在曲线上看见的故障：Q 值单调抬升对应过估计，Double 把“选”与“评”分开；多数状态里动作无所谓，Dueling 把状态价值与优势拆开；回放池里多数转移已学不动，PER 按误差分配预算；ϵ-贪心在大动作空间里探不到东西，Noisy Net 把噪声放进权重。补丁都带代价——偏差、方差、实现复杂度或语义偏移——是否值得用，取决于那个失效模式是否真的存在。

连续动作是第四个洞：$\max$ 算不出来，DDPG 用确定性策略梯度绕开它，TD3 用双 critic、目标平滑与延迟更新修补它的过估计与外推，SAC 干脆换掉目标函数，把探索从外加噪声变成目标的一部分。到这里必须收住一句：本章的算法几乎没有收敛定理，定理 6.1 那样精确的结论很少，“某个补丁让训练更稳”通常只是经验规律——所以 6.4节的评估协议是读这些结论的前提：种子数、评估时的探索设置、回报的统计量，缺一项就无法比较。最后一节把视角从仿真拉到真机：观测延迟、动作频率、安全约束都不在公式里，却决定了同一个策略在真机上是否还成立。

关键公式

下面六条是全章的主干，从过估计的根源出发，经三个 Q-learning 补丁，到两种连续控制的目标。

$$\mathbb{E}\Big[\max_a \hat{Q}(s,a)\Big] \;\geq\; \max_a \mathbb{E}\big[\hat{Q}(s,a)\big].$$

$$y = r + \gamma\,(1-d_t)\,Q_{\bar{\phi}}\Big(s', \arg\max_{a'} Q_{\phi}(s',a')\Big).$$

$$Q(s,a) = V(s) + \Big(A(s,a) - \frac{1}{|\mathcal{A}|}\sum_{a'} A(s,a')\Big).$$

$$P(i) = \frac{p_i^{\alpha}}{\sum_k p_k^{\alpha}}, \qquad w_i = \Big(\frac{1}{N}\cdot\frac{1}{P(i)}\Big)^{\beta}.$$

$$y = r + \gamma\,(1-d_t)\min_{i=1,2} Q_{\bar{\phi}_i}\big(s', \tilde{a}'\big), \qquad \tilde{a}' = \mu_{\bar{\theta}}(s') + \mathrm{clip}(\epsilon, -c, c).$$

SUMMARY / 总结

$$J(\pi)=\sum_t \mathbb{E}\big[r(s_t,a_t)+\alpha_{\text{ent}}H(\pi(\cdot\mid s_t))\big],\qquad V(s)=\mathbb{E}_{a\sim\pi}\big[Q(s,a)-\alpha_{\text{ent}}\log\pi(a\mid s)\big].$$

习题

1. 设 m 个动作的估计各带独立、零均值、方差 σ^2 的噪声，说明式 (6.3) 的偏差为何随 $\sigma\sqrt{\log m}$ 增长，动作数多时 DQN 的过估计为何更严重。
2. Double DQN 只改目标式，收益却依赖两个网络“误差不相关”。若把目标网络换成每步软更新，这个条件变好还是变差？
3. 说明式 (6.5) 为何不可辨识，并证明式 (6.7) 不改变 Q 值的相对次序（对任意 s，$\arg\max_a Q(s,a)$ 不变）。
4. 优先回放在 $\beta=1$ 时无偏但方差大，$\beta=0$ 时方差小但有偏。结合式 (6.9) 说明为何要让 β 从 β_0 退火到 1。
5. 写出 DDPG 的 actor 梯度，说明它为何不能用 $\max_a Q(s,a)$ 作目标；若动作一维有界，能否用网格搜索代替 actor，代价是什么？
6. TD3 的 $\min$ 修正会带来低估。设两个 critic 误差独立同分布、均值为零，说明 $\min$ 的偏差为何与 $\max$ 相反，两 critic 高度相关时修正为何失效。
7. SAC 中把 α_{ent} 设为 0 会退化成什么？设得过大又会出现什么现象？结合式 (6.16) 与式 (6.17) 说明。
8. 设计评估协议比较两个 DQN 变体在同一 Atari 游戏上的优劣：写明种子数、评估回合数、是否保留探索、统计量与误差范围，并说明为何不能用训练回报代替评估。

延伸阅读

- Sutton & Barto (2018) 第 11、16 章：致命三要素的形式化讨论，以及 DQN 三个修改与消融实验的原始叙述。
- Mnih et al. (2015)：DQN 原文，经验回放与目标网络的工程细节；与 van Hasselt et al. (2016) 同读，后者对过估计的诊断与式 (6.4) 的推导最清楚。
- Wang et al. (2016) 与 Schaul et al. (2016)：Dueling 的可辨识性论证与 57 个游戏评测、优先回放的偏差分析与 sum-tree 实现（式 6.5—6.9）。

SUMMARY / 总结

- Lillicrap et al. (2016)、Fujimoto et al. (2018)、Haarnoja et al. (2018a, 2018b)：DDPG、TD3、SAC 三篇原文，按此顺序读，注意后两篇都把“过估计”作为核心动机。
- Espeholt et al. (2018)：IMPALA 与 V-trace，理解大规模分布式采样中“行为策略落后”为何必须修正。

SUMMARY / 总结

第 3 部分

规划与进阶决策

第 7 章　模型、规划与搜索

第 8 章　离线强化学习与策略评估

第 9 章　层次、多智能体与安全约束

第 7 章　模型、规划与搜索

前述采样式方法主要通过真实交互收集经验，模型方法进一步利用学习得到的动力学信息进行规划。第 3 章用采样绕开模型，第 5 章把交互变成梯度，第 6 章把一次交互放进回放池反复用——三条路都在同一条通道上省着花。在真实交互代价较高的任务中，大规模在线采样可能受到时间、设备和安全约束。本章换一个假设：如果智能体能从已经试过的经验里学出一个**模型**——给定 s 与 a，预测接下来会发生什么——它就能在模型上做实验，把昂贵的交互换成便宜的计算。这条路叫**基于模型的强化学习**，在模型上做实验叫**规划**。

本章以前两章的 MDP 与贝尔曼方程为基础。第 3 章的动态规划使用已知模型，本章则从数据中学习模型；规划把一步预测延伸到多步，预测误差也会逐步累积。Dyna　将模拟经验用于价值估计，搜索则为当前动作进行临时计算。后文将从不确定性、规划视野和模型集成三个方面分析模型误差的影响，并给出相应的工程判据。

本章结论的理论强度取决于具体条件。确定性环境中，表格模型可以准确记录已观测的转移；随机环境中，转移概率仍需依据样本估计。误差随规划视野线性累积的上界属于 [精确] 结论，条件见式 (7.5)；规划步数与学习速度的关系属于 [经验规律]；MCTS 的渐近最优性要求模拟次数趋于无穷，有限预算下应依据具体评测结果判断。

7.1 Dyna：把模型当作加速器

7.1.1 三条回路

真实经验可直接用于更新价值或策略，也可先用于学习模型，再由模型生成模拟经验以更新价值或策略。前一种方式称为**直接强化学习**，后一种称为**间接强化学习**。Dyna　中的规划更新与直接价值学习可以采用相同的备份形式；模型学习和搜索控制仍需单独分析。

SUMMARY / 总结

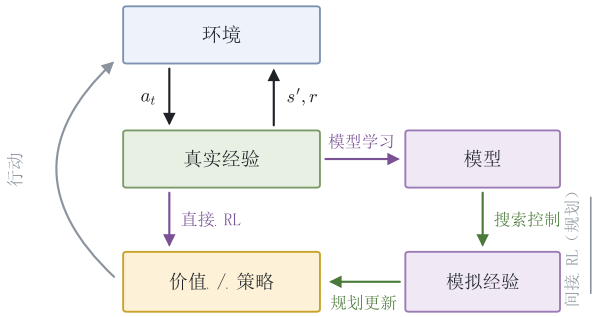


图 7-1 Dyna 的三条回路。真实经验一路直接更新价值与策略，一路写入模型；模型产生的模拟经验经搜索控制（选哪些状态做规划）走同一条更新规则回到价值与策略。图中的“搜索控制”只指挑起点状态，不指第 7.4 节的树搜索。

图 7-1 上有三个接口，每一个都可能出错。**模型学习**把一条转移 (s, a, r, s') 写进模型：表格情形是查表覆盖，函数逼近下是一步梯度。**搜索控制**决定规划从哪里采样——均匀抽样最省事，按价值变化或优先级抽样更省算力，第 7.2 节的悲观项也是从这里进来的。**行动**这一端则说明：策略同时被真实经验与模拟经验改动，所以它比纯直接学习更早“知道”远处的事。

加速的道理可以用一句话说清。一次真实转移只包含一个状态-动作对的信息，直接更新也只改一个数；可这条信息进了模型之后能被反复查询，规划沿模型链把回报向前传播一步、再一步，于是一次真实交互的影响被分摊到许多状态上。规划步数 n 的含义就是“每得到一次真实经验，额外做多少次模拟更新”。规划反复使用有偏模型时，预测误差可能被传播并影响策略改进。

持续使用模拟经验更新并保存价值或策略的方式称为**背景规划**；第 7.4 节讨论的**决策时规划**则在当前状态下进行搜索，并据此选择动作。Dyna 属于背景规划，规划更新写入 Q 函数；两种规划分别关注可复用的策略信息与当前决策计算。

7.1.2 规划步数的真实收益

下面这个实验直接测量 n 的作用。环境是一个 9 行 6 列的迷宫（按 S&B 例 8.1 的规模自建，不是逐格复刻其插图），去掉 7 个障碍格后剩 47 个状态；四个动作确定性移动，撞墙或越界则停在原处；只有进入目标格的一步给 $+1$ 奖励；折扣 $\gamma = 0.95$、步长 $\alpha = 0.1$、探索率 $\varepsilon = 0.1$、并列动作随机打破。每个真实步之后做 n 次规划更新，规划从已访问的状态-动作对中均匀抽样。三种设置 $n \in \{0, 5, 50\}$ 各跑 30 个随机种子，每回合上限 2000

步，记录每回合到达目标所用的步数。

图 7-2 把 n 的作用量成了三个数字。以“连续三个回合不超过 30 步”为达标线，$n = 0$ 要到第 20 回合，$n = 5$ 只要 5 个回合，$n = 50$ 只要 3 个回合。三者的渐近表现相同，最终都稳定在每回合 15 步左右——最优路径是 13 步（用 BFS 在同一迷宫上复算得到），多出的两步来自 $\varepsilon = 0.1$ 的探索。在上述迷宫实验中，增加规划次数主要缩短了达到目标表现所需的真实回合数；这一结果不构成规划方法普遍性能上限的证明。

收益随规划次数递减：n 从 0 增至 5 可减少 15 个回合，从 5 增至 50 则只再减少 2 个回合。其原因有四点：价值沿模型链每次传播一步，覆盖整个迷宫所需的规划步数至少与路径长度同阶；模型只覆盖已访问的状态—动作对，未访问区域无法通过重复规划获得信息；随机环境中的模型误差会随查询次数累积；探索策略仍会引入由 ε 决定的噪声下限。因此，规划次数增加所带来的收益存在上限。

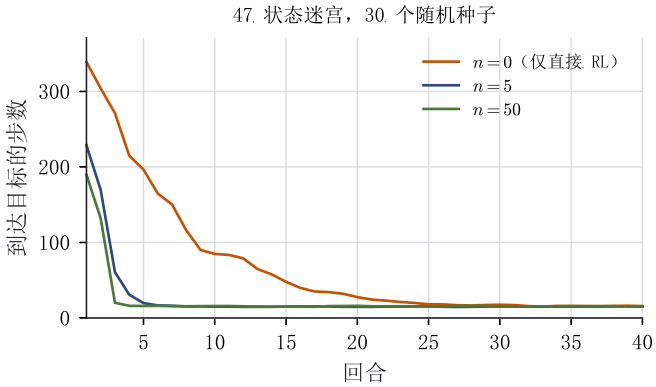


图 7-2 规划步数对收敛速度的影响。47 状态（9 行 6 列）迷宫，三个 n 各 30 个随机种子，曲线为每回合步数的三点滑动平均；三者共享同一动作采样流，差别只来自规划。最短路径 13 步由 BFS 在同一个迷宫上复算，脚本为 `review/reproductions/CH07-MAZE_maze_bfs.py`。

SUMMARY / 总结

算法 7-1 表格 Dyna-Q

1: 对所有 s, a 初始化 Q(s,a) = 0，模型 M(s,a) = 未知
2: 每个回合：
3: S ← 当前非终止状态
4: A ← ε-greedy(S, Q)
5: 执行 A，观测 R, S'
6: Q(S,A) ← Q(S,A) + α[R + γ max_a Q(S',a) - Q(S,A)] # 直接 RL
7: M(S,A) ← (R, S') # 模型学习
8: 重复 n 次： # 规划
9: (S_s, A_s) ← 从已访问的 (S,A) 中均匀抽样
10: R_s, S_s' ← M(S_s, A_s)
11: Q(S_s,A_s) ← Q(S_s,A_s) + α[R_s + γ max_a Q(S_s',a) - Q(S_s,A_s)]
12: 若 S' 为终止状态则结束本回合

7.1.3 模型误差对规划结果的影响

模型准确性包含不同层次。**记录准确**指确定性环境中的表格模型保存了已观测到的奖励与后继状态。**期望准确**指随机环境中的模型通过样本估计转移概率与奖励期望，有限样本下存在估计误差。函数逼近模型还需考察其在策略访问分布上的预测误差；当规划访问数据覆盖不足的区域时，误差可能增大。

第三种最危险，因为它与策略改进直接冲突。策略越好，访问分布越集中，模型在旧数据覆盖的边缘就越薄；而规划恰恰喜欢往这些边缘走，因为那里可能藏着更高的回报。于是出现一个自我强化的偏差：模型在没数据的地方给出乐观预测，规划据此改进策略，新策略又把智能体带到更没数据的地方。第 4 章把“函数逼近 + 自举 + 离策略”称为致命三要素，规划正是那个放大器：更新分布从行为策略走过的状态换成了模型想象出来的状态。

表格情形之所以安全，是因为模型的支撑集就是真实发生过的转移，规划查询的每个 (s,a) 都有确定答案。函数逼近下模型会泛化，而泛化既是它有用的原因（能对没见过的状态给预测），也是它危险的原因（预测可能错，而且错得系统）。这条分界线会在第 7.3 节以“集成模型 + 短 rollout”的形式重新出现。

SUMMARY / 总结

7.2 模型学习与不确定性

7.2.1 监督式的模型学习

模型的学习本身是一个监督学习问题：给定数据集 $\mathcal{D}=\{(s,a,r,s')\}$，学两个预测器——转移 $\hat{P}_\varphi(s'\mid s,a)$ 与奖励 $\hat{r}_\varphi(s,a)$。最直接的写法是把两项损失相加：

$$\min_{\varphi}\ \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\Big[-\log\hat{P}_\varphi(s'\mid s,a)+\big(\hat{r}_\varphi(s,a)-r\big)^2\Big]. \tag{7.1}$$

确定性环境里 $\hat{P}$ 退化为一个点预测，第一项换成平方误差；连续状态空间里常用高斯输出（均值与方差各一个头）；图像观测则用重构或对比损失。表面上这只是“再训一个网络”，实际有三处与价值学习不同。

第一，**数据分布由行为策略决定**。模型只在 μ 的占用测度上准确，策略一改，准确区就漂移，这称为模型失配。第二，**模型要对分布建模**，而不只是对均值建模：随机环境里若只学均值，规划会系统性低估方差，把“有风险”当“确定”。第三，**模型的容量与价值函数的容量在争同一份数据**：两者共享表示能省样本，也会互相干扰，这是第 6 章表示共享问题的另一面。

7.2.2 两类不确定性

模型误差按来源分成两类，应对方式完全不同。模型不确定性可区分为认识性不确定性与环境随机性。

表 7-1 两类不确定性的对照。把二者混为一谈会犯两种相反的错误：把偶然性当认识性，会以为“再多采一点就好”；把认识性当偶然性，会在没数据的地方盲目自信。

类型	来源	数据增多会消失	该怎么做
认识性	该区域数据不足	会	集成方差、乐观探索、悲观惩罚
偶然性	环境转移本身随机	不会	学分布、对期望做规划、加大采样

认识性不确定性（epistemic）来自数据不足：某片状态空间没被访问过，模型在那里只能猜。它会随数据增多而消失，因此可以用“模型之间不一致”来度量——训练 M 个模型（不同初始化或自助重采样），看它们对同一输入的预测分歧有多大。

$$\hat{\sigma}^2(s,a)=\frac{1}{M-1}\sum_{m=1}^{M}\Big(\hat{f}_m(s,a)-\bar{f}(s,a)\Big)^2,\qquad \bar{f}=\frac{1}{M}\sum_{m=1}^{M}\hat{f}_m. \tag{7.2}$$

偶然性不确定性（aleatoric）来自环境本身的随机：同样的状态与动

作，下一次转移就是可能不同。数据再多也不会消失，只能把它的分布学出来。若每个集成成员都输出一个分布，则成员内部的方差对应偶然性，成员之间的方差对应认识性。

这张表把后面几节的设计都解释清楚了。第 7.3 节的模型几乎都以集成的形式出现，是为了把认识性不确定性变成一个可以用数字读取的量；短 rollout 之所以有效，是因为在认识性不确定性大的地方，推得越远越不可信。

7.2.3 悲观、乐观与短 rollout

有了不确定性，就可以改变规划的目标。用 $\lambda \geq 0$ 表示保守程度，定义悲观奖励

$$\tilde{r}(s,a) = \hat{r}(s,a) - \lambda \hat{\sigma}(s,a). \tag{7.3}$$

λ 越大，规划越不敢去不确定的地方，得到的策略越保守；取 $+\lambda$ 则是乐观，用来驱动探索，这与第 1 章 UCB 的“乐观面对不确定性”是同一个思想。两种用法都只是启发式，λ 没有理论最优值，要在“保守到不探索”与“乐观到送死”之间调。

另一个更常用的手段是**缩短规划视野**。不把模型推到底，而是推 h 步之后接上价值函数：

$$\hat{G}_h = \sum_{k=0}^{h-1} \gamma^k \hat{r}(s_k, a_k) + \gamma^h V_\phi(s_h). \tag{7.4}$$

若真实环境在视野内终止，求和应在终止那一步截断、不再接 $\gamma^h V_\phi(s_h)$——这与第 6 章 (6.2) 的 $(1 - d_t)$ 掩码是同一个约定；模型里没有终止概念时按截断处理（继续自举）。

$h = 0$ 时它退化为纯价值估计（无模型），h 增大则越来越多地依赖模型。这样做的理由是**误差换手**：偏差随 h 上升——每一步都乘上一次模型误差，量级是 $h\varepsilon_m$（式 (7.5)）；方差则取决于模型是否确定性——确定性模型下 γ^{2h} 把价值函数的方差压掉，h 越大方差越小，随机模型下模型噪声会把它补回来甚至更大。两股力量方向相反，所以存在一个最优的 h，它取决于模型精度与价值函数精度谁更差：模型很准时可以推得远，模型很糙时只推一步。第 7.3 节的 PETS 与 Dreamer 都是随机模型，那里的 h 主要由偏差一侧决定；只有确定性模型才适用“推得越远方差越小”这一说法。

模型误差随规划视野变化的关系可由总变差距离与转移核的稳定性刻

画。设同一动作序列下，模型每一步的状态分布与真实分布的总变差距离不超过 ε_m，则由三角不等式可得

$$\left\| \hat{P}_h(\cdot \mid s_0) - P_h(\cdot \mid s_0) \right\|_{\mathrm{TV}} \le h\,\varepsilon_m. \tag{7.5}$$

> **定理 7.1（误差随视野线性累积 [精确]）**
>
> 在式 (7.5) 的假设下，h 步开环推演的状态分布误差至多按 h 线性增长；若单步模型对真实转移的估计误差为 ε_m，则把视野从 h 增加到 $2h$ 至多把分布误差翻倍。该界不依赖模型的参数化形式，但要求每步误差都在同一动作序列诱导的分布上成立。

证明用递推而不是逐项相加：记 D_h 为 h 步后的分布与真实分布的总变差距离，则 $D_{h+1} \le D_h + \varepsilon_m$（前一步的偏差原样传下去，本步再引入至多 ε_m），从 $D_0 = 0$ 递推得 $D_h \le h\varepsilon_m$。系数为 1 是因为转移非扩张，**不是**把「前 k 步已偏 $k\varepsilon_m$、第 $k+1$ 步再偏」逐项相加——那样会得到 $\sum_{k=1}^{h} k\varepsilon_m = h(h+1)\varepsilon_m/2$，量的是各步偏差的累积总量，不是第 h 步的分布差。界是紧的当且仅当各步误差同向累积。方向值得说清：若转移核在总变差下是 λ-压缩（$\lambda < 1$），误差被压到 $\varepsilon_m/(1-\lambda)$ 而不再随 h 增长——压缩只让误差有界，不会让它指数上升；只有动力学扩张（李普希茨常数大于 1）时才会出现比线性更快的增长。

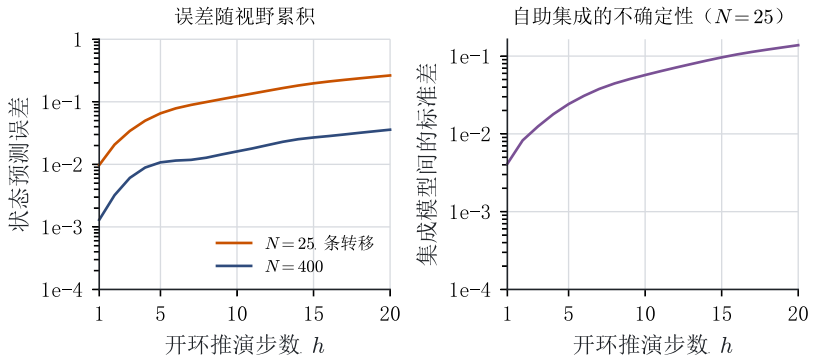


图 7-3 模型误差随推演视野的累积。二维线性系统、两条转移数据量（25 与 400 条），开环推演 1 到 20 步的状态预测误差；右图是 8 个自助重采样集成在同样视野下的分歧。

图 7-3 是这个上界的数值版本。左图两条曲线在 $h = 1$ 处相差一个数量级（0.0098 对 0.0013），到 $h = 20$ 时差距仍在（0.2637 对 0.0358），说明数据量决定的是误差的斜率而不只是截距。若模型集成在长视野预测上出现较大分歧，相关预测应视为不确定性较高的结果。这张图测的是状态预测误差，不是回报偏差；后者还要乘奖励尺度与 $1/(1-\gamma)$。

SUMMARY / 总结

7.3 从 PETS 到 Dreamer

7.3.1 PETS：概率集成加模型预测控制

PETS 把第 7.2 节的两件事组合起来：用 M 个概率动力学模型组成集成，每个成员输出高斯均值与方差；规划时用**轨迹采样**传播不确定性——每条候选轨迹在每一步随机挑一个成员，等价于对模型参数做边缘化。控制用模型预测控制（MPC）：在模型上优化未来 H 步的动作序列，只执行第一步，然后拿真实观测重新规划。

这两个优点互补。短视野 H 限制误差累积，重规划让真实反馈纠正模型偏差，形成闭环。代价是算力：每步都要解一个 H 维优化，候选序列数还要乘以集成规模。PETS 的贡献是把“概率集成 + 轨迹采样 + MPC”这套组合在连续控制上跑通，把真实交互压到几百个回合量级——原文标题就叫“in a handful of trials”，与无模型方法的百万步量级差着几个数量级。

7.3.2 MBPO：短 rollout 与真实数据混合

MBPO 把短 rollout 推到极致：从回放池里的**真实状态**出发，用当前策略采样动作，让模型只推很短一段（典型 1 步，长任务可到几步），把生成的转移与真实转移放进同一个回放池，再交给无模型算法（原文用 SAC）。

三个设计各有针对性。**分支起点取自真实数据**，把查询限制在访问过的状态附近，抑制分布偏移；**短视野**让误差不累积，对应式 (7.5) 中 h 很小的情形；**模型数据只作增广**，真实数据一直在池中，价值随时能被真实回报拉回。三者缺一个，收益就会掉。

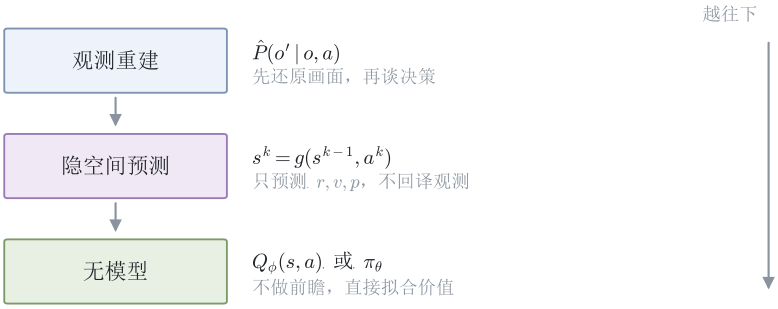
模型数据的有效性可依据以下经验条件判断，属于 [经验规律]：模型在当前策略访问的状态上足够准；模型数据与真实数据的比例要有限；回报尺度与模型误差可比，否则模型偏差淹没真实信号；rollout 长度有最优点，太短无增广，太长误差主导。这四条都不是定理，但解释了 MBPO 为何在平滑动力学上收益明显、在接触丰富或视觉任务上迅速失效。

7.3.3 Dreamer：在隐空间里想象

Dreamer 换了对象：不在观测空间学模型，而在一个**压缩的隐空间**里学世界模型。它的模型由三部分组成：表示模型把观测编码成隐状态，转移模型在隐状态上预测下一步（通常同时含一个确定性的循环路径与一个随机的隐变量，随机部分承载偶然性不确定性），奖励与终止各有一个预测头。训

练时用重构项与 KL 正则约束隐状态，使表示不塌缩；策略与价值则在**想象的**隐状态轨迹上学习，梯度穿过转移模型反传，不需要解码回观测。

这就带来一个常见误解：Dreamer 的模型**不是**“能预测下一帧画面的世界模型”。它提供的是一条足够准、低维、可微的转移，使策略优化能在想象中进行；重构项只是训练表示的手段，部署时不需要解码器。判断隐空间模型好坏的标准是它上面优化出的策略在真实环境里好不好。



自上而下模型越来越少、越来越靠近决策；三者都能做出好决策，区别只在要不要还原观测

图 7-4 模型预测的对象可以有三种选择。上：预测观测（需要解码器）；中：预测隐状态上的转移、奖励与价值（MuZero 式）；下：不做前瞻，直接拟合价值或策略。越往下模型越少，越靠近决策。

表 7-2 五种用模型的方式。前两行在观测空间规划，后三行在隐空间或价值空间规划；MBPO 干脆不显式规划，只把模型当数据生成器。

方法	模型预测什么	数据怎么用	规划方式
Dyna-Q	表格转移与奖励	真实经验 + 模拟更新	一步 Q 规划
PETS	概率集成动力学	少量真实轨迹	MPC，每步重规划
MBPO	集成动力学（短分支）	真实数据 + 模型增广	无（交给 SAC）
Dreamer	隐状态、奖励、终止	训练模型 + 想象策略	隐空间想象
MuZero	隐状态、奖励、价值	自我对弈 + 回放	MCTS

表 7-2 的顺序就是本章的主线：模型从“复制环境”一路收缩到“预测决策需要的东西”，到 MuZero 已经不对应任何可解释的物理量（见 7.4.3 节）。越往下模型越少，越靠近决策，也越难说清“这个模型究竟学的是什么”。

SUMMARY / 总结

7.4 搜索：从 MCTS 到 MuZero

到这里，规划换了性质。它不再改进一张可复用的价值表，而是针对当前状态现算一个动作，中间结果用完就丢。第 7.1 节那种“后台更新、结果存起来”的做法叫背景规划，本节这种叫**决策时规划**；前者关心“学到什么”，后者关心“这一步走哪”。

7.4.1 MCTS 的四步

蒙特卡洛树搜索要解决的是“给定当前状态，把有限的计算花在哪条分支上”。它把预算分成四步循环：**选择**从根按树策略走到叶节点，**扩展**给叶节点加一个子节点，**模拟**从新节点随机走到底得到一个回报，**回传**把回报沿路径累加到每个节点的统计量上。整棵树因此长得很不对称，访问集中在“看起来好”和“还没试够”的分支上——这正是第 1 章探索与利用的树版本。

树策略的选择规则来自 bandit。UCB1 在 t 次拉杆后选

$$a_t = \arg\max_a \left[\bar{Q}_t(a) + c\sqrt{\frac{2\ln t}{N_t(a)}} \right], \tag{7.6}$$

UCT 把它搬到树的每个节点上，用父节点的访问次数 $N(s)$ 代替总次数 t：

$$a^* = \arg\max_a \left[\bar{Q}(s,a) + c\sqrt{\frac{\ln N(s)}{N(s,a)}} \right]. \tag{7.7}$$

两式的关系很清楚：UCB1 是 UCT 在“只有一层、没有状态”时的特例。探索项随 $N(s,a)$ 增大而衰减，随 $N(s)$ 增大而增长——一个动作被访问得越多，它越不需要被再试；而整棵树被访问得越多，每个动作的探索项都会重新变大，这是一种自动的“回头检查”。常数 c 的量级由奖励范围决定：奖励在 $[0,1]$ 时 c 取 1 左右合适，把奖励放大十倍而 c 不变，探索项就会被价值项淹没。

SUMMARY / 总结

算法 7-2 UCT 版蒙特卡洛树搜索

1: 输入：根状态 s0，模拟预算 N，探索常数 c
2: 初始化树，只含根节点 s0
3: 重复 N 次：
4: 从 s0 沿树下行，按 argmax_a[Q(s,a) + c·sqrt(ln N(s)/N(s,a))] 选动作，直到叶节点 # 1 选择
5: 若该叶节点未终止：为它加一个未试过的动作子节点 s' # 2 扩展
6: v ← 从 s' 随机模拟到底得到的回报 # 3 模拟
7: 沿 s0 → s' 回传：N ← N+1，Q ← 均值更新 # 4 回传
8: 返回：访问次数最多的动作（或按 N 归一化的策略）

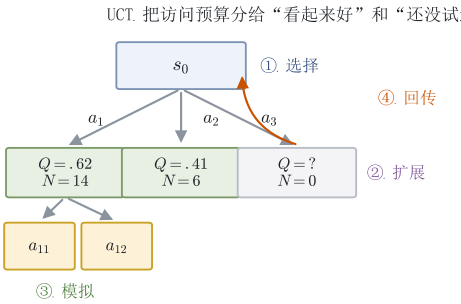


图 7-5 MCTS 的一轮循环。根节点下三个动作，前两个已被访问并带有 Q 与 N，第三个尚未扩展；带虚线的箭头表示回报沿路径回传，更新沿途每个节点。

有限预算下 MCTS 没有最优性保证，这一点必须说清楚。它只在“模拟次数趋于无穷且选择策略满足条件”时 [渐近] 收敛到博弈树的值；在有限模拟下，它给出的是一次有偏估计加一个搜索策略。下面的实验直接把这个差距量出来。

实验在井字棋上进行。用精确的极小化极大搜索算出每个局面的最优着法集合，再从随机对局中取出 120 个局面作为测试集；对每个局面跑 UCT（均匀先验、随机模拟、$c=1$），模拟次数从 10 增到 1280，统计“选中的着法属于最优集合”的比例，以及根节点价值估计与真值之差的绝对值。

SUMMARY / 总结

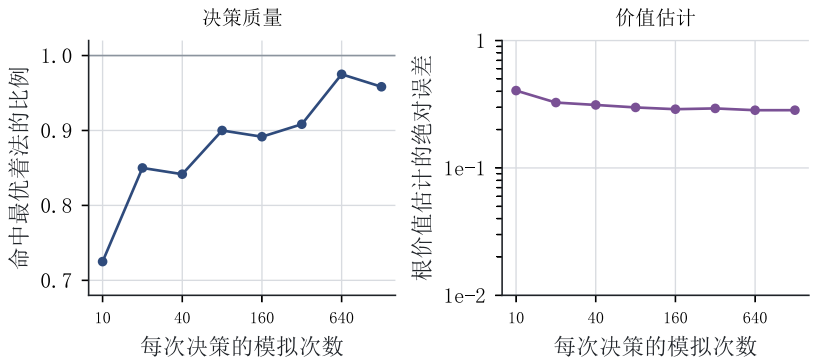


图 7-6 模拟预算与决策质量。井字棋 120 个随机对局局面，UCT（c=1，随机模拟）在 10 到 1280 次模拟下的最优着法命中率与根价值误差。

结果分成两半，而这两半正好说明了问题。命中率从 0.725 稳步升到 0.975（640 次），说明树策略确实在把预算导向正确的分支。但根价值的平均误差从 0.405 只降到 0.284 就停住了，1280 次模拟与 640 次几乎一样。原因是模拟环节用均匀随机走子，它本身带一个系统性偏差：某些“看起来安全”的着法在随机对手面前被高估。更多模拟只能压低方差，压不掉这个偏差。这就是“有限模拟不保证最优”的实证版本。

7.4.2 AlphaZero：先验与计数互相喂养

AlphaZero 把 MCTS 的两个环节换成神经网络。第一个是**先验**：叶节点不再用均匀分布展开，而由策略网络给出每个动作的先验概率 $P(s,a)$；选择规则相应改成 PUCT：

$$U(s,a) = c_{\text{puct}}\, P(s,a)\, \frac{\sqrt{\sum_b N(s,b)}}{1+N(s,a)}. \tag{7.8}$$

先验高的动作一开始就被优先尝试，网络知识因此注入搜索，省掉了大量随机模拟。第二个是**价值**：叶节点不再随机走到底，而直接用价值网络估 v——这正是图 7-5 底部那句话的含义。

反方向的信息流同样重要：搜索结束后，根节点的访问计数被归一化成策略目标

$$\pi(a \mid s) = \frac{N(s,a)^{1/\tau}}{\sum_b N(s,b)^{1/\tau}}, \tag{7.9}$$

其中温度 τ 在训练早期取 1（保留探索），评估时趋于 0（按访问次数贪心）。网络被训练去模仿这个分布，同时用对局结果训练价值。于是形成闭环：**先验引导搜索，搜索改进先验**。这与“网络直接输出策略”的差别在

于多了一层验算：搜索把一步的直觉变成了几百步的推演。

数据完全来自自我对弈，这带来两个后果。好处是数据分布随策略前进，始终在“当前水平附近”提供最难的学习信号；风险是没有外部锚点，策略一退化，数据跟着退化，工程上用回放池与温度调度来缓冲。

原文给出的规模数字说明了代价：每次搜索 800 次模拟，训练 700k 个 mini-batch；从零开始训练，国际象棋 4400 万局、将棋 2400 万局、围棋 2100 万局，训练时间 9、12、34 小时；学习率从 0.2 起三次降为 0.02、0.002、0.0002；根节点加 Dirichlet 噪声，参数 α 分别取 0.3、0.15、0.03（按合法着法数反比缩放）。思考时间是 40 到 200 毫秒。

7.4.3 MuZero：预测而非重建

AlphaZero 依赖已知的游戏规则开展搜索。MuZero 将这一条件改为学习一个“足够用于搜索”的模型，并不要求模型重建原始观测。该模型由三个函数组成：

$$\begin{aligned} s^0 &= h_\theta(o_1, \dots, o_t), \\ r^k,\, s^k &= g_\theta\big(s^{k-1}, a^k\big), \\ p^k,\, v^k &= f_\theta\big(s^k\big). \end{aligned} \tag{7.10}$$

表示函数 h 把观测序列压成初始隐状态，动力学 g 在隐状态上推进一步并给出即时奖励，预测 f 给出先验与价值。搜索在这个隐状态空间里做 MCTS，节点用 p, v, r。训练目标让三者分别逼近策略、回报与奖励：

$$\mathcal{L}(\theta) = \sum_{k=0}^{K} \Big[\ell^p\big(\pi_{t+k}, p^k\big) + \ell^v\big(z_{t+k}, v^k\big) + \ell^r\big(u_{t+k}, r^k\big) \Big], \tag{7.11}$$

其中回报目标 z 是搜索价值或 n 步自举回报：

$$z_t = \sum_{i=0}^{n-1} \gamma^i u_{t+i} + \gamma^n v_{t+n}. \tag{7.12}$$

同样地，搜索内部若遇到真终止，n 步自举在该处停止、不接 v_{t+n}；把终止当截断会让搜索价值系统性偏低，这一条在 7.5 节的边界里会再出现。

关键在于 s^k 的语义。原文明确写道：这个内部状态“不携带任何环境状态的语义”，它只是模型的隐状态，唯一目的是准确预测与决策相关的量——策略、价值与奖励。所以它学的是一个**值等价**的抽象：能算回报、能算价值、能给先验，但不能还原画面，也不能解释“世界为什么这样演化”。它无法像物理模型那样回答“把杯子推下去会怎样”。

SUMMARY / 总结

规模上，$K = 5$ 步展开训练，棋盘每次搜索 800 次模拟，Atari 每四帧 50 次模拟并重复动作四次；训练 100 万个 mini-batch（批量 2048/1024）；网络 16 个残差块、256 个隐藏平面（AlphaZero 20 个）。在 57 个 Atari 游戏上达到当时最好水平，围棋上同等模拟数略超 AlphaZero，且不知道规则。Atari 上奖励与价值尺度变化大，原文用交叉熵替代平方误差，这是“损失函数要跟着目标尺度走”的一个实例。

7.4.4 规划的边界

搜索质量随模拟预算提高，但决策时延也会增加。是否采用决策时规划，取决于评估结果能否证明质量收益足以抵偿计算成本。

第一条边界是**搜索成本**。决策时规划的成本约为“模拟次数 × 单次前向”，且这笔开销每遇到一个新状态就要重付一次。AlphaZero 每步 800 次模拟换来 40 到 200 毫秒；棋类可以，100 Hz 的机器人控制不行。背景规划没有这个约束：更新在后台做。

第二条是**模型误差累积**。式 (7.5) 的线性增长在搜索里更严重：每个叶子都要沿树走 h 次模型查询，单叶误差约 $h\varepsilon_m$；而叶子数随深度按 b^h 增长，整棵树的误差预算因此被放大——这是“深树不可信”的算术来源，不是单条路径的误差被逐层相乘。作为对照，MBPO 对 k 步分支 rollout 的界里模型项是 $2r_{\max}k\varepsilon_m/(1-\gamma)$（Theorem 4.3），对误差与长度都线性；其完整界另需一个策略误差 $\varepsilon_\pi = \max_s D_{TV}(\pi(\cdot\mid s)\|\pi_D(\cdot\mid s))$（$\pi_D$ 是收集数据用的上一轮策略），本节不展开。所以控制手段是缩短 rollout，而不是指望误差不累积。MuZero 能工作，部分因为它只用 5 步展开。

第三条是**非平稳对手**。对手策略在变，价值目标就不是固定函数；自我对弈必须持续产生新数据，否则会在过时对手上过拟合。

第四条是**长时程信用分配**。视野之外的奖励拿不到信用；γ 接近 1 而视野很浅，等于假设“视野之外没有未来”，估值系统性偏低。

关于规划，有三处说法要当心。“MuZero 学会了环境的模型”是错的：它学的是隐空间预测，不是可还原的世界模型。“模型法样本效率一定更高”也不对：前提是模型在策略访问分布上够准。“MCTS 保证最优”更不成立：只在无限模拟下渐近成立，有限预算给出有偏估计，图 7-6 的根价值误差平台就是证据。

四条边界合起来看，规划是用算力换决策质量，代价是模型精度与响应时间。一个便宜的检验是：若加倍模拟预算不能改善离线评估的决策质量

SUMMARY / 总结

（图 7-6 的平台），瓶颈就不在搜索，而在价值估计或模型精度。另一种省法是把搜索**蒸馏**进策略网络：搜索只用来产生训练目标，部署时不必真的搜，AlphaZero 的价值网络与策略网络就是这一步的产物。

SUMMARY / 总结

7.5 基于模型方法的适用条件

本节把取舍写成判据，不写成立场。三个量决定判断：真实交互有多贵、规划算力有多少、“模型、策略、价值”哪个最容易学。第三个常被忽略：有的任务价值函数难学而动力学简单（迷宫、棋类），模型法占优；有的任务最优策略只是一句简单规则（“看到障碍就躲”）而动力学随机（过马路），无模型法更容易。

表 7-3 是否值得用模型的判据。前四行属“值得”，后四行属“谨慎”或“不值得”；同一行在不同任务上可能翻转，判据是量级而非标签。

情形	是否值得用模型	依据
真实交互昂贵或慢（机器人、临床试验）	值得	用算力换交互，规划成本远低于一次真实试验
交互危险、不可逆	值得	先在模型里试错，失败不付代价
需要前瞻（博弈、路径、组合决策）	值得	搜索是唯一能“看几步”的手段
模型易学（低维、近确定性、物理清晰）	值得	单步误差小，视野可以推得远
高维像素、混沌动力学、接触丰富	谨慎	模型误差主导，随视野爆炸式放大
对手非平稳、任务频繁变化	谨慎	模型要持续重训，收益被更新成本吃掉
实时性硬约束、算力受限	不值得	规划成本超过收益，来不及算
数据便宜、策略接近反应式	不值得	无模型更简单，模型是多余的一层

表 7-3 是四条工程经验：问模型误差在策略访问分布上有多大，而不是在训练集上多准；优先短视野加反馈，而不是长开环推演；模型数据只当增广，保留真实数据的锚点；用集成方差做闸门，分歧大处退回无模型估计。

最后，这条分界线会漂移：一个系统里往往两者都有，底层用无模型策略快速反应，上层用模型做慢速规划（第 9 章的层次结构）。要避免的是把两者当成阵营——差别只是“用不用预测”，以及预测准不准。

SUMMARY / 总结

本章小结

本章讲的其实是一件事的两面：模型能把一次真实交互摊薄到许多次计算上，也能把一次预测误差放大到整条推演链上。7.1 节的迷宫实验里，$n = 50$ 只用 3 个回合就达标，$n = 0$ 要 20 个回合，可三者的最终表现相同——规划改的是样本效率，不是渐近性能。这决定了它的适用面：交互昂贵时它值钱，交互便宜时它只是多一层会出错的部件。

于是整章的技术手段都在回答同一个问题——在模型不准的前提下，还能不能信它、能信到多远。安全感来自模型在**策略访问分布**上的准确性，而表格情形下支撑集就是真实转移，所以安全；函数逼近下模型会泛化，规划会把状态推到覆盖之外，误差与策略改进互相强化（7.1.3 节）。应对手段因此分两类：把不确定性显式读出来（集成方差、认识性与偶然性之分，7.2 节），或者干脆不用它（短 rollout、真实数据锚点，7.3 节）。而式 (7.5) 给出的 $h\varepsilon_m$ 线性上界是这一切的算术根据：推得越远，误差预算越薄；压缩动力学让它有界，扩张动力学让它比线性还快。到了搜索这一端（7.4 节），同样的算术以 b^h 的叶子数形式重演，这也是为什么 MuZero 只展开 5 步、而 AlphaZero 敢用 800 次模拟——前者怕误差累积，后者只是在一个准模型上多花算力。有限预算下没有任何最优性保证：图 7-6 里命中率升到 0.975，根价值误差却停在 0.284，因为更多模拟降的是方差，降不掉随机模拟的偏差。这条线索会在第 9 章与层次、多智能体（用模型做慢速规划、用无模型策略做快速反应）再次合流。

关键公式

这几条是全章的主干：一条“学习与规划共用”的更新规则、一个监督式的模型目标、两个把不确定性变成决策的量，一个搜索规则，以及 MuZero 的三个函数。公式本身不改，只按出现顺序列在这里备查。

$$Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma \max_{a} Q(S',a) - Q(S,A)\big]$$

监督式模型学习的目标，式 (7.1)：

$$\min_{\varphi} \mathbb{E}_{\mathcal{D}}\Big[-\log \hat{P}_{\varphi}(s' \mid s,a) + \big(\hat{r}_{\varphi}(s,a) - r\big)^2\Big]$$

集成方差，式 (7.2)：

$$\hat{\sigma}^2(s,a)=\frac{1}{M-1}\sum_{m=1}^{M}\big(\hat{f}_m(s,a)-\bar{f}(s,a)\big)^2$$

悲观奖励与短 rollout 回报，式 (7.3) 与式 (7.4)：

$$\tilde{r}=\hat{r}-\lambda\hat{\sigma},\qquad \hat{G}_h=\sum_{k=0}^{h-1}\gamma^k\hat{r}_k+\gamma^h V_\phi(s_h)$$

UCT 的选择规则，式 (7.7)：

$$a^*=\arg\max_a\Big[\bar{Q}(s,a)+c\sqrt{\frac{\ln N(s)}{N(s,a)}}\Big]$$

MuZero 的三函数与损失，式 (7.10) 与式 (7.11)：

$$s^k=g_\theta(s^{k-1},a^k),\quad p^k,v^k=f_\theta(s^k),\quad \mathcal{L}=\sum_k\big[\ell^p+\ell^v+\ell^r\big]$$

习题

1. 在 7.1.2 节的迷宫上取 $n=0$ 与 $n=200$，画出每回合步数曲线，解释 n 超过某个值后曲线为何不再改善（提示：规划只覆盖已访问的状态-动作对）。
2. 把算法 7-1 第 9 行的均匀抽样换成按 $|R+\gamma\max_a Q(S',a)-Q(S,A)|$ 从大到小抽样（优先级扫描），比较收敛回合数，并说明何时反而更慢。
3. 推导式 (7.5) 的三角不等式分解，说明它为何在动力学不稳定时低估实际误差。
4. 设环境有 k 个等概率后继状态，模型只学均值。用式 (7.4) 算 $h=1$ 与 $h=5$ 的回报偏差，说明“只学均值”为何会系统性乐观或悲观。
5. 对式 (7.7)，说明 $N(s,a)=0$ 时该如何处理（提示：无穷大探索项），以及为何这会让 UCT 在 $|\mathcal{A}|$ 很大时浪费预算。
6. 复现图 7-6 的实验，把随机模拟换成带启发式的模拟（如优先占中心），根价值误差的平台是否消失？
7. 用表 7-3 分析机械臂抓取、围棋、广告竞价三个场景：各指出“值得用模型”的关键理由，以及一个会让结论翻转的条件。

SUMMARY / 总结

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 8 章是 Dyna 的原始表述，含图 8.2 的迷宫实验与第 8.3 节的优先级扫描；本章 7.1 节的实验设置与它对齐，只是规模缩小。
- Schrittwieser 等（2020）《Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model》（MuZero）：第 2 节的模型定义与“隐状态没有环境语义”的说明值得逐句读，第 3 节的训练目标与本章式 (7.10) – (7.12) 一一对应。
- Silver 等（2018）《A General Reinforcement Learning Algorithm that Masters Chess, Shogi, and Go through Self-Play》（AlphaZero）：方法附录给出 PUCT 的原始形式与 800 次模拟的配置，表 S3 是本章规模数字的来源。
- Plaat《An Introduction to Deep Reinforcement Learning》第 6 章：6.1 节讲前瞻搜索与轨迹优化，6.2 节用“迷宫”与“过马路”两个例子说明模型法与无模型法各自的适用面，是 7.5 节判据表的起点。
- Chua 等（2018）PETS、Janner 等（2019）MBPO、Hafner 等（2019）Dreamer 三篇按年代读，能看清“概率集成 → 短 rollout 混合 → 隐空间想象”这条演化线；注意三者的实验环境不同，跨论文比较样本效率要谨慎。

第 8 章　离线强化学习与策略评估

在线强化学习与经验回放方法通常允许训练期间继续采集环境数据。第 4 章的离策略方法使用旧策略的数据，第 6 章的 DQN 重复使用回放缓冲区；当覆盖不足时，仍可继续与环境交互并收集新样本。离线强化学习只使用预先收集的固定数据集 $\mathcal{D}$，策略学习期间不新增环境样本。这种设定适用于在线试验成本高或受到安全限制的任务，例如医学试验、机器人和自动驾驶。

固定数据集限制了通过新交互改善动作覆盖的能力。第 8.1 节将数据覆盖、行为策略分布和目标策略可评估性分别表述为后续分析所需的条件。

本章以第 2 章的状态、价值和折扣概念，以及第 4 章的离策略分布偏移为先修知识。固定数据通常无法直接确定覆盖范围以外动作的价值，因此离线算法需要限制对这类估计的依赖。BCQ、CQL 与 IQL 都处理这一问题，但分别约束动作选择、价值估计和价值查询。

本章讨论离线强化学习的两个任务：改进策略与评估策略。改进时，数据集固定，算法需要在行为策略的基础上寻找更优策略，并控制数据覆盖不足带来的估值风险。第 8.2 节分别介绍 BCQ 的数据支持约束、CQL 的保守价值学习和 IQL 的数据内优势加权；第 8.3 节介绍以条件序列建模为基础的 Decision Transformer。策略评估研究如何仅依据固定数据估计策略价值（第 8.5 节）。第 8.4 节讨论模仿学习；行为克隆是离线学习的基础情形，其复合误差有助于分析预测误差如何沿决策过程累积。

本章结论的可靠性并不齐。覆盖假设下的误差界与重要性采样的无偏性是 [精确] 的；CQL 的下界性质在表格或线性设定、策略慢变的前提下也是 [精确] 的，搬到深度网络只剩 [近似]；“某个离线算法在某基准上稳定”一律是 [经验规律]，不能当成安全性保证。

8.1 离线设定与三个假设

8.1.1 数据固定意味着什么

监督学习的前提是“数据分布固定，学一个映射”。离线强化学习使用固定数据进行序贯决策优化，目标策略仍可能改变部署后的状态访问分布。于是数据分布本身成了某个策略的产物——换策略就等于换分布，“训练分布”与“测试分布”的差距不再由采样噪声决定，而由你自己的决策决定。这就是本章所有麻烦的根。

SUMMARY / 总结

定义 8.1（离线强化学习）

设已有一份数据集 $\mathcal{D}=\{(s_i,a_i,r_i,s_i')\}_{i=1}^{N}$，它由未知的行为策略 μ 在一个未知的 MDP 里预先采集。离线强化学习的目标是只用 $\mathcal{D}$、不与环境交互，输出一个策略 π 使其期望回报 $J(\pi)$ 尽可能大：训练期间不允许调用环境，也不允许向专家查询新状态上的动作。

数据集里只有 μ 走过的状态与动作。若 π 想做的事 μ 从没做过，关于“这样做会怎样”的信息在 $\mathcal{D}$ 里一个字也没有。这与第 4 章的离策略学习不同：那里也有分布偏移，但可以继续采样修正；这里只能把“不知道”显式当作约束。

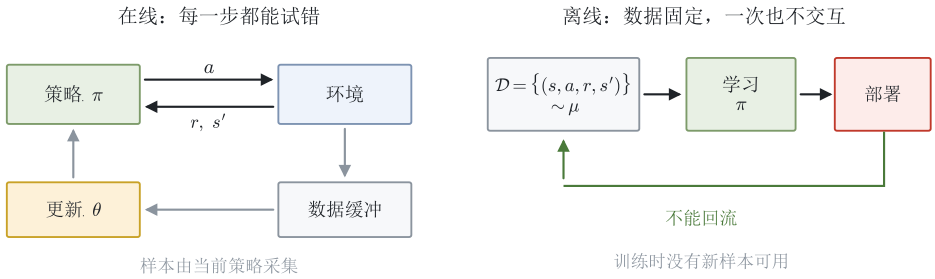


图 8-1 两种设定的对照。左侧在线强化学习每一步都能拿到新样本，策略与环境构成闭环；右侧离线强化学习的数据集固定，训练期间没有回到数据的通路，只在最后部署一次。

图 8-1 右侧被切断的那条回路就是本章全部困难的来源：回路存在时，偏离数据分布会被新数据纠正；不存在时，偏离不会被发现，只会被自举不断放大。

8.1.2 覆盖假设与它的松弛

先看一条最基础的要求。重要性采样要能定义，分母不能为零；这句话写出来就是覆盖假设。

定义 8.2（覆盖与单策略集中系数）

称数据集对策略 π 满足**覆盖**，若对任意状态 s，$\pi(\cdot\mid s)$ 的支持集包含于 $\mu(\cdot\mid s)$ 的支持集，即 $\operatorname{supp}\pi(\cdot\mid s)\subseteq\operatorname{supp}\mu(\cdot\mid s)$。进一步用集中系数衡量“覆盖得有多好”。

$$C_{\pi,\mu}=\max_{s}\frac{d_\gamma^{\pi}(s)}{d_\gamma^{\mu}(s)}, \tag{8.1}$$

SUMMARY / 总结

其中 d_γ^π 是占用测度。$C_{\pi,\mu}$ 越小，说明目标策略常去的状态在数据里也常见；它趋于无穷时，这个策略在这份数据上根本估不出来。

式 (8.1) 是覆盖假设最常用的松弛：完全覆盖要求“π 可能走的每条轨迹都被 μ 覆盖”，集中系数只要求“π 常去的状态在 μ 下也不罕见”。前者是集合关系，后者是密度比。多数离线算法的误差界都写成 $C_{\pi,\mu}$ 的函数，因此界的意义取决于它能否被估计——而这需要先知道 π 会去哪，构成循环。工程上通常不估它，只用“数据是否覆盖了策略实际访问的状态”做定性检查。

当目标策略访问的数据区域超出行为数据支持集时，相应策略价值可能无法仅由现有数据辨识。下面用一个可以直接复算的小例子把这件事量出来。

> **例 8.1（外推误差的直接观测）**
>
> 取一个上下文老虎机，状态 $s \sim \mathrm{Unif}[0,1]$，奖励取一条开口向下的抛物线 $r(s,a) = -(a-0.35)^2 + 0.55$，行为策略只在 $a \in [0.05, 0.40]$ 内采样（一个保守的行为策略）。用三次多项式加 s 的线性项拟合 $\hat{Q}(s,a)$，做 8 次独立 80 点子采样。数据覆盖的 $a \in [0.10, 0.35]$ 内，8 条曲线的标准差平均为 0.003；$a \approx 0.9$ 处为 0.612，已经分叉到相反方向。真实函数与数据都没变，变的只是“数据是否约束了该方向的参数”。

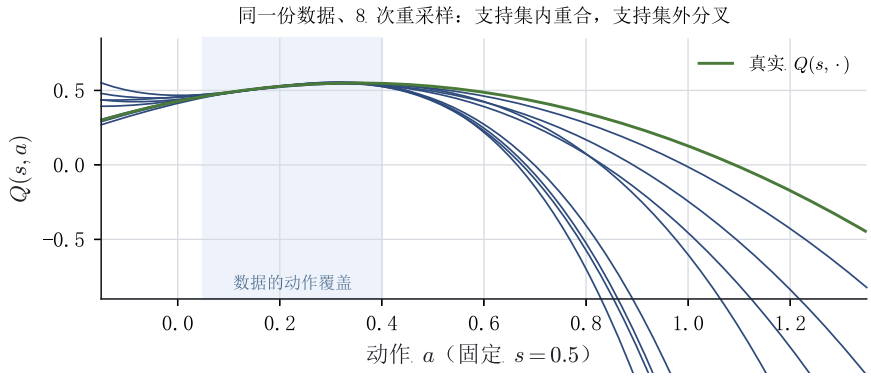


图 8-2 外推误差的直接观测。同一份数据、8 次 80 点子采样、同一个三次多项式模型：数据覆盖区间内八条曲线几乎重合，区间外迅速分叉。图中虚线是真实 Q。种子 11，噪声标准差 0.02。

8.1.3 三个误差来源与它们的耦合

分布偏移：训练数据来自 μ，评估针对 π，两者占用测度之比正是 (8.1) 的集中系数。这一项在线设定里也有，但在线方法能用新样本把比值压回 1，离线没有这个手段。

SUMMARY / 总结

外推误差：数据支撑之外，$\hat{Q}$ 由函数逼近的归纳偏置决定，数据对那里没有任何约束。这不是统计误差，再多样本也不会降低它——样本根本不落在那里。更反直觉的是，模型越灵活外推越自由：**更强的函数逼近在离线设定下可能更差**。

自举放大：时序差分把当前估计当作下步目标，误差沿时间反向传播。表格情形下，只要残差处处有界，误差就被放大 $1/(1-\gamma)$ 倍：

> 命题 8.1（残差到误差的放大 [精确]）
>
> 设 $\gamma < 1$，若 $\hat{Q}$ 满足 $\|\hat{Q} - T^{\pi}\hat{Q}\|_{\infty} \le \delta$，则误差被 $1/(1-\gamma)$ 放大：

$$\|\hat{Q} - Q^{\pi}\|_{\infty} \le \frac{\delta}{1-\gamma}. \tag{8.2}$$

式 (8.2) 的证明与第 2 章的残差界相同：压缩性加三角不等式。但它有个尖锐的推论：**前提不可检验**——它要求残差在**所有** (s,a) 上有界，而数据只覆盖 μ 的支撑；数据外的残差可以任意大，界照样成立却毫无信息量。

三个误差是耦合的：外推误差给出虚高的 $\hat{Q}$，自举沿轨迹累加，贪婪策略专挑它，分布偏移随之变大。算法必须切断其中一条链路。

SUMMARY / 总结

8.2 悲观与保守：BCQ、CQL、IQL

8.2.1 悲观原则的一般形式

既然数据外的 Q 值不可信，一个自然的反应是：只相信“最坏情况下也不坏”的那个价值。把可信的价值函数集合记作 $\mathcal{Q}$，悲观策略就是从最坏的那个成员出发做改进：

$$\hat{\pi} = \arg\max_{\pi} \min_{Q \in \mathcal{Q}} \mathbb{E}_{s \sim d^{\pi}_{\gamma},\, a \sim \pi(\cdot|s)} \big[Q(s,a) \big]. \tag{8.3}$$

式 (8.3) 是一个博弈：策略想抬高价值，而对手在 $\mathcal{Q}$ 里挑一个最低的。若 $\mathcal{Q}$ 恰好包含真值，即 $Q^{\pi} \in \mathcal{Q}$，那么 $\min$ 不会高估，改进就是安全的；反之，$\mathcal{Q}$ 取得过窄会让悲观变成纯粹的保守，$\mathcal{Q}$ 取得过宽则退化回普通 Q-learning。所有离线算法都在回答同一个问题：**$\mathcal{Q}$ 该取多大，以及用什么可计算的方式表达这个 $\min$**。

三种主流做法把不确定性放在了三个不同的位置，这一点必须讲清楚，否则很容易把它们读成同一件事的三个变体。BCQ 认为不确定性长在**动作**上：数据外动作的 Q 不可信，那就干脆不让贪婪操作看见它们。CQL 认为不确定性长在**值**上：数据外动作的 Q 该被压低，那就直接在损失函数里压，不用改策略抽取。IQL通过仅对数据中的动作进行价值更新，减少对分布外动作价值的直接查询。三者压制的对象分别是动作选择、价值本身与查询行为，所以它们的失效方式也不同（表 8-1、图 8-3）。

8.2.2 BCQ：把动作选择限制在支持集内

BCQ（Fujimoto et al., 2019）从动作这一侧下手：数据外的动作不可信，那就不让贪婪操作在远离数据的动作上做选择。它先训一个生成模型 G_{ω} 近似行为策略 $\mu(a \mid s)$，用它在状态 s 处采样若干候选动作，再给每个候选加一个小扰动，最后只在候选集合上取 $\hat{Q}$ 的最大值：

$$\begin{aligned} a'(s) = \arg\max_{a_i + \xi_{\phi}(s,a_i)} & \hat{Q}_{\theta}\big(s,\, a_i + \xi_{\phi}(s,a_i)\big), \\ & \{a_i\}_{i=1}^{n} \sim G_{\omega}(\cdot \mid s). \end{aligned} \tag{8.4}$$

式 (8.4) 里的扰动项 ξ_{ϕ} 有实际作用：生成模型只能复现数据里出现过的动作，而最优动作往往在它们之间，扰动把候选集合略微“撑开”，让 $\arg\max$ 能在支持集**附近**平滑移动，而不是被钉死在数据点上。这里的“附近”由裁剪阈值 Φ 界定：候选动作满足 $-\Phi \le \xi_{\phi} \le \Phi$，严格的措辞是“约束区域”而非“支持集内部”。两个端点也说明了这一点：$\Phi = 0$ 且采样数

$n=1$ 时 BCQ 退化为行为克隆，Φ 放到动作区间全长且 $n\to\infty$ 时它退化为 Q-learning——外推误差随之全部回来。

代价是**多一个生成模型**，而这个模型的覆盖范围直接决定算法的安全边界。生成模型过窄，候选里没有好动作，策略退化为模仿；过宽（比如高维动作上欠拟合），候选落到数据外，贪婪操作又会踩进被高估的区域。更隐蔽的一点：BCQ 只改**策略抽取**，不改 Q 的学习目标；若 $\hat{Q}$ 在支持集内部就已经被自举推高，它无能为力。

8.2.3 CQL：压低数据外动作的价值

CQL（Kumar et al., 2020）换了个位置：不动策略抽取，改 Q 的学习目标，在 Bellman 误差之外加一项保守惩罚。最一般的形式是一个 min-max 博弈：

$$\min_{Q}\ \max_{\mu'}\ \alpha_{\text{off}}\Big(\mathbb{E}_{s\sim\mathcal{D},\,a\sim\mu'}\big[Q(s,a)\big]-\mathbb{E}_{s\sim\mathcal{D},\,a\sim\hat{\pi}_\beta}\big[Q(s,a)\big]\Big)+\frac{1}{2}\mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[\big(Q(s,a)-\hat{\mathcal{B}}\hat{Q}(s,a)\big)^2\Big]. \tag{8.5}$$

式 (8.5) 的符号需要逐项读清楚，因为它常被误写成“压低数据动作的 Q”。内层对 μ' 取最大，挑的是**最会高估的那一族动作分布**；外层对 Q 取最小，于是这一族动作的 Q 被压下去。第二项前面是负号，最小化整体就等于把它**抬高**。合起来是：数据动作相对提升、数据外动作相对压低，两者之差被拉开。第 8.2.1 节的“悲观”在这里体现为“对 π 的价值取下界”，而不是“对所有 Q 统一减一个常数”。

内层最大化有闭式解。取正则项 $R(\mu')=-D_{\text{KL}}(\mu'\,\|\,\rho)$ 可得 $\mu'(a\mid s)\propto\rho(a\mid s)\exp Q(s,a)$；再取 ρ 为均匀分布，$\exp Q$ 的归一化常数就是 $\log\sum_a\exp Q(s,a)$，于是式 (8.5) 变成可直接采样的 **CQL(H)** 形式：

$$\min_{Q}\ \alpha_{\text{off}}\,\mathbb{E}_{s\sim\mathcal{D}}\Big[\log\sum_{a}\exp Q(s,a)-\mathbb{E}_{a\sim\hat{\pi}_\beta(\cdot|s)}\big[Q(s,a)\big]\Big]+\frac{1}{2}\mathbb{E}_{\mathcal{D}}\Big[\big(Q-\hat{\mathcal{B}}\hat{Q}\big)^2\Big]. \tag{8.6}$$

式 (8.6) 中，$\alpha_{\text{off}}>0$ 控制保守惩罚的强度。SAC 的熵温度 α_{ent} 控制策略随机性，学习率 α 控制参数更新幅度。三者作用不同。α_{off} 与奖励尺度相乘，因此改变奖励尺度时需相应调整；理论下界所需的系数也会随数据量和覆盖情况变化。连续动作空间中，$\log\sum_a$ 无法直接枚举，实践中可通过动作采样近似，或采用 $\rho=\hat{\pi}_{k-1}$ 的指数加权形式。

SUMMARY / 总结

定理 8.1（CQL 的间隙扩张与价值下界 [精确，表格或线性、策略慢变]）

设在 CQL 迭代中 $\hat{\pi}_k(a \mid s) \propto \exp \hat{Q}_k(s,a)$，且每次策略更新满足 $D_{\mathrm{TV}}(\hat{\pi}_{k+1}, \pi_{\hat{Q}_k}) \le \varepsilon$。有两点结论，条件不同。第一（间隙扩张），当 α_{off} 足够大时，对任意状态 s，数据动作与数据外动作之间的估值差被**扩张**，即下式成立。第二（价值下界），除策略慢变外还需 $\mathbb{E}_{\pi_{\hat{Q}_k}}[\pi_{\hat{Q}_k}/\hat{\pi}_\beta - 1] \ge \max_a(\pi_{\hat{Q}_k}/\hat{\pi}_\beta) \cdot \varepsilon$，此时 $\hat{V}_{k+1}(s) \le V_{k+1}(s)$ 对每个 s 都成立，学到的价值是真实价值的下界。这两条在原文里是两条定理，条件不能合并着说。

$$\mathbb{E}_{\hat{\pi}_\beta}\big[\hat{Q}_k(s,a)\big] - \mathbb{E}_{\mu'_k}\big[\hat{Q}_k(s,a)\big] > \mathbb{E}_{\hat{\pi}_\beta}\big[Q_k(s,a)\big] - \mathbb{E}_{\mu'_k}\big[Q_k(s,a)\big], \tag{8.7}$$

式 (8.7) 的左边是“数据动作比数据外动作好多少”的估值，右边是真实值；不等式说明 CQL 把这一差距**放大**了，于是贪婪策略更愿意留在数据里。

定理 8.1 的两个结论合起来说明了机制：间隙扩张使贪婪策略倾向选数据内的动作，价值下界使“用 $\hat{Q}$ 估出的性能”不会系统性高估。但条件必须照抄：间隙扩张要 α_{off} 足够大，价值下界要策略慢变外加那条 $\pi_{\hat{Q}_k}/\hat{\pi}_\beta$ 的期望不等式，两者都不能省；再加上表格或线性逼近、噪声可控。搬到深度网络上，这三条都只剩近似，因此 CQL 的训练稳定性是 [经验规律]，不是定理保证。

8.2.4 IQL：不查询数据外动作

IQL（Kostrikov et al., 2021）进一步避免直接查询数据分布之外的动作价值。其关键观察是：$\max_{a'} Q(s',a')$ 只在预测**下一步价值的上界**时才需要；策略改进真正想要的只是“在这个状态里比平均好多少”，也就是优势。

于是 IQL 用期望回归（expectile regression）把价值函数学成一个**数据内的高期望值**（upper expectile），替掉最大值：

$$\begin{aligned} \mathcal{L}_V(\psi) &= \mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[L_2^\tau\big(\hat{Q}(s,a) - V_\psi(s)\big)\Big], \\ L_2^\tau(u) &= \big|\tau - \mathbf{1}\{u<0\}\big|\, u^2. \end{aligned} \tag{8.8}$$

当 $\tau \to 1$ 时，在有限数据支持集上，式 (8.8) 的最优解趋近高价值样本对应的上界；$\tau = 0.5$ 对应均方回归的均值。增大 τ 会提高高于当前估计值的样本在回归中的权重。该参数影响价值估计的乐观程度，但并非唯一决定保守性的因素，函数逼近、数据覆盖与优势加权参数也会影响最终策略。

SUMMARY / 总结

Expectile 与分位数使用不同的非对称损失。式 (8.8) 采用平方误差，分位数回归采用绝对误差；二者对高于和低于估计值的样本赋予不同权重。IQL 的 τ 控制 expectile 的非对称程度，$\tau = 0.5$ 对应均值，较大的 τ 更重视高价值样本；有限 $\tau < 1$ 下，expectile 一般不等于样本最大值。

有了 V_ψ，动作价值不再需要查询动作外，直接用数据里的 (s, a, r, s') 拼出来：

$$\hat{Q}(s,a) = r + \gamma(1 - d_t) V_\psi(s'), \tag{8.9}$$

其中 $d_t = 1$ 表示 s' 是**真终止**（不是长度截断）：终止后价值为零、自举必须停；截断时 $d_t = 0$，尾部价值仍要由 V_ψ 补回。把两者当成同一个标志是离线数据里最常见的错。

式 (8.9) 与标准的 $r + \gamma \max_{a'} Q(s', a')$ 只差一个 $\max$，但差别是本质的：它不需要对 s' 的所有动作求值，因此不会碰到数据外的动作。策略则用优势加权回归（AWR 式）抽取：

$$\mathcal{L}_\pi(\theta) = \mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[\exp\big(\beta_{\text{awr}}\,(\hat{A}(s,a) - \max_{a'} \hat{A}(s,a'))\big) \cdot \log \pi_\theta(a \mid s)\Big], \tag{8.10}$$

其中 $\hat{A}(s,a) = \hat{Q}(s,a) - V_\psi(s)$。权重里的最大值减法是数值稳定措施，不改变 $\arg\max$。

IQL 的代价是**只能隐式改进**。它从不评估数据里没有的动作，因此不可能发现“没人做过但更好”的动作——这既是它稳的原因，也是它上限的来源。数据覆盖面较宽时，它接近甚至超过 CQL；数据极窄时，它安分地学成一个略好于行为策略的模仿者。τ 与 β_{awr} 的敏感度是主要工程难点，理论地位只有 [近似]。

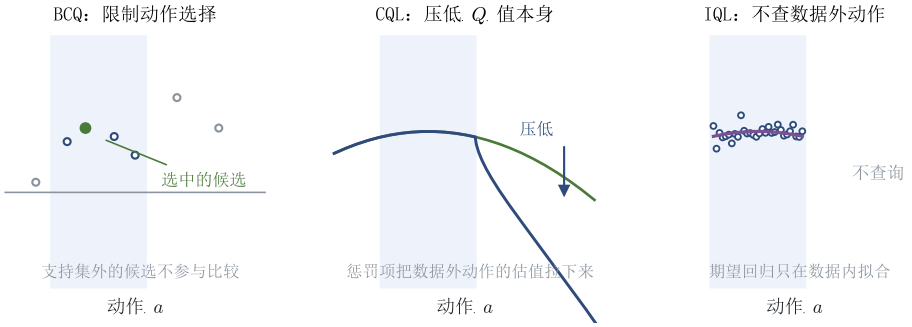


图 8-3 三种方法压制的对象不同。左：BCQ 只在行为支持集内取 $\arg\max$；中：CQL 在损失里把数据外动作的 Q 压下去；右：IQL 根本不在数据外做查询，只在数据内做期望回归。阴影带是行为策略的动作覆盖范围。

SUMMARY / 总结

表8-1 BCQ、CQL与IQL的约束机制及典型失效方式。BCQ限制动作候选范围，CQL施加保守价值惩罚，IQL通过数据内价值学习避免直接评价分布外动作。

方法	压制对象	需要的额外模型	典型失效模式
BCQ	动作选择：只在数据附近取 $\arg\max$	生成模型 G_ω 与扰动网络 ξ_ϕ	覆盖过宽或过窄；Φ 的两端分别退化为模仿与 Q-learning
CQL	价值本身：数据外动作的 Q 被压低	无（连续动作需动作采样器）	α_{off} 与奖励尺度不匹配；过度保守使价值塌成常数
IQL	查询：完全不做数据外查询	无（V_ψ 与 π_θ 两个网络）	τ、β_{awr} 敏感；无法发现数据外的好动作

表 8-1 的第三列值得再看一眼：只有 BCQ 需要额外模型，而它对数据质量也最敏感——生成模型的覆盖范围无法从数据直接验证，却决定了“悲观”作用在哪个范围上。CQL 与 IQL 把不确定性放进损失或估计式里，没有显式的支持集，保守强度只能靠超参数调。算法既无法自证安全，就只能靠 8.5 节的评估把关。

SUMMARY / 总结

8.3 序列建模路线：Decision Transformer

8.2 节那三条路线都站在价值函数上：先估 Q，再从 Q 里抽策略。Decision Transformer（Chen et al., 2021）把这条路整个换掉，它把强化学习写成**条件序列建模**：给定“希望达到的回报”，直接生成动作序列。

具体做法是把一条轨迹改写成 token 序列

$$\tau = \left(\hat{R}_1, s_1, a_1,\ \hat{R}_2, s_2, a_2,\ \ldots,\ \hat{R}_T, s_T, a_T\right), \tag{8.11}$$

其中 $\hat{R}_t = \sum_{t' \geq t} r_{t'}$ 是**剩余回报**（return-to-go），即从当前步到回合结束的累计奖励。模型是一个因果 transformer，训练目标是预测下一个动作：

$$\mathcal{L}_{\mathrm{DT}}(\theta) = -\mathbb{E}_{\tau \sim \mathcal{D}}\left[\sum_{t=1}^{T} \log \pi_\theta\left(a_t \mid \hat{R}_{1:t}, s_{1:t}, a_{1:t-1}\right)\right]. \tag{8.12}$$

式 (8.12) 里没有任何贝尔曼方程：没有 Q，没有自举，没有 $\max$。推理时把条件 $\hat{R}_1$ 设成一个较大的目标值，模型就生成“能做到这个回报”的动作。Decision Transformer避免了显式的TD自举，但其泛化和分布外性能仍受数据质量、回报条件化及模型训练影响。

但“稳”不等于“会改进”，它的能力边界必须写清楚。第一，条件回报是一种**插值**：若数据里的最高回报是 100，把条件设成 150 不会得到更强的策略，只会得到一段语义混乱的生成，因为那个条件从未在训练中出现过。第二，它不能超越数据里回报分布的支撑，本质上是“从数据中挑出最好的片段并复用”，与第 8.2.1 节的悲观原则方向相反：它靠**乐观的条件**而不是保守的估计来驱动改进，因此在数据覆盖的回报范围内有效，超出范围就失效 [经验规律]。第三，长回合、随机性强的环境里，回报条件与动作的对应关系会被稀释，稳定性依赖实现细节，没有定理支持。

Decision Transformer 以回报条件下的轨迹生成实现策略学习，不显式使用价值函数与贝尔曼方程。它仍依赖离线数据、回报信号和独立评估。其分布外表现取决于训练数据覆盖、目标回报设定与序列模型的泛化能力；模型仍可能对未充分覆盖的状态—动作组合产生外推误差。

SUMMARY / 总结

8.4 模仿学习与交互式数据收集

8.4.1 行为克隆与复合误差

行为克隆是离线学习最简的形式：把专家的状态—动作对当作监督样本，直接拟合一个策略。

$$\max_{\theta} \ \mathbb{E}_{(s,a)\sim\mathcal{D}_{\text{exp}}}\big[\log \pi_\theta(a \mid s)\big]. \tag{8.13}$$

式 (8.13) 完全不涉及奖励，也不涉及价值。它的失败方式与监督学习不同：分类错误率可以很低，策略却可能把机器人开进沟里。原因在于**误差会改变后续输入分布**——一旦某一步动作偏离专家，后续状态就落到训练集没覆盖的地方，那里的策略没有被监督过，错误继续累积。

把这件事写成界。设回合长度 T、损失有界（每步至多 1），策略在专家访问到的状态上犯错的概率不超过 ε。

> **定理 8.2（行为克隆的复合误差 [精确，确定性专家、0-1 损失]）**
> 在上述设定下，行为克隆策略 $\hat{\pi}$ 与专家策略的累计回报之差满足如下上界：

$$J(\pi^\star) - J(\hat{\pi}) \ \le \ T^2\varepsilon. \tag{8.14}$$

证明梗概. 把回合按“每一步是否出错”分解。在第 t 步，出错只有两种可能：此前一直待在专家状态上（每步都有 ε 的机会出错），或此前已经偏离（此后按最坏情形算）。于是第 t 步的出错概率不超过 $t\varepsilon$，把各步的概率相加即得界：

$$J(\pi^\star) - J(\hat{\pi}) \ \le \ \sum_{t=1}^{T} \Pr(\text{第 } t \text{ 步出错}) \ \le \ \sum_{t=1}^{T} t\varepsilon = \frac{\varepsilon T(T+1)}{2} \ \le \ T^2\varepsilon.$$

最后一步用了 $(T+1)/2 \le T$（$T \ge 1$）。要点是“出错概率随步数线性增长”：越靠后的步骤，前面已经出错的机会越多；直接把 $\sum_t t\varepsilon$ 算出来是 $\varepsilon T(T+1)/2$，再松到 $T^2\varepsilon$。**不要在中间把 $(T-t)$ 丢成 T**——那会得到 $\varepsilon T^2(T+1)/2$，比结论大 $(T+1)/2$ 倍。 □

界 (8.14) 的 T 是二次的，这个二次方来自“错误概率随步数累积”。它的实践含义是：回合越长，单纯模仿越不可靠。图 8-4 用一维走廊做了一次真算——策略在专家状态上以 $1-\varepsilon$ 的概率走对，一旦偏离就退化为随机游走；实测后悔值在 $T = 56$ 时是 47.6，对 $T \ge 16$ 做 log-log 拟合的斜率约

1.27（全程 1.37），即**增长慢于二次上界 $T^2\varepsilon = 313.6$**。所以 $T^2\varepsilon$ 是上界而非预期曲线，这一点属 [经验规律]。

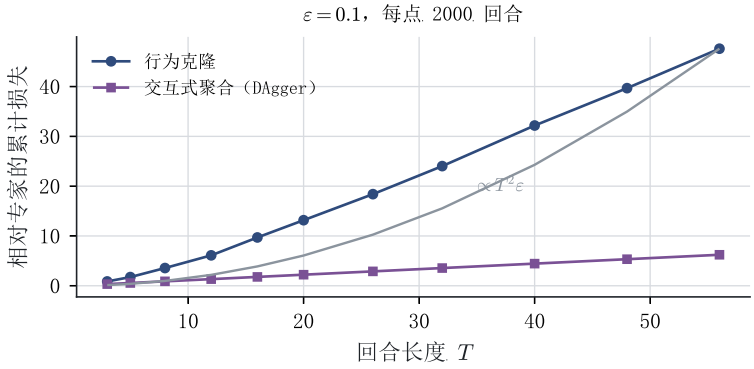


图 8-4 复合误差的数值演示。一维走廊，专家每步前进一格；克隆策略在专家状态上以 0.9 的概率正确，在未访问过的状态上随机。每个数据点 2000 回合，种子 5。点线是按 T^2 缩放的参考曲线，带方块的虚线是交互式聚合的线性增长。

8.4.2 DAgger：交互式数据聚合

既然错误来自“策略自己会去、但专家没去过的状态”，修法就明确了：让策略先跑，把**它访问到的状态**拿给专家标注，再把这些新样本并入数据集。这就是 DAgger（Ross、Gordon 与 Bagnell, 2011，算法 3.1）。

算法 8-1 DAgger（数据集聚合）

用专家数据训练初始策略 pi_1（等价于行为克隆）
D <- **专家数据集**
for i = 1, 2, ..., N do
  用 pi_i 与环境交互，记录访问到的状态序列 s_1, ..., s_T
  请专家对这些状态给出动作 a_t^* = pi^*(s_t)
  D <- D ∪ {(s_t, a_t^*)}
  在 D 上重新训练，得到 pi_{i+1}
end for
返回在验证集上最好的 pi_i

DAgger 常被误写成“数据增强”或“对专家数据做扰动”。这不是同一件事。数据增强是在**已有样本**上做变换（旋转、加噪、裁剪），分布不变，只是让模型见到更多的等价样本；DAgger 是**改变数据分布**——新增的样本来自学习者自己会去的状态，正是行为克隆缺的那部分。也正因为如此，DAgger 需要“能查询专家”这一能力，它不是纯离线算法：没有专家在线标注，第 5 行就无从执行。把 DAgger 当成离线强化学习的一种，是

把“有交互但不需要奖励”与“完全不能交互”混为一谈。

DAgger 的理论收益是把这个二次界降成线性：在在线学习（no-regret）的框架下，聚合后的策略满足 $J(\pi^\star) - J(\hat{\pi}) \le T\varepsilon + o(1)$（Ross et al., 2011 的定理 4.1）[渐近]。直观上，因为训练分布逐步覆盖了策略自己的访问分布，定理 8.2 证明里“出错概率随 t 线性增长”的那一项被消掉了。

8.4.3 与离线设定的关系

把三条路线放在一起看：行为克隆只用专家数据、不估价值；DAgger 需要专家在线标注；离线强化学习既不能交互也不能查询专家，只能靠悲观原则处理“不知道”。逆问题（从示范反推奖励函数，再在学到的奖励上做规划）是第四条路线，本章不展开，列入延伸阅读。

这个谱系也解释了第 8.2 节的一个设计选择。BCQ 之所以要训一个生成模型，本质上是在**离线条件下重建 μ 的支持集**，用它替代 DAgger 里“让专家标注新状态”的能力；CQL 与 IQL 则放弃显式重建，改用惩罚或上期望值把不确定性吸收进价值估计。三条路线的代价不同，但都在回答同一个问题：没有新数据时，如何知道哪些动作是“没被验证过”的。

三条路线的理论地位也不同。行为克隆的 $T^2\varepsilon$ 是 [精确]（确定性专家、0-1 损失的设定下）；DAgger 的 $T\varepsilon$ 是 [渐近]（依赖 no-regret 学习器与 β_i 的衰减）；离线设定下的悲观原则只有 [近似] 或 [经验规律]——覆盖假设无法检验，误差界里的 $C_{\pi,\mu}$ 也不可估。实践上判断自己落在哪条线上，只看一件事：能不能为“策略自己会访问到的状态”拿到标签或奖励。能，就走 DAgger 或在线试错；不能，就只能接受悲观带来的上限，并靠 8.5 节的评估把关。

SUMMARY / 总结

8.5 离线策略评估

8.5.1 评估问题与三条路线

策略评估要回答的是“这个策略值多少”：目标是估 $V^\pi(\rho_0)=\mathbb{E}_{s_0\sim\rho_0}[V^\pi(s_0)]$，手上却只有来自 μ 的数据。它是本章第二条主线，而且比改进更难——改进至少有反馈，评估连反馈都没有；估计一旦有偏，错误会原样写进后面的决策。

三条路线对应不同假设。**普通重要性采样（IS）**要求行为策略覆盖目标策略，并使用轨迹概率比估计目标策略下的期望；在覆盖条件及行为概率已知时，普通 IS 无偏，但方差可能很大。**自归一化重要性采样（WIS）**将权重归一化，通常降低方差，同时引入有限样本偏差。**直接法（DM）**依赖准确的模型或价值函数，可能因模型错设产生偏差。**双重稳健（DR）**结合两类估计，在相应正则条件下，模型或权重模型至少一方正确时具有一致性。

IS 的出发点是一条恒等式。记轨迹 $\tau=(s_0,a_0,r_1,\dots)$、权重

$$w(\tau)=\prod_{t=0}^{T-1}\frac{\pi(a_t\mid s_t)}{\mu(a_t\mid s_t)}, \tag{8.15}$$

则对任意有界回报 $G(\tau)$，

$$V^\pi=\mathbb{E}_{\tau\sim\mu}\big[w(\tau)\,G(\tau)\big]. \tag{8.16}$$

式 (8.16) 的证明只需把两个分布下的轨迹概率相除：μ 的每个因子被分母约掉，剩下的正好是 π 下的期望。前提是 $\mu(a_t\mid s_t)>0$ 对所有 π 可能取的动作成立——这正是覆盖假设（定义 8.2）在评估侧的版本。

8.5.2 重要性采样：无偏，但方差可以无穷

> **定理 8.3（重要性采样的无偏性与方差 [精确]）**
>
> 在覆盖假设与固定回合长度 T 下，式 (8.16) 给出的估计量无偏。若各步的比率相互独立且 $\mathbb{E}_\mu[\rho_t^2]=\kappa>1$，则权重的二阶矩随回合长度指数增长：

$$\mathbb{E}_\mu\big[w^2\big]=\prod_{t=0}^{T-1}\mathbb{E}_\mu\big[\rho_t^2\big]=\kappa^T, \tag{8.17}$$

式 (8.17) 是 OPE 最重要的一条事实，它的前提是每步比率的二阶矩 κ

SUMMARY / 总结

存在。前提不成立时情形更糟：离策略轨迹里只要含环，缩放回报的二阶矩就会发散，普通 IS 的方差变成无穷，连大数定律都不再保证——估计仍然无偏，但这里“无偏”救不了任何事。即使每一步的分布只差一点点（比如 $\kappa = 1.2$），回合长度 $T = 50$ 时 $\kappa^T \approx 9100$，估计量的标准差会放大近百倍。有效样本量把这件事写得更直白：

$$\mathrm{ESS} = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}, \tag{8.18}$$

当所有权重相等时 $\mathrm{ESS} = N$；当某个权重独占全部质量时 $\mathrm{ESS} = 1$。图 8-5 在 8.5.4 节的小 MDP 上真算了这条曲线：ESS/N 从 $T = 1$ 的 0.535 掉到 $T = 7$ 的 0.032，衰减速度与式 (8.17) 一致。

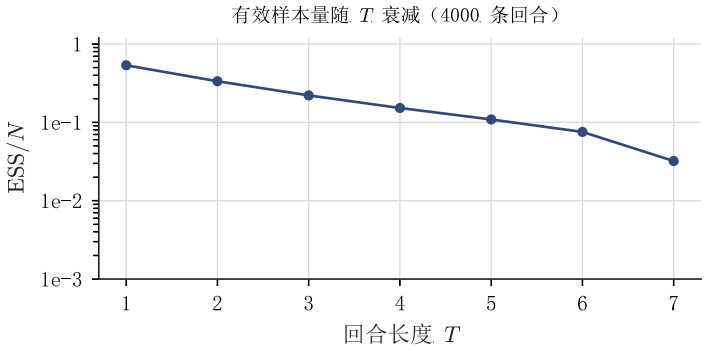


图 8-5 有效样本量随回合长度的衰减。同一个三状态 MDP，行为策略与目标策略不同，4000 条长度为 8 的回合，按前 T 步截断计算权重。种子 23。

最常用的补救是**自归一化**（WIS）：用权重之和做分母，

$$\hat{V}_{\mathrm{WIS}} = \frac{\sum_i w_i G_i}{\sum_i w_i}. \tag{8.19}$$

式 (8.19) 有偏（分母是随机变量），但方差显著下降，且当 $|G| \le G_{\max}$ 时估计值自动落在 $[-G_{\max}, G_{\max}]$ 内。代价是偏差随权重分布的不均匀上升：权重集中在少数轨迹上时，WIS 事实上只用了几条样本。这就是“无偏”与“可用”之间的取舍——8.5.4 节的实验里，IS 的标准差是 WIS 的近两倍。WIS 之所以能用在方差无穷的情形，是因为它把每个回报的权重归一化到不超过 1：即使比率的方差无穷，有界回报下它的方差仍收敛到零。

8.5.3 直接法与双重稳健

直接法先用数据拟合一个模型，再在模型内评估目标策略。模型的两种常见形态是转移模型 $\hat{P}$（配上奖励模型 $\hat{r}$）与价值函数 $\hat{Q}_\phi$（即拟合 Q 评

估，FQE）：

$$\begin{aligned}\hat{V}_{\mathrm{DM}} &= \mathbb{E}_{s_0\sim\rho_0}\big[\hat{V}^{\pi}_{\hat{M}}(s_0)\big],\\ \hat{Q}_\phi &\leftarrow \arg\min_{\phi}\ \mathbb{E}_{\mathcal{D}}\Big[\big(Q_\phi(s,a) - r - \gamma\,\mathbb{E}_{a'\sim\pi}Q_\phi(s',a')\big)^2\Big].\end{aligned} \tag{8.20}$$

式 (8.20) 方差小得多，因为它不乘重要性权重，单个样本的贡献被限制在 $O(1)$。代价是偏差直接来自模型误差，且**偏差不会被平均掉**：数据再多，模型错的地方照样错。离线设定里这一点尤其危险——π 与 μ 的动作分布不同，模型恰好在 π 常去而 μ 少去的地方最不准。

双重稳健把两者结合起来，用直接法作基线、用重要性权重修正残差：

$$\hat{V}_{\mathrm{DR}} = \hat{V}_{\mathrm{DM}} + \frac{1}{N}\sum_{i=1}^{N} w_i\big(G_i - \hat{V}_{\mathrm{DM}}(s_{0,i})\big). \tag{8.21}$$

> **定理 8.4（双重稳健性 [精确]）**
>
> 若 $\hat{V}_{\mathrm{DM}}$ 等于真值，则式 (8.21) 的期望等于真值；若权重正确（覆盖成立），残差项的期望为零，估计同样等于真值。两者只要有一个正确，估计就一致。

“双重稳健”这个名字容易让人高估它。定理 8.4 说的是**一致性**：两者之一正确时偏差为零，它没有说方差也会变小——权重的方差仍按式 (8.17) 指数增长，只有当 $\hat{V}_{\mathrm{DM}}$ 很准时残差变小，方差才随之下降。实践中更常见“两者都略有偏差”，此时 DR 的偏差居中、方差接近 IS。MAGIC（Thomas & Brunskill, 2016）把多个估计量用非线性规划加权组合，权重由数据估计的协方差决定：不押注单一估计量，代价是计算更贵。

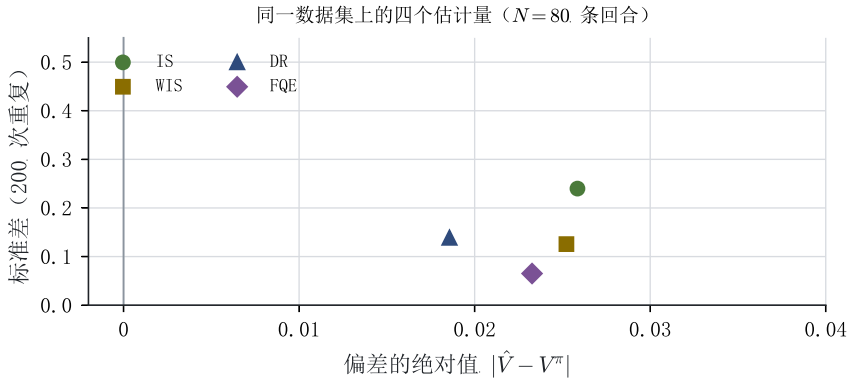


图 8-6 同一固定数据集上四个估计量的偏差—方差位置。三状态两动作 MDP、折扣 0.9、回合长度 8；每点由 200 个独立数据集重复，每个 80 条回合。真值 0.3728，种子 17。

SUMMARY / 总结

8.5.4 同一数据集上的四个估计量

图 8-6 是一个可复算的最小实验：三状态、两动作的 MDP，状态 2 为吸收态，$\gamma = 0.9$，回合长度 8。行为策略 μ 与目标策略 π 在状态 0 上差别很大（π 以 0.8 的概率选动作 1，μ 以 0.65 选动作 0），重要性权重因此波动明显。真值由动态规划算出：$V^{\pi}(s_0) = 0.3728$。对 200 个独立生成的数据集（每个 80 条回合）分别运行四个估计量：

表 8-2 四个估计量在同一批数据集上的偏差与标准差。真值 0.3728，200 次重复，每次 80 条回合。

估计量	平均偏差	标准差
IS	-0.026	0.240
WIS	-0.025	0.126
DR	-0.019	0.139
FQE（线性特征）	$+0.023$	0.065

表 8-2 里有三件事值得注意。第一，IS 的方差比其余三个大一个量级，与式 (8.17) 的预言一致；它的偏差并不显著为零，因为 200 次重复的平均本身有抽样误差，不要把“无偏”读成“每次都对”。第二，WIS 与 DR 的偏差接近，DR 没显出“双重稳健”的优势——这一组数据里直接法有偏，DR 只继承了它的偏差。第三，FQE 方差最小但偏差最大，这是**模型错设**的直接后果：线性特征表达不了真实的 Q^{π}，偏差不会被样本量消除。还要提醒：本节的权重有界（固定回合长度、行为策略覆盖较宽），因此只能展示“方差大”，展示不了“方差无穷”。

四个估计量的标准差在 0.065 到 0.240 之间，而真值只有 0.37：若策略改进只带来 5% 的收益（约 0.02），OPE 的噪声完全盖住了它。**OPE 的估计误差常大于策略改进的收益**，这是落地时最容易被忽略的一条。

8.5.5 离策略评估的可靠性条件

既然估计量都有偏或方差大，实践上只能靠交叉检查判断结果是否可信。第一，报告有效样本量：若 ESS/N 低到个位数百分比，IS 与 DR 的数字基本是少数几条轨迹的产物。第二，同时看直接法与重要性采样：两者接近时结论较稳，分叉时以更保守的为准。第三，报告置信区间而非点估计，常用以轨迹为单位的自助法，但它同样低估方差——重采样无法创造数据里没有的覆盖。第四，同时评估多个目标策略，检查排序是否稳定：排序比绝对值更稳。

SUMMARY / 总结

必须写清楚：检查是诊断，不是保证——覆盖不成立时没有方法可信。

SUMMARY / 总结

本章小结

本章拿掉的是“还能采样”这条前提，代价是三个能力同时消失：探索、验证、纠错。三者合起来把“估计”变成了可辨识性问题——覆盖假设 $\operatorname{supp}\pi \subseteq \operatorname{supp}\mu$ 是最低要求，它的松弛形式单策略集中系数 $C_{\pi,\mu}$ 在实践中难以估计，因此离线学习的误差界只能当定性指引，不能当安全证书。覆盖一旦失效，坏的就不是细节：$\hat{Q}$ 在数据外由归纳偏置决定，样本再多也约束不住（例 8.1：同一份数据、同一模型族，仅在支持集外重采样，标准差从 0.003 涨到 0.612）。残差到误差的放大 $\|\hat{Q}-Q^{\pi}\| \le \delta/(1-\gamma)$ 本身是 [精确] 的，可它的前提“残差处处有界”在离线设定下不可检验，所以这条界不能当安全论证。

离线策略改进主要有三类约束方式：BCQ 限制候选动作，CQL 通过惩罚降低数据外动作的估值，IQL 通过数据内的 expectile 价值学习减少对数据外动作的查询。Decision Transformer 使用回报条件下的轨迹生成，不显式进行贝尔曼自举；其泛化仍受数据覆盖和条件回报范围限制。策略评估方面，普通重要性采样无偏但方差可能随轨迹长度迅速增长，直接法可能因模型错设产生偏差，双重稳健在相应条件下保证一致性，并不自动降低方差。第 8.5.4 节的实测中，四种估计量的标准差为 0.065 至 0.240，真实价值为 0.37；当策略改进幅度较小时，离线评估噪声可能掩盖改进效果。

关键公式

下面八条是本章的主干：先是“数据与策略差多远”的度量，再是三处压制的位置，然后是模仿学习的复合误差与评估的三个估计量。公式按出现顺序列出，便于回头查符号。

$$C_{\pi,\mu} = \max_{s} \frac{d_{\gamma}^{\pi}(s)}{d_{\gamma}^{\mu}(s)}$$

悲观原则，式 (8.3)：

$$\hat{\pi} = \arg\max_{\pi} \min_{Q \in \mathcal{Q}} \mathbb{E}_{s\sim d_{\gamma}^{\pi}, a\sim\pi}\left[Q(s,a)\right]$$

CQL 的保守惩罚（CQL(H) 形式），式 (8.6)：

$$\min_{Q}\ \alpha_{\text{off}}\,\mathbb{E}_{\mathcal{D}}\left[\log\sum_{a}\exp Q(s,a) - \mathbb{E}_{a\sim\hat{\pi}_{\beta}}\left[Q(s,a)\right]\right] + \frac{1}{2}\mathbb{E}_{\mathcal{D}}\left[\left(Q-\hat{\mathcal{B}}\hat{Q}\right)^{2}\right]$$

IQL 的期望回归与动作价值，式 (8.8) 与式 (8.9)：

$$\mathcal{L}_V(\psi)=\mathbb{E}_{\mathcal{D}}\Big[L_2^\tau\big(\hat{Q}-V_\psi\big)\Big],\qquad \hat{Q}(s,a)=r+\gamma V_\psi(s')$$

行为克隆的复合误差，式 (8.14)：

$$J(\pi^\star)-J(\hat{\pi})\le T^2\varepsilon$$

重要性采样的无偏性与方差增长，式 (8.16) 与式 (8.17)：

$$V^\pi=\mathbb{E}_{\tau\sim\mu}\big[w(\tau)G(\tau)\big],\qquad \mathbb{E}_\mu[w^2]=\prod_{t}\mathbb{E}_\mu[\rho_t^2]=\kappa^T$$

双重稳健估计，式 (8.21)：

$$\hat{V}_{\mathrm{DR}}=\hat{V}_{\mathrm{DM}}+\frac{1}{N}\sum_{i=1}^{N}w_i\big(G_i-\hat{V}_{\mathrm{DM}}(s_{0,i})\big)$$

习题

1. 证明命题 8.1：由 $\|\hat{Q}-T^\pi\hat{Q}\|_\infty\le\delta$ 推出 $\|\hat{Q}-Q^\pi\|_\infty\le\delta/(1-\gamma)$。然后说明为什么在离线设定下这个前提“不可检验”，并给出一个只有两个状态的反例：数据只覆盖 s_0，而残差在 s_1 上任意大。

2. 在例 8.1 的设置里把多项式次数从 3 改到 5，重算支持集内与 $a=0.9$ 处的标准差。解释为什么模型变强之后数据外的分叉更严重，并说明这与“过拟合”是不是同一回事。

3. 逐项解释 CQL 惩罚项 (8.5) 的符号：内层 $\max$ 挑的是什么分布？为什么 $\mathbb{E}_{a\sim\hat{\pi}_\beta}[Q]$ 前面的负号意味着数据动作的估值被抬高？若把 α_{off} 换成负值，算法会退化成什么？

4. 证明：当 $\tau=1/2$ 时，期望回归 (8.8) 的最优解是 $\mathbb{E}[\hat{Q}(s,a)\mid s]$；当 $\tau\to1$ 时它逼近 $\max_{a\sim\mathcal{D}(\cdot\mid s)}\hat{Q}(s,a)$。据此说明 IQL 的 τ 与 CQL 的 α_{off} 在“保守程度”上扮演的角色有何不同。

5. 设单步动作为二值，$\pi(a_1)=0.8$、$\mu(a_1)=0.5$，每步奖励独立地取 0 或 1，回合长度 T。写出 w 的分布，算 $\mathbb{E}_\mu[w]$、$\mathbb{E}_\mu[w^2]$ 与 $\mathrm{Var}_\mu[w]$，再算 $T=10$ 时 w 的相对标准差。若要求相对标准差不超过 1，最大可用的回合长度是多少？

6. 用式 (8.18) 计算：三条轨迹的权重为 $w=(1,1,0.02)$，求 ESS；若把第三条轨迹复制 10 份，ESS 如何变化？据此说明为什么“多收集数据”不能修复覆盖率不足。

SUMMARY / 总结

7. 用定理 8.2 估计：$\varepsilon = 0.1$、$T = 20$ 时行为克隆的最坏累计损失是多少？与图 8-4 的实测值比较，解释这个界为什么在实践中过于悲观，以及“界松”是否意味着方法可用。
8. 用自己的话说明 DAgger 与数据增强的区别，并解释为什么 DAgger 不能算作离线强化学习的一种。如果一个真实系统只允许采集一次数据、不允许向专家提问，DAgger 的哪一步无法执行？

延伸阅读

- Levine、Kumar、Tucker 与 Fu 的综述 Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems（2020）给出了这一领域的完整地图，对“分布偏移—悲观—评估”三条线索的梳理与本章一致，适合作为第一篇入门读物。
- Fujimoto、Meger 与 Precup 的 BCQ 论文（Off-Policy Deep Reinforcement Learning without Exploration, ICML 2019）第 3 节给出了“外推误差”的形式化定义，第 4 节的生成模型与扰动结构是本章式 (8.4) 的来源。
- Kumar、Zhou、Tucker 与 Levine 的 CQL 论文（Conservative Q-Learning for Offline Reinforcement Learning, NeurIPS 2020）第 3 节包含本章引用的三个结论：价值下界、间隙扩张与安全改进；附录 A 给出 $\rho = \hat{\pi}_{k-1}$ 变体的推导，工程实现细节在附录 B。
- Kostrikov、Nair 与 Levine 的 IQL 论文（Offline Reinforcement Learning with Implicit Q-Learning, 2021）用期望回归绕开 $\max$ 的想法值得对照第 3 章的 Bellman 最优方程阅读，注意它优化的是数据内的上期望值（expectile），不是最优价值。
- Ross、Gordon 与 Bagnell 的 DAgger 论文（A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning, AISTATS 2011）给出定理 8.2 的完整形式与第 4 节的线性界；同一作者 2010 年的工作把复合误差的 T^2 与 T 之别讲得更细。
- Jiang 与 Li 的双重稳健估计（2016）与 Thomas 与 Brunskill 的 MAGIC（2016）是 OPE 的两个经典入口；Voloshin 等人 2021 年的 OPE 基准测试则给出了各估计量在标准环境上的偏差—方差实测，可与本章 8.5.4 节的小实验互为参照。
- Chen、Lu、Rajeswaran 等 2021 年的 Decision Transformer 论文（Decision Transformer: Reinforcement Learning via Sequence Modeling, NeurIPS

2021）第 3 节把轨迹写成 (回报, 状态, 动作) 的 token 序列，第 4 节的条件生成与本章 8.3 的记号一一对应；同年 Janner 等 2021 年的 Trajectory Transformer 可对照阅读，它把序列模型用于规划而非条件生成。

- Fu、Kumar、Nachum 等 2020 年的 D4RL 基准（D4RL: Datasets for Deep Data-Driven Reinforcement Learning）是离线算法最常用的评测数据集，8.2 节的三条路线在其上都有成熟实现；读它的数据统计（行为策略水平、覆盖宽度）比读排行榜更能理解各算法的适用边界。

SUMMARY / 总结

第 9 章　层次、多智能体与安全约束

本章假定你已熟悉第 2 章的状态、动作与价值函数。本章讨论层次决策中的回报优化、多智能体博弈中的均衡分析和约束决策中的可行性与性能优化。平均回报、尾部风险与约束违背概率需要分别定义和评估。

前述章节主要从单智能体、逐步决策与标量回报等基本设定出发建立分析。第2章采用单智能体、逐步执行原始动作及标量回报的标准MDP设定；动作的长期影响由状态转移持续传递。单智能体、动作持续时间与目标形式的设定分别影响动态规划、策略优化和约束分析。

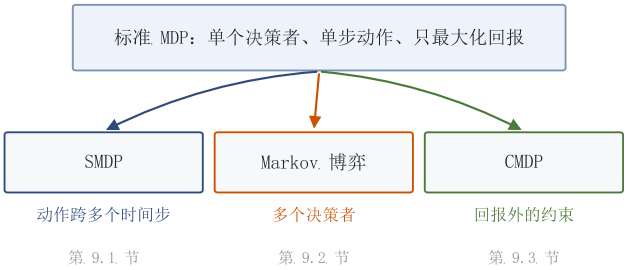
复杂决策系统可能涉及持续多步的技能、多个参与者或同时满足性能与安全要求的目标。机械臂的一次“抓取”持续几百毫秒，这期间它不做决策——坏的是第二条，动作的时间粒度；十字路口的转移由几个司机同时决定，每个人只看得见自己那一侧——坏的是第一条，决策者的数目；自动驾驶既要到达目的地又不能撞人，两个要求折不成一个数——坏的是第三条，目标的数目。

本章依次建立半马尔可夫决策过程、马尔可夫博弈与约束马尔可夫决策过程的形式化模型。每个框架都回答同一组问题：它替换了上面哪一条、新的最优性条件长什么样、这个条件在什么情况下失效。第 9.4 节的元学习只作案例，因为它不改单个任务的 MDP——理由放在那一节的开头。

三类扩展改变了最优性结论的对象或强度。在有限折扣 MDP 中，最优价值函数唯一，但并列最优动作可能使最优策略不唯一；多智能体博弈可能存在多个均衡；约束 MDP 的期望约束只控制总体期望，单条轨迹仍可能违反约束。相关分析需要区分价值函数、策略、均衡和约束满足分别具有的性质。

本章的实验全部可复现：图 9-3、图 9-5、图 9-6 由 `figures/ch09_figs.py` 生成，种子、样本量与评估协议写在图注中。文献截止日为 2026-10-19。

SUMMARY / 总结



本章只对这三个框架做完整推导；元学习仅作案例（9.4）

图 9-1 标准 MDP 的三个最小改动。半马尔可夫决策过程改动作的时间粒度，马尔可夫博弈改决策者的数目，约束马尔可夫决策过程改目标的数目；第 9.4 节的元学习不改变单个任务的 MDP 形式，故只作案例。

9.1 选项与半马尔可夫决策过程

9.1.1 选项的定义与持续时间

标准 MDP 每走一步决策一次。这个假设在工程上代价很高：设想一个迷宫，要走到目标必须连续通过两道门，而门的位置事先未知。用原始动作学，每一步都要随机选一次，成功路径却有几十步——撞对“第一道门 → 第二道门”，等于在 4^{30} 量级的动作序列里盲搜。层次化策略可以先选择长期技能，再由技能内部策略执行具体动作。

把“走的过程中不再重新规划”形式化，就是**选项**（option）。

> **定义 9.1（选项）**
>
> 给定马尔可夫决策过程，一个选项是三元组 $o=(I_o,\pi_o,\beta_o)$：起始集合 $I_o\subseteq\mathcal{S}$，内部策略 $\pi_o:\mathcal{S}\times\mathcal{A}\to[0,1]$，终止条件 $\beta_o:\mathcal{S}\to[0,1]$。选项 o 在状态 $s\in I_o$ 时可用；一旦被选中，智能体按 π_o 选动作，每到达一个新状态 s' 就以概率 $\beta_o(s')$ 终止该选项，回到“重新选择”的决策点。终止必然发生时（$\beta_o\equiv 1$）的选项退化为原始动作。

选项把决策的时间粒度变成可变的：选一个选项，内部执行 τ 步（τ 随机）才重新决策，τ 就是图 9-2 里括号的宽度。决策时刻不再等间隔，过程于是变成**半马尔可夫**的：状态仍满足马尔可夫性，但相邻决策的间隔是随机变量。

SUMMARY / 总结

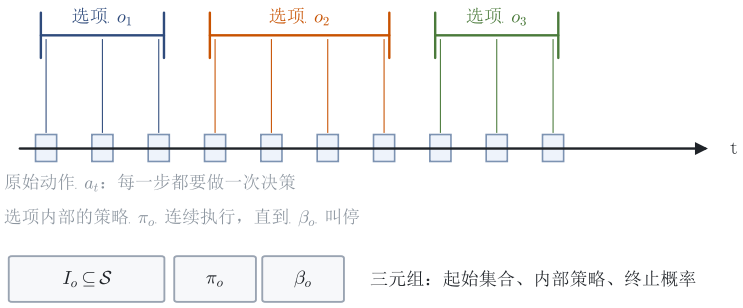


图 9-2 选项的时间结构：一次决策换成 τ 步执行。

把选项与原始动作并进同一个动作集合 $\mathcal{O} \cup \mathcal{A}$，价值函数的定义就要改写：从 s 选 o，先收 τ 步折扣奖励，再从 s_τ 继续。

$$Q^{\pi}(s,o) = \mathbb{E}_{\tau, s_\tau}\Big[\sum_{k=0}^{\tau-1} \gamma^{k} r_{t+k+1} + \gamma^{\tau} V^{\pi}(s_\tau) \;\Big|\; s_t = s,\, o_t = o\Big] \tag{9.1}$$

其中第一项 $R(s,o) = \mathbb{E}[\sum_{k=0}^{\tau-1}\gamma^k r_{t+k+1} \mid s,o]$ 是选项内部累积的折扣奖励，期望同时对内部策略 π_o、终止时间 τ 与转移取。式 (9.1) 与普通动作价值函数的差别只有一处：折扣因子从 γ 变成 γ^{τ}。这一处差别是全部理论的关键，下面单独说明。

选项持续 τ 步，后续价值相对于当前决策时刻折扣 τ 次，因此折扣因子为 γ^{τ}。由于持续时间可能随机，式 (9.1) 的期望同时覆盖持续时间、内部策略与状态转移。若统一使用单步折扣 γ，就会忽略选项持续时间对回报的影响。

把式 (9.1) 中的 V^{π} 换成对选项取最大，得到半马尔可夫的最优方程。

> **定理 9.1（半马尔可夫最优方程 [精确]）**
>
> 设状态与选项集有限、$\gamma < 1$，则最优选项价值函数满足下面式 (9.2) 的不动点方程；该不动点唯一，从任意初值做迭代都收敛到它。

$$Q^{*}(s,o) = \mathbb{E}_{\tau, s_\tau}\Big[R(s,o) + \gamma^{\tau} \max_{o' \in \mathcal{O}\cup\mathcal{A}} Q^{*}(s_\tau, o') \;\Big|\; s_t = s,\, o_t = o\Big] \tag{9.2}$$

证明与定理 2.2 同构：把式 (9.2) 的右边看作一个算子 $T^{\diamond}$，它在 $\gamma^{\tau} \le \gamma < 1$ 的意义下仍是 γ-压缩（因 $\tau \ge 1$），压缩映射定理给出唯一不动点与收敛性。区别只在于“一步”变成了“一个选项”，而这正好说明压缩性来自折扣、不来自时间步的定义。

SUMMARY / 总结

式 (9.2) 还有一个容易忽略的推论：**选项的价值依赖于终止函数**。同一个内部策略配上不同的 β_o，会有不同长度的选项与不同的价值，所以“设计选项”不只是设计技能，还包括设计“技能用多久”。

9.1.2 选项评论家：终止函数也可以求梯度

终止函数既然影响价值，就该被学。Option-Critic 把 β_o 参数化成 $\beta_o(s;\theta_\beta)$，与内部策略、价值函数一起做梯度上升。麻烦在于 β 藏在“循环次数”里，而循环次数不可微；办法是先看最简情形 $\tau \in \{1,2\}$，循环展开成一层就能直接求导。

设 s' 是选项内部走一步之后到达的状态，选项以 $\beta_o(s')$ 的概率在此终止。则

$$Q(s,o) = \sum_{s'} P(s' \mid s,o)\Big[r + \gamma\big[(1-\beta_o(s'))Q(s',o) + \beta_o(s')V(s')\big]\Big] \tag{9.3}$$

对 $\beta_o(s')$ 求偏导，只有一项活下来：

$$\frac{\partial Q(s,o)}{\partial \beta_o(s')} = P(s' \mid s,o)\,\gamma\big[V(s') - Q(s',o)\big] \tag{9.4}$$

符号就是直觉：$A_\Omega(s',o) = Q(s',o) - V(s')$ 恒不大于零（V 是对所有选项取最大，含 o 自己），所以式 (9.4) 的导数非负——这个选项比“换一个”差得越多，提高终止概率越有价值。于是它自发长成“技能失效处退出”的形状，不需要任何人工规则。

用到多步情形，要把 γ 换成 γ^τ 并对 τ 的分布取期望，还要加上“内部策略也在变”带来的一项（intra-option 项）。原始推导见 Bacon 等（2017）定理 1；这里只留方向性结论：**终止梯度等于终止优势 $A_\Omega(s',o) = Q_\Omega(s',o) - V_\Omega(s')$ 的负值再乘 γ^τ**，即“继续优于退出时把终止概率调低”。

SUMMARY / 总结

算法 9-1 选项评论家（单选项层，一次迭代）

输入：状态 s，选项集 O，学习率 eta_theta, eta_beta, eta_w
1: **在 s 处按** eps-**贪心从 O 中选** o
2: **重复**
3: **按** pi_o(.|s; theta) **采样动作 a，执行，观测 r 与 s'**
4: **用** critic V(s; w) **或** Q(s,o; w) **算 TD 误差** delta
5: w <- w + eta_w * delta * grad_w V(s; w)
6: theta <- theta + eta_theta * grad_theta log pi_o(a|s) * Q_U(s,o,a; w)
7: beta <- beta + eta_beta * gamma * (V(s'; w) - Q(s',o; w)) * grad_beta beta_o(s')
8: **以概率** beta_o(s') **终止，否则** s <- s' **继续**
9: **直到终止**

伪代码里有两处必须**分开**说清，因为它们的性质完全不同。

第 6 行的价值函数必须含动作。 Option-Critic 原文定理 1 的 intra-option 梯度是 $\sum_a \nabla_\theta \pi_o(a \mid s) Q_U(s,o,a)$ 的加权和，权重随动作变。换成只依赖 (s,o) 的 Q_Ω，被乘数就与 a 无关，而 $\sum_a \nabla_\theta \pi_o(a \mid s) = 0$，于是**期望梯度恒为零**——不是近似变差。

第 7 行用的是估计值，不是式 (9.4) 里的真值。 式 (9.4) 的导数是精确的（转移概率与 Q 都当作已知），实现里 $Q(s',o;w)$ 只是 critic 的估计，而且按“选项尚未终止”估价值：选项短时偏差小，选项长时更新方向滞后，这是要调小 η_β 的原因。另外 β_o 用硬阈值时梯度不存在（改 sigmoid 松弛），而内部策略与终止函数同时学会收敛到“每个选项只持续一步”，层次结构退化，损失函数却毫无异议。

9.1.3 选项的适用条件与实验表现

上一小节说明选项“可以”学，没说明它“值不值得”。下面用一个能精确统计的实验回答。

任务是图 9-3 左的三室迷宫：15×11 网格，中间两道竖墙各留一个开口（w_1、w_2）。起点在左室、目标在右室，必须先摸到第一道门穿过去，再摸到第二道门；每回合最多 200 步。

两组只在动作集上不同。**原始动作组**用四方向 ε-贪心（$\varepsilon = 0.1$）Q-learning，$\alpha = 0.1$、$\gamma = 0.95$，到达得 10、每步 -0.05，每个种子 150 回合。**选项组**把“走到第一道门”“走到第二道门”“直达目标”设为三个选项，内

部策略是到该格的确定性最短路，β_o 在门口取 1，其余完全相同。

40 个随机种子统计“首次到达目标所需回合数”：两组都是 40/40 成功，但原始动作的中位数是 15 回合，选项是 1 回合。

在该迷宫实验中，选项将探索决策从原始动作序列转移到较少的高层技能选择，减少了找到目标路径所需的采样步数。**层次化的收益来自把组合搜索从“动作序列”降到“选项序列”**，不是来自更聪明的算法。

这个数字必须配上前提才成立。**选项是给定的**——门的位置写进了内部策略，若选项也要学，收益会大幅缩水，因为学选项本身就要探索，所以图 9-3 只是“给定好选项时的收益上界”。**探索的困难被转移而没被消除：**选项层仍要在 $|\mathcal{O}|$ 个选项上探索，选项一多，组合爆炸会换个形式回来。**选项还会与价值函数一起变：**内部策略更新后，先前学到的 $Q(s,o)$ 就不准了，这种非平稳性是半马尔可夫情形特有的。

SUMMARY / 总结

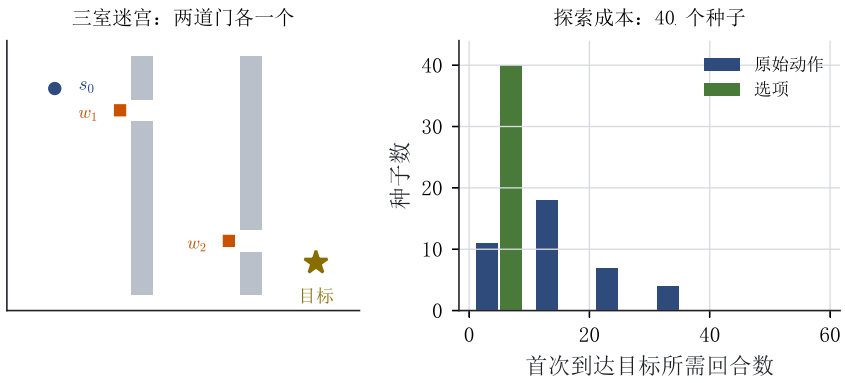


图 9-3 选项对探索成本的削减，以及它的前提。左：三室迷宫，两道门各一个开口。右：40 个随机种子上首次到达目标所需回合数的分布（每 10 回合一个箱）。选项把中位数从 15 回合降到 1 回合，但这里的选项是**已知**的。

9.1.4 平均奖励下的半马尔可夫形式

式 (9.2) 用的是折扣目标。若任务没有自然终止、看的是长期平均吞吐（第 2 章表 2-1 的第二种目标），半马尔可夫形式就要额外除以选项的期望时长，否则长选项单靠“占的时间久”就能多拿回报。

在有限状态与有限选项集、所有策略下选项时长有界且马尔可夫链单链（unichain）的假设下，平均奖励的最优方程是下面式 (9.5)（[精确]）：存在常数 ρ^{*}（每步的最优平均奖励）与偏差函数 h 使其成立，其中 $R_{\text{avg}}(s,o)$ 是**不折扣**的选项内累积奖励，$\bar{\tau}(s,o)=\mathbb{E}[\tau \mid s,o]$ 是选项的期望时长。

$$\max_{o\in\mathcal{O}}\Big\{R_{\text{avg}}(s,o)-\rho^{*}\bar{\tau}(s,o)+\sum_{s'}P(s'\mid s,o)h(s')\Big\}=h(s) \tag{9.5}$$

式 (9.5) 中各项均以奖励为单位。$\rho^{*}\bar{\tau}$ 将平均每步收益换算为选项持续期间的累计收益，再扣除相应代价；持续时间 $\bar{\tau}$ 因此是该目标定义的一部分。

SUMMARY / 总结

9.2 马尔可夫博弈与多智能体

9.2.1 形式化：当“最优”不再唯一

标准 MDP 的转移只依赖一个动作。有 n 个决策者时，转移依赖**联合动作**，每个决策者有**自己的**奖励——这就是马尔可夫博弈（随机博弈）。

> **定义 9.2（马尔可夫博弈）**
>
> n 个智能体的马尔可夫博弈把“一个决策者”换成“多个决策者”：状态集与转移核由全体共享，动作与奖励按人分开。形式上是五元组 $(\mathcal{S}, \{\mathcal{A}_i\}_{i=1}^{n}, P, \{r_i\}_{i=1}^{n}, \gamma)$。智能体 i 有自己的动作集 $\mathcal{A}_i$ 与奖励函数 r_i，折扣 γ 公共；奖励依赖**整个**联合动作，这是耦合的唯一来源。联合动作记作 $\boldsymbol{a}$，联合策略是各人策略的乘积。

第 i 个智能体的目标是在其他人的策略给定的条件下最大化自己的折扣回报：

$$V_i^{\pi}(s) = \mathbb{E}_{\pi}\Big[\sum_{t\ge 0}\gamma^t r_i(s_t,a_t)\;\Big|\; s_0 = s\Big] \tag{9.6}$$

注意式 (9.6) 的下标：每个智能体有自己的价值函数，且它的值依赖**所有人**的策略——单智能体情形 V^{π} 只依赖自己，这个差别是后面一切困难的源头。

于是“最优策略”这个概念失效了。单智能体时最优策略满足 $V^{\pi^*}(s)\ge V^{\pi}(s)$ 对**所有** π 成立——一个策略同时打败所有对手，“最优”才良定义。多智能体时一个策略好不好取决于别人选什么，不存在同时占优的策略，剩下的概念是**最优反应**：π_i^* 是对 π_{-i}^* 的最优反应，若

$$V_i^{(\pi_i^*,\pi_{-i}^*)}(s) \ge V_i^{(\pi_i,\pi_{-i}^*)}(s) \quad \text{对所有 } \pi_i \text{ 与所有 } s. \tag{9.7}$$

当每个 i 都取最优反应时，联合策略 $\boldsymbol{\pi}^* = (\pi_1^*,\dots,\pi_n^*)$ 称为**纳什均衡**（Nash equilibrium）。

博弈均衡与社会最优或帕累托最优并非同一概念，均衡解取决于博弈结构。因此，“一般和博弈的最优策略”需要结合具体解概念定义；报告相对最优性的比例时，也需明确参照的解概念。

三类目标据此区分：**合作**时所有 r_i 相同，问题等价于动作空间为联合动作的单智能体 MDP（动作空间随 n 指数增长）；**零和**时 $r_1 = -r_2$，值唯一

（minimax 定理），但最优策略可能只在混合策略中存在；**一般和**时以上都不成立，只剩均衡。表 9-1 把本章三个框架的改动集中列出。

表 9-1 本章三个框架对标准 MDP 的改动、新的最优性条件与各自的失效方式。三个“失效方式”都是形式化本身的性质。

框架	对标准 MDP 改了什么	新的最优性条件	主要失效方式
SMDP	动作持续 τ 步，折扣变 γ^{τ}	式 (9.2)：对选项取最大	选项退化、β 不可微
Markov 博弈	转移依赖 n 个动作，奖励分 n 份	式 (9.7)：纳什均衡	均衡不唯一、学习不收敛
CMDP	增加期望代价约束	原始—对偶最优（式 (9.11)）	对偶间隙、尾部失控（9.3.3）

9.2.2 集中训练、分散执行

多智能体强化学习最常用的工程折中叫**集中训练、分散执行**（centralized training with decentralized execution，CTDE）：训练时看全局信息（全局状态、所有人的动作），执行时每个智能体只用局部观测 o_i。它直接来自上一小节的结构：训练时要看到 $\boldsymbol{a}$ 的完整组成才能正确评估 r_i，执行时又不可能要求每个智能体知道别人的策略。

CTDE 在两处给出了具体算法。第一处是**集中式评论家**：给每个智能体配一个评论家 $Q_i(s, a_1, \ldots, a_n)$，它看全局状态与联合动作，而演员只用自己的 o_i。确定性策略梯度写成

$$\nabla_{\theta_i} J_i = \mathbb{E}_{s,\boldsymbol{a}\sim\mathcal{D}}\Big[\nabla_{\theta_i}\mu_i(o_i;\theta_i)\,\nabla_{a_i} Q_i(s, a_1, \ldots, a_n; \phi_i)\Big] \tag{9.8}$$

这就是 MADDPG 的核心：评论家集中、演员分散。式 (9.8) 要求评论家能给出准确的动作梯度，而 Q_i 由函数逼近估计，故这一步是[近似]；“集中式评论家能加速学习”则属于[经验规律]。

第二处是**值分解**：给每个智能体一个局部 $Q_i(o_i, a_i)$，用混合网络合成联合价值，使分散执行时每个智能体对自己的 Q_i 取最大即得联合最优动作。QMIX 用的充分条件是单调性：

$$\begin{aligned} &\frac{\partial Q_{\text{tot}}(s, a_1, \ldots, a_n)}{\partial Q_i(o_i, a_i)} \geq 0 \quad \text{对所有 } i \\ &\Longrightarrow \ \arg\max_{\boldsymbol{a}} Q_{\text{tot}} = \Big(\arg\max_{a_1} Q_1, \ldots, \arg\max_{a_n} Q_n\Big) \end{aligned} \tag{9.9}$$

式 (9.9) 的箭头要看清：单调性是**充分条件**，它保证“各自取最大”等于“联合取最大”，分散执行因而不需要通信；但反方向不成立——存在可

分解的联合价值函数，它不满足任何单调混合。

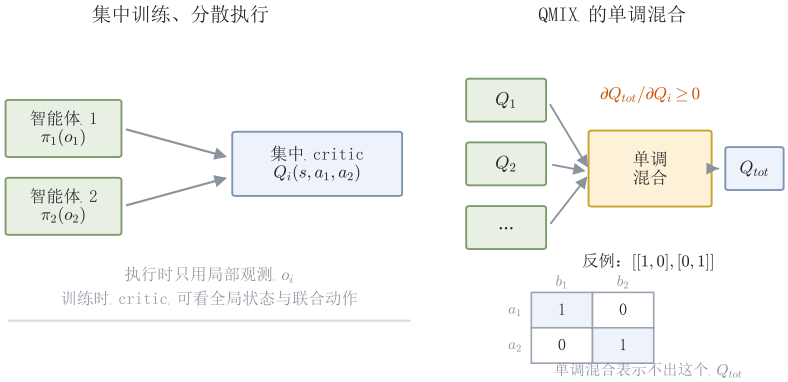


图 9-4 集中训练、分散执行的两个实现。左：集中式评论家看全局状态与联合动作，演员只用局部观测。右：QMIX 用单调混合网络把局部 Q_i 合成 Q_tot，单调性保证联合 argmax 可分解成各自 argmax；右下 2×2 矩阵是它表示不了的联合价值。

图 9-4 右侧的矩阵是显式反例：Q_{tot} 在 (a_1, b_1) 与 (a_2, b_2) 两格为 1、其余为 0。它**可以**写成局部 Q 的函数（如 $Q_1(a_1) = 1, Q_1(a_2) = 0$、$Q_2(b_1) = 1, Q_2(b_2) = 0$ 的组合），但对每个 Q_i 不单调：固定 a_1 时 Q_2 的增减会翻转 Q_{tot} 的排序。因此单调混合网络无论怎么训练都表示不出它，而这正是“两个智能体必须错开”的协作结构。

这个限制的实际含义是：**QMIX 适合“多出力总不会更差”的任务，不适合“必须有人让路”的任务**。后者要么改用能表示非单调分解的结构，要么放弃分散执行、接受通信成本。

9.2.3 多智能体学习中的非平稳性与收敛条件

CTDE 解决的是“信息不对称”，没有解决更根本的问题：每个智能体的环境里包含其他智能体的策略，而那些策略正在同时改变。对第 i 个智能体，转移核是 $P(s' \mid s, a_i; \pi_{-i})$，它随 π_{-i} 的更新而**非平稳**；而 Q-learning 的收敛性定理（第 3、4 章）都以“转移核固定”为前提。转移核随策略变化时，固定转移核条件下的收敛结论不再适用。这不是哲学论断，两个 2×2 的博弈就能测出来。

- **协调博弈**：r = [[11, 0], [0, 7]]，两个智能体同动作时得 11 或 7，不匹配时得 0。两个都是均衡，但 11 优于 7。
- **匹配硬币**：r_1 = [[1, -1], [-1, 1]]，$r_2 = -r_1$，零和，唯一的纳什均衡是双方各以 1/2 概率出招。

实验设置：采用表格法 Q-learning，

$\alpha = 0.1$，
$\varepsilon = 0.1$，
$\gamma = 0$（单步博弈），使用 60 个随机种子，每个种子运行 2000 回合（匹配硬币运行 1500 回合）。比较两种方式：**独立学习**（每个智能体只更新自己的 Q_i，把对方动作视为环境的一部分）与**联合动作学习**（一个学习者在 4 个联合动作上更新价值，即集中式学习）。

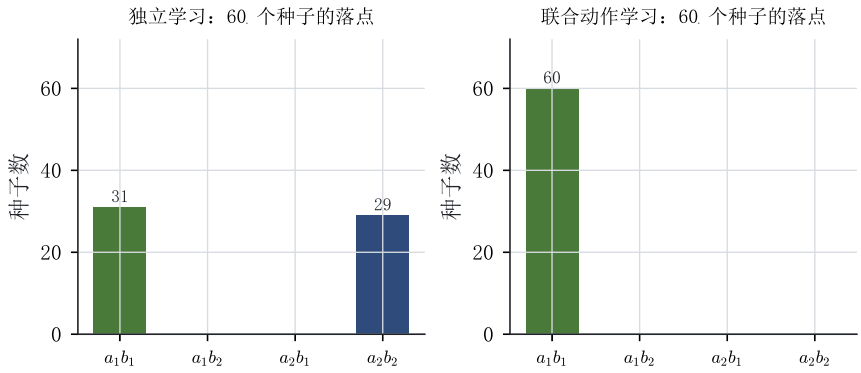


图 9-5 同一组 2×2 博弈上的两种学习方式。左：独立学习在协调博弈上的落点分裂成两群（31 个种子到 r=11，29 个到 r=7），联合动作学习 60 个种子全落在 r=11。右：匹配硬币上独立学习的 Q 差值 1500 回合内变号 109 次，最后 300 回合两个智能体的动作频率都是 0.48，四个联合动作频率约 0.23/0.26/0.26/0.26——接近均衡的边缘分布，其实是一直翻转的副产品。

实验结果显示，独立学习的收敛结果受博弈结构和初始化影响。协调博弈中，60 个种子的收敛点分别落在两个均衡附近，计数为 31 和 29。该实验说明，对单个博弈实例观察到收敛，不能据此推断独立 Q-learning 在所有博弈中都会收敛到同一均衡。

在该匹配硬币实验中，**独立学习未表现出收敛**。Q 差值在 1500 回合内变号 109 次，表明贪心动作持续翻转。边缘频率接近均衡值（0.48 对 0.5），但这一统计量无法区分混合均衡与持续振荡，仍需检查学习轨迹。

集中式联合动作学习在这两个例子中得到稳定结果，其代价是联合动作空间规模按 $\prod_i |\mathcal{A}_i|$ 增长。20 个智能体各有 3 个动作时，联合动作数为 $3^{20} \approx 3.5 \times 10^9$。

因此本章不写“多智能体 Q-learning 收敛”：势博弈、队友固定、两人零和三类有结论，其余只是经验观察[经验规律]。

SUMMARY / 总结

9.3 约束马尔可夫决策过程与风险敏感

9.3.1 约束 MDP 与拉格朗日方法

前面两节改的是“动作的时间粒度”与“决策者的数目”，目标仍是把某个回报最大化。第三类改动来自目标本身：自动驾驶要到达目的地，同时必须不撞人；推荐系统要提升点击率，同时必须控制不良内容的曝光。这类要求的形式是“**在某项代价不超过预算的前提下**最大化回报”，而不是“回报减去代价的某个倍数”。

> **定义 9.3（约束马尔可夫决策过程）**
>
> 约束马尔可夫决策过程（CMDP）在标准 MDP 上增加代价函数 $c:\mathcal{S}\times\mathcal{A}\to\mathbb{R}_{\ge 0}$ 与预算 $d\in\mathbb{R}$，要求策略满足期望折扣代价不超过 d。与奖励一样，代价按折扣累计；两者各自有自己的折扣和，且**约束是对期望成立的**，不是对每条轨迹成立的。

CMDP 的优化形式为：

$$\begin{aligned}\max_{\pi}\ & J_r(\pi)=\mathbb{E}_{\pi}\Big[\sum_{t\ge 0}\gamma^t r(s_t,a_t)\Big]\\ \text{s.t.}\ \ & J_c(\pi)=\mathbb{E}_{\pi}\Big[\sum_{t\ge 0}\gamma^t c(s_t,a_t)\Big]\le d\end{aligned}\tag{9.10}$$

将代价并入单一奖励函数会形成目标 $J_r-\lambda J_c$，其中权重 λ 需要校准。约束任务通常直接给出代价上限 d，而确定相应的边际权重需要知道最优解附近的收益—代价权衡（图 9-6 与第 9.3.3 节）。单一总回报也会掩盖约束违反程度，降低训练监控和部署后风险诊断的可解释性。

正确的形式化是拉格朗日乘子法。定义

$$\mathcal{L}(\pi,\lambda)=J_r(\pi)-\lambda\big[J_c(\pi)-d\big],\qquad \lambda\ge 0\tag{9.11}$$

原问题的最优值等于 $\min_{\lambda\ge 0}\max_{\pi}\mathcal{L}(\pi,\lambda)$。给定 λ，内层问题是一个**无约束**的 MDP——奖励改成 $r-\lambda c$，可以用第 5 章的任何策略梯度方法求解；外层只需对 λ 做梯度下降。两者一起更新，得到最常用的原始—对偶算法：

$$\theta\leftarrow\theta+\eta_\theta\nabla_\theta\big[J_r(\pi_\theta)-\lambda J_c(\pi_\theta)\big],\qquad \lambda\leftarrow\big[\lambda+\eta_\lambda\big(J_c(\pi_\theta)-d\big)\big]_+\tag{9.12}$$

其中 $[\cdot]_+=\max(\cdot,0)$ 保证乘子非负。式 (9.12) 的直观是：代价超预算（$J_c>d$）时 λ 增大，惩罚变重，策略被推向保守；代价低于预算时 λ 减小，

SUMMARY / 总结

策略被允许更激进。乘子因此可以被读作“约束的**影子价格**”：λ 等于在最优解处每放宽一单位预算能换来多少回报。

对偶性成立到什么程度。 若把策略集松弛到占用测度的凸包上，CMDP 是一个线性规划，强对偶成立，式 (9.12) 收敛到原问题的最优值（[精确]，条件是 Slater 条件：存在严格可行的策略）。但实际的策略类是神经网络参数化的**非凸**集合，此时内层最大化不是凸问题，可能存在正的对偶间隙，式 (9.12) 只保证收敛到对偶问题的最优点（[近似]）。实践中还能观察到一个更麻烦的现象：λ 与 θ 用相同的步长更新时，两者会互相追逐——λ 上升迫使策略变保守，代价下降后 λ 又回落，形成振荡。常见的对策是让 λ 的更新慢一个量级。

CPO（constrained policy optimization）走另一条路：把约束写成信赖域内的代理约束，每一步解“在 KL 球内最大化回报、同时不让代价增加”的二次规划。它比原始—对偶稳定，但保证只对**代理问题**成立——线性化约束与二次近似都用采样梯度，误差一大，“单调改进”就失效。**因此 CMDP 的求解不构成“安全”的证明**：它保证的是期望约束，且只在这个近似模型内成立。

9.3.2 风险度量：VaR 与 CVaR

约束 MDP 约束的是**期望**代价。期望对稀有但巨大的损失几乎不敏感：一件概率 1% 的事故，只要其余时候代价够低，期望仍可能很好看。要描述“最坏的那一小部分”，需要尾部度量。

符号约定必须先固定，否则整节都会读反。令 Z 为**损失**变量，**越大越坏**——与收益的方向相反；引用以收益定义风险度量的文献时须先把收益取负，否则“下尾”会被当成“上尾”。$\alpha \in (0,1)$ 是**水平**（level），不是概率、不是置信度。

> 定义 9.4（VaR 与 CVaR）
>
> 水平 α 的风险价值 $\mathrm{VaR}_\alpha(Z)$ 是损失分布的第 α 分位数：超过它的概率不超过 $1-\alpha$。条件风险价值 $\mathrm{CVaR}_\alpha(Z)$ 是超出 VaR 那部分损失的**平均**，它有一个不必先求 VaR 的变分定义（式 9.14）。两者都是损失分布的**上尾**统计量；把 Z 换成收益，同一公式描述的就是下尾。

$$\mathrm{VaR}_\alpha(Z) = \inf\{z \in \mathbb{R} : \ \Pr(Z \le z) \ge \alpha\} \tag{9.13}$$

SUMMARY / 总结

$$\mathrm{CVaR}_\alpha(Z) = \inf_{\eta\in\mathbb{R}}\left\{\eta + \frac{1}{1-\alpha}\mathbb{E}\big[(Z-\eta)_+\big]\right\}, \qquad (x)_+ = \max(x,0) \tag{9.14}$$

式 (9.14) 将最坏的 $1-\alpha$ 比例损失写成一个**一维凸优化**。目标函数关于 η 为凸函数；在分布连续且没有原子的条件下，对 η 求导得到 $\Pr(Z>\eta)=1-\alpha$，最优 $\eta^\ast$ 对应一个 VaR。代回目标函数即可得到尾部条件平均：

$$\mathrm{CVaR}_\alpha(Z) = \mathbb{E}\big[Z \mid Z \ge \mathrm{VaR}_\alpha(Z)\big] \tag{9.15}$$

即“超过 VaR 的那部分的平均损失”。这里要特别注意两点。第一，式 (9.15) 是**上尾**：平均的是最大的那部分损失，不是最小的。第二，式 (9.15) 只在连续分布下成立；分布有原子时，$\inf_\eta$ 的最优点会把 η 放在原子之间，此时 CVaR 等于“用最坏的一部分质量、加上必要的原子权重凑够 $1-\alpha$ ”的加权平均，可以严格小于条件期望。

> **命题 9.1（CVaR 的性质 [精确]）**
>
> 对任意损失 Z 与 $\alpha\in(0,1)$，CVaR_α 满足：单调性（$Z\le Z'$ 逐点则 $\mathrm{CVaR}_\alpha(Z)\le\mathrm{CVaR}_\alpha(Z')$）、正齐次性、平移等变性，以及**次可加性**，因此是凸的、是一致风险度量。VaR_α 只满足前三条，不满足次可加性——两个独立风险的组合，其 VaR 可以大于各自 VaR 之和，这正是 VaR 不适合做优化目标的原因。

命题 9.1 的实用含义：以 CVaR 为约束的优化问题在策略集凸化后是凸的，以 VaR 为约束的不是。这就是风险敏感的强化学习几乎都用 CVaR 的原因。

把这些度量放到一个具体策略上，可以看到期望与尾部能差多远。图 9-6 的两个策略都满足同一个预算 $d=1$：稳妥策略每回合固定损失 1.00；冒进策略有 99% 的回合损失 0.20，1% 的回合损失 20.20（一次事故）。样本量 10^6，按式 (9.14) 在 η 网格上取最小（网格 20001 点，含原子处精确取值）。

SUMMARY / 总结

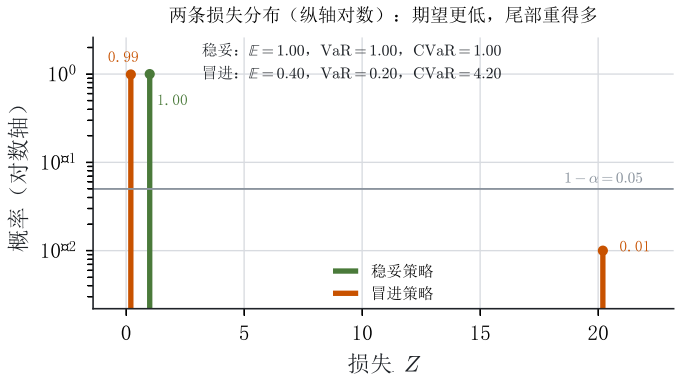


图 9-6 同一预算下的两个策略。稳妥策略的损失恒为 1.00；冒进策略以 99% 的概率损失 0.20、1% 的概率损失 20.20。两者的期望分别是 1.00 与 0.40，VaR 分别是 1.00 与 0.20，CVaR 分别是 1.00 与 4.20。冒进策略在期望与 VaR 上都更“好”，只有 CVaR 暴露了它的尾部。

这组结果显示：冒进策略的期望更低（0.40 对 1.00），VaR 也更低（0.20 对 1.00），只有 CVaR 更高（4.20 对 1.00，4.2 倍）。也就是说，**用期望或 VaR 做筛选，会挑中这个策略**。这不是构造出来的病态例子：任何“平时便宜、偶尔灾难”的系统都是这个形状，而这类系统恰恰是安全约束要防的。

9.3.3 期望约束不能替代尾部约束

图 9-6 直接给出了一个反例式的事实：同一个预算 $d=1$ 下，期望约束完全不能满足的两个策略，CVaR 差 4.2 倍。因此“策略满足 CMDP 约束”推不出“策略的尾部受控”。

反过来的方向成立，而且证明只有一行。因为分位数函数 $q_Z(u)$ 关于 u 单调不减，最坏的 $1-\alpha$ 质量的平均值不低于全体质量的平均值，即

$$\mathrm{CVaR}_\alpha(Z) \ge \mathbb{E}[Z] \quad \text{对所有 } \alpha \in (0,1).$$

（[精确]）所以 CVaR 约束是**更强**的约束：$\mathrm{CVaR}_\alpha(Z)\le d$ 推出 $\mathbb{E}[Z]\le d$，反之不成立。这给出一条实用的设计规则：若真的关心“最坏情况”，约束应该写在 CVaR 上，而不是写在期望上；只写期望的约束，等于告诉优化器“只要平均下来不超，尾部怎么坏都行”。

还有一层容易被忽略的差别。CMDP 的约束是对**策略的期望**成立的，而“安全”通常是对**每条轨迹**的要求。二者的距离由图 9-6 量化：冒进策略满足期望约束，但它有 1% 的轨迹会付出 20 倍的代价。若任务要求“任意一条轨迹的代价都不超过 20.20”，那么期望约束对此**毫无约束力**——它可以被任意多的低代价轨迹稀释。把逐轨迹约束写成期望约束，是安全强化学

SUMMARY / 总结

习里最常见的建模错误。

9.3.4 三种落地做法

把风险写进目标有三条常见路线，它们的差别在于“估计什么”以及“估计的代价随 α 怎么涨”。

表 9-2 把风险写进目标的三种路线。三者的共同前提是能拿到“同一策略下的多条轨迹”，差别在于用这些轨迹的哪个统计量。

路线	约束的对象	需要的估计量	主要代价与失效方式
CVaR 约束 + 拉格朗日	损失的尾部平均	每回合的代价分布尾部样本	$\alpha \to 1$ 时尾部样本极少，方差爆炸
方差惩罚	回报的二阶矩	回报的一、二阶矩	对稀有事件仍然盲：方差被大量小偏差主导
分布式/分位数网络	整个回报分布	分位数或分布参数	分布投影的近似误差；分布漂移下不稳定

表 9-2 的第一行是唯一有凸性保证的路线（命题 9.1）：把 J_c 换成 $\mathrm{CVaR}_\alpha(Z)$，式 (9.12) 的结构不变，只是内层要估计尾部平均。第二行最便宜，但它对图 9-6 那种“1% 概率 20 倍损失”的分布几乎无效——方差被 99% 的 0.20 主导，事故项贡献很小。第三行信息最全，代价是要学一个分布而非一个数，且分布随策略漂移。三条都不是“安全保证”，只是把“关心什么”写得更准确。

SUMMARY / 总结

9.4 元学习与前述决策框架的关系

元学习常与本章三个框架并列，但它不在同一层：前三个改的是单个任务的 MDP，元学习改的是“面对一族任务怎么用数据”，所以这里只作案例。

MAML 的内外双层优化。 任务 T_i 从 $p(\mathcal{T})$ 抽样，各有自己的损失 $\mathcal{L}_{T_i}$。MAML 学一个初始化 θ，使从它出发做几步梯度就能在新任务上好用：

$$\min_{\theta} \mathbb{E}_{T_i \sim p(\mathcal{T})} \left[\mathcal{L}_{T_i} \left(\theta - \alpha \nabla_{\theta} \mathcal{L}_{T_i}(\theta) \right) \right] \tag{9.16}$$

内层是“适应”，外层是“学会适应”：外层梯度要对内层更新求导，因此含二阶项 $\left(I - \alpha \nabla_{\theta}^2 \mathcal{L}_{T_i}(\theta)\right)$；忽略它（FOMAML）常常够用，但已不是式 (9.16) 的梯度（[近似]）。与强化学习结合还多一层困难：策略梯度方差本来就大，再套一层内外循环会被放大。

RL^2 的循环记忆。 另一条路线不求二阶导：在任务序列上训练循环网络，把过去的转移与奖励编码进隐状态，测试时在前向传播里“学习”。代价是问题变成**部分可观测**（第 2.5 节的 POMDP），任务的隐变量只能从历史里推断。

两条路线都不改“给定一个 MDP 什么最优”，只改“给定一族 MDP，什么初始化能让适应更快”——把它们并列成“四种扩展”，会让“最优性条件”这个词失去意义。

SUMMARY / 总结

本章小结

本章把标准 MDP 的三条假设逐条拆开。选项只把折扣从 γ 换成 γ^{τ}（式 9.1），最优方程与贝尔曼方程同构（式 9.2）；终止函数也能学，梯度正比于终止优势的**负值**（式 9.4），代价是硬阈值不可微、软松弛会退化。

多决策者时“最优”消失，只剩均衡（式 9.7），且可能不唯一、未必想要：独立 Q-learning 在协调博弈里分裂成 31 比 29，在匹配硬币里 1500 回合变号 109 次。约束同理：CMDP 约束期望，CVaR 约束尾部，不可互换——图 9-6 那个期望与 VaR 都更低、CVaR 高 4.2 倍的策略即是证据。

关键公式

全章的主干是六条：选项价值（9.1）、半马尔可夫最优方程（9.2）、终止梯度（9.4）、纳什均衡（9.7）、约束的原始—对偶更新（9.12）与 CVaR 的变分定义（9.14）。

前三条属于选项，第四条是多决策者的最优性条件，后两条是约束与风险。

$$Q^{\pi}(s,o)=\mathbb{E}_{\tau,s_{\tau}}\Big[R(s,o)+\gamma^{\tau}V^{\pi}(s_{\tau})\Big],\qquad R(s,o)=\mathbb{E}\Big[\sum_{k=0}^{\tau-1}\gamma^{k}r_{t+k+1}\Big]$$

$$Q^{*}(s,o)=\mathbb{E}_{\tau,s_{\tau}}\Big[R(s,o)+\gamma^{\tau}\max_{o'}Q^{*}(s_{\tau},o')\Big]$$

$$\frac{\partial Q(s,o)}{\partial \beta_{o}(s')}=P(s'\mid s,o)\,\gamma\big[V(s')-Q(s',o)\big]$$

$$V_{i}^{(\pi_{i}^{*},\pi_{-i}^{*})}(s)\geq V_{i}^{(\pi_{i},\pi_{-i}^{*})}(s)\quad \text{对所有 } \pi_{i},\ s$$

$$\theta\leftarrow\theta+\eta_{\theta}\nabla_{\theta}\big[J_{r}(\pi_{\theta})-\lambda J_{c}(\pi_{\theta})\big],\qquad \lambda\leftarrow\big[\lambda+\eta_{\lambda}\big(J_{c}(\pi_{\theta})-d\big)\big]_{+}$$

$$\mathrm{CVaR}_{\alpha}(Z)=\inf_{\eta}\Big\{\eta+\frac{1}{1-\alpha}\mathbb{E}\big[(Z-\eta)_{+}\big]\Big\}$$

习题

1. 证明定理 9.1 的压缩性，指出哪一步用到 $\tau\geq 1$，以及 $\tau=0$ 时结论怎么变。
2. 推导式 (9.4)；说明终止概率用硬阈值时它在什么意义下失效，并构

造“选项退化成单步”的例子。

3. 把图 9-3 的 ε 从 0.1 改成 0.3，先猜中位数怎么变，再用 `figures/ch09_figs.py` 验证，并解释选项组为什么对 ε 更不敏感。
4. 说明式 (9.9) 为什么只是**充分**条件：用图 9-4 的 2×2 反例算四个联合动作，指出哪个使它不随 Q_2 单调。
5. 推导 CVaR 的 $\inf_\eta$ 表示：证 $f(\eta)$ 是凸函数、求次梯度、证 η^* 是某个 $\mathrm{VaR}_\alpha(Z)$，由此得式 (9.15)；再说有原子时（图 9-6 的冒进策略）它为什么不成立。
6. 证明 $\mathrm{CVaR}_\alpha(Z) \geq \mathbb{E}[Z]$，并举一个 $\mathbb{E}[Z] \leq 1$ 而 $\mathrm{CVaR}_{0.95}(Z) > 3$ 的策略说明反之不成立。
7. 设计一个必须让两个智能体**错开**的任务（如两条传送带交替放行），说明 QMIX 的单调混合为什么必然失败，并给出不需要单调性的替代结构。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 17 章是选项与半马尔可夫的教材式处理。
- Puterman《Markov Decision Processes》第 11 章是半马尔可夫与平均奖励的标准参考，单链假设与偏差函数都在那里。
- Bacon 等的 Option-Critic（AAAI 2017）给出终止函数梯度的完整推导（式 9.4 的单步版）。
- Lowe 等的 MADDPG（NeurIPS 2017）与 Rashid 等的 QMIX（AAMAS 2018）是 CTDE 两条路线；后者第 3 节写明单调性假设，图 9-4 的反例正是它的边界。
- CPO（Achiam 等，ICML 2017）用信赖域解 CMDP，保证只对代理问题成立；式 (9.14) 见 Rockafellar 与 Uryasev（2000）。

SUMMARY / 总结

第 4 部分

语言模型与自主智能体

预备　语言模型作为策略

第 10 章　RLHF 与偏好优化

第 11 章　RLVR 与推理强化学习

第 12 章　Agentic RL 与持续学习

预备　语言模型作为策略

前九章的每个问题都能这么写下来：一个状态集合、一个动作集合、一个转移核、一个奖励函数。到了语言模型这里，你手上只有一个会吐字的模型——没有状态表，没有“动作”这个变量，也没有环境在每一步回你一个分数。要把第 10 – 12 章的东西接上去，得先把这套词汇重新接一遍。

接的过程只有三件事要交代清楚。第一，什么是“动作”：语言模型每一步只选一个　token，于是动作空间就是词表；第二，训练时同时有好几个模型在场，哪一个在被更新、哪两个只是参照物；第三，奖励只落在整条回答的末尾，梯度却要落到几千个 token 上，这中间怎么换算。

这三件事都是约定，不是定理。自回归分解与序列 KL 的链式分解是[精确]的构造性事实——它们只是把同一个概率分布换一种写法；SFT　是固定数据集上的极大似然，也是[精确]的，但它不是强化学习。“把序列奖励广播到每个 token”才是[近似]，它丢掉的正是信用分配；围着它长出来的重要性比率、裁剪、长度归一化，都停在[经验规律]。后面三章最容易出错的地方，就是把这些约定当成了结论。

接口：从 token 到策略

动作是 token，轨迹是一条序列

一次生成可以写成一串离散符号。给定提示　x，模型逐个吐出 $y_1, y_2, \dots, y_T$，每一步的输出分布依赖此前已经生成的整段前缀。把词表记作 $\mathcal{V}$，动作空间就是 $\mathcal{V}$ 本身——十万量级的离散符号，每一步选一个。这与第 2　章的“动作是有限集合里取一个”在形式上完全一致，只是集合大得多、而且同一个 token 在不同位置上的含义并不相同。

> **定义 P.1（语言模型策略）**
>
> 给定提示 x，语言模型策略是以词表 $\mathcal{V}$ 为动作空间、以已生成前缀为状态的随机策略：在状态 $(x, y_{<t})$ 上给出 $\mathcal{V}$ 上的一个分布，采样一次得到一个 token，状态随之确定性地前移；整条序列的分布由这些条件分布的乘积给出。

自回归分解把整条序列的概率写成一串条件概率的乘积：

SUMMARY / 总结

$$\pi_\theta(y \mid x) = \prod_{t=1}^{T} \pi_\theta\big(y_t \mid x, y_{<t}\big), \qquad y_{<t} = (y_1, \ldots, y_{t-1}). \tag{P.1}$$

式 (P.1) 是本章唯一的“结构性”假设，它说的是：第 t 步只依赖前缀，不依赖未来。这条假设让“状态”有了明确的所指——状态就是前缀 $(x, y_{<t})$，它包含了决策所需的全部信息。于是转移是确定性的：给定前缀与刚生成的 token，下一个状态唯一确定，没有任何随机性；**随机性全部在策略里**（选哪个 token），而不在环境里。这一点与第 2 章的随机转移形成对照，也是语言模型 RL 里“环境”异常简单、“策略”异常复杂的原因。

一个回合就是一次生成：从提示 x 开始，到模型吐出结束符或达到长度上限为止。这里对应第 2 章必须分清的那对概念。吐出结束符是**终止**（terminated）：序列真的结束了，后续没有奖励，价值自举应当置零；达到长度上限是**截断**（truncated）：只是被强行切断，理论上后面还有内容，价值自举必须保留。把两者都当成“结束”，是语言模型 RL 实现里最常见的一类错误——它会让价值估计系统性偏低，而且这种偏低会被基线吸收一部分，因而更难察觉。

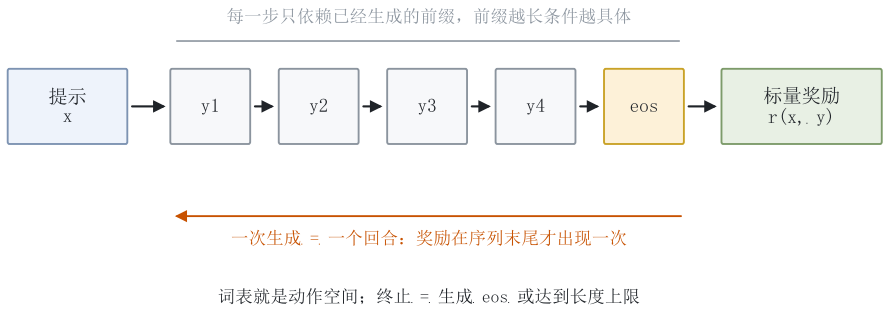


图 P-1 一次生成就是一个回合。提示之后逐个生成 token，每步只依赖已经生成的前缀；奖励只在序列末尾出现一次，中间没有任何标量信号。终止符与长度上限是两种不同的结束方式。

图 P-1 把这条时间线画了出来。读图时注意两件事。第一，奖励的位置是“序列之后”而不是“每步之后”，这与前九章的环境奖励完全不同——第 2 章的 R_{t+1} 是每步都有的，这里只有一个 $r(x, y)$。第二，每一步的动作分布由同一个网络给出，参数在全序列共享；一次更新会同时改变所有位置的策略，不像表格型方法那样一个状态一个参数。

奖励只在末尾这件事决定了后面所有的困难。若奖励每步都有，信用分配是局部的；现在只有一个总数，模型必须猜“这一千个 token 里是哪几个

让总分变高的”。工程上的做法放弃了这个猜测，转而把同一个标量广播给所有 token——这就是“粗信用分配”。

从 SFT 到策略

进入强化学习之前先交代监督微调（supervised fine-tuning, SFT），因为后面出场的三个模型里，有两个就是它的快照。给定一批专家示范 $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}$，SFT 最小化的是逐 token 的交叉熵：

$$\mathcal{L}_{\mathrm{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}}\Big[\sum_{t=1}^{|y|} \log \pi_\theta\big(y_t \mid x, y_{<t}\big)\Big]. \tag{P.2}$$

式 (P.2) 与第 3 章的价值回归长得不一样，但把它看成“对固定数据集做极大似然”就清楚了：数据分布 $p_{\mathrm{data}}(x, y)$ 是固定的，模型只在这个分布上拟合条件概率，梯度只经过对数似然而不经过任何采样。这正是监督学习的定义——有标签、有固定数据集、有明确损失。

也正因如此，它不属于强化学习。数据由人给出，模型不决定看哪些样本，也就没有“试错”这回事；损失是似然，不是任务奖励，模型优化的目标是“更像示范”，不是“得分更高”；每个位置都有确定的标签 y_t，第 t 步该输出什么一目了然，不需要从总数里反推。三条合起来说明：SFT 只能模仿，不能超越。示范里没有的行为它不会去试，示范不够好的地方它原样学下来。这正是后面需要 RL 的原因——当“好”无法用示范穷举、却可以用一个标量衡量时，才有回报可优化。所以 SFT 之后通常只当作起点，同时充当后面 KL 正则的锚点。

三个模型：策略、参考与旧策略

进入 RL 阶段后，同一份权重会以三种身份同时出现，这是语言模型 RL 与前面各章最不同的一点。第一个是**策略** π_θ，也就是正在被优化的模型；第二个是**参考策略** π_{ref}，通常是 SFT 结束时的快照，全程冻结，只用来定义“离起点多远”；第三个是**旧策略** π_{old}，是采样那一轮所用的策略快照，只在重要性比率的分母里出现。

SUMMARY / 总结

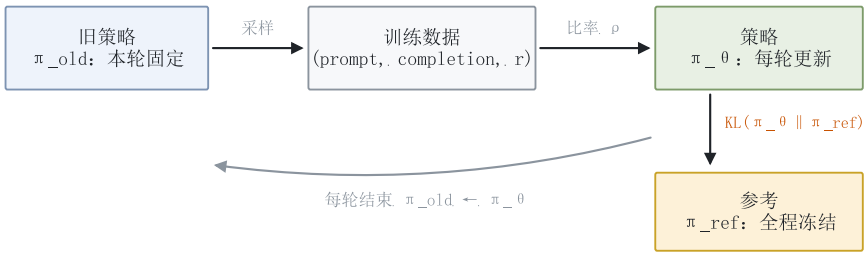


图 P-2 一轮 PPO 里三个模型的分工。旧策略负责采样，策略被更新若干轮，参考策略只出现在 KL 项里；每轮结束时旧策略刷新为当前策略，参考策略永不更新。

三者的关系可以用一句话概括：π_θ 是唯一被更新的对象，π_{ref} 是恒定的锚，π_{old} 是每轮刷新一次的采样器。训练刚开始时三者相同（都等于 SFT 的结果）；随着训练推进，π_θ 逐渐偏离，π_{old} 每个批次刷新为当时的 π_θ，而 π_{ref} 始终不动。

最容易混淆的是后两者，因为它们都是“过去的策略”，作用却完全不同。π_{old} 是**重要性采样的分母**，它保证“用旧策略采的数据估计新策略的期望”这件事在数学上成立；π_{ref} 是**正则项的锚**，它保证新策略不会为了奖励跑到离起点太远的地方。混用之后后果也不同：用 π_{ref} 当比率分母，分子分母不再是“新旧”关系，比率失去意义；用 π_{old} 当 KL 锚，锚跟着策略一起动，KL 永远接近零，正则等于没写。

还有一个细节：π_{old} 是“数据复用”的产物。若每批数据只更新一次，比率恒为 1，重要性采样退化成恒等式；正是为了在同一批数据上多走几步，才需要一个固定的分母描述“走了多远”。第 5 章的裁剪与 KL 早停，就是为这几步设的闸。

SUMMARY / 总结

KL 正则的两种位置

奖励模型给出的是分数，不是保证：它只学过人类比较的偏好特征，一旦策略开始利用它的盲区，分数会继续涨而质量不会。所以语言模型 RL 的目标几乎总要在奖励后面挂一根皮带，把策略拴在参考策略附近：

$$\max_{\pi_\theta} \mathbb{E}_{x\sim\mathcal{D}}\Big[\mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\big[r(x,y)\big] - \beta_{KL}\, D_{\mathrm{KL}}\big(\pi_\theta(\cdot\mid x)\,\big\|\,\pi_{\mathrm{ref}}(\cdot\mid x)\big)\Big], \tag{P.3}$$

其中 $\beta_{KL}>0$ 是系数。式 (P.3) 有闭式解：最优策略是参考策略按奖励指数重加权后的分布，

$$\pi^\star(y\mid x) = \frac{1}{Z(x)}\,\pi_{\mathrm{ref}}(y\mid x)\,\exp\!\Big(\frac{r(x,y)}{\beta_{KL}}\Big), \tag{P.4}$$

其中 $Z(x)=\sum_{y'}\pi_{\mathrm{ref}}(y'\mid x)\exp\big(r(x,y')/\beta_{KL}\big)$ 是**配分函数**：它只依赖提示 x、与候选回答 y 无关，作用是把右端归一化成分布。它在巨大输出空间上通常难以直接精确求和，但在需要用到它的场合往往可以消掉——例如第 10 章把同一个 x 的两条回答相减时，$Z(x)$ 在比值里正好约去。

β_{KL} 是 KL 项的系数。它在式 (P.4) 里出现在指数的分母上，所以 β_{KL} 越大，指数项越平，最优策略越靠近 π_{ref}；它越小，最优策略越集中于高奖励区域。反过来的量 $1/\beta_{KL}$ 才是**逆温度**——两者互为倒数，把“增大 β_{KL}”说成“提高探索温度”，方向正好相反。

> β_KL 是系数，不是温度
>
> 把式 (P.4) 读成“温度为 β_{KL} 的 softmax”不算错，但容易把 β_{KL} 与采样温度混为一谈：β_{KL} 是 KL 项的系数，式 (P.4) 的指数分母上取的是它；反过来的量 $1/\beta_{KL}$ 才叫逆温度。增大 β_{KL} 使分布更靠近参考策略（更保守），这与“提高采样温度使分布更平”是两件事，混用会把调参方向弄反。

式 (P.3) 的 KL 有两种实现位置，二者在数学上相关、在工程上不同。第一种是把 KL 折进奖励：在序列末尾给出任务奖励 $r(x,y)$，同时在每个 token 上扣一项

$$\tilde r_t = \mathbb{1}\{t=|y|\}\,r^{\mathrm{task}}(x,y) - \beta_{KL}\log\frac{\pi_\theta(y_t\mid x,y_{<t})}{\pi_{\mathrm{ref}}(y_t\mid x,y_{<t})}, \tag{P.5}$$

指示函数 $\mathbb{1}\{t=|y|\}$ 不能省：任务奖励只在序列末尾给出一次，若每个 token 都加一遍，整条序列的奖励就被重复了 $|y|$ 次，等于把奖励乘上了长度

——这正是实践中“回答越写越长”的一个来源。工程上常把最后一步的 token KL 换成 k3 估计器 $\log(\pi_{\text{ref}}/\pi_\theta)$ 的无偏形式，理由与这里的指示函数无关，属数值细节。

于是整条序列的累计惩罚在**期望意义下**等于序列 KL（单条轨迹上它等于对数比之和，取期望才是 KL）。第二种是把 KL 直接写进损失：策略损失之外再加一项 $\beta_{KL} D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$，优化时与策略梯度一起下降。两种位置在“每 token 一个惩罚”这个意义上是等价的，区别在于前者把惩罚变成回报的一部分（因而进入优势估计），后者把它当作独立的正则项（因而不参与优势）。

序列 KL 与 token KL 的关系值得单独说明。对自回归模型，序列 KL 可以精确地按链式法则拆成逐 token 的 KL 之和。记

$$\kappa_t(x, y_{<t}) = D_{\text{KL}}\big(\pi_\theta(\cdot \mid x, y_{<t}) \,\|\, \pi_{\text{ref}}(\cdot \mid x, y_{<t})\big), \tag{P.6}$$

则序列 KL 是这些逐位置 KL 在前缀分布下的期望之和：

$$D_{\text{KL}}\big(\pi_\theta(\cdot \mid x) \,\big\|\, \pi_{\text{ref}}(\cdot \mid x)\big) = \sum_{t=1}^{T} \mathbb{E}_{y_{<t} \sim \pi_\theta}\big[\kappa_t(x, y_{<t})\big]. \tag{P.7}$$

式 (P.7) 是[精确]的，但它的两个含义常被混淆。其一，**期望**意义上的相等，不保证**单条样本**上的估计就准：用一条采样序列算出的 token KL 之和，在“前缀由 π_θ 自己生成”（on-policy）时是序列 KL 的**无偏**估计——正因为前缀服从 π_θ，对数比的期望才逐位置等于 κ_t；它真正的毛病是**方差随长度线性增长**（每多一个 token 就多一项随机量），而不是偏差。只有当前缀来自另一个策略（例如用旧策略采的数据、却按新策略算 KL）时，才会引入偏差。其二，token KL 之和随序列长度增长，长回答天然被罚得更重，于是“长度”成了一个隐藏的优化目标——这是实践中长回答变短或变长的常见原因之一，与奖励本身无关。

两种位置还有一个共同的数值后果：β_{KL} 必须与奖励同量级。奖励在 $[0,1]$ 时它常取 10^{-2} 到 10^{-1}；奖励在 $[0,100]$ 时同一组超参会让 KL 项几乎不起作用。这是标定问题，不是理论问题。

SUMMARY / 总结

奖励与信用分配

奖励从哪来

前九章的奖励由环境给出。语言模型这里没有环境，奖励必须从外部造出来。常见的来源有四类，它们的可靠性与代价差别很大。

第一类是**奖励模型**：用成对偏好数据训练一个标量打分器，第 10 章会给出它的完整推导。它的优点是覆盖广——任何回答都能打分；缺点是只学到偏好的相关特征，容易被长度、格式、口头禅这类捷径带走，于是策略会去优化这些捷径而不是质量。第二类是**验证器或判定器**：单元测试、判题器、答案比对，输出 0/1。它只在“可验证”的任务上可用（数学、代码、结构化问答），但一旦可用，信号就相当硬。第三类是**规则**：格式检查、长度限制、关键词惩罚。它几乎零成本，也几乎总能被绕过。第四类是**工具返回**：检索到的证据、代码执行结果、API 的真实返回。它可靠但窄——只有能被工具检验的那部分行为才拿得到分。

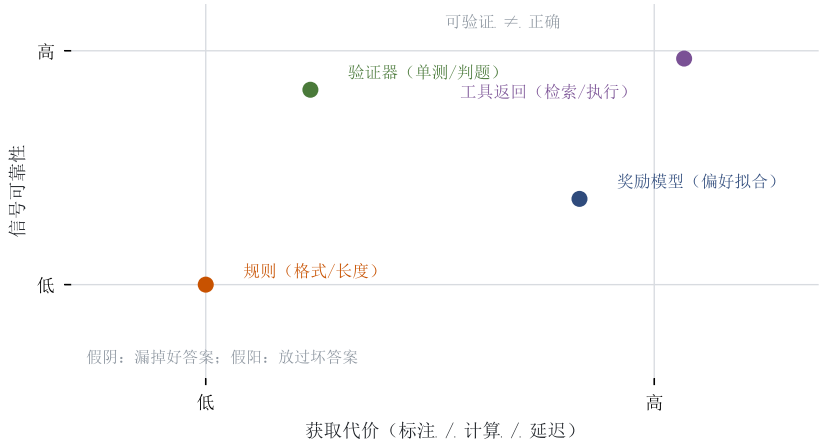


图 P-3 四类奖励来源在“获取代价—信号可靠性”平面上的位置。规则最便宜也最容易被绕过；验证器在可验证任务上可靠但覆盖窄；奖励模型覆盖广却会奖励捷径；工具返回最硬，但只覆盖能被工具检验的行为。

图 P-3 把这四类放进同一个平面。它想说的不是“哪一类最好”，而是“每一类都有自己的失效模式”，而失效模式决定训练会出现什么病。假阴（漏掉好答案）让模型不敢探索新解法；假阳（放过坏答案）让模型学会钻空子；覆盖窄让模型只在那类任务上变好，其余能力退化。这三件事在奖励模型与规则上尤其常见，在验证器与工具上相对轻，但并没有消失。

这里必须强调一句：**可验证不等于正确**。单元测试通过只说明这几条测试没抓到错，不说明解法在语义上对；判题器比对答案只说明最终字符串一

致，不说明推理过程成立；工具返回成功只说明调用没报错，不说明调用的是该调用的东西。把“可验证”当成“正确”，等价于把“这套检查没发现错”当成“没错”——这是第 11 章要反复处理的偏差来源。

从序列奖励到 token 梯度

最后一个接口问题是信用分配：只有一个序列级标量 $r(x, y)$，而梯度要落在成千上万个 token 上。最直接的做法是把同一个标量广播给每个位置：

$$\hat{A}_{i,t} = \hat{A}_i = \frac{r(x, y_i) - \bar{r}}{s_r + \varepsilon_{\text{num}}}, \qquad t = 1, \ldots, |y_i|, \tag{P.8}$$

其中 $\bar{r}$ 与 s_r 是同一组（同一个提示下采样出的）G 条回答的均值与标准差，$\varepsilon_{\text{num}} > 0$ 只是数值保护、不是理论定义；若某组内所有回答的奖励完全相同（$s_r = 0$），这一组的相对信号没有意义，工程上整组跳过。式 (P.8) 的含义是“这条回答在本组里相对好多少”，它对每个 token 都成立——同一回答的所有 token 共享同一个优势。第 11 章还会说明：这个减均值再除以标准差的写法**不等于**“无偏地估出了 A^{π}”，组均值本身含有当前样本，学到的信号带着 $(1 - 1/G)$ 的缩放。

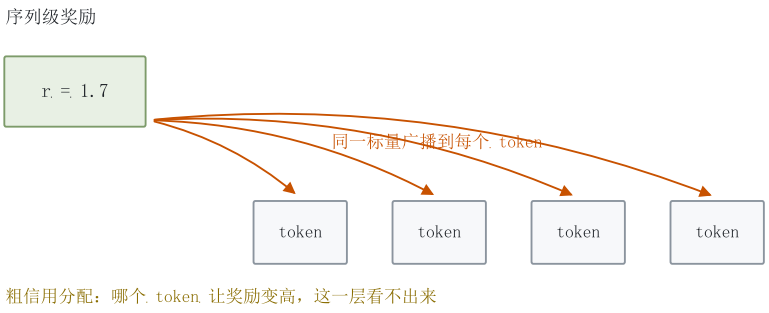


图 P-4 序列级奖励广播到 token。一个标量被复制到每个位置，于是整条序列的 token 共享同一个优势；哪个 token 该为结果负责，这一层信息完全丢失。

图 P-4 标出了这个做法的代价。若回答里恰好有一个关键步骤做对了、其余步骤平庸，广播会把功劳平摊给所有 token；反之，一个致命错误也会让整条回答的所有 token 一起受罚。这就是**粗信用分配**：它不是错误的实现，而是接口本身的信息量决定的——序列级奖励里没有“哪个 token 有功”的信息，任何试图从单个标量里恢复逐 token 功劳的做法，都只是在加先验。

由此可以理解为什么这里仍需要重要性比率与裁剪。数据由

π_{old} 采得，而被优化的策略是 π_θ，两者的分布已经不同，于是每个 token 的贡献要乘一个比率

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(y_{i,t} \mid x, y_{i,<t})}{\pi_{\text{old}}(y_{i,t} \mid x, y_{i,<t})}, \tag{P.9}$$

并按第 5 章的裁剪目标限制单步幅度；把式 (P.9) 与式 (P.8) 组合，就得到 token 级的代理目标。这里有两个容易写错的地方。第一，$\hat{A}_i$ 是**相对奖励信号**——它是同一 prompt 下若干样本之间的比较结果，不是学出来的 $A^\pi(s,a)$，两者只在“相对好坏”这个意义上近似。第二，比率的分子分母必须都对应**同一个 token 位置**，不能把序列级比率当成逐 token 比率使用；序列级比率是各 token 比率的乘积，方差随长度指数增长，这正是 PPO 在语言模型上坚持逐 token 比率的原因。

最后把这一章与前九章的词汇对齐。表 P-1 是本章的接口约定，它不产生新定理，只固定说法。

表 P-1 马尔可夫决策过程与语言模型策略的对应。这张表是接口约定，不是定理；其中“折扣取 1”与“长度归一化”两条在工程上互为替代，选哪一种取决于任务对长度的偏好。

MDP 的概念	语言模型里的对应
状态 s	前缀 $(x, y_{<t})$，含提示与已生成 token
动作 a	下一个 token $y_t \in \mathcal{V}$
转移 $P(s' \mid s, a)$	确定性拼接；随机性只在策略的采样温度里
奖励 R	序列末尾一个标量 $r(x, y)$，中间无信号
折扣 γ	通常取 1；用长度归一化或长度惩罚代替
策略 $\pi(a \mid s)$	参数共享的 softmax 网络，逐位置输出分布

表 P-1 的最后两行值得再解释一句。折扣在语言模型里通常取 1，因为“越远的 token 越不重要”这个假设在文本上不成立——最后一个 token 与前一千个 token 同样重要。替代方案是把回报按长度归一化（除以 token 数），或用长度惩罚显式建模；两者都会改变最优策略，前者偏向短回答，后者偏向指定长度。这是接口层面的选择，不是理论推导的结果。

本章小结

语言模型当策略用时，能严格说的其实只有三件事：序列概率是条件概率的乘积 (P.1)、SFT 是固定数据集上的极大似然 (P.2)、序列 KL 精确等于逐 token KL 的期望和 (P.7)。其余全是约定：动作是 token、状态是前缀、一次生成是一个回合；π_{ref} 是冻结的锚、π_{old} 只在比率分母里；奖励落在末尾、优势广播到每个 token。约定不产生定理，但它决定了后面三章的公式长什么样，也决定了错误会从哪里长出来。

两个最常见的坑都跟“位置”有关。结束有两种，终止要停自举、截断要留自举，混同会让价值系统性偏低；KL 有两种，折进奖励就进了优势估计，写进损失就不进，β_{KL} 是前一种里那个把惩罚折成奖励的系数，$1/\beta_{KL}$ 才是逆温度。奖励的四类来源各有各的失效方式，可验证不等于正确——这句话是第 11 章整章的出发点。

关键公式

全章的主干是六组式子：自回归分解 (P.1)、SFT 的交叉熵 (P.2)、KL 正则目标与它的 Gibbs 解 (P.3)(P.4)、逐 token 的 KL 惩罚 (P.5)、序列 KL 的链式分解 (P.7)、序列级优势的广播与逐 token 比率 (P.8)(P.9)。前两条定义“策略”与“起点”，中间三条定义“约束”，最后两条把序列级的信号落到 token 上。

$$\pi_\theta(y \mid x) = \prod_{t=1}^{T} \pi_\theta\big(y_t \mid x, y_{<t}\big)$$

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}}\Big[\sum_{t=1}^{|y|} \log \pi_\theta\big(y_t \mid x, y_{<t}\big)\Big]$$

$$\max_{\pi_\theta} \mathbb{E}_{x\sim\mathcal{D}}\Big[\mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\big[r(x,y)\big]\Big] - \beta_{KL}\,\mathbb{E}_{x\sim\mathcal{D}} D_{\text{KL}}\big(\pi_\theta(\cdot \mid x)\|\pi_{\text{ref}}(\cdot \mid x)\big), \qquad \pi^\star(y \mid x) \propto \pi_{\text{ref}}(y \mid x)\exp\Big(\frac{r(x,y)}{\beta_{KL}}\Big)$$

$$\tilde{r}_t = \mathbb{1}\{t = |y|\}\, r_t^{\text{task}} - \beta_{KL} \log \frac{\pi_\theta(y_t \mid x, y_{<t})}{\pi_{\text{ref}}(y_t \mid x, y_{<t})}$$

其中 r_t^{task} 是 token 级的任务奖励：除末尾 $t = |y|$ 之外都为零，末尾取值等于整条序列的 $r(x,y)$。

$$D_{\text{KL}}\big(\pi_\theta \| \pi_{\text{ref}}\big) = \sum_{t=1}^{T} \mathbb{E}_{y_{<t}}\Big[D_{\text{KL}}\big(\pi_\theta(\cdot \mid x, y_{<t}) \,\Big\|\, \pi_{\text{ref}}(\cdot \mid x, y_{<t})\big)\Big]$$

SUMMARY / 总结

$$\hat{A}_{i,t} = \hat{A}_i = \frac{r(x, y_i) - \bar{r}}{s_r + \varepsilon_{\text{num}}}, \qquad \rho_{i,t}(\theta) = \frac{\pi_\theta(y_{i,t} \mid x, y_{i,<t})}{\pi_{\text{old}}(y_{i,t} \mid x, y_{i,<t})}$$

习题

1. 用式 (P.1) 证明：若两个模型在同一前缀上的条件分布相同，则它们诱导的整条序列分布相同。反过来是否成立？给出理由。
2. 说明为什么“长度上限”必须当作 truncated 而不是 terminated 处理。若把它当成 terminated，价值估计会偏高还是偏低？用一条具体的两 token 序列算出偏差。
3. 设奖励只在序列末尾给出，且 $r \in \{0, 1\}$。写出用式 (P.8) 广播后的 token 级代理目标，并说明为什么它的梯度在“整条回答完美”与“整条回答全错”两种情形下都接近零。
4. 用式 (P.7) 验证：当 π_θ 与 π_{ref} 只差最后一个 token 的分布时，序列 KL 等于该位置的 token KL。若两者在每个位置都差一点，序列 KL 与 token KL 之和的关系是什么？
5. 某一组超参在奖励量级为 $[0, 1]$ 时训练正常，换到 $[0, 100]$ 后策略迅速坍缩到 π_{ref}。用式 (P.3) 解释原因，并给出两种修正方案。
6. 举一个“可验证但错误”的例子（单元测试通过但解法语义错误），并说明它会怎样污染优势估计与后续训练。

延伸阅读

- Sutton 与 Barto《Reinforcement Learning: An Introduction》第 2 章与第 13 章：前者的 MDP 六元组与终止/截断约定是本章的对照基准，后者的策略梯度推导说明“序列级回报如何进入梯度”。
- Christiano 等《Deep Reinforcement Learning from Human Preferences》（2017）：偏好如何变成标量奖励的最早完整流程，本章第 5 节的“奖励模型”一类即源于此。
- Ouyang 等《Training language models to follow instructions with human feedback》（InstructGPT, 2022）：SFT → 奖励模型 → PPO 三段式流程的工程版本，可对照本章第 2、3 节看三个模型如何落地。
- Schulman 等《Proximal Policy Optimization Algorithms》（2017）：逐

token 比率、裁剪与多轮复用的原始定义，第 4 节的自适应 KL 与本章第 4 节的两种位置直接相关。

- Shao 等《DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models》（2024）：GRPO 的组内相对奖励与粗信用分配，是本章式 (P.8) 的直接应用，第 11 章会展开。

SUMMARY / 总结

第 10 章　从人类反馈到偏好优化

在人类反馈强化学习中，训练信号来自对回答质量的评价。本章介绍两类常见处理方式：先用成对偏好训练奖励模型，再依据奖励优化策略；或直接用偏好数据优化策略。策略优化通常加入相对参考策略的 KL 正则项，以限制策略分布的变化。

本章按训练链路展开。第 10.1 节用 Bradley–Terry 模型把成对偏好写成奖励差的概率模型；第 10.2 节分析带 KL 正则的策略优化及其闭式解；第 10.3 节在明确的建模假设下推导 DPO；第 10.4 节比较其他偏好优化目标；第 10.5 节讨论奖励代理与真实任务表现之间的偏差。理解本章需要策略梯度、概率分布和 KL 散度的基础知识。

本章会区分推导结论与经验判断。DPO 的等价推导在给定 KL 正则目标、Bradley–Terry 偏好模型和策略函数族时成立；它不保证所选目标完整代表人类偏好。KL 正则目标的闭式解是精确结果，PPO 等 token 级实现则包含近似。β_{KL} 的具体取值需要依据任务和验证结果确定，目前没有适用于所有任务的最优值定理。

10.1 从人类反馈到奖励模型

10.1.1 成对偏好与绝对评分的标注特性

绝对评分要求标注者共同使用一套分数尺度，而不同标注者对同一分值的理解可能不同。成对比较记录同一提示下两条回答的相对偏好，减少了对绝对分数刻度的依赖；标注结果仍会受到标注者差异和任务表述影响。每条比较只约束回答之间的相对质量，奖励模型据此学习能够解释这些比较的评分函数。

成对比较可以用概率模型表示：给定奖励函数，回答被选中的概率由两者的奖励差决定。奖励模型可用偏好数据进行最大似然训练，并在留出集上检查预测表现。Christiano 等人（2017）展示了这一训练链路：策略生成轨迹，人类比较轨迹片段，奖励预测器拟合比较结果，再用于策略优化。该研究以轨迹累计奖励差解释人类选择概率，并允许采样、标注和奖励模型训练异步进行。

10.1.2 Bradley–Terry：把偏好写成奖励差

Bradley–Terry 配对比较模型假设回答被选中的概率由两者奖励差决定。奖励差越大，第一条回答被偏好的概率越高。

SUMMARY / 总结

定义 10.1（Bradley – Terry 偏好模型）

给定同一上下文中的两个回答，记被偏好的回答为 y_w，被拒绝的回答为 y_l。Bradley – Terry 模型以二者奖励差决定偏好概率。

$$P(y_w \succ y_l \mid x) = \sigma\big(r(x, y_w) - r(x, y_l)\big), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}. \tag{10.1}$$

式 (10.1) 将奖励差映射为偏好概率。数据约束的是回答之间的相对奖励，整体平移不改变似然；每对回答应来自同一上下文并使用同一奖励尺度。式 (10.2) 还依赖给定奖励后各对比较相互独立的假设。标注流程存在关联时，训练目标更适合作为加权回归解释。图 10-1 展示偏好数据、奖励模型与策略优化之间的关系。

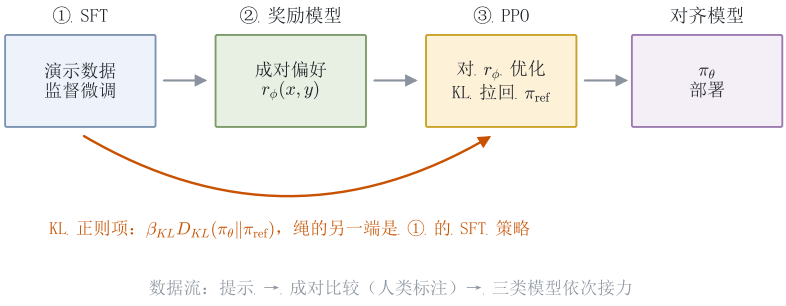


图 10-1 RLHF 的三阶段流程与 KL 正则。左侧依次为监督微调、奖励模型训练和 PPO 优化；橙色虚线表示策略优化目标中的 KL 正则项，该项约束策略相对 SFT 参考策略的变化，权重由 β_{KL} 控制。

给定偏好数据集 $\mathcal{D} = \{(x^{(i)}, y_w^{(i)}, y_l^{(i)})\}$，奖励模型的最大似然训练就是最小化负对数似然。

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \Big[\log \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big)\Big]. \tag{10.2}$$

式 (10.2) 是本章唯一一个“标准监督学习”目标：没有采样、没有自举、没有时序差分，梯度只经过一个 sigmoid。图 10-2 画出了它的两个关键形状。左图是式 (10.1) 的概率曲线，奖励差为零时概率恰为一半，差为正且增大时概率趋一；右图是单个样本的损失 $-\log \sigma(z)$，当模型已经把 y_w 排在 y_l 前面且差距很大时，损失趋零、梯度也趋零。在奖励差较大且排序正确时，成对logistic损失的单样本梯度幅度趋于零；这一性质本身不能单独证明奖励模型必然过拟合。

SUMMARY / 总结

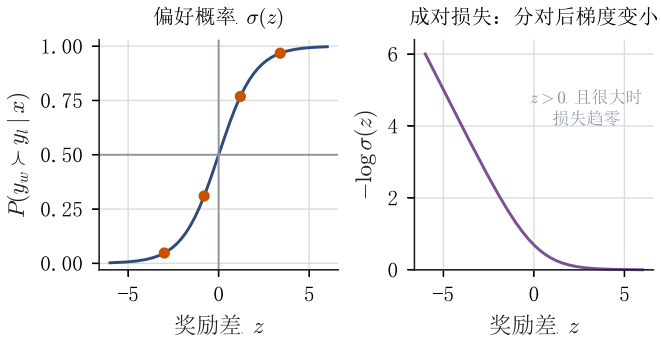


图 10-2 Bradley – Terry 的两个形状。左：偏好概率随奖励差单调上升，零点为 1/2；右：成对 logistic 损失随奖励差下降，分对且差距大时梯度趋零。曲线为解析函数，无采样。

10.1.3 奖励模型的可辨识性与偏好压缩

把式 (10.1) 与式 (10.2) 放在一起看，会发现奖励模型受到两类结构性限制，它们都与“训练是否收敛”无关。

第一类是尺度不确定性。对任意常数 c，把 r 换成 $r+c$ 不改变式 (10.1) 的任何一项，因此也不改变式 (10.2) 的值。

$$\mathcal{E}(r_\phi) = \{ r_\phi + c \mid c \in \mathbb{R} \} \tag{10.3}$$

式 (10.3) 说的是**等价类**：同一个 $\mathcal{E}(r_\phi)$ 里的任何两个奖励函数在式 (10.1) 下完全不可区分，所以不能把它读成“r_ϕ 等于 $r_\phi + c$”。

式 (10.3) 的实践含义是：奖励的绝对位置由训练过程之外的约定决定，而不是由数据决定。Christiano 等人对此的处理是把奖励归一化到零均值、固定标准差，并在文中说明这么做“尤其合适，因为奖励的位置在我们的学习问题里本来就是欠定的”。工程上常见的另一种做法是在 PPO 里用奖励的滑动均值做基线，效果等价——被减掉的常数不影响优势函数的排序。

第二类是模型误设。式 (10.1) 断言偏好只由奖励差决定，且这个关系是 logistic 的。真实标注者的判断会系统性地偏离这个形式：有人偏好更短的答案，有人偏好带列表的格式，有人对“我不确定”这类措辞特别敏感。把这些异质性硬压进一个 logistic，等价于假设所有标注者共享同一个奖励函数，而这个假设在多人标注的数据上通常不成立。一个更诚实的写法是把标注者当作隐变量。

SUMMARY / 总结

$$
\begin{aligned}
P(y_w \succ y_l \mid x) &= \sum_{k=1}^{K} w_k \, \sigma\big(r_k(x, y_w) - r_k(x, y_l)\big), \\
w_k &\geq 0, \quad \sum_{k=1}^{K} w_k = 1,
\end{aligned}
\tag{10.4}
$$

其中 r_k 是第 k 类标注者的奖励，w_k 是其占比。式 (10.4) 对标注者偏好差异进行建模，所得奖励解释依赖所选统计模型及其可辨识性条件。式 (10.2) 训练得到的 r_ϕ 概括了训练数据中的偏好信号，其解释范围受标注人群、任务与比较协议限制。本章后续推导均以这一奖励模型为基础。

SUMMARY / 总结

10.2 带 KL 正则的策略优化

10.2.1 目标与它的闭式解

有了奖励模型，剩下的问题是：给定 r_ϕ，怎样更新语言模型。直接把 $\mathbb{E}_\pi[r_\phi]$ 最大化会立刻出问题——语言模型的输出空间是全部 token 序列，奖励模型只在训练分布附近被约束过，只要策略稍微走远，奖励模型给出的高分就不再可信。KL 正则的作用是在目标函数里显式地为“走远”标价。

$$\max_{\pi} \ \mathbb{E}_{x\sim\rho}\mathbb{E}_{y\sim\pi(\cdot|x)}\big[r_\phi(x,y)\big] - \beta_{KL}\,\mathbb{E}_{x\sim\rho}\Big[D_{KL}\big(\pi(\cdot\mid x)\,\|\,\pi_{\text{ref}}(\cdot\mid x)\big)\Big], \tag{10.5}$$

其中 π_{ref} 是参考策略（通常是 SFT 之后的模型），$\beta_{KL}>0$ 是正则化系数，ρ 是提示分布。式 (10.5) 的两项在拔河：第一项要策略去追奖励，第二项要策略留在参考策略附近。这里必须把符号约定说清楚：β_{KL} 是 KL 项的系数，KL 越大惩罚越重，策略越贴参考策略；在下面式 (10.6) 的指数形式里，β_{KL} 同时充当温度，$1/\beta_{KL}$ 是逆温度，$\beta_{KL}\to 0$ 对应“贪心于奖励”，$\beta_{KL}\to\infty$ 对应“完全不动”。

式(10.5)的最优解在给定条件下具有闭式表达式。

> **命题 10.1（KL 正则目标的最优策略）[精确]**
>
> 对每个上下文 x，式 (10.5) 的最优策略为 Gibbs 形式，见式 (10.6)，其中配分函数 $Z(x)$ 只依赖 x、不依赖策略，且对任意 x 有限、为正。该解在 π 取遍所有以 x 为条件的分布时唯一。

$$\pi^\star(y\mid x)=\frac{1}{Z(x)}\,\pi_{\text{ref}}(y\mid x)\,\exp\!\Big(\frac{r_\phi(x,y)}{\beta_{KL}}\Big),\qquad Z(x)=\sum_{y}\pi_{\text{ref}}(y\mid x)\exp\!\Big(\frac{r_\phi(x,y)}{\beta_{KL}}\Big). \tag{10.6}$$

命题 10.1 的证明是一步变分：把式 (10.5) 里的 KL 展开成 $\mathbb{E}_\pi[\log\pi-\log\pi_{\text{ref}}]$，对每个 x 单独做带归一化约束的拉格朗日乘子法，解出的分布必然是指数族形式，乘子由归一化条件定出。结论本身不新鲜，重要的是它给出了一个可以直接计算的基准：把式 (10.6) 代回式 (10.5)，可以得到最优值等于 $\beta_{KL}\mathbb{E}_x[\log Z(x)]$，也就是说，KL 正则目标的全部难度都被压进了配分函数 $Z(x)$ 里。

式 (10.6) 难以直接用于语言模型优化，因为 $Z(x)$ 需要对全部可能回答

SUMMARY / 总结

求和，而输出空间随序列长度呈指数增长。即使采用重要性采样，长序列上的估计方差也可能很大。DPO 的推导利用同一提示下两个回答共享配分函数这一性质，在成对奖励差中消去 $Z(x)$，由此得到可直接训练的偏好目标。

图 10-3 用一个闭式可算的小例子说明 β_{KL} 的作用。取 200 个候选回答、奖励服从标准正态、参考策略取均匀分布，则式 (10.6) 可以逐点精确算出 $\pi^\star$ 及其期望奖励和 KL。左图显示期望奖励随 β_{KL} 单调下降：β_{KL} 小，策略几乎把全部质量压在奖励最高的那个回答上，期望奖励逼近 $\max_a r_a$ 的上限；β_{KL} 大，策略回到均匀，期望奖励趋零。右图显示 $D_{KL}(\pi^\star\|\pi_{\text{ref}})$ 也随 β_{KL} 单调下降，且在对数坐标下近似是一条斜率固定的直线——在温度很高的区域，KL 与 $1/\beta_{KL}$ 近似成正比。

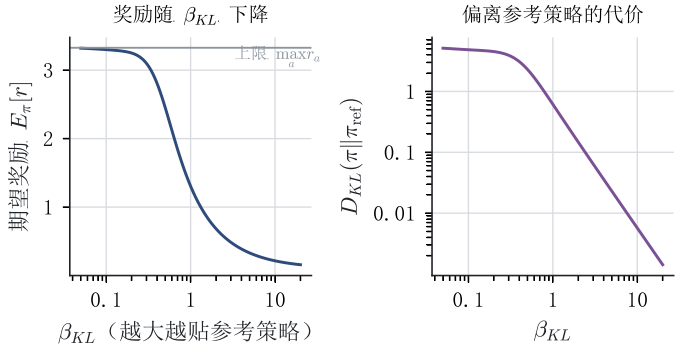


图 10-3 KL 正则的两个方向。左：期望奖励随 β_{KL} 下降，虚线为贪心上限 max_a r_a；右：与参考策略的 KL 随 β_{KL} 下降。数据为式 (10.6) 的闭式计算：200 个候选回答、奖励服从 N(0,1)、π_ref 取均匀分布、β_{KL} 从 0.05 扫到 20（120 个点），无采样误差。

10.2.2 token 级 PPO 的实现要点

式 (10.5) 是关于整条回答的期望，而策略梯度算法工作在 token 粒度，两者之间需要一次改写。做法是把整条奖励摊到 token 上：奖励只在序列末尾发放，KL 惩罚则逐 token 计算。序列末尾有两种来源，按 `content/_CONVENTIONS.md` 第 1.2 节必须分开记账：模型生成 EOS 而结束，是真终止（terminated）；达到长度上限被切断，是截断（truncated），后面还有价值，只是没预算了。

$$
\begin{aligned}
r_t &= \mathbf{1}\{t = |y|\}\, r_\phi(x,y) - \beta_{KL} \log \frac{\pi_\theta(y_t \mid x, y_{<t})}{\pi_{\text{ref}}(y_t \mid x, y_{<t})}, \\
Y_t &= r_t + \gamma\big(1 - d_t^{\text{term}}\big) V_\psi(h_{t+1}),
\end{aligned}
\tag{10.7}
$$

式 (10.7) 里 h_t 指策略在读到第 t 个 token 之后的隐状态（实现中通常是最后一层的最后一个位置），V_ψ 是挂在这个表示上的价值头，Y_t 是它要回归的 TD 目标；ψ 与奖励模型的 ϕ 不是同一套参数，别混。

SUMMARY / 总结

式 (10.7) 涉及四项实现约定。其一，稀疏奖励作用于序列末尾的 token；若将同一奖励重复分配到每个 token，梯度尺度会随回答长度变化。其二，序列以 EOS 终止时停止自举；达到长度上限而截断时，应通过价值头补入尾部价值，以避免系统性低估长回答。其三，逐 token KL 项沿一条回答的总和等于序列对数比 $\sum_t \log(\pi_\theta/\pi_{\text{ref}}) = \log\big(\pi_\theta(y)/\pi_{\text{ref}}(y)\big)$；对该等式取期望即得到序列级 KL。其四，逐 token KL 项作为奖励塑形进入优势估计。

工程上另一个常见细节是 KL 的估计方式。直接按定义算需要在对数域取期望，方差较大；实践中常用一个低方差的三阶展开估计

$$\widehat{D}_{KL}(t) = \frac{\pi_{\text{ref}}(y_t \mid x, y_{<t})}{\pi_\theta(y_t \mid x, y_{<t})} - \log \frac{\pi_{\text{ref}}(y_t \mid x, y_{<t})}{\pi_\theta(y_t \mid x, y_{<t})} - 1, \tag{10.8}$$

它在 $\pi_\theta = \pi_{\text{ref}}$ 处取零且恒非负，方差比直接估计小得多。

价值头的做法有两种，选择会明显影响稳定性。第一种是“共享主干 + 额外标量头”：在策略网络的最后一层并联一个输出维数为 1 的价值头，actor 与 critic 共享大部分参数，省显存，但两个目标的梯度会互相干扰，且价值头需要额外的归一化才能和策略的激活尺度匹配。第二种是“独立价值网络”：另起一个小模型（或同一模型的冻结副本加一个可训练头），显存开销大，但 critic 的更新不会污染策略的表示。近年的实现更常见第一种加上奖励归一化，原因很实际：语言模型的参数量下，独立 critic 的显存代价往往比训练不稳定更贵。

还需要澄清一个流传很广的说法：PPO 的 clip 操作**不是**信赖域保证。clip 只是把重要性比截断在 $[1-\epsilon, 1+\epsilon]$，它限制的是单次更新的幅度上限，既不保证 KL 约束被满足，也不保证单调改进；把它当作“安全的信赖域”来推理更新大小，会在长序列、大模型的情形下给出错误的预期。这一点在第 5 章已经讨论过，这里只强调它在 RLHF 里的具体表现：当奖励尺度较大时，clip 之后的实际 KL 可以远超预期，此时真正起约束作用的是式 (10.7) 里的 β_{KL} 项，而不是 clip。

10.2.3 结果监督与过程监督

奖励模型可以对整条回答评分，也可以对每一步推理评分；这对应两种不同的标注路线。

结果监督（outcome reward model，ORM）只在最终答案上标注对错或偏好，训练信号稀疏但便宜：一道数学题的标注成本是一次判断，标注者不需要读懂中间过程。过程监督（process reward model，PRM）要求标注每一

SUMMARY / 总结

步推理是否正确，信号密集、credit assignment 更容易，但标注成本随步数线性增长，而且“这一步是否正确”本身常常有歧义——一个中间步骤可能在特定解法下正确、在另一解法下错误。

两者的差别不只是成本。ORM 的失败模式是“答案对但过程错”被当成正例（模型学到蒙对），PRM 的失败模式是“步骤标注的粒度与被评估的粒度不一致”（模型学会迎合标注者的分解方式）。表 10-1 把两类监督放在同一组维度上对比。这张表描述的是标注协议，不是算法优劣：在推理任务上 PRM 通常更省样本，在开放式生成上 ORM 更常见，因为“好回答”很难被分解成逐步正确的判断。

表 10-1 结果监督与过程监督的对比。两者是标注协议的选择，不是算法优劣；混用（末端用 ORM、中间用 PRM）在工程上很常见。

维度	结果监督（ORM）	过程监督（PRM）
标注单位	整条回答的偏好或对错	每个推理步骤的对错
标注成本	每题一次判断	随步数线性增长
信号密度	稀疏，末端才有	密集，逐步可用
credit assignment	困难，需靠价值函数分摊	较易，步骤即时间尺度
典型失败模式	蒙对答案被当成正例	迎合标注者的步骤分解方式
适用场景	开放式生成、风格对齐	多步推理、可验证任务

两类监督在实践中常常混用：末端用一个 ORM 给整条回答打分，中间用 PRM 给关键步骤打分，再按权重相加。混用的代价是两套标注协议要同时维护，且两者的奖励尺度必须先对齐，否则权重没有意义。无论选哪一种，奖励模型的输出都只是偏好的压缩——第 10.3 节会看到，把这份压缩进一步消掉需要额外的假设。

SUMMARY / 总结

10.3 DPO：把奖励重参数化

10.3.1 七步推导

第 10.2 节停在式 (10.6)：最优策略是 Gibbs 形式，但配分函数让这个式子不可用。DPO 的出发点是换个方向读同一个式子——不要用它算策略，用它把奖励表示成策略的函数。

第一步，反解奖励。 对式 (10.6) 两边取对数并移项，得到

$$r_\phi(x,y) = \beta_{KL}\log\frac{\pi^\star(y\mid x)}{\pi_{\text{ref}}(y\mid x)} + \beta_{KL}\log Z(x). \tag{10.9}$$

这个式子是恒等的，没有引入任何新假设：只要 $\pi^\star$ 是式 (10.5) 的最优解，式 (10.9) 就成立。它的意义是把“奖励”换成了“策略与参考策略的对数比”，代价是多出一个只依赖 x 的项 $\beta_{KL}\log Z(x)$。

第二步，代回偏好模型。 把式 (10.9) 代入式 (10.1)，注意到 Bradley–Terry 只依赖奖励差：

$$\begin{aligned} r_\phi(x,y_w) - r_\phi(x,y_l) = {} & \beta_{KL}\log\frac{\pi^\star(y_w\mid x)}{\pi_{\text{ref}}(y_w\mid x)} \\ & - \beta_{KL}\log\frac{\pi^\star(y_l\mid x)}{\pi_{\text{ref}}(y_l\mid x)}, \end{aligned} \tag{10.10}$$

同一上下文下的两个回答共享配分函数 $Z(x)$，因此在两者的对数比中，项 $\beta_{KL}\log Z(x)$ 相消。

第三步，得到只含策略的偏好概率。

$$\begin{aligned} P(y_w \succ y_l\mid x) = \sigma\Bigg(& \beta_{KL}\log\frac{\pi^\star(y_w\mid x)}{\pi_{\text{ref}}(y_w\mid x)} \\ & - \beta_{KL}\log\frac{\pi^\star(y_l\mid x)}{\pi_{\text{ref}}(y_l\mid x)}\Bigg). \end{aligned} \tag{10.11}$$

第四步，写成可优化的损失。 用参数化策略 π_θ 替换 $\pi^\star$，对数据集取负对数似然：

$$\begin{aligned} \mathcal{L}_{\text{DPO}}(\pi_\theta;\pi_{\text{ref}}) = -\mathbb{E}_{\mathcal{D}}\Bigg[\log\sigma\Bigg(& \beta_{KL}\log\frac{\pi_\theta(y_w\mid x)}{\pi_{\text{ref}}(y_w\mid x)} \\ & - \beta_{KL}\log\frac{\pi_\theta(y_l\mid x)}{\pi_{\text{ref}}(y_l\mid x)}\Bigg)\Bigg]. \end{aligned} \tag{10.12}$$

第五步，读出隐式奖励。 式 (10.12) 括号里的两项各自是一个“奖

励”，它由策略与参考策略的对数比给出，不需要单独训练：

$$\hat{r}_\theta(x, y) = \beta_{KL} \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}. \tag{10.13}$$

式 (10.13) 将奖励写成策略与参考策略的对数概率比。真奖励还包含 $\beta_{KL} \log Z(x)$，该项只依赖提示 x，在同一提示下的成对差中会抵消。因此，式 (10.13) 给出的是奖励等价类的一个代表，而非唯一的绝对奖励。给定参考策略和 β_{KL} 后，隐式奖励仅在相差提示相关常数的意义下确定。由此可比较同一提示下回答的隐式奖励差；跨提示比较其绝对数值则没有依据。第 10.5.2 节采用同一提示下的成对样本定义长度偏差指标。

第六步，求梯度看它做了什么。 对式 (10.12) 求导，

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\text{DPO}} = -\beta_{KL}\, \mathbb{E}_{\mathcal{D}} \Big[& \sigma\big(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)\big) \\ & \cdot \Big(\nabla_\theta \log \pi_\theta(y_w \mid x) - \nabla_\theta \log \pi_\theta(y_l \mid x) \Big) \Big]. \end{aligned} \tag{10.14}$$

两项梯度分别提高被偏好回答的对数似然并降低被拒绝回答的对数似然。权重 $\sigma(\hat{r}_\theta(y_l) - \hat{r}_\theta(y_w))$ 在模型排序错误时较大、排序正确且差距较大时较小，因此模型主要更新尚未正确排序或置信度较低的样本。DPO 目标包含这一权重；对所有样本等权更新会改变原目标的梯度性质。

第七步，确认这是一个可训练的目标。 式 (10.12) 只用到两类量：策略在四个位置上的对数概率（y_w、y_l 各在 π_θ 与 π_{ref} 下），以及一个 sigmoid。训练时无需采样生成新回答，也无需单独调用奖励模型或价值函数；一次前向计算和一次反向传播构成一步更新。图 10-4 展示了 RLHF 与 DPO 的信息流：RLHF 使用奖励模型，DPO 则直接根据同一网络与冻结参考策略的概率比构造目标。

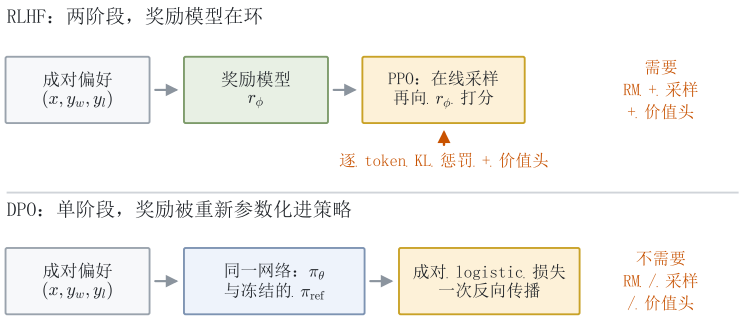


图 10-4 RLHF 与 DPO 的信息流对比。上排：偏好数据训练奖励模型，PPO 在线采样并由奖励模型打分，需要逐 token KL 惩罚与价值头；下排：同一网络与冻结参考策略的比值充当隐式奖励，直接进入成对 logistic 损失，不需要奖励模型、在线采样与价值头。

SUMMARY / 总结

10.3.2 推导成立的七个条件

上节的七步每一步都只用了一个等式，但“等式成立”与“用它训练能得到想要的东西”是两件事。在逐条摊开隐含条件之前，先明确这条推导不该被用来主张什么。

> **警告 10.1（不要把 DPO 说成 RLHF 的等价替换）**
>
> 正确的说法是：在“KL 正则目标 + Bradley–Terry 偏好 + 参数化策略族”这三项假设同时成立时，对奖励做重参数化后可以直接优化相应的偏好似然，两者在这一层上是同一个问题的两种写法。

把这个结论推广成“DPO 与 RLHF 等价”是错的，理由有三：其一，RLHF 的奖励模型可以被复用、被检查、被单独评估，DPO 的隐式奖励只能通过策略反算；其二，RLHF 是在线算法（采样会随策略变化），DPO 是离线算法（数据固定），两者的分布偏移性质不同；其三，式 (10.12) 假设偏好由 BT 生成，而真实偏好不满足 BT 时，两种方法偏离最优的方式并不相同。下面把这条推导依赖的条件逐条摊开。

第一，**目标是 KL 正则的**。式 (10.9) 是从式 (10.5) 反解出来的，如果实际优化的是别的目标（例如加了熵奖励、或对 KL 用了非标准的方向），反解出来的隐式奖励就不是式 (10.13)。

第二，β_{KL} **严格为正**。式 (10.6) 的 Gibbs 形式要求 $\beta_{KL} > 0$；$\beta_{KL} = 0$ 时最优策略退化为把全部质量压在奖励最大的回答上，式 (10.9) 不再有意义。

第三，**支持集包含**。式 (10.9) 中的 $\log \pi^\star/\pi_{\text{ref}}$ 要求 $\pi_{\text{ref}}(y \mid x) > 0$ 对所有可能被采样的 y 成立；若参考策略对某个回答赋予零概率，隐式奖励在该点无定义。因此，参考策略应与偏好数据及策略训练设定保持一致，它决定 KL 正则和隐式奖励所采用的基准。

第四，**配分函数有限**。式 (10.6) 的 $Z(x)$ 必须有限且为正；对有限词表这自动成立，但如果奖励无上界（例如奖励模型没有输出裁剪），$\exp(r/\beta_{KL})$ 会溢出。

第五，**偏好服从 Bradley–Terry，或它的可扩展版本**。式 (10.10) 的相消用到了“两个回答共享同一 $Z(x)$”，这要求比较发生在同一上下文内；跨上下文的比较（x 不同）会让两个 Z 不同、无法相消。若要处理多回答排序，可以把 BT 换成 Plackett–Luce，DPO 原文的附录给出了对应形式。

第六，**同一 prompt 内比较**。这是第五条的直接推论，但值得单列，因

为数据工程上最容易违反：把不同 prompt 的回答拼成一对，会让推导失效，而损失函数不会报错，只是学出错误的东西。

第七，**有限数据下只是经验近似**。式 (10.12) 是式 (10.11) 在数据集上的经验版本，样本有限时最小化它得到的是“在这批偏好上最像最优策略的策略”，不是真正的最优策略。这条是所有经验风险最小化的共同处境。

10.3.3 失效模式

DPO 的简洁是有代价的，代价集中在“它把全部假设都藏进了策略参数”这一点上。四类失效最值得警惕。

偏好数据外推。 式 (10.12) 只在被比较过的回答对上给出约束。对训练集中从未出现的回答，隐式奖励 $\hat{r}_\theta$ 可以取任意值，而这些值恰恰是模型在部署时最常遇到的。RLHF 用在线采样缓解这个问题（策略变了就重新采样），DPO 没有这个机制。

长度利用。 隐式奖励是整条序列的对数概率比，长回答的这个量天然更容易做大，于是优化过程会系统性地偏向更长的输出。这是目标函数的性质：式 (10.13) 没有对长度做任何归一化。

参考策略漂移。 训练中 π_θ 会离 π_{ref} 越来越远，式 (10.13) 的比值随之变大。数据里如果没有足够的“两者都合理”的样本，模型会沿着少数几个方向把比值推到极端，表现为输出风格崩塌或复读。

离线分布偏移。 DPO 的偏好数据由某个固定的行为策略（通常是 SFT 模型）产生。当 π_θ 偏离该策略时，式 (10.12) 的期望是在一个与被优化分布不匹配的样本上算的；样本越不匹配，梯度信号的偏差越大。

10.3.4 工程对比

表 10-2 汇总了两条路线的资源开销。资源占用较低不必然带来更好的任务表现：若多个下游模型需要复用同一偏好信号，单独训练奖励模型具有复用价值；若只需优化一个模型，DPO 可省去奖励模型训练及在线采样成本。

SUMMARY / 总结

表 10-2 RLHF 与 DPO 的工程对比。显存一行按“同时驻留的模型副本数”估计；超参数敏感度是经验判断，不是定理。

维度	PPO-RLHF	DPO
需要训练的模型	策略 + 奖励模型（+ 价值头）	仅策略
是否需要在线采样	是，每轮更新都要生成	否，纯离线
单步显存峰值	高（策略/参考/奖励/价值四份）	低（策略/参考两份）
奖励可复用性	高，奖励模型独立存在	低，奖励藏在策略里
超参数敏感度	高（β_{KL}、clip、价值损失权重、批大小）	中（β_{KL}、学习率）
分布偏移	在线采样部分缓解	离线，靠参考策略约束
典型失败模式	奖励黑客、训练崩溃	长度膨胀、风格崩塌

RLHF 与 DPO 在研究和实践中并存，源于它们对资源和数据条件的不同要求。RLHF 可以复用并单独评估奖励模型；DPO 采用单阶段离线训练，显存开销较低。方法选择取决于偏好信号的复用需求、是否允许在线采样以及任务验证结果。固定历史偏好数据与 DPO 的离线训练设定相匹配。

SUMMARY / 总结

10.4 其他偏好优化路线

后面出现的几条路线，共同点是都从式 (10.12) 出发改动一处假设。它们是在不同假设下对同一组取舍的不同回答。

IPO 针对的是式 (10.12) 的一个病态行为：当某个回答的对数比趋于正无穷时，sigmoid 饱和、梯度消失，KL 正则实际上被架空，模型会过拟合到偏好数据。IPO 把成对 logistic 换成对“对数比之差”的平方损失，相当于给这个差一个有限的目标值，从而在数据可分时仍然保留约束力。

KTO 放弃成对结构，只要求每个回答带一个二元的“好/坏”标签。它的动机来自前景理论：人对得失的敏感度不对称，于是目标里对正例与负例使用不同的权重函数。代价是丢掉了“哪一个更好”的相对信息，收益是标注成本大幅下降——很多场景下能拿到“这句话不能说”却拿不到“这两句哪句更好”。

ORPO 不使用独立的参考策略，而将 SFT 损失与 odds-ratio 形式的偏好项合并为一个训练目标。这样可以减少参考模型带来的显存和前向计算开销；对策略变化的约束也由式 (10.5) 中的显式 KL 项转为目标中的隐式约束。

SimPO 同样去掉参考策略，并对对数似然做长度归一化，再加一个奖励间隔 γ_{margin}（与折扣因子 γ 不是一回事）。长度归一化直接针对 10.3.3 节说的长度利用问题：把 $\log \pi_\theta(y \mid x)$ 除以 $|y|$，让长短回答的隐式奖励落在同一尺度上。

表 10-3 汇总各方法采用的假设及其代价。数据包含成对偏好且算力充足时，PPO-RLHF 可复用并单独评估奖励模型；只有二元标签时，KTO 与反馈形式更匹配；显存受限时，ORPO 和 SimPO 的单阶段训练具有资源优势。图 10-5 按工程复杂度和假设强度定性展示这些方法，图中位置不代表测量结果。

SUMMARY / 总结

表 10-3 偏好优化方法家族。各行的“改动了什么”都以 DPO 为基准；代价一列是设计上的结构性代价，不是实测缺陷。

方法	改动了什么	解决什么问题	代价
PPO-RLHF	显式训练奖励模型，在线采样	奖励可复用、可单独评估	显存与工程复杂度最高
DPO	用策略与参考策略的比值替代奖励	去掉奖励模型与在线采样	离线偏移、长度利用
IPO	把成对 logistic 换成平方损失	数据可分时防止 KL 约束失效	需要选目标间隔，收敛更慢
KTO	用二元标签替代成对比较	标注成本大幅下降	丢失相对排序信息
ORPO	去掉参考策略，合并 SFT 与偏好项	单阶段训练、省一份显存	失去显式 KL 约束
SimPO	去参考策略 + 长度归一化 + 间隔	抑制长度膨胀	长度归一化对长回答惩罚偏重

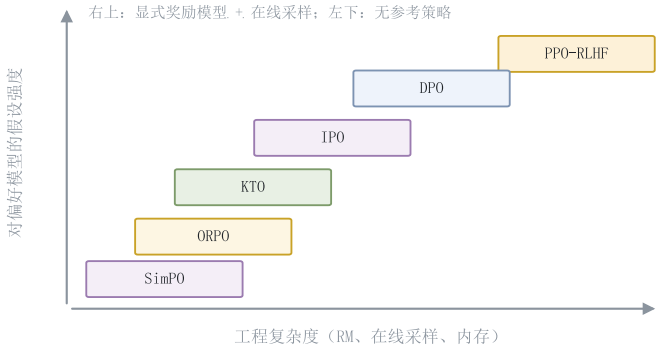


图 10-5 偏好优化方法家族（定性示意）。横轴为工程复杂度（是否需要奖励模型、在线采样与额外显存），纵轴为对偏好模型的假设强度。位置由各方法的目标形式定性确定，不是测量值；右上为 PPO-RLHF，左下为 SimPO。

SUMMARY / 总结

10.5 评估与失效

10.5.1 奖励黑客的三种表现

奖励黑客（reward hacking）指策略找到了提高代理指标、却不提高真实目标的方式。在偏好优化里它有三种典型形态。

第一种是**长度膨胀**。代理指标是奖励模型的分数，而奖励模型从人类偏好里学到了“更长通常更好”这个统计规律（因为人类标注者确实系统性偏好信息更全的长回答）。策略于是把长度当作免费的分数来源。第二种是**谄媚**。奖励模型学到“附和用户观点的回答得分高”，策略便学会在任何话题上先附和再展开。第三种是**格式刷分**。分点、加粗、总结句这些在偏好数据里与高质量相关的外壳特征，会被策略当成因果特征来优化。

三者共同的机制可以用一个式子概括。设真实质量为 $r^\star$、代理为 r_ϕ，则策略在代理上的得分可以分解为

$$\mathbb{E}_\pi[r_\phi] = \mathbb{E}_\pi[r^\star] + \mathbb{E}_\pi\big[r_\phi - r^\star\big], \tag{10.15}$$

第二项就是奖励黑客的贡献。优化过程只看得见左边，它会同时推高真实质量与这一项；一旦这一项涨得更快，左边还在升，真实质量却已经开始降——这就是“代理升、真实降”的过优化现象。左边那条曲线本身看不出危机，这正是它危险的地方。

图 10-6 用一个可复现的小实验把这条曲线算出来。构造 300 个候选回答，每个带一个与长度无关的质量项和一条长度；人类真实判断对长度取倒 U 形（适度长度有帮助、冗长开始扣分），而奖励模型只从偏好数据里拟合出线性的长度项。用式 (10.6) 对不同 β_{KL} 扫描，得到代理分数与真实质量两条曲线。代理分数随优化变强（β_{KL} 变小）单调上升，从 0.06 升到 3.61；真实质量先升后降，在 β_{KL} 约为 0.90 处达到峰值 0.786，继续压到 0.05 时跌回 0.094，与完全不做优化时的 0.00 相差无几。同时平均长度从 0.02 膨胀到 1.59。峰值处 60 次重复的标准误为 0.088，峰的位置比标准误大一个数量级，不是噪声。

SUMMARY / 总结

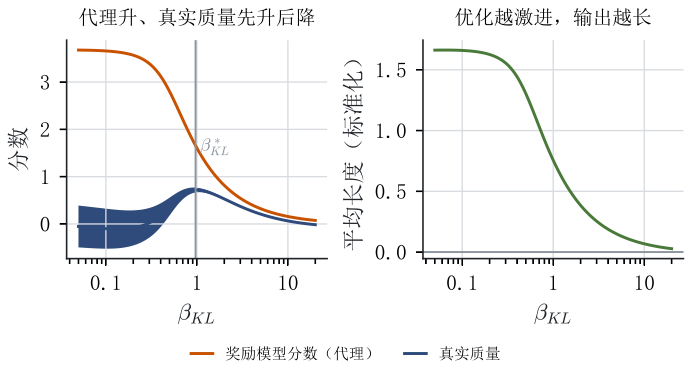


图 10-6 过优化：代理分数与真实质量分道扬镳。左：奖励模型分数随 β_{KL} 减小单调上升，真实质量在 $\beta_{KL}\approx 0.9$ 处见顶后回落，阴影为 ±1 标准误；右：优化越激进，输出越长。实验设定：300 个候选回答、60 次重复、种子 20261020、β_{KL} 从 0.05 到 20 共 90 个点；真实质量为倒 U 形长度函数，奖励模型只含线性长度项；π_ref 取均匀分布。

10.5.2 长度偏差的量

长度偏差不能只看“平均长度变长了”，因为任务本身可能就需要更长的输出。可操作的度量有三种。一是**长度受控胜率**：在长度差不超过若干 token 的子集上单独算胜率，

$$\hat{p}_{\text{ctrl}}(\delta)=\frac{1}{|\mathcal{S}_\delta|}\sum_{i\in\mathcal{S}_\delta}\mathbf{1}\{\text{judge prefers }\pi\text{ on }x_i\},\qquad \mathcal{S}_\delta=\{i:\big||y_\pi^{(i)}|-|y_{\text{base}}^{(i)}|\big|\le\delta\},\tag{10.16}$$

其中 $y_\pi^{(i)}$ 是被评估策略在第 i 个提示上的回答、$y_{\text{base}}^{(i)}$ 是基线回答——筛子必须筛**被比较的那一对回答**，不能用偏好数据里的 y_w, y_l：那对长度差不等于策略与基线的长度差。

如果总体胜率显著高于受控胜率 $\hat{p}_{\text{ctrl}}$，说明胜率里有相当一部分来自长度而非质量。二是**长度残差回归**（回归系数记 c_{len} 而不是 γ，后者在本章专指折扣因子）：把成对结果对长度差做 logistic 回归，

$$\operatorname{logit}\Pr(y_w\succ y_l)=\alpha+c_{\text{len}}\big(|y_w|-|y_l|\big),\tag{10.17}$$

系数 c_{len} 的指数变换给出“每多若干 token 换来多少胜率”，它是一个可以直接报告的量。三是**截断对照**：把长回答截到与短回答等长再评一次，观察胜率的变化幅度。三种度量都不完美——受控胜率在极端长度分布下方差很大，回归假设线性，截断会破坏语义完整性——但任何一种都远好于只看平均长度。

10.5.3 对齐税、数据泄漏与评估协议

SUMMARY / 总结

对齐税指对齐训练带来的通用能力回退。它可以按任务逐项度量：

$$\Delta_{\text{align}}(b) = S_b(\pi_{\text{ref}}) - S_b(\pi_\theta) \;\geq 0 \text{ 表示在基准 } b \text{ 上的回退，} \tag{10.18}$$

其中 S_b 是基准 b 上的分数，π_{ref} 是 SFT 后的策略。InstructGPT 的报告里明确记录了这一现象：RLHF 微调之后，模型在 SQuAD、DROP、HellaSwag 与 WMT 等公开任务上出现性能回退，作者称之为“alignment tax”，并给出缓解手段——把 PPO 的更新与提高预训练分布对数似然的更新混合（PPO-ptx），在不牺牲标注者偏好分数的前提下压回大部分回退。这条经验值得记住：对齐目标与通用能力不是正交的，任何只报告偏好胜率、不报告能力基准的评估都是不完整的。

数据泄漏与去污染在偏好数据上尤其隐蔽。偏好数据常从公开榜单、评测集的同源语料里构造，如果训练集里出现了评测题的原题或改写，胜率会被系统性高估。可操作的检查是用 n-gram 重叠做粗筛：

$$\text{overlap}(y, \mathcal{E}) = \frac{\left|\{n\text{-gram} \in y\} \cap \{n\text{-gram} \in \mathcal{E}\}\right|}{\left|\{n\text{-gram} \in y\}\right|}, \tag{10.19}$$

其中 $\mathcal{E}$ 是评测集。重叠率超过阈值的样本应从训练集剔除，并在报告里写明阈值。

评估协议本身也需要交代清楚。成对评估的标准做法是让裁判在两条回答中选一条，报告胜率与其置信区间：

$$\begin{aligned} \hat{p} &= \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\{\text{judge prefers } \pi \text{ on } x_i\}, \\ \text{CI}_{95\%} &= \hat{p} \pm 1.96\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}. \end{aligned} \tag{10.20}$$

式 (10.20) 的三个参数必须写进任何一份胜率报告：样本量 n、裁判是谁（人类还是模型）、以及比较的基线是什么。缺少任何一项，胜率都无法被复核。最后一条判断贯穿全章：**离线指标好不等于在线体验好**。偏好胜率是在一批固定提示上算的，而部署时的提示分布会漂移；奖励模型与 DPO 的隐式奖励都只在那批数据覆盖的区域里被约束过，区域之外没有任何保证。

SUMMARY / 总结

本章小结

本章从成对偏好出发，介绍奖励模型训练、KL 正则策略优化和 DPO 推导。偏好数据约束回答之间的相对奖励，Bradley–Terry 模型将其写为奖励差的概率；因此奖励的整体平移无法由成对数据确定。KL 正则目标有 Gibbs 形式的闭式解，但语言模型的输出空间使配分函数难以直接计算。PPO-RLHF 通过采样和价值函数近似优化该目标；DPO 则在特定假设下消去配分函数，直接优化偏好似然。

DPO 的推导是精确的，精确性的范围却有限：它依赖第 10.3.2 节列的**七条前提**，把这套推导说成“DPO 与 RLHF 等价”就越过了前提能支撑的边界。去掉奖励模型也不等于去掉奖励假设——奖励被压进策略与参考策略的比值里，代价是无法单独检查、无法复用、也无法在离线数据之外被约束。后来的 IPO、KTO、ORPO、SimPO 各自改动一处假设，没有一条是普适改进，选方法等于选你愿意承担哪一组假设。最后，代理指标可以被优化到与真实目标背离：图 10-6 里代理分数单调上升而真实质量在 β_{KL} 约 0.9 处见顶，长度从 0.02 膨胀到 1.59，“训练得越久越好”在偏好优化里是错的。

关键公式

全章的主干是六条：把偏好写成奖励差（10.1）、KL 正则目标（10.5）、它的 Gibbs 闭式解（10.6）、把奖励反解成策略与参考策略的比值（10.9）、DPO 损失（10.12），以及隐式奖励与它的梯度权重（10.13、10.14）。最后一条里的隐式奖励定义到相差 $\beta_{KL}\log Z(x)$ 为止，只用于同一 prompt 内的比较。

$$P(y_w \succ y_l \mid x) = \sigma\big(r(x,y_w) - r(x,y_l)\big)$$

$$\max_{\pi}\ \mathbb{E}_{x\sim\rho}\mathbb{E}_{y\sim\pi}[r_\phi(x,y)] - \beta_{KL}\mathbb{E}_{x\sim\rho}\big[D_{KL}(\pi(\cdot\mid x)\|\pi_{\text{ref}}(\cdot\mid x))\big]$$

$$\pi^\star(y\mid x) = \frac{1}{Z(x)}\pi_{\text{ref}}(y\mid x)\exp\Big(\frac{r_\phi(x,y)}{\beta_{KL}}\Big),\qquad Z(x) = \sum_y \pi_{\text{ref}}(y\mid x)\exp\Big(\frac{r_\phi(x,y)}{\beta_{KL}}\Big)$$

$$r_\phi(x,y) = \beta_{KL}\log\frac{\pi^\star(y\mid x)}{\pi_{\text{ref}}(y\mid x)} + \beta_{KL}\log Z(x)$$

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{\mathcal{D}}\Big[\log\sigma\Big(\beta_{KL}\log\frac{\pi_\theta(y_w\mid x)}{\pi_{\text{ref}}(y_w\mid x)} - \beta_{KL}\log\frac{\pi_\theta(y_l\mid x)}{\pi_{\text{ref}}(y_l\mid x)}\Big)\Big]$$

SUMMARY / 总结

$$\hat{r}_\theta(x,y)=\beta_{KL}\log\frac{\pi_\theta(y\mid x)}{\pi_{\text{ref}}(y\mid x)},\qquad \nabla_\theta\mathcal{L}_{\text{DPO}}=-\beta_{KL}\mathbb{E}_{\mathcal{D}}\Big[\sigma\big(\hat{r}_\theta(y_l)-\hat{r}_\theta(y_w)\big)\big(\nabla_\theta\log\pi_\theta(y_w)-\nabla_\theta\log\pi_\theta(y_l)\big)\Big]$$

习题

1. 由式 (10.5) 推导式 (10.6)。提示：对每个 x 单独构造拉格朗日函数，约束为 $\sum_y\pi(y\mid x)=1$，乘子记作 $\lambda(x)$，并说明 $\lambda(x)$ 如何由归一化条件定出。
2. 证明式 (10.3)：若把奖励函数整体平移 c，Bradley–Terry 似然不变；并说明为什么这意味着奖励模型的绝对尺度必须由训练过程之外的约定（例如归一化）确定。
3. 设 π_{ref} 为均匀分布、奖励只取两个值 0 与 1、$\beta_{KL}=1$。写出式 (10.6) 的配分函数，并计算最优策略在奖励为 1 的回答上的概率。
4. 数值题：取 $K=50$ 个候选回答、奖励服从 $N(0,1)$、π_{ref} 均匀，用式 (10.6) 在 β_{KL} 从 0.1 扫到 10 的过程中计算 $\mathbb{E}_\pi[r]$ 与 $D_{KL}(\pi\|\pi_{\text{ref}})$，画出两条曲线，并解释为什么在大 β_{KL} 区域 KL 近似与 $1/\beta_{KL}$ 成正比。要求报告网格点数与所用种子（若用随机数生成奖励）。
5. 把式 (10.12) 中的 π_{ref} 换成 π_θ 的一个冻结的历史副本，推导此时损失函数变成什么，并说明它对应哪一种“无参考策略”的近似。
6. 说明为什么式 (10.11) 的相消要求两个回答共享同一上下文 x。如果比较对的一侧来自 prompt x_1、另一侧来自 x_2，损失函数会变成什么？此时最小化它会学出什么？
7. 论述题：给定一批只有二元“好/坏”标签、没有成对比较的反馈，你会选择 KTO 还是先把数据拼成伪成对再跑 DPO？从假设、标注成本、偏差三个角度给出理由，并指出你的选择在哪种情况下会失效。

延伸阅读

- 奖励建模与三阶段流程的原始描述见 Christiano 等（2017）第 2.2 节：奖励预测器、偏好收集、以及“人类偏好某段的概率随奖励之和指数增长”的假设；同文的第 2.2.1 节还讨论了奖励可能非平稳、因此需要鲁棒策略梯度方法的观察。
- InstructGPT（Ouyang 等，2022）第 3 节给出 SFT → 奖励模型 → PPO 的三步标准流程，“alignment tax”与 PPO-ptx 的缓解手段见该文摘要之后

的引言部分。

- DPO 的完整推导见 Rafailov 等（2023）第 4 节与附录 A.2；附录 A.3 给出把 Bradley–Terry 换成 Plackett–Luce 的版本，第 5 节讨论隐式奖励的理论性质，第 6 节是实验。
- 偏好优化方法的系统综述见 “Reinforcement Learning for LLM Post-Training” 综述（2024）第 7 章，其中 IPO 见 7.1 节、KTO 见 7.1 节关于二元反馈的段落、SimPO 的长度归一化见 7.3 节。
- 策略梯度与信赖域的基础见本书第 5 章；PPO 的 clip 与信赖域的关系在该章已作澄清，本章 10.2.2 节只讨论它在 token 级实现中的具体后果。

SUMMARY / 总结

第 11 章　RLVR 与推理强化学习

第 10 章介绍的奖励模型由偏好数据训练得到。策略偏离训练数据分布后，奖励模型的评分可靠性可能下降，因此训练过程通常用 KL 项限制策略变化。本章讨论以程序检查器提供奖励的训练方式。答案正确性、单元测试结果和输出格式都可以由检查器判定；学习对象是策略，优化目标是组内相对奖励，训练过程中可以重新采样。

可验证奖励依赖程序判定器及其覆盖范围，判定规则本身可能存在误判和可利用的缺陷。规则判定器将特定任务的结果映射为可计算的反馈；反馈的可靠性取决于判定器与真实任务目标的一致性。规则反馈与学习型奖励模型的偏差来源不同，需分别评估误判率及分布外行为。本章依次讨论可验证奖励的判定范围、GRPO的组内相对优势估计、长链推理训练的稳定性与失效现象。

本章以第 5 章的策略梯度为先修知识。RLVR 是以可验证结果构造奖励的训练机制，GRPO 是一种策略优化算法，二者处于不同层次；RLVR 也可以使用 PPO 等优化方法。GRPO 的组内均值包含当前样本奖励，因此在 on-policy、组内独立同分布且单步更新的条件下，减去组均值会使期望梯度缩放为 $(1-1/G)$ 倍；再除以组内标准差后，有限组大小下通常不再是无偏优势估计。GRPO 的收敛性尚无一般定理，长度变化、策略熵下降与奖励利用属于实验中观察到的现象，不能视为必然结果。表格方法的收敛结论不能直接推广到语言模型策略优化。

11.1 可验证奖励的定义与判定范围

11.1.1 判定器与它的四种形态

可验证奖励训练使用程序检查器提供反馈。与人类偏好训练中的奖励模型不同，检查器按预先定义的规则评估回答；其判定范围和准确性由规则、测试覆盖率及运行环境决定。

确定性判定器在代码、环境、依赖版本和随机种子固定时，对相同输入产生可复现结果。这有助于复现实验，也使奖励规则不随策略训练过程改变。

> **定义 11.1（可验证奖励）**
>
> 设提示为 x、回答为 y，判定器 V 是可计算函数，把 (x,y) 映射到 $\{0,1\}$。可验证奖励取

SUMMARY / 总结

$$r(x, y) = V(x, y) \in \{0, 1\}. \tag{11.1}$$

和式 (10.5) 里那个要拟合的 r_ϕ 比，式 (11.1) 没有参数、没有训练集，也不随策略漂移。但“不被优化”只说明它不会在训练过程中被改，不说明它不会出错：判定器把自己的偏差在数据准备阶段一次性写死，第 11.1.2 节量的就是这份偏差有多重，第 11.4.4 节看到的是策略怎么把它变成一条捷径。

常见判定器包括答案匹配、单元测试、格式约束和工具辅助验证，各自检查不同属性。**答案匹配**从回答中抽取最终答案，再与标准答案进行字符串或数值比较。**单元测试**检查预先指定的程序行为，其可靠性取决于测试覆盖率、执行环境和对抗性输入处理。**格式与长度约束**只检查规定的段落标记、推理过程或长度范围，无法直接判断内容正确性。**工具辅助验证**使用计算器、符号引擎或检索器的输出作为判据。表 11-1 汇总这些判定方式。

表 11-1 判定器的四种形态。可靠性一栏是相对量级，不是统计估计；同一条流水线通常组合使用，例如“格式分 + 正确性分”。

形态	判据	可靠性	主要风险
答案精确匹配	抽取终答案后比较	中：依赖抽取正则	等价写法被判错
单元测试	执行代码跑测试	高	执行环境、超时、作弊
格式与长度约束	结构检查	低	只验证外壳，不看内容
工具返回	计算器/符号引擎	中高	工具本身的错误与延迟

11.1.2 可验证不等于正确

式(11.1)定义判定器输出的反馈信号；该信号与真实答案正确性之间的差异由误判机制决定。两者之间的差距可以用两个数刻画：假阳率 $\alpha = \Pr(V = 1 \mid y \text{错})$ 与假阴率 $\beta = \Pr(V = 0 \mid y \text{对})$。若回答的真实正确率为 p，那么判定器给出的期望奖励是

$$\mathbb{E}[V] = (1 - \beta)\, p + \alpha\,(1 - p) = \alpha + (1 - \alpha - \beta)\, p. \tag{11.2}$$

偏差的量级可以直接从同一个式子读出：无论 p 取何值，判定器期望奖励与真实正确率之差都不会超过两个误判率中较大的那个，

$$\left|\mathbb{E}[V] - p\right| = \left|\alpha(1 - p) - \beta p\right| \le \max(\alpha, \beta). \tag{11.3}$$

式 (11.3) 给出判定器期望奖励与真实正确率之间的偏差上界。式 (11.2) 表明，当假阳率 α 与假阴率 β 固定且 $\alpha + \beta < 1$ 时，$\mathbb{E}[V] = \alpha + (1 - \alpha - \beta)p$ 随真实正确率 p 严格递增，因此两者具有相同的最优策略集合。若 $\alpha + \beta = 1$，判定器不提供区分正确率的信息；若 $\alpha + \beta > 1$，期望判定奖励随正确率递

SUMMARY / 总结

减。具体任务中的误判偏差主要来自答案等价形式处理、测试覆盖不足和结果抽取规则等因素。

最常见的是等价答案。$x = 2$ 与 2 是同一个答案，$1/2$ 与 0.5 也是，可字符串比较会把后者判错。这类假阴教给模型的是“照抄标准答案的格式”，而不是“解出答案”。

证明题与开放题更麻烦。证明没有唯一写法，开放题没有标准答案，判定器只能退化成“看最终结论有没有出现”，此时它测的是有没有复述结论，与有没有证明结论基本无关。

更隐蔽的一种来自判定器自己的实现。用正则抽答案时，如果模型把答案写在推理中间而不是最后一行，抽取器可能什么都抽不到（假阴），也可能抽到推理中途的错误数字并碰巧匹配（假阳）。

11.1.3 稀疏奖励与信用分配

在二值判定设定下，每条回答只获得一个序列级奖励，因此监督信号没有直接标明各推理步骤的局部贡献。按 token 位置表示时，奖励仍然是稀疏的：

$$r_t = \mathbf{1}\{t = |y|\}\, r(x, y). \tag{11.4}$$

式 (11.4) 说的是奖励只落在最后一个 token 上。二值结果监督只对整条回答给出单个标量，不能将其解释为各 token 独立且等比例的信息量；长序列因此面临更困难的信用分配问题。后果有两个。组内相对奖励训练依赖同一提示下候选样本的奖励差异：样本组奖励相同时，常见的组内中心化优势全部为零，无法由该组提供相对更新方向。第 11.2 节的组内标准化是为第二个后果设计的，第 11.5 节的动态采样则直接把“没有信息”的组丢掉。

降低信用分配难度的一种方法是**过程监督**：判定器对推理步骤分别提供反馈，使监督信号具有比终局结果更细的时间粒度。相应代价是标注成本随步骤数增加，而且中间步骤的正确性未必有唯一判定标准；不同推理路径可能得到同一正确结论。DeepSeekMath 将这两种设定称为结果监督与过程监督，并指出过程监督可能提高样本效率，但依赖可靠的逐步判定器。以下内容以当前 RLVR 实践中常见的结果监督为主。

11.1.4 模型评审反馈的可靠性边界

当判定器本身是一个语言模型——比如“让模型给自己打分”——奖励就重新变成了一个被优化的模型。这时候策略提高分数有两条路：答得更

好，或者更迎合判分者。更糟的是判分者与策略常常同源，两者的偏差相关，优化会把共同的偏差一起放大。这就是第 10.1 节讨论过的奖励模型过优化，区别只在于这一次连留出的训练数据都没有。DeepSeek-R1 在 R1-Zero 阶段刻意只用规则奖励、不碰神经奖励模型，正是为了绕开这条路。

实际系统很少只用一种判定器，常见做法是加权求和：格式分、答案分、测试分各占一个权重。组合起来就得到一条工程判据——**每增加一个能被低成本满足的子奖励，就多了一条捷径**。若格式分的权重压过正确性分的误判代价，策略会先去补齐格式；反过来，若正确性判定过严（假阴高），策略学会的是避开那些容易被误判的写法。权重没有原则性的选法，只能靠留出集上“奖励与真实正确率是否同步”来校准。

图 11-1 把整条流水线画在一起：同一提示采 G 条回答，判定器逐条给出 0/1，组内标准化把绝对奖励变成相对信号，再回到策略更新。

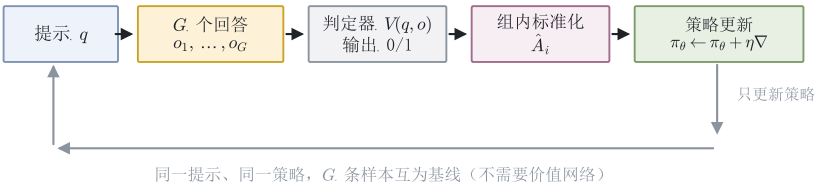


图 11-1 可验证奖励的流水线。同一提示采 G 条回答，判定器逐条给出 0/1，组内标准化把绝对奖励换成相对信号，策略只按相对信号的方向更新；整条流水线里没有价值网络。

SUMMARY / 总结

11.2 GRPO：组内相对奖励

11.2.1 出发点：PPO 的目标

第 5.4 节给出的 PPO 裁剪目标 (5.25) 与比率定义 (5.21)，在语言模型上被逐 token 使用。记裁剪后的比率为 $\rho_t^c(\theta) = \mathrm{clip}\big(\rho_t(\theta), 1-\varepsilon_{\mathrm{clip}}, 1+\varepsilon_{\mathrm{clip}}\big)$，则

$$J^{\mathrm{PPO}}(\theta) = \mathbb{E}\Big[\frac{1}{|y|}\sum_{t=1}^{|y|}\min\big(\rho_t(\theta)\hat{A}_t,\ \rho_t^c(\theta)\hat{A}_t\big)\Big], \tag{11.5}$$

其中 $\rho_t(\theta) = \pi_\theta(y_t \mid x, y_{<t})/\pi_{\theta_{\mathrm{old}}}(y_t \mid x, y_{<t})$。式 (11.5) 有两个不便明说的前提：$\hat{A}_t$ 要由 critic 在**每个 token** 上给出，而 token 级奖励只有最后一个位置非零（式 (11.4)），critic 因此必须靠自举把未来的奖励摊回每一步；语言模型的 critic 通常与策略同规模，显存直接翻倍。

GRPO（Group Relative Policy Optimization）利用奖励的序列级特征，直接比较**同一提示生成的多个样本**。样本之间的相对奖励可作为优势信号，因此算法无需另行学习逐 token 的价值函数。

11.2.2 组内标准化

对提示 x，用旧策略采 G 条回答 $\{o_1, \ldots, o_G\}$，判定器给出 $\{r_1, \ldots, r_G\}$。定义组均值与组标准差

$$\bar{r} = \frac{1}{G}\sum_{j=1}^{G} r_j, \qquad s_r = \sqrt{\frac{1}{G}\sum_{j=1}^{G}(r_j - \bar{r})^2}, \tag{11.6}$$

组内标准化优势取

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r + \varepsilon_{\mathrm{num}}}. \tag{11.7}$$

先把两个 ε 分开。式 (11.7) 里的 $\varepsilon_{\mathrm{num}}$ 只是数值保护，防止 $s_r = 0$ 时除零，不属于任何理论定义；真遇到 $s_r = 0$（全组同奖励），标准做法是把这个组**掩掉**——它不提供任何相对信息。式 (11.5) 里的 $\varepsilon_{\mathrm{clip}}$ 才是裁剪区间，两者含义完全不同（第 5.4 节）。

式 (11.7) 的效果可以直接算。取 $G = 6$、奖励为 0/1：三条对三条，$\bar{r} = 0.5$、$s_r = 0.5$，标准化后只剩 ± 1 两个值；两条对四条，$\bar{r} = 1/3$、$s_r = 0.4714$，两个取值是 $+1.414$ 与 -0.707；六条全对，$s_r = 0$，整组被掩掉。图 11-2 画的就是这三种情形。

SUMMARY / 总结

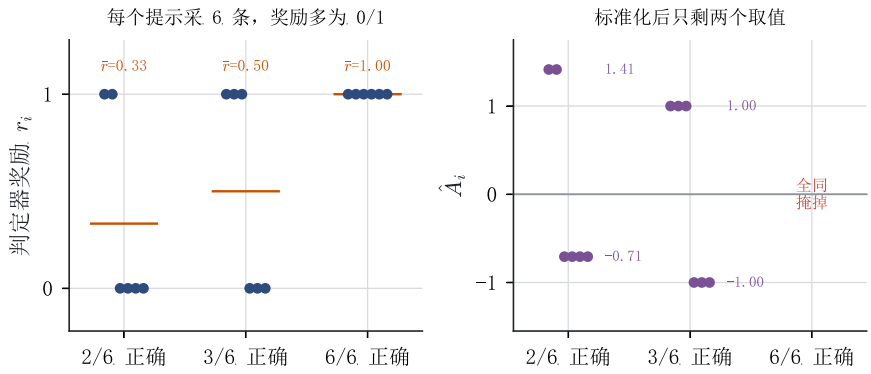


图 11-2 组内标准化的几何。左：三组各 6 条回答的 0/1 奖励与组均值；右：标准化后的 $\hat{A}$，2/6 与 3/6 组各只剩两个取值（1.414 与 -0.707、1 与 -1），6/6 组因组内方差为零被整组掩掉。数值由式 (11.6) 与式 (11.7) 直接算出，ε _num 取 0.0001。

图 11-2 的右图说明了一件容易被忽略的事：在二值奖励下，标准化后的优势只有两个取值，它在整组内是常数。这是 RLVR 的结构性特征——同一提示的所有样本只按“对/错”被分成两档，档内的差别全部丢失。

11.2.3 GRPO 的目标

token 级比率与 PPO 相同，只是下标多了一层“第 i 条回答”：

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} \mid x, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid x, o_{i,<t})}. \tag{11.8}$$

GRPO 的目标沿用同一套记号，其中裁剪后的比率记作 $\rho^c_{i,t} = \text{clip}\big(\rho_{i,t}, 1-\varepsilon_{\text{clip}}, 1+\varepsilon_{\text{clip}}\big)$：

$$J^{\text{GRPO}}(\theta) = \mathbb{E}\Big[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\Big(\min\big[\rho_{i,t}\hat{A}_i,\ \rho^c_{i,t}\hat{A}_i\big] - \beta_{KL}\widehat{D}_{KL}(i,t)\Big)\Big], \tag{11.9}$$

式 (11.9) 里出现的 $\hat{A}_i$ 没有 token 下标，这本身就是定义的一部分：同一条回答的每个 token 共享同一个优势，

$$\hat{A}_{i,t} := \hat{A}_i, \qquad t = 1, \ldots, |o_i|. \tag{11.10}$$

其中 KL 项用第 10.2 节的低方差估计器逐 token 计算：

$$\widehat{D}_{KL}(i,t) = \frac{\pi_{\text{ref}}(o_{i,t} \mid x, o_{i,<t})}{\pi_\theta(o_{i,t} \mid x, o_{i,<t})} - \log\frac{\pi_{\text{ref}}(o_{i,t} \mid x, o_{i,<t})}{\pi_\theta(o_{i,t} \mid x, o_{i,<t})} - 1, \tag{11.11}$$

它在每个 token 上非负。与第 10.2 节式 (10.7) 的写法相比，这里有一处位置差别：**KL 不进奖励，直接进损失**。原因是奖励一旦被 KL 项污染，式

(11.6) 的组均值与标准差就同时被污染，标准化后的 $\hat{A}_i$ 会变成“相对熵惩罚”，不再是相对奖励；把 KL 放到损失里，优势估计就只依赖纯净的判定器输出。

11.2.4 GRPO 的估计性质与适用范围

GRPO基于同一提示的候选样本构建组内相对训练信号。式 (11.7) 的分子 $r_i - \bar{r}$ 与标准策略梯度的权重 r_i 只差一个**组内均值**，而组内均值里含 r_i 本身，所以它并不满足基线恒等式的条件。把它算清楚：设同一提示的 G 条回答独立同分布、由**当前**策略采样，记 $g_i = \mathbb{E}[r_i \nabla_\theta \log \pi_\theta(o_i \mid x)]$，则

$$\begin{aligned} \mathbb{E}\big[(r_i - b)\nabla_\theta \log \pi_\theta(o_i \mid x)\big] &= \mathbb{E}\big[r_i \nabla_\theta \log \pi_\theta(o_i \mid x)\big] \\ \mathbb{E}\big[(r_i - \bar{r})\nabla_\theta \log \pi_\theta(o_i \mid x)\big] &= \Big(1 - \frac{1}{G}\Big) g_i \end{aligned} \tag{11.12}$$

第二式可以逐项看出来：$j \neq i$ 的样本与 o_i 独立，而 $\mathbb{E}_{\pi_\theta}[\nabla_\theta \log \pi_\theta] = 0$，于是 $\mathbb{E}[r_j \nabla_\theta \log \pi_\theta(o_i \mid x)] = 0$，只剩 $j = i$ 那一项贡献 $\frac{1}{G} g_i$，合起来就是 $(1 - \frac{1}{G}) g_i$。**这个因子是与 i 无关的正常数**，所以方向不变、只整体缩小——$G = 1$ 时因子为零，单样本的 GRPO 完全学不到东西，这正是“组”不可省的原因。也正因为它是缩放而非“消去”，说“减组均值不改变期望梯度”是不准确的：改变的是一个已知的常数倍。

三条限定必须和上式一起读：其一，成立条件是 o_i 由**当前**策略采样、组内独立同分布、且只做单步更新；用旧策略 π_{old} 采的数据会留下交叉项，偏差随 π_{old} 与 π_θ 的距离增大。其二，式 (11.7) 还要除以 $s_r = \text{std}(r) + \varepsilon_{\text{num}}$，这使整体变成比率估计量——$s_r$ 依赖同一组样本，有限 G 下**没有一般无偏性**；ε_{num} 只是数值保护，s_r 为零的组被整组掩掉，实际参与的有效样本质量因此低于名义 G。其三，除以 s_r 让权重随组内离散度变化，而离散度又与回答长度相关（越长的回答奖励越分散），长度与奖励因此被耦合起来，这是长度偏差的来源之一。

至于方差：减基线确实通常降方差，但组均值是**含噪**基线，它的降方差效果弱于一个独立估计的 V^π，这就是 GRPO 省掉 critic 所付的代价（[经验规律]，见 11.5 节对长度偏差与难度偏差的讨论）。

组内标准化得到的信号一般不等于状态—动作优势函数的无偏估计。

最常见的误读是把它当成优势函数的估计。优势函数是“在同一状态下，某动作比策略平均好多少”的期望量；$\hat{A}_i$ 是“这条回答比同组其他回答的奖励高多少”的样本量，既没有对状态取期望，也不含任何状态——语言

SUMMARY / 总结

模型里“状态”是前缀 $o_{i,<t}$，而 $\hat{A}_i$ 对整条回答是常数。用 A^π 的公式去解释它，或者声称它无偏地估计了 A^π，都是错的。

除以 s_r 改的也不只是中心。分子把奖励中心化，分母把尺度归一化，后者使梯度权重变成 $1/s_r$。把式 (11.10) 代入策略梯度，这一步实际优化的方向是

$$\nabla_\theta J \propto \mathbb{E}\Big[\frac{1}{s_r}\,(r_i-\bar{r})\,\nabla_\theta \log \pi_\theta(o_i \mid x)\Big], \tag{11.13}$$

即“组内越难分辨（s_r 小），这一步的梯度越大”。这是有意的设计——难题的信号更珍贵——但它确实不是对优势的无偏变换。

还有一层更根本的粗糙：序列级奖励让信用分配只能到序列这一级。$\hat{A}_i$ 对一条回答的所有 token 相同，式 (11.9) 里对 t 求和只是把同一个优势复制到每个位置；形式上叫“token 级优势”，信号粒度仍然是序列级。

11.2.5 与 PPO 的对照

比较式 (11.5) 与式 (11.9)，主要差异有四处：采样单位、优势来源、比率与裁剪的作用对象，以及 KL 项的位置。表 11-2 和图 11-3 分别从公式和流程角度说明这些差异。

表 11-2 PPO 与 GRPO 的四点对照。最后一行是结果不是原因：critic 的缺席来自第二、四行的改动。

对照点	PPO（第 5.4 节）	GRPO
采样单位	单步转移 (s_t, a_t)	同一提示的 G 条完整回答
优势估计	critic 学 V_ϕ，GAE 汇总	组内标准化奖励 $\hat{A}_i$
比率与裁剪	token 级 ρ_t，对称裁剪	token 级 $\rho_{i,t}$，对称裁剪
KL 的位置	进奖励，与奖励一起被优势估计吸收	进损失，直接加在目标上
额外网络	需要 critic	不需要

SUMMARY / 总结



图 11-3 PPO 与 GRPO 的四处差异。四行分别是采样单位、优势来源、比率与裁剪、KL 的位置；左列为 PPO 的做法，右列为 GRPO 的做法。差异不止“有没有 critic”这一行。

把 GRPO 概括成“去掉 critic 的 PPO”，会丢掉三件事：优势不再是学出来的基线，而是组内相对奖励；归一化不只是减均值，标准差还会放大难题的梯度；信用分配的粒度停在序列这一级，而不是逐 token 的 GAE。

还有一处不能省的改动是裁剪本身。语言模型的训练通常不是同策略的：采样与更新出自不同引擎，采到的回答带有轻微的离策略偏差，裁剪与重要性比率正是为它准备的。GRPO 去掉的是 critic，不是这项修正。

SUMMARY / 总结

11.3 从 RLVR 到长链推理

11.3.1 R1 路线的四个阶段

DeepSeek-R1 的流水线值得单独讲，它把“规则奖励能走多远”这件事拆成了几段来答。R1-Zero 完全跳过监督微调，直接在基座模型上用 GRPO 训练，只用规则奖励（答案正确性与格式），刻意不用神经奖励模型。它证明了一件事：纯强化学习可以诱导出长链推理、自我检查与回溯这些行为。但它也暴露了问题——输出可读性差、语言混杂。完整的 R1 因此改成四阶段（图 11-4）：

① 冷启动监督微调：用少量人工整理的长链推理示范，先把 `think` 格式与基本推理结构教给模型；② 推理导向的 RLVR：在冷启动检查点上用 GRPO 训练，奖励仍是规则判定（正确性、格式、语言一致性）；③ 拒绝采样 + 监督微调：用第 ② 阶段的模型采样，只保留判定器通过的回答，再混入非推理数据，做一次监督微调，把推理能力固化下来、同时恢复通用能力；④ 全场景 RL：在推理任务之外加入偏好奖励（有用性、安全性），做第二次 GRPO。

阶段 ② 与阶段 ④ 的奖励设计不同，这不是随意安排：规则奖励只在“答案可判定”的任务上可靠，偏好奖励则要求在推理能力已经稳定之后才引入，否则模型会优先优化容易被偏好模型喜欢的表面特征。图 11-4 把这个顺序画了出来。

第 ③ 阶段本身是一个普通的监督微调目标，只是训练集被判定器筛过一遍。记 $\mathcal{D}_{\text{pass}} = \{(x, o) : V(x, o) = 1\}$ 为通过集合，则

$$\mathcal{L}^{\text{RS}}(\theta) = -\mathbb{E}_{(x,o)\sim\mathcal{D}_{\text{pass}}}\big[\log \pi_\theta(o \mid x)\big]. \tag{11.14}$$

式 (11.14) 值得单独写出来，因为它暴露了 R1 路线的一个隐含假设：筛选后的样本分布就是想要的策略分布。这个假设在“判定器只认真答案”时大致成立，在判定器有假阳时就会把错误示范固化进模型——第 11.1.2 节的式 (11.2) 在这里换了一种形式出现。

SUMMARY / 总结

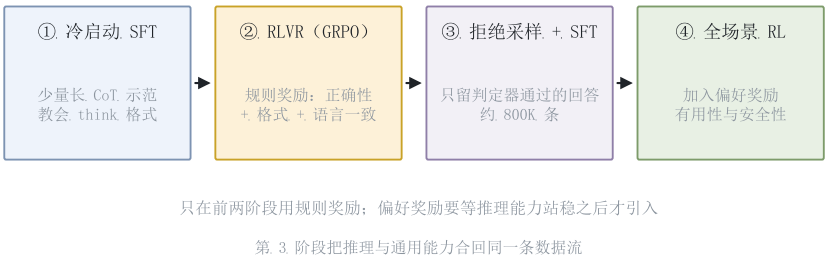


图 11-4 R1 的多阶段训练流水线。① 冷启动 SFT 教会格式；② 推理导向 RLVR 用规则奖励；③ 拒绝采样 + SFT 固化推理并恢复通用能力；④ 全场景 RL 才引入偏好奖励。

11.3.2 长度膨胀与熵塌缩

RLVR 训练中反复被观察到的两个现象是**回答变长**与**策略熵下降**。前者通常表现为平均长度在训练早期快速上升、随后趋于平台；后者的表现是每个位置上的输出分布越来越尖，采样出的回答彼此越来越像。熵在这里指的是逐位置的输出分布熵，

$$H\big[\pi_\theta(\cdot \mid x, o_{<t})\big] = -\sum_{a \in \mathcal{V}} \pi_\theta(a \mid x, o_{<t}) \log \pi_\theta(a \mid x, o_{<t}), \tag{11.15}$$

对一条序列取平均就得到工程上报告的“每 token 熵”。图 11-5 给出这两个趋势的示意形状。

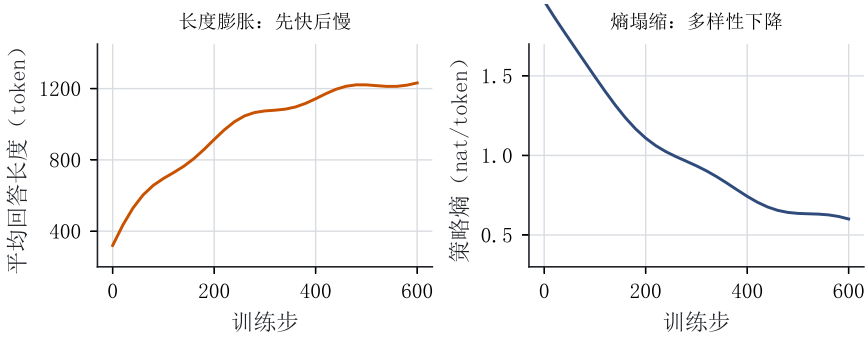


图 11-5 训练中回答长度与策略熵的典型演化（示意）。左：平均回答长度先快后慢地上升并趋于平台；右：策略熵单调下降并在低位波动。两条曲线只是文献报告的趋势，量级依任务与超参而变，不是定理，标 [经验规律]。

这两个现象都需要小心解读，它们的地位是 [经验规律] 而不是必然结果，而且彼此可以解耦。长度上升的一个自然解释是：判定器只检查最终答案，而更长的推理链平均而言更容易撞对答案，于是“变长”被奖励间接强化。但这条解释立刻遇到反例——如果长度本身就是奖励的一部分（长度惩

SUMMARY / 总结

罚或格式分），趋势会完全不同；有些工作在训练中加入长度惩罚后仍观察到长度上升，说明还有别的机制（例如长回答更容易包含自我检查，而自我检查提高了正确率）。熵下降同样有两面：它意味着采样多样性降低、探索变弱，也意味着策略更确定；把熵下降一律称为“塌缩”是一种价值判断，只有当它伴随正确率停滞或下降时才构成问题。

11.3.3 pass@1 与 pass@k 的错配

RLVR 常用的两个指标是 pass@1（贪心或低温采样一次就对的比例）与 pass@k（采 k 次至少一次对的比例）。后者的无偏估计写作

$$\widehat{\text{pass@}k} = \mathbb{E}_x\left[1 - \frac{\binom{n-c(x)}{k}}{\binom{n}{k}}\right], \tag{11.16}$$

其中对每个提示采 n 条、其中 $c(x)$ 条正确，$n \geq k$。两个指标的错配是本章最实用的一条经验：**训练提高 pass@k 未必提高 pass@1**。组内标准化奖励的是“比同组平均好”，它会把概率质量推向已经能对的那些轨迹；如果这些轨迹的正确性依赖于采样到某个少数分支，那么 pass@k 会上升，而贪心解码的 pass@1 可能不动甚至下降。反过来，只盯 pass@1 会奖励“稳定但保守”的回答，压制长链推理。评估协议因此必须同时报告两者，并写清采样温度与 k 的取值。

式 (11.16) 的估计量还有一个容易被忽略的成本项：它的方差来自“每个提示的 $c(x)$ 只有 n 次采样”。n 越大估计越准，但评测成本随 n 线性增长，而模型规模又不允许在小 k 上少采。常见的折中是取 $n = 8$ 或 $n = 16$，对每个报告值给出标准误，并在多个温度上各跑一遍——只报单点、不给标准误的 pass@k 表格，在不同 n 之间无法比较。这一点与第 8 章评估协议的要求是同一条纪律：估计量的口径必须先于数字被说清。

SUMMARY / 总结

11.4 稳定性与工程

11.4.1 KL 系数与参考策略

式 (11.9) 里的 β_{KL} 与第 10.2 节同义：它把策略拉向参考策略。RLVR 的不同之处在于参考策略怎么选——它通常是 SFT 之后的检查点，且在多阶段流水线里**每个阶段重新设定一次**（R1 的算法把参考模型设为每轮迭代开始时的策略）。差别在这里：KL 约束的是“相对本轮起点漂移多少”，不是“相对最初模型漂移多少”。参考策略更新过频，KL 就限制不住长程漂移；从不更新，早期检查点的缺陷又会被一直锁住。

还有一派做法直接去掉 KL 项（第 11.5 节的 DAPO 与部分开源实现），理由是判定器奖励本身不易被过优化，KL 反而抑制了必要的探索。这两种选择都有代价：有 KL 时策略倾向于复述参考策略的风格，长度与多样性受抑制；无 KL 时训练更不稳定，对学习率与批大小更敏感。可以把它们看成同一个旋钮的两端，而不是对错之争。

工程上真正要定下来的是三个量：参考策略取哪一个检查点、β_{KL} 取多大、参考策略多久换一次。三者耦合，改一个就要重调另外两个。一个常见的失误是把“每轮重设参考”与“小 β_{KL}”叠在一起：前者让约束只对局部有效，后者让约束本身很弱，两者相加等于没有 KL，而表面上仍然写着正则项。反过来，固定参考策略配大 β_{KL} 会让策略锁死在早期风格上，长度涨不上去，pass@k 也上不去。这两种配置在日志里的区别很小，只看训练奖励曲线往往看不出来，必须对照长度分布与留出集指标。

11.4.2 token 级比率与序列级比率

式 (11.8) 的比率是逐 token 的，一次策略更新里要对上千个 token 各算一个重要性权重。当旧策略与新策略的差别在序列级别上很小时，token 级权重仍可能在个别位置上剧烈波动，长序列累积后形成高方差噪声。第 11.5 节的 GSPO 把比率换成序列级 ρ_i，正是针对这一点。本章不展开该方法的推导，只需记住：**比率的单位与奖励的单位不一致**，是 GRPO 家族共同的结构性张力。

这个张力有一个可直接检验的后果：梯度估计的方差随回答长度增长。一条 4 token 的回答，比率估计只累积 4 项；一条 4000 token 的回答，同样的逐 token 噪声要累积 4000 次，而奖励仍旧只有一个。于是“长回答”在目标里既贡献了更多的 token 项，也贡献了更多的噪声项，两者的比例并不随

长度保持不变。工程上的三种缓解手段——调低学习率、收紧裁剪区间、缩短最大生成长度——都是在压方差而不是改结构；真正的结构性修改要等到比率单位被换掉（第 11.5.1 节）。

11.4.3 采样温度与组大小

组内标准化依赖组内有差异。若温度过低，同一提示的 G 条样本几乎相同，$s_r \approx 0$，整组被掩掉；若温度过高，样本质量普遍下降，正确样本变少，信号同样稀疏。组均值本身的方差随 G 下降：

$$\mathrm{Var}(\bar{r}) = \frac{\sigma^2}{G}, \tag{11.17}$$

σ^2 是单条奖励的方差。式 (11.17) 说明 G 越大基线越准，但采样成本线性增长；工程上常见的取值为 4–16，代价与收益的拐点依任务而变，没有普适最优。

11.4.4 奖励黑客

判定器一旦进入训练回路，就会被优化。RLVR 特有的几种作弊方式在文献中反复出现：**格式作弊**（只写规定的段落标记，内容空洞）、**把答案抄进推理过程**（用“由题意可知答案为 X”跳过推理）、**利用抽取正则**（把答案写成抽取器一定命中的形式）、**训练集污染**（评测题出现在训练数据里）。

图 11-6 用一个三臂老虎机把这件事实测出来：臂 0 是真推理（判定器与真值都以 0.35 的概率给 1），臂 1 是格式捷径（格式分 0.5 稳拿，另以假阳率拿到正确性分，真实正确率恒为 0），臂 2 是其他。这个模型的要点是三条臂的期望奖励都是常数：无论策略怎么变，真推理始终是 0.35，格式捷径是 0.5 或 0.65，其他是 0；策略唯一能动的是三条臂上的概率质量。用 REINFORCE 训练 200 个种子、每种子 400 步，可以清楚看到判定器奖励上升而真实正确率下降：假阳率为 0 时，判定器奖励从 0.283 升到 0.492，真实正确率从 0.117 掉到 0.011；假阳率 0.30 时，奖励升到 0.643，正确率掉到 0.004。三条臂的期望都是提前算好的，图里画出的每一条曲线都只是策略在这些常数上的加权平均，不含任何随机估计。

SUMMARY / 总结

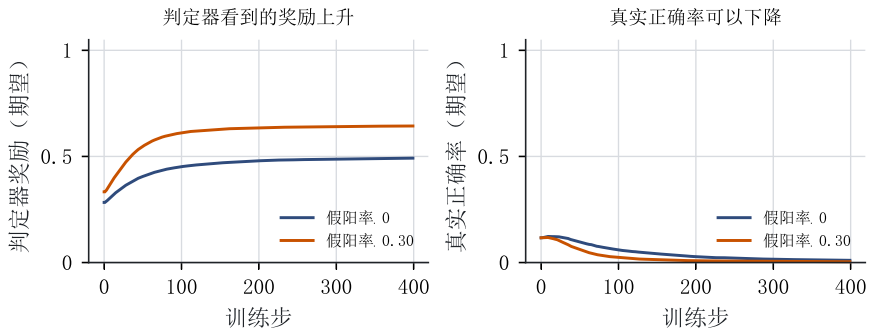


图 11-6 奖励黑客的最小模型。三臂老虎机（真推理 / 格式捷径 / 其他）+ REINFORCE，200 个种子 × 400 步，学习率 0.3。左：判定器奖励上升；右：真实正确率下降——假阳率 0 时，仅凭 0.5 的格式分就足以把策略从真推理上拉走。

这张图要读出的是部分信用的结构决定了最优策略的形状：只要捷径的期望奖励高于真推理，策略就会走向捷径，而“真推理”这一臂的奖励期望是固定的 0.35——它不会因为策略更努力而升高。现实中的判定器比这个三臂模型复杂，但机制相同：任何可被低成本满足的子条件，都会在足够长的训练里被单独优化。

11.4.5 评估协议

由 11.1.2 与 11.3.3 的讨论可以推出三条评估纪律。其一，**去污染**：训练集与评测集的重叠必须显式检查，常用做法是 n-gram 重叠检测与题目指纹比对；判定器正确率再高，也救不了训练时见过题的模型。其二，**留出判定器**：至少保留一种与训练时不同的判定器（例如换了答案抽取器、或改用人工抽查一小批），用来估计假阳率。其三，**同时报告 pass@1 与 pass@k**，并写清温度、k、采样条数 n——只报一个数的结果无法判断是“更会推理”还是“更会复述”。

还有一条纪律与前三条不同，它针对的是训练循环本身：**同一个提示被重复使用多少次，必须记录**。RLVR 的提示池通常远小于模型见过的文本量，几百步训练之后，大批提示会被反复采样；一旦某个提示的答案被模型记住，它的奖励就不再反映推理能力，而反映记忆。这与 11.4.4 的训练集污染是同一件事的两种形态：前者发生在数据准备阶段，后者发生在训练过程中。缓解办法是控制每个提示的复用次数、定期换一批新题，并在留出集上检查“见过的题”与“没见过的题”的准确率差距——这个差距本身就是污染程度的估计量。

SUMMARY / 总结

11.5 研究前沿与未解问题

11.5.1 三个方向：DAPO、GSPO 与 Dr.GRPO

在 GRPO 之后出现的一批工作，大多可以被读成对式 (11.9) 三个组件的修改。以下三项**是研究方向，不是已解决的结论**：它们各自报告了更好的实验结果，但都缺少收敛性证明或可迁移的理论保证。

DAPO 有两处改动。第一，**动态采样**：丢掉全对或全错的组，只保留组内有对有错、能产生非零优势的提示，

$$\text{保留 } x \iff 0 < c(x) < G, \tag{11.18}$$

其中 $c(x)$ 是该组正确的条数。第二，**非对称裁剪**（clip-higher）：把式 (11.9) 的裁剪区间改成 $[1-\varepsilon_{\text{low}}, 1+\varepsilon_{\text{high}}]$ 且 $\varepsilon_{\text{high}} > \varepsilon_{\text{low}}$，

$$\text{clip}\big(\rho_{i,t},\, 1-\varepsilon_{\text{low}},\, 1+\varepsilon_{\text{high}}\big), \tag{11.19}$$

给高优势方向更大的更新空间，同时收紧低优势方向。此外 DAPO 把损失按整批 token 总数平均，而不是逐条回答按 $|o_i|$ 平均——这个差别会在第 11.5.2 节回到。

GSPO 把重要性比率从 token 级换成序列级：

$$\rho_i(\theta) = \left(\frac{\pi_\theta(o_i \mid x)}{\pi_{\theta_{\text{old}}}(o_i \mid x)}\right)^{1/|o_i|}, \tag{11.20}$$

指数 $1/|o_i|$ 把序列概率开方到“每 token 平均”，使比率的单位与序列奖励一致，裁剪也在序列级进行。它的动机是 token 级比率在长序列上方差过大。

Dr.GRPO 去掉两处归一化：一是式 (11.7) 里的除以 s_r，二是逐条回答的 $1/|o_i|$。改动后的优势退化为

$$\hat{A}_i^{\text{DG}} = r_i - \bar{r}, \tag{11.21}$$

理由是：除以 s_r 会让方差小的组（过易或过难的题）获得更大的梯度，这与“难题更值得学”的直觉相反；除以 $|o_i|$ 则让短回答的每个 token 权重更大，与“长链推理应该被鼓励”冲突。表 11-3 把三者与 GRPO 并列。

表 11-3 四个方法的改动点。三行“改动的组件”互不重叠，实践中常被组合使用；表中“主张解决的症状”是各文作者给出的动机，不是已证实的因果。

SUMMARY / 总结

方法	改动的组件	具体做法	主张解决的症状
GRPO	—	式 (11.7)、式 (11.9) 原样	无 critic 的优势估计
DAPO	采样 + 裁剪	动态采样式 (11.18)、clip-higher 式 (11.19)	零优势批与探索不足
GSPO	比率的单位	序列级比率式 (11.20)	长序列上 token 级比率方差大
Dr.GRPO	归一化	去掉 s_r 与 $1/\lvert o_i\rvert$，式 (11.21)	难度与长度偏置

11.5.2 开放问题

长度归一化到底该按什么平均，目前没有定论。式 (11.9) 用 $1/\lvert o_i\rvert$ 逐条平均，等价于给每个 token 权重 $1/(G\lvert o_i\rvert)$，短回答的 token 权重更大；改成按整批 token 总数平均，则每个 token 权重相同，总梯度更偏向长回答：

$$w_t = \frac{1}{G\,|o_i|} \quad \text{对} \quad w_t = \frac{1}{\sum_{j=1}^{G}|o_j|}, \tag{11.22}$$

前者是逐条平均，后者是整批平均。两种权重只在 $\lvert o_i\rvert$ 全相同时一致。它们在不同的长度分布下给出不同的有效学习率，**这是优化器的选择问题，不是奖励设计问题**，却常常被混为一谈。

当前仍有三个开放问题。推理长度与正确率的相关性会随任务、模型规模和训练阶段变化，尚无可迁移的规律。可验证奖励扩展到主观任务时，常将规则用于可验证部分、将偏好用于主观部分，但两类奖励的权重缺少原则性依据。离线蒸馏与在线 RL 的关系也未充分刻画：R1 第 ③ 阶段以拒绝采样构造 SFT 数据，效果接近一次 RL，提示数据筛选与策略优化可能在同一批样本上产生相近作用。两者等价的条件仍有待研究。

SUMMARY / 总结

本章小结

本章讨论可验证奖励的判定机制及其在策略优化中的作用。式 (11.1) 至式 (11.3) 刻画判定器奖励与真实正确率之间的关系：误判会改变奖励尺度；当假阳率与假阴率之和小于 1 时，期望判定奖励仍随真实正确率递增。答案等价形式处理、证明题判定与结果抽取规则是常见误差来源。序列级二值奖励只为整条回答提供一个标量，无法单独识别各 token 对结果的贡献；当同一提示下所有样本奖励相同时，组内相对优势为零，动态采样可用于增加奖励有差异的样本组。

GRPO 的主要设计包括组内相对奖励、优势归一化和 KL 正则。组均值包含当前样本奖励，因此在式 (11.12) 的 on-policy、组内独立同分布与单步更新条件下，期望梯度按 $(1-1/G)$ 缩放；除以组内标准差后，有限组大小下通常不再是无偏优势估计。GRPO 与 PPO 在优势来源、归一化方式和 KL 项位置上存在差异（式 (11.9) 与式 (10.7)）。长度变化、熵下降、奖励利用及 pass@1 与 pass@k 的差异属于经验观察，尚无一般理论保证。

关键公式

下面这几条串起了全章的主干：可验证奖励的定义、判定器偏差的线性形式、组内标准化的两个统计量、GRPO 的目标，以及组内基线相对真正基线恒等式的偏离。把它们按顺序读一遍，也就把 11.1 与 11.2 重走了一遍。

可验证奖励，式 (11.1)：

$$r(x,y) = V(x,y) \in \{0,1\}$$

判定器误差对期望奖励的线性影响，式 (11.2)：

$$\mathbb{E}[V] = \alpha + (1-\alpha-\beta)\,p$$

组均值与组标准差，式 (11.6)：

$$\bar{r} = \frac{1}{G}\sum_{j=1}^{G} r_j, \qquad s_r = \sqrt{\frac{1}{G}\sum_{j=1}^{G}(r_j-\bar{r})^2}$$

组内标准化优势，式 (11.7)：

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r + \varepsilon_{\text{num}}}$$

SUMMARY / 总结

token 级比率，式 (11.8)：

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} \mid x, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid x, o_{i,<t})}$$

GRPO 目标，式 (11.9)：

$$J^{\text{GRPO}}(\theta) = \mathbb{E}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\Big(\min\big[\rho_{i,t}\hat{A}_i, \text{clip}(\rho_{i,t}, 1-\varepsilon_{\text{clip}}, 1+\varepsilon_{\text{clip}})\hat{A}_i\big] - \beta_{KL}\widehat{D}_{KL}(i,t)\Big)\right]$$

减基线不改变期望梯度，式 (11.12)：

$$\mathbb{E}\big[(r_i - b)\nabla_\theta \log \pi_\theta(o_i \mid x)\big] = \mathbb{E}\big[r_i \nabla_\theta \log \pi_\theta(o_i \mid x)\big]$$

pass@k 的无偏估计，式 (11.16)：

$$\widehat{\text{pass@}k} = \mathbb{E}_x\left[1 - \frac{\binom{n-c(x)}{k}}{\binom{n}{k}}\right]$$

习题

1. 证明式 (11.12) 的两条式子：对任意不依赖 o_i 的常数 b，减基线不改变期望梯度；把 b 换成组均值 $\bar{r}$ 后，期望梯度变成原来的 $(1 - 1/G)$ 倍。说明为什么第二式**不**是“基线恒等式”（$\bar{r}$ 依赖 r_i），并指出 $G = 1$ 时会发生什么。

2. 设 $G = 6$、奖励为 0/1 且恰有 c 条正确。写出 $\bar{r}$、s_r 与标准化后两个取值的解析式，并画出它们随 c 变化的曲线。解释为什么 $c = 6$ 与 $c = 0$ 都要掩掉。

3. 用式 (11.2) 说明：若判定器假阳率 $\alpha = 0.1$、假阴率 $\beta = 0.05$，真实正确率 $p = 0.6$ 的回答期望奖励是多少？若策略可以提高 p 也可以提高“被误判的概率”，它更愿意做哪一件事？给出定量比较。

4. 在 11.4.4 的三臂模型里把格式分从 0.5 改成 0.2，预测策略最终落在哪个臂、判定器奖励与真实正确率各是多少，并用实验验证（改动 `figures/ch11_figs.py` 中 `f05_false_positive` 的参数）。

5. 推导式 (11.17)。若希望组均值的标准差降到单条奖励标准差的十分之一，需要多大的 G？这个代价在什么情况下不划算？

6. 说明 GSPO 的序列级比率式 (11.20) 与 token 级比率式 (11.8) 在什么条件下近似相等（提示：考虑对数概率与 $|o_i|$ 的关系），并解释指数 $1/|o_i|$ 的

作用。

7. 构造一个例子说明 pass@1 与 pass@k 可以反向变化：给一个提示分布与两组回答（每组 $k = 8$ 条），使 A 组的 pass@1 更高而 B 组的 pass@8 更高。这个例子对“只报一个指标”的评估协议意味着什么？

延伸阅读

- Shao 等《DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models》（2024）第 4 章是 GRPO 的原始出处：4.1.1 节从 PPO 推到 GRPO，4.1.2 与 4.1.3 节分别给出 outcome supervision 与 process supervision 两种优势设定，4.2 节讨论统一范式。本书第 11.2 节的记号与它一致，式 (11.9) 即该文的目标函数。
- DeepSeek-R1（Guo 等, 2025）的多阶段流水线与“纯 RL 可诱导推理”的结论，可对照综述 `2407.16216_rl-for-llm-post-training-survey.txt` 第 2.5.2 节（R1 四阶段）与第 2.5.3 节（GRPO 的改进谱系）阅读；该综述第 5 章把 dynamic sampling、非对称裁剪与序列级比率放在同一张表里比较。
- Yu 等关于 DAPO 的工作（2025）与 Zheng 等关于 GSPO 的工作（2025）分别给出式 (11.18)–(11.16) 的完整动机与消融；Liu 等的 Dr.GRPO（2025）给出了去掉 s_r 与 $1/|o_i|$ 的梯度分析，是理解式 (11.21) 的最短路径。
- 第 5 章 5.4 节介绍比率与裁剪，第 10 章 10.2 节说明 KL 项与参考策略。对照式 (11.9)、(5.25) 和 (10.7)，可以区分由语言模型训练形式和组内标准化分别带来的变化。
- 若想看清“判定器即奖励”这一视角的边界，可回读第 10.1 节关于奖励模型过优化的讨论，再对照本章 11.1.2 的式 (11.2)：两个框架里的失效机制是同一条——优化的是代理量而不是目标量。

第 12 章　Agentic RL 与持续学习

第 10 章与第 11 章讨论的都是“一次回答”：给提示、生成一条回复、末端给奖励。这套设定能推出干净结论，是因为它把一整个回合压成了一个动作。本章拆掉这个压缩——模型开始调工具、读观测、在几十步里推进任务时，目标函数、状态定义与终止判定都不再够用。

拆掉之后并非一切都要重写。回报仍是奖励之和，策略梯度仍然成立，第 5 章的 REINFORCE 与第 10 章的 KL 正则可以原样搬进来。搬不动的是**关于收敛与稳定性的结论**：状态转移不再由策略单独决定，回合长度不再平稳，奖励不再只在末端。所以本章要答的不是“用哪个算法”，而是“哪些对象变了、哪些保证失效”：先形式化，再分类，最后谈工程。所有结论只按能站住的程度标注，形式化部分 [精确]，遗忘与权衡 [经验规律]，没有定理支持的“会更稳”一律不写。

> 导读
>
> **问题**：一次回答变成一个回合、一次训练变成一串任务时，哪些对象变了、哪些保证失效。**先修**：第 2 章 MDP 与终止状态、第 4 章离策略、第 5 章策略梯度、第 9.1 节选项、第 10.2 节 KL 正则。**主要来源**：Sutton & Barto 第 3、17 章；source/text/2407.16216「Extensions」；source/text/2509.16679 §4.5；ReAct、Reflexion、EWC。**资料截止日**：2026-10-19。此后出现的 agent 训练框架只进研究框，不作定理依据。

12.1 从单次回答到多步交互

12.1.1 一次回答与一个回合

第 10 章的目标是

$$J_{\text{single}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)}\big[r(x,y)\big], \tag{12.1}$$

其中 x 是提示、y 是整条回复、r 是奖励模型或可验证奖励。式 (12.1) 的关键性质是：**动作空间与输出空间是同一个东西**——一次生成就是一次决策，奖励只在末端发放一次，回合长度完全由策略自己决定。第 10.2 节与第 11 章的推导都依赖它：逐 token 摊派奖励（式 (10.7)）、组内标准化优势、KL 的序列级到 token 级分解。一旦中间出现工具调用与观测返回，这三条都会松动。

多步交互的最小模型是：模型生成一段文本或发出一个工具调用，环境

执行后返回观测，观测被追加进上下文，模型基于更长的上下文继续，循环到任务完成或预算用尽。此时的回报是整条轨迹的函数

$$R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t, \tag{12.2}$$

其中 $\tau = (h_0, a_0, o_0, a_1, o_1, \ldots, a_{T-1})$，$h_0 = x$ 是初始提示，r_t 是第 t 步奖励。图 12-1 对照展示了两种设定。

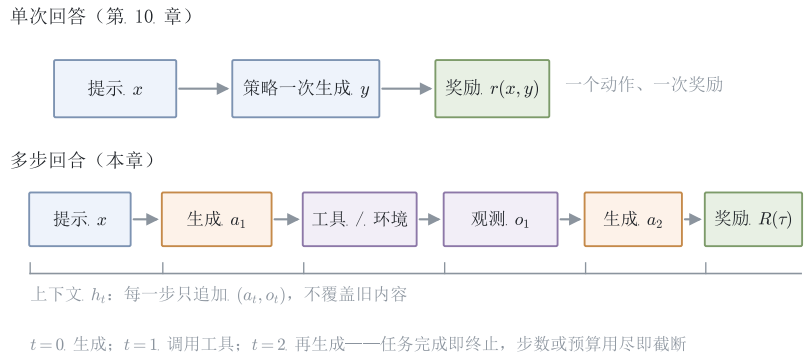


图 12-1 单次回答与多步回合的对照。上：一个动作、一次末端奖励，回合长度等于回复长度。下：动作在“生成”与“工具调用”之间交替，每步的观测被追加进上下文，奖励可以逐步发放；终止由任务完成决定，截断由步数或预算上限决定。

变化有三处，每一处都破坏一个既有结论。

最明显的一处是动作空间。回合里的动作有两类：生成一段 token，或发出一个工具调用（检索、执行代码、读写文件）。前者长度可变，后者离散、参数结构化，塞进同一个策略就必须显式建模动作类型。不能假装所有动作都是 token：工具调用的参数错误与措辞错误是两类失败，混在一起，奖励设计立刻失焦。

第二处是状态。上下文按式 (12.3) 只增不减地增长，而单次回答里没有外部信息进入，那条路在生成中是例外而非常态。同一个物理状态可以对应长度不同的上下文，策略的判断会随历史长度漂移；上下文又是有限资源，截断历史等于换了状态定义（12.5 节再谈）。

$$h_{t+1} = h_t \oplus (a_t, o_t) \tag{12.3}$$

第三处是终止。任务完成是环境给的事件，步数上限或预算耗尽也是事件，两者都能结束回合，含义却相反：前者之后没有价值，后者之后还有价值、只是没时间了。单次回答里看不到这个区别，回合里它决定自举项要不要保留。

SUMMARY / 总结

这三处变化各自推翻一条 token 级结论。“给定策略即给定转移核”（式 (2.1)）要改成“给定策略与环境的联合分布”，而后者通常非平稳；奖励不再只在末端，因此 ORM 只覆盖末端、PRM 覆盖中间步，而中间步往往最难标注；动作粒度与 token 不对齐，同样的梯度尺度被分给“关键的一步”与“礼貌性的复述”，第 11 章说的 credit assignment 更粗。结论不是“token 级方法没用”，而是：**有一步以上交互时需要显式的步级结构**（步级状态、奖励与优势），否则算法仍能跑，但“为什么有效”不再是第 10 章的解释。

12.1.2 三条失效的结论

把上面的话说得更具体，有三条结论在回合里不成立。

状态转移不再是策略的副产品：工具返回什么、多快返回、格式对不对都由环境决定，环境自身的版本与可用性也在变，因此任何“给定策略即给定 MDP”的推导都要补一句“环境平稳”。奖励不再只在末端：中间步可以有奖励，也可以完全没有，直接套末端奖励会让方差随步数增长，第 10.2.2 节“把稀疏奖励挂在最后一个 token 上”的做法则失去对象。优势的尺度也不再可比：一步工具调用可能等价于几十个 token 的推理，也可能什么也没做，均匀尺度会把梯度分给“关键的一步”与“礼貌性的复述”——第 11 章说过信用分配很粗，这里是放大版。

三条合起来只说明一件事：回合级算法需要一个显式的步级模型，哪怕它只是“最后 k 步的价值头”。

12.1.3 terminated 与 truncated：为什么在回合里更要紧

第 2 章与全书的约定（`content/_CONVENTIONS.md` 第 1.2 节）只有两句话：terminated 是 MDP 进入终止状态，此时 $V(\text{terminal}) = 0$ 且自举停止；truncated 是因时间上限、采样预算或系统条件中断，此时自举继续，用 mask 保留 bootstrap。表格型问题里这两者的差别常被“回合都很短”掩盖；agent 任务里它直接决定价值估计的偏差方向。

把一步的自举目标写成带 mask 的形式：

$$y_t = r_t + \gamma \left(1 - d_t^{\text{term}}\right) V_\phi(h_{t+1}), \tag{12.4}$$

其中 $d_t^{\text{term}} \in \{0, 1\}$ 只在**真正终止**时取 1，截断时取 0。对应的截断回合回报是

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k} + \gamma^{T-t} V_\phi(h_T)\,\mathbf{1}\{\text{truncated}\}, \tag{12.5}$$

第二项只在截断时出现：式 (12.5) 与式 (12.4) 是同一件事的两种写法——前者说“没走完的尾巴用价值估”，后者说“没终止就别把自举关掉”。

把截断当终止，后果可算。设真实回报的尾巴期望为 v，错误处理把它记成 0，价值估计就系统性偏低约 $\gamma^{T-t}v$。偏差不是随机的：步数上限越紧、任务越长，偏差越大，而且偏向**短回合**——模型学到“早点结束比较划算”，表现为草率收尾。反过来把终止当截断，则在本该归零的状态上继续自举，价值会被“死循环”式的后继状态污染。

工程上，`terminated` 与 `truncated` 必须是环境返回的两个布尔量，不能在数据管线里合并成 `done`：一旦合并就无法恢复，“哪一步因预算而断”这个信息已经丢了。

SUMMARY / 总结

12.2 Agentic 循环的形式化

12.2.1 状态、动作与转移的分解

把 12.1 节的描述写成元组。状态取

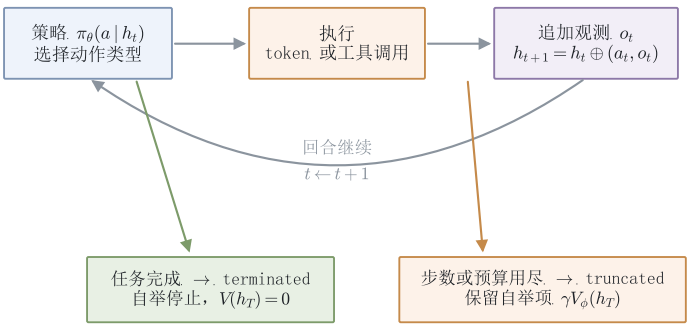
$$s_t = (h_t, e_t), \tag{12.6}$$

其中 h_t 是上下文，e_t 是工具或环境的内部状态（文件树、浏览器会话、代码运行时）。策略只观测 h_t、看不到 e_t，所以这是**部分可观测**的（POMDP）：$V_\phi(h_t)$ 估计的是观测而非状态。动作 a_t 要么是生成的 token，要么是带参数的工具调用。转移分两步：

$$P(o_t, e_{t+1} \mid h_t, e_t, a_t) = P_{\text{env}}(e_{t+1}, o_t \mid e_t, a_t), \qquad h_{t+1} = h_t \oplus a_t \oplus o_t.$$

下一步的分解用了两条独立性：环境的演化 P_{env} 只依赖 (e_t, a_t)、与上下文无关；h_{t+1} 由 (h_t, a_t, o_t) 确定性拼接。没有第一条，$\pi_\theta(a \mid h_t)$ 与 P_{env} 不能相乘成联合转移。

第一步由策略决定（$a_t \sim \pi_\theta(\cdot \mid h_t)$），第二步由环境决定（工具的执行结果既改变 e，也作为观测 o_t 进入 h）。图 12-2 画出这个循环与它的两个出口。



两个出口必须分开记账：把截断当终止会系统性低估长回合的价值。

图 12-2 Agentic 循环。策略在“生成”与“工具调用”两类动作之间选择，观测被追加进上下文后回到策略；任务完成走 terminated 出口（自举停止），步数或预算用尽走 truncated 出口（保留自举项）。

这里有一个不对称：P_{llm} 可微可采样，P_{env} 不是，所以对 a_t 求梯度时只有第一项有梯度。这与第 9.1 节的选项相似，但选项时长由终止函数决定、可以学，这里由环境与预算决定、不能学。

SUMMARY / 总结

12.2.2 三条“不能直接套用”

有三条路走不通，原因各不相同。

把整条轨迹当成一个动作、只给末端奖励再套式 (12.1)，在奖励只依赖结果时可行，但中间决策被合并成黑箱：梯度只会说“整体不错”，说不出“第 3 步的检索是多余的”。把每步压成一个“超级 token”去套第 11 章的 token 级 PPO，问题就移到优势估计上——token 级优势依赖价值函数对“当前前缀”的估计，而前缀里混着观测，价值头没在这种输入上训练过；用分布外输入自举，偏差还会被 γ 放大（第 4.3 节结论的另一种形态）。假设回合长度有界且平稳同样危险：长度受超时、限流、任务难度影响会漂移，任何依赖“固定 T”的推导都不安全，除非把 T 当随机变量。

三条合起来只有一个结论：回合级算法需要显式的步级模型，哪怕很粗糙（只看最后 k 步的价值头也算）。没有它，第 10、11 章的算法仍能训练出可用策略，但“为什么能收敛”的论证不再成立。

12.2.3 两条代表路线

ReAct（Yao 等, 2023, ICLR）把“推理”与“行动”交错：先写内部推理，再发工具调用，拿到观测后继续，一次前向同时产出思考与动作。ReAct 是**上下文内适应**（第 12.3 节）的极端形式：全部“学习”都在上下文里，参数一步没动。

Reflexion（Shinn 等, 2023, NeurIPS）在回合结束后复盘并写进外部记忆，下次读回来：比 ReAct 多一步“跨回合”。但参数依然没动——按本书定义它是**记忆更新**，不是持续学习；遗忘曲线对它没有意义，因为记忆不会被参数更新覆盖。

12.2.4 把回合放回已有的算法框架

要用参数更新改进 agent，可行的做法是在回合级套用已有算法。轨迹级策略梯度写成

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}\Big[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid h_t)\, \hat{A}_t\Big], \tag{12.7}$$

式 (12.7) 里与每步梯度相乘的是步级优势估计，形式同第 5 章的 REINFORCE，区别在来源：回合级回报均摊、步级价值函数（需式 (12.4) 的 mask）、或第 10.2.3 节的过程奖励。三者偏差与方差不同，但都属 [近似]。

SUMMARY / 总结

12.3 四类“适应”的判别

12.3.1 一个统一写法

“适应”这个词在 agent 语境里被用得很松。为了不再混用，本节给出一个统一写法：把一次适应写成作用在三元组上的算子

$$\mathcal{U}:\ (\theta, M, h) \longmapsto (\theta', M', h'), \tag{12.8}$$

其中 θ 是策略参数，M 是外部记忆或存储，h 是当前上下文。四类适应的差别，就是这三个分量里**哪一个被改写**。图 12-3 给出判别顺序：先问参数变不变，再问存储写不写，最后问是否要求跨任务不遗忘。

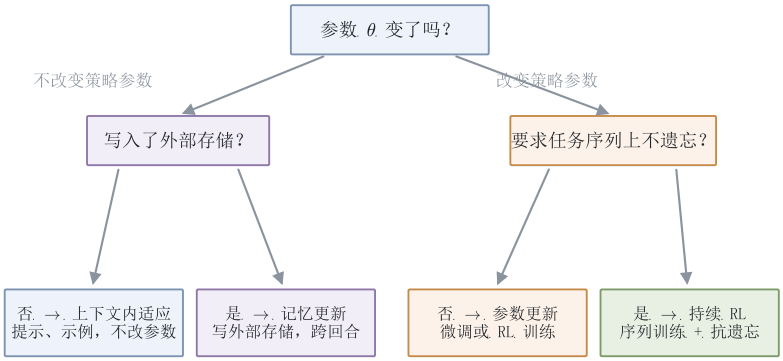


图 12-3 四类适应的判别。根节点问参数是否改变；参数不变时问是否写入外部存储，分成上下文内适应与记忆更新；参数改变时问是否要求任务序列上不遗忘，分成参数更新与持续 RL。只有右下角一类是严格意义上的持续学习。

12.3.2 上下文内适应：只改 h

上下文内适应不改变任何持久状态，只把信息放进当前上下文：

$$\theta' = \theta, \qquad M' = M, \qquad h' = h \oplus (\textbf{提示、示例、检索结果}). \tag{12.9}$$

典型例子是少样本提示与系统提示：把“先查文档再回答”的指令写进上下文，模型的行为立刻改变。将策略表示为“以完整上下文为条件的分布” $\pi_\theta(a \mid h)$ 时，改变 h 会改变行为分布，形式上相当于在扩展状态空间中评估同一个策略。由于这一过程**没有参数更新，也没有奖励驱动的优化**，它属于推理时的策略条件化，不属于训练意义上的 RL。这个区分很重要：它意味着上下文内适应不会遗忘（旧上下文不覆盖参数），也不会泛化到没见

过的上下文模式。

12.3.3 记忆更新：改 M

记忆更新把信息写进外部存储，在后续回合检索回来：

$$M_{k+1} = M_k \oplus m_k, \qquad r_t = \mathrm{Ret}(M_k, h_t), \tag{12.10}$$

其中 m_k 是本回合要写入的条目（复盘、摘要、事实），Ret 是检索函数。Reflexion 属于这一类。这一过程是否构成 RL，取决于写入内容是否由回报驱动。只在成功回合写入或按回报筛选条目，属于策略改进；无差别地存储全部轨迹则属于缓存。判断依据是**是否依据奖励筛选记忆内容**。

12.3.4 参数更新：改 θ

参数更新是最熟悉的一类：

$$\theta_{k+1} = \theta_k + \alpha \nabla_\theta J_k(\theta_k), \tag{12.11}$$

其中 J_k 是第 k 个任务（或第 k 轮交互）的目标。第 5 章到第 11 章的全部算法都在这一格里。当 J_k 表示期望回报且梯度由采样估计时，这类方法属于 RL。这一类方法**不要求**跨任务保持性能；完成任务 2 的微调后，任务 1 的表现可能下降。

12.3.5 持续 RL：改 θ 且要求在序列上不退

持续 RL 是参数更新加上一个额外约束：参数要在任务序列上持续更新，同时不丢掉先前任务的能力。形式化成一个序列目标

$$\min_\theta \sum_{k=1}^{K} J_k(\theta) + \lambda\, \Omega\big(\theta, \theta^\star_{1:k-1}\big), \tag{12.12}$$

其中 $\Omega(\theta, \theta^\star_{1:k-1})$ 是对**历史锚点集合**逐项求和：$\sum_{j<k} \frac{\lambda}{2} (\theta - \theta^\star_j)^\top F_j (\theta - \theta^\star_j)$（式 12.14 就是只取一项的两任务特例）。

其中 Ω 是约束项，$\theta^\star_{1:k-1}$ 是先前任务的解：12.4.2 节的三类对策就是 Ω 的三种实现——正则把它写成参数距离，回放把它写进数据，参数隔离把它写进网络结构。与式 (12.11) 的唯一差别是这一项；没有它，“持续”就退化成“顺序微调”。

四个分支的差别可以用五列说清。表 12-1 逐行对比：状态（信息放在哪）、动作（策略看到什么）、奖励（有没有回报驱动）、更新对象（改什么）、参数是否改变。

SUMMARY / 总结

表 12-1 四类适应的五列对照。“奖励”一列问的是有没有回报驱动的选择，而不是有没有奖励信号；“更新对象”一列决定遗忘是否可能发生——只有改 θ 的两行才需要第 12.4 节的对策。

类别	状态	动作	奖励	更新对象	参数改变
上下文内适应	h（本次会话）	提示后的策略	可无（用回报挑示例）	无（只改 h）	否
记忆更新	(h, M)	带回溯检索的策略	常有（决定写什么）	M（外部）	否
参数更新	(h, θ)	π_θ	有（J_k 的期望）	θ	是
持续 RL	(h, θ) 加序号	π_θ	有（含跨任务项）	θ（受 Ω 约束）	是

表 12-1 的两条读法值得强调。其一，**只有改参数的两行会出现灾难性遗忘**：上下文与记忆不覆盖参数，旧能力不会因为新信息而消失（记忆会变脏，但那是检索问题）。其二，**“是不是 RL”与“是不是持续学习”是两个独立的问题**：上下文内适应可以借回报挑示例（有 RL 成分，但不是持续学习），持续 RL 一定是 RL 且一定要求抗遗忘。把这两问混在一起，就会出现“我们的 agent 会持续学习”这类无法证伪的说法。

SUMMARY / 总结

12.4 持续学习与遗忘

12.4.1 遗忘从哪里来

灾难性遗忘指参数更新后旧任务性能大幅下降。它有三个来源，各对应一种机制，值得分开数。

第一个是分布漂移：新任务的数据分布与旧任务不同，梯度方向与旧任务的最优方向冲突。线性情形下这个冲突可以精确写出——设旧损失在 $\theta^\star_{\text{old}}$ 处有 Hessian H_{old}，参数移动 $\Delta\theta$ 后旧损失增量约为

$$\Delta L_{\text{old}} \approx \tfrac{1}{2}\,\Delta\theta^\top H_{\text{old}}\,\Delta\theta, \tag{12.13}$$

H_{old} 特征值越大，那个方向上的“记忆”越硬，越容易被新梯度抹掉。这个二次近似 [近似] 只在 $\Delta\theta$ 小时成立，却已足够解释遗忘为什么是方向性的：有些参数改一点就出事，有些改很多也无所谓。

另外两个来源不在参数度量上。表征覆盖是指共享隐藏层被新任务重写：旧任务输出头可能完好，输入特征却被改掉，遗忘表现为“输入的含义变了”而不是“输出错了”——这解释了为什么 linear probing 几乎不遗忘、全参数微调遗忘严重。目标位置则是更根本的一条：式 (12.11) 里根本没有旧任务，“保住旧性能”不在优化者考虑范围内。这不是 bug，而是目标写错了地方；希望不遗忘，就得把它写进目标（式 (12.12) 的 Ω）或数据（回放）。

12.4.2 三类对策

正则化。 代表是 EWC（Kirkpatrick 等, 2017, PNAS），在损失里加按重要性加权的二次惩罚：

$$L_k(\theta) = L_k^{\text{data}}(\theta) + \frac{\lambda}{2}\sum_i F_i\left(\theta_i - \theta_i^\star\right)^2, \tag{12.14}$$

其中 F_i 是 Fisher 信息对角元，衡量第 i 个参数对旧任务有多重要：

$$F_i = \mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{old}}}\left[\left(\partial \log p_\theta(y\mid x)/\partial\theta_i\right)^2\right]. \tag{12.15}$$

式 (12.14) 只写了两任务单锚点形式（任务 $k-1\to k$）。多任务时按 Fisher 逐任务加权求和，两个二次惩罚相加仍是二次惩罚；但“把 Fisher 累加成一个、再配单锚点”只是近似：$\sum_k \lambda_k F_k(\theta-\theta_k^\star)^2$ 展开后的中心是 F-加权平均 $\bar\theta$，而不是任一 $\theta_k^\star$，两者只差一个常数项——代价是“锚点”的含义

变了，不能再逐任务单独回滚。前提是 Laplace 近似：后验近似为以 $\theta^\star$ 为均值、Fisher **对角**为精度的高斯；对角化丢掉参数相关性，二次型只在 $\theta^\star$ 邻域内可信。

直观看，式 (12.14) 用 F 给每个参数装了一根“弹簧”：重要的被拉住，不重要的自由移动。问题是 F 只在一个点上估计，对参数空间的其他区域没有约束；任务差异大时，弹簧刚度选小了没用、选大了学不动新任务。第 10.2 节的 KL 正则 $\beta_{KL} D_{KL}(\pi \| \pi_{\text{ref}})$ 与它共享同一个直觉，但作用空间不同：EWC 约束参数距离，KL 约束输出分布。这是类比而非等价——不能把“二次惩罚只在 $\theta^\star$ 邻域可信”这条搬给 KL；参考策略取代了 Fisher 矩阵，惩罚落在输出分布上，因此它能保护“参考策略具备的能力”而不必逐参数度量重要性。

回放。 保留一小部分旧数据（或旧数据的生成样本），每次更新时与当前数据混合：

$$L_k(\theta) = L_k^{\text{data}}(\theta) + \beta \mathbb{E}_{(x,y)\sim\mathcal{M}}\big[\ell\big(f_\theta(x), y\big)\big], \tag{12.16}$$

其中 $\mathcal{M}$ 是记忆缓冲区。在本章实验里回放最有效（[经验规律]，见 12.4.4）：它直接约束“在旧数据上仍要表现好”，不绕道参数距离；收益随缓冲区与任务相似度变化，无一手文献支持“放之四海最有效”。代价是存储与隐私。

参数隔离。 给每个任务一组独立（或部分独立）的参数，例如低秩适配器（LoRA）或模块化网络。任务之间不共享可写参数，干扰从结构上被切断。代价是容量与推理成本随任务数增长，且任务边界必须已知——真实部署里往往不成立。

三类对策的取舍可以用四个维度对比，见表 12-2。

表 12-2 三类抗遗忘对策的对照。四列都是工程约束，不是理论优劣；实践中常见的是回放加轻量正则的组合。

对策	需要旧数据	额外存储	对任务边界的假设	主要失效模式
正则化（EWC）	否（只要 Fisher）	$O(\lvert\theta\rvert)$	需要知道何时切换任务	弹簧刚度过大导致学不动
回放	是（样本或生成样本）	$O(\lvert\mathcal{M}\rvert)$	不需要	缓冲区太小、旧样本失真
参数隔离	否	$O(K\lvert\theta_{\text{adapter}}\rvert)$	需要知道任务编号	任务数增长后容量与调度

12.4.3 任务序列与评估协议

SUMMARY / 总结

有了对策还需要能比较。评估协议由三样东西定义：任务序列、每个任务训练完后的测试矩阵、以及从矩阵算出的三个数。

设 $a_{k,j}$ 是“学完第 k 个任务之后，在第 j 个任务上的性能”（本书取负的 MSE 或成功率，越大越好），K 个任务依次训练，全程只测不训练。两个指标是

$$\mathrm{ACC} = \frac{1}{K}\sum_{k=1}^{K} a_{K,k}, \tag{12.17}$$

$$\mathrm{BWT} = \frac{1}{K-1}\sum_{k=1}^{K-1}\left(a_{K,k} - a_{k,k}\right). \tag{12.18}$$

ACC 是学完所有任务后在全部任务上的平均性能；BWT（backward transfer）衡量旧任务被后来的训练改变了多少：为负表示遗忘，为正表示后学的任务帮了前面的任务。第三个指标 FWT（forward transfer）衡量“没学之前就会多少”，定义为 $a_{k-1,k}$ 相对随机初始化基线的差值，只在正文给出、不单列编号。

三个数要一起看：一个方法可以 ACC 很高但 BWT 很负，也可以在 BWT 上占优而 ACC 落后；只报 ACC 不可比，它没说清“新任务学得怎么样”与“旧任务保住了多少”。

12.4.4 一个可复现的遗忘实验

为了让讨论有数字，本节给一个小规模实验：三个定义在**不相交输入区间**上的一维回归任务（$[0, 0.3]$ 拟合 $\sin(2\pi x)$，$[0.35, 0.65]$ 拟合 $1 - 2x$，$[0.7, 1]$ 拟合 $0.3 + 0.4\cos(2\pi x)$），模型为两层 32-tanh 网络，每任务 40 点、Adam（0.01）400 步，评估 120 点网格、5 个种子（1000–1004）。三种设置：无防护顺序微调、EWC（$\lambda = 10$）、回放（每任务留 40 点，混合 0.5）。

结果见图 12-4。左图：任务 1 的 MSE 无防护时从 1.1×10^{-4} 涨到 4.2，即学完任务 3 后任务 1 的预测彻底失效；EWC 只压到 2.6，量级上仍失败；回放稳在 1.2×10^{-3}。右图：学完任务 3 后在整段输入上的预测，无防护的曲线在前两个区间上几乎是任意形状，回放与真值基本重合。

这三个数字各说一件事。EWC 在这个设定下远不如回放（与本章实验一致，不作文献通例）：区间不相交时 Fisher 的单点估计失准。回放的代价落在末任务上：末任务 MSE 是 7×10^{-4}，比无防护的 1.1×10^{-4} 还差。三种

设置的 ACC 分别是 -1.54、-0.94、-0.003，只有回放接近零。

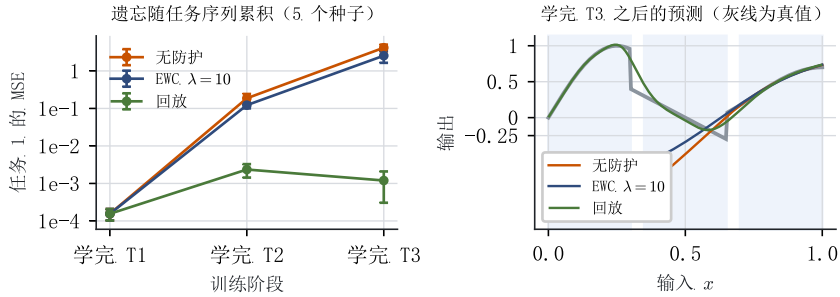


图 12-4 三类设置的遗忘曲线（真算，5 个种子，均值）。左：任务 1 的 MSE 随阶段累积上升（对数刻度，误差棒为一个标准差）；右：学完任务 3 后的整段预测，灰线为真值。

12.4.5 稳定性—可塑性权衡

把 EWC 的正则强度当旋钮：$\lambda \in \{0.3, 1, 3, 10, 30, 100\}$ 各跑 5 个种子，看得图 12-5 的权衡。

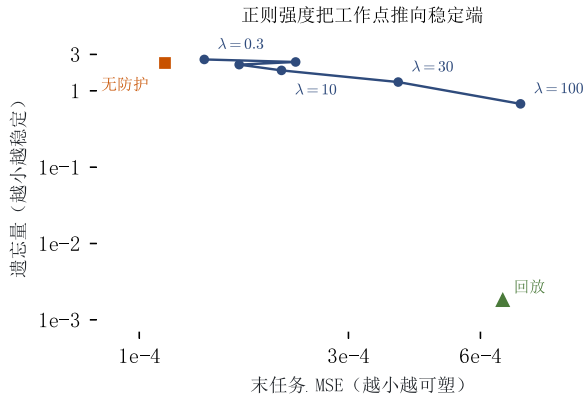


图 12-5 稳定性—可塑性权衡（真算，5 个种子）。横轴末任务 MSE（可塑性代价），纵轴遗忘量（稳定性收益），两轴对数刻度；蓝线为 EWC 的 λ 从 0.3 到 100 的工作点轨迹，橙方块为无防护，绿三角为回放。

曲线单调：λ 从 0.3 到 100，遗忘量 $2.58 \to 0.67$，末任务 MSE $1.4 \times 10^{-4} \to 7.4 \times 10^{-4}$。**两个目标竞争**，没有哪个 λ 同时取到两端；回放（绿三角）靠数据约束而非参数约束，越过了帕累托前沿。

这条结论是 **[经验规律]**：只在小回归序列上成立，但给出可检验的预测——只靠参数正则的方法都要在“更不忘”与“更学得动”之间付代价；若报告“两者都提升”，先查基线是否同步变强。

SUMMARY / 总结

12.5 工程与未解问题

12.5.1 长时程信用分配

回合越长，信用分配越难，这一点没有巧妙的解法，只有三种工程折中。步级价值函数是最直接的一种：给每步估计 $V_\phi(h_t)$，用式 (12.4) 的 mask 算优势；它降方差，但引入价值函数的近似误差，而价值函数最容易在分布外的观测上出错。过程奖励用第 10.2.3 节的 PRM 给中间步打分，信号密集，代价是标注成本与歧义随步数增长，模型还会学会迎合标注粒度。结果奖励加回溯只在末端给奖励，训练后从成功轨迹里回溯“哪一步关键”，不需要额外标注，但需要大量成功样本，成功率低时样本效率极差。

三者不互斥，常见组合是“末端奖励 + 粗糙的步级价值 + 少量过程奖励”。它们的共同点是都只能给出 [近似] 的步级优势。

12.5.2 可复现性

Agent 实验的可复现性比单次回答差一个量级，原因有三个，都该写进实验记录。**外部依赖**：搜索结果会变、API 版本会变、网页会消失，同一条轨迹换一天跑不出来——办法是把观测连同时间戳记下来，回放时用记录而不是重跑。**超时与重试**：超时阈值决定“哪一步会失败”，失败会改变整条轨迹；不写清超时等于没写实验设置。**种子与采样**：温度、top-p、每步的工具选择都引入随机性，四件套（种子、样本数、置信区间、评估协议）一个不能省，缺项应写“未报告”而不是略去。

12.5.3 评估：成功率、步数与成本

Agent 的评估至少是三维的：任务成功率、平均步数、单位任务成本（token 数、工具调用数、墙钟时间）。只看成功率会奖励“用一百步硬试”，只看步数会奖励“一步就放弃”。实用做法是画成功率—成本的前沿：对每个方法扫一遍预算（最大步数或最大 token），比较曲线而不是单点。这与第 8.5 节的离线评估精神一致——单点数字在不同预算下不可比，协议比数字重要。

12.5.4 安全：不可逆动作

Agent 与聊天模型的根本差别是它有副作用：读文件安全，写文件、发邮件、下单、执行删除不可逆。这让探索的代价从“浪费算力”变成“造成真实损失”。常见的三类约束是沙箱（动作先在隔离环境执行）、权限（按

动作类型分级，危险动作需人工确认）、可回滚（保留快照）。它们都不是 RL 问题，但决定了 RL 能探索的动作空间——不能探索的策略无法靠试错学到东西。

12.5.5 三个没有定论的问题

到这里，三个问题仍然没有答案，而且都不是缺一个实验，而是缺一个定义。

回合级与 token 级的信用分配目前采用分层处理：先用回合级奖励训练步级价值，再据此计算 token 级优势；这一做法有工程经验支持，尚无理论保证。持续学习与在线 RL 的边界也尚未明确。工具升级或偏好改变等环境变化，可以描述为任务序列，也可以描述为非平稳环境；第 8 章讨论的非平稳性与本章讨论的遗忘现象，仍缺少统一的形式化框架。四类适应方式各有代价，目前也没有判据决定某项任务是否值得更新参数。工程中常采用先调整提示、效果不足时再微调的经验规则。

这些问题有一个共同的形状：保证在逐层减弱。表格方法有收敛定理，线性函数逼近有投影不动点（第 4 章），深度 RL 只有经验稳定性，到了 agent 与持续学习，连“什么是同一个任务”都要先定义。这不是学科的缺陷，而是问题变难的正常代价；写清每一层的前提，比追求统一“大理论”更有用。

SUMMARY / 总结

本章小结

本章拆掉的是第 10、11 章那个“一次回答”的压缩。差别不在长度，而在三处结构：动作空间变成混合的（生成与工具调用）、状态包含只增不减的历史、终止由任务与环境共同决定。式 (12.1) 的干净结论依赖这三处都不出现；一旦出现，token 级 MDP 的三条结论（末端奖励摊派、状态由策略决定、回合长度平稳）同时失效，回合级算法因此必须补一个显式的步级模型：步级状态、步级奖励、步级优势。terminated 与 truncated 也要分开记账，把截断当终止会系统性低估长回合的价值，偏差偏向短回合、表现为草率收尾，代码里必须是两个布尔量。

四类适应按“改什么”区分：上下文内适应只改 $\boldsymbol{h}$，记忆更新改 $\boldsymbol{M}$，参数更新改 $\boldsymbol{\theta}$，持续 RL 改 $\boldsymbol{\theta}$ 且要求在任务序列上不遗忘；只有后两类会出现灾难性遗忘。遗忘的三个来源（分布漂移、表征覆盖、目标只含当前任务）与三类对策（正则化、回放、参数隔离）大体一一对应，评估要用 ACC、BWT、FWT 三个数一起看，只报 ACC 不可比。稳定性与可塑性在参数空间里确实竞争：本章实验里 λ 从 0.3 增到 100，遗忘量从 2.58 降到 0.67，末任务 MSE 同时从 1.4×10^{-4} 升到 7.4×10^{-4}。这条权衡是 [经验规律]，不是定理。

关键公式

下面这几条按“一次回答→一个回合→一串任务”的顺序排列：两种回报、回合里必须补的掩码自举、回合级梯度、持续学习的目标与它的抗遗忘实现，最后是评估用的三个数。

单次回答与回合的回报：

$$J_{\text{single}}(\theta)=\mathbb{E}\big[r(x,y)\big],\qquad R(\tau)=\sum_{t=0}^{T-1}\gamma^{t}r_t.$$

掩码自举与截断回报（terminated 时 $d^{\text{term}}=1$，truncated 时为 0）：

$$y_t=r_t+\gamma\big(1-d_t^{\text{term}}\big)V_\phi(h_{t+1}),\qquad G_t=\sum_{k=0}^{T-t-1}\gamma^{k}r_{t+k}+\gamma^{T-t}V_\phi(h_T)\,\mathbf{1}\{\text{truncated}\}.$$

回合级策略梯度：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}\Big[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid h_t)\, \hat{A}_t\Big].$$

持续学习的序列目标：

$$\min_\theta \sum_{k=1}^{K} J_k(\theta) + \lambda\, \Omega\big(\theta, \theta^\star_{1:k-1}\big),$$

抗遗忘惩罚（EWC，式 (12.14)）：

$$L_k(\theta) = L_k^{\text{data}}(\theta) + \frac{\lambda}{2}\sum_i F_i\big(\theta_i - \theta^\star_i\big)^2.$$

评估三个数（$a_{k,j}$ 为学完任务 k 后在任务 j 上的性能）：

$$\text{ACC} = \frac{1}{K}\sum_{k=1}^{K} a_{K,k}, \qquad \text{BWT} = \frac{1}{K-1}\sum_{k=1}^{K-1}\big(a_{K,k} - a_{k,k}\big).$$

习题

12.1（终止掩码）某 agent 环境的步数上限是 $T_{\max} = 20$。现有代码在每一步都写 `done = (t == T_max)`，并在 `done` 为真时把自举目标置零。请指出这个写法在什么情况下是错的，写出修正后的目标式，并说明修正后价值估计的偏差方向。

12.2（截断偏差的量级）设真实回报的尾部期望为 $v = 1.0$，$\gamma = 0.99$，截断发生在第 10 步（即还剩 10 步的预算）。把截断当终止会低估多少价值？若 $\gamma = 0.999$ 呢？由此说明为什么长时程任务里这个错误更严重。

12.3（分类判别）对下列四个系统，判断它属于表 12-1 的哪一类，并说明理由：(a) 用少样本示例把“先检索再回答”的流程写进系统提示；(b) 把每次失败的轨迹摘要写进向量库，下次检索相似任务；(c) 在每个新任务上做 100 步 PPO 微调，任务之间不做任何约束；(d) 在任务序列上训练，并用 EWC 惩罚参数偏离。

12.4（EWC 的二次近似）设旧任务的损失在 $\theta^\star$ 附近可写成 $\frac{1}{2}(\theta-\theta^\star)^\top H (\theta-\theta^\star)$，新任务的梯度为常数 g。写出一步梯度下降后旧损失增量的表达式，并说明 H 的特征值分布如何决定“哪些方向不能动”。

12.5（BWT 的符号）用式 (12.18) 计算：若某方法在任务 1 上的性能从 $a_{1,1} = 0.8$ 掉到 $a_{3,1} = 0.5$，在任务 2 上从 $a_{2,2} = 0.7$ 掉到 $a_{3,2} = 0.6$，$K = 3$ 时 BWT 是多少？它是正还是负，对应“遗忘”还是“迁移”？

SUMMARY / 总结

12.6（预算与评估）两个 agent 在同一任务上：A 的成功率 72%、平均 8.3 步；B 的成功率 78%、平均 21 步。只报成功率会得出什么结论？如果按“每单位 token 成本的成功率”比较，还需要补哪些数据？请设计一个能同时反映成功率与成本的评估协议。

12.7（持续学习的目标）说明为什么式 (12.11) 的顺序微调在 K 增大时必然面临遗忘，而式 (12.12) 只是把这个冲突写进目标、并没有消除它。举一个反例说明“加了 Ω 就一定不忘”不成立。

延伸阅读

标了文件名的都在 `source/text/` 目录里，其余按作者与年份可查。读法建议：先读 2509.16679 的第 4.5 节建立“agent 训练有哪几块”的地图，再看 2407.16216 的「Extensions」一节里作者自己划在范围之外的问题。

- `source/text/2509.16679_rl-meets-llms-survey.txt`，第 4.5 节「Agents/Tool-use」：把工具与动作空间、长期奖励设计、agent 记忆分成三类并列出代表工作，是本章 12.1 – 12.2 节的组织依据。
- `source/text/2407.16216_rl-for-llm-post-training-survey.txt`，末节「Extensions: Frontiers Beyond Current Scope」：把多模态与 agentic RLVR、持续与跨语言对齐列为当前管线“不直接适用”的设定，与 12.2.2 节的三条“不能直接套用”呼应。
- Yao 等 (2023), ReAct: Synergizing Reasoning and Acting in Language Models, ICLR：推理与行动交错，本章归为上下文内适应的极端形式。
- Shinn 等 (2023), Reflexion: Language Agents with Verbal Reinforcement Learning, NeurIPS：复盘写进外部记忆、跨回合生效，本章归为记忆更新。
- Kirkpatrick 等 (2017), Overcoming Catastrophic Forgetting in Neural Networks, PNAS：EWC 的原始出处，式 (12.14) 与式 (12.15) 的来源。
- Korbak 等 (2022), On Reinforcement Learning and Distribution Matching for Fine-Tuning Language Models with No Catastrophic Forgetting, NeurIPS：从分布匹配角度解释 KL 正则为何能减轻遗忘，与 12.4.5 节互补。

SUMMARY / 总结

附录 A　符号表

上标写作 ^、下标写作 _；估计量一律带帽号或下标 φ，以示与真值不同

γ	折扣因子，0 ≤ γ < 1；不是学习率
λ	资格迹 / GAE 的迹参数；安全章的概率水平用 η
τ	轨迹 (s_0,a_0,r_1,⋯)；时间下标 t 是步
μ	行为策略（采样策略）；不表示均值
π	目标策略；π_old 是 PPO 的采样策略
π_ref	参考策略，KL 正则的中心
α	学习率；熵温度写作 α_ent，不与之共用
β_KL	KL 正则系数；1/β_KL 是逆温度
α_ent	最大熵 RL 的温度（SAC）
ε_greedy	ε-贪心的探索概率
ε_clip	PPO 的裁剪半径
ε_num	数值保护小量，不是算法参数
ρ_t	重要性比率 π(a_t|s_t)/μ(a_t|s_t)
δ_t	TD 误差 r_t + γV(s_{t+1}) - V(s_t)
G_t	从 t 起的折扣回报
G^λ	λ-回报 (1-λ)Σ λ^{n-1}G^(n)
V^π(s)	策略 π 下的状态价值（真值）
Q^π(s,a)	策略 π 下的动作价值（真值）
A^π(s,a)	优势 Q^π - V^π
V_φ, Q_φ	参数化的价值估计，不得当真值
Â_t	估计的优势；帽号必须写
V*, Q*	最优价值函数
d^π_γ(s)	折扣占用测度，总质量 1/(1-γ)
d_bar^π_γ(s)	归一化占用测度，总质量 1
T^π, T*	贝尔曼算子 / 最优贝尔曼算子
Φ	特征矩阵（满列秩）；V_θ = Φθ
D	加权分布矩阵（对角）；数据集写作 D_data
Π_D	D-内积下的投影 Φ(Φ^TDΦ)^{-1}Φ^TD
θ, φ	策略参数 / 价值参数
MSBE	未投影的均方贝尔曼误差
MSPBE	投影后的均方贝尔曼误差
TV	总变差距离
KL(p‖q)	KL 散度，方向必须写明

H(π)	策略熵
Z(x)	DPO 的配分函数 Σ_y π_ref(y|x)e^{r(x,y)/β}
r_φ(x,y)	奖励模型的输出
B	经验回放缓冲区；老虎机的臂数用 K
K	臂数（第 1 章）；状态数用 |S|
Regret(T)	T 步累积遗憾
UCB	置信上界索引
N(s), N(s,a)	访问计数
P(s'|s,a)	转移概率
r(s,a)	期望奖励
p(s'|s,a)	环境动力学（连续情形）
|S|, |A|	状态数 / 动作数
E	期望；下标写明所服从的分布
Var	方差
CVaR_α	条件风险价值（损失的上尾）
VaR_α	风险价值（分位数）
η	CVaR 的优化变量；也是安全章的概率水平
Q_tot	多智能体的联合动作价值
f(•)	QMIX 的混合网络
o_i	第 i 个智能体的局部观测
β_o	Option 的终止函数
I_o, π_o	Option 的初始集与内部策略
R_to	Decision Transformer 的回报条件（return-to-go）
ε	扰动 / 噪声，含义按上下文写明
σ²	方差；σ_r 是奖励标准差
Δθ	参数增量
grad	梯度

附录 B　公式索引

按章编号排列，数字为该公式所在页

(0.1) 20
(0.2) 20
(0.3) 20
(0.4) 20
(0.5) 21
(1.1) 28
(1.2) 29
(1.3) 30
(1.4) 31
(1.5) 32
(1.6) 32
(1.7) 33
(1.8) 33
(1.9) 34
(1.10) 35
(1.11) 35
(1.12) 36
(1.13) 37
(1.14) 37
(1.15) 37
(1.16) 37
(1.17) 40
(1.18) 40
(1.19) 40
(1.20) 41
(2.1) 45
(2.2) 46
(2.3) 47
(2.4) 50
(2.5) 50
(2.6) 50
(2.7) 50
(2.8) 50
(2.9) 51
(2.10) 51
(2.11) 52
(2.12) 52
(2.13) 52
(2.14) 52
(2.15) 53
(2.16) 53
(2.17) 53
(2.18) 55
(2.19) 55
(2.20) 55
(2.21) 56
(2.22) 58
(2.23) 58
(2.24) 61
(2.25) 62
(3.1) 67
(3.2) 67
(3.3) 68
(3.4) 68
(3.5) 70
(3.6) 70
(3.7) 70
(3.8) 71
(3.9) 71
(3.10) 71
(3.11) 72
(3.12) 73
(3.13) 73
(3.14) 73
(3.15) 74
(3.16) 75
(3.17) 77
(3.18) 77
(3.19) 78
(3.20) 78
(3.21) 78
(3.22) 79
(3.23) 80
(3.24) 80
(3.25) 82
(3.26) 82
(4.1) 88
(4.2) 88
(4.3) 89
(4.4) 89
(4.5) 91
(4.6) 91
(4.7) 91
(4.8) 93
(4.9) 94
(4.10) 94
(4.11) 94
(4.12) 94
(4.13) 95
(4.14) 95

(4.15) 95
(4.16) 96
(4.17) 96
(4.18) 97
(4.19) 98
(4.20) 99
(4.21) 100
(4.22) 100
(4.23) 101
(4.24) 102
(4.25) 103
(4.26) 104
(4.27) 104
(4.28) 104
(4.29) 105
(5.1) 109
(5.2) 110
(5.3) 110
(5.4) 110
(5.5) 110
(5.6) 111
(5.7) 111
(5.8) 111
(5.9) 112
(5.10) 113
(5.11) 113
(5.12) 114
(5.13) 114
(5.14) 115
(5.15) 115
(5.16) 115
(5.17) 116
(5.18) 116
(5.19) 119
(5.20) 119
(5.21) 119
(5.22) 120
(5.23) 120
(5.24) 121
(5.25) 121
(5.26) 124
(5.27) 124
(6.1) 131
(6.2) 131
(6.3) 133
(6.4) 134
(6.5) 135
(6.6) 135
(6.7) 135
(6.8) 136
(6.9) 136
(6.10) 137
(6.11) 139
(6.12) 139
(6.13) 139
(6.14) 140
(6.15) 140
(6.16) 141
(6.17) 141
(6.18) 141
(6.19) 142
(6.20) 148
(7.1) 157
(7.2) 157
(7.3) 158
(7.4) 158
(7.5) 159
(7.6) 162
(7.7) 162
(7.8) 164
(7.9) 164
(7.10) 165
(7.11) 165
(7.12) 165
(8.1) 173
(8.2) 175
(8.3) 176
(8.4) 176
(8.5) 177
(8.6) 177
(8.7) 178
(8.8) 178
(8.9) 179
(8.10) 179
(8.11) 181
(8.12) 181
(8.13) 182
(8.14) 182
(8.15) 185
(8.16) 185

(8.17) 185
(8.18) 186
(8.19) 186
(8.20) 187
(8.21) 187
(9.1) 196
(9.2) 196
(9.3) 197
(9.4) 197
(9.5) 200
(9.6) 201
(9.7) 201
(9.8) 202
(9.9) 202
(9.10) 205
(9.11) 205
(9.12) 205
(9.13) 206
(9.14) 207
(9.15) 207
(9.16) 210
(P.1) 215
(P.2) 216
(P.3) 218
(P.4) 218
(P.5) 218
(P.6) 219
(P.7) 219
(P.8) 221
(P.9) 222
(10.1) 227
(10.2) 227
(10.3) 228
(10.4) 229
(10.5) 230
(10.6) 230
(10.7) 231
(10.8) 232
(10.9) 234
(10.10) 234
(10.11) 234
(10.12) 234
(10.13) 235
(10.14) 235
(10.15) 241
(10.16) 242
(10.17) 242
(10.18) 243
(10.19) 243
(10.20) 243
(11.1) 248
(11.2) 248
(11.3) 248
(11.4) 249
(11.5) 251
(11.6) 251
(11.7) 251
(11.8) 252
(11.9) 252
(11.10) 252
(11.11) 252
(11.12) 253
(11.13) 254
(11.14) 256
(11.15) 257
(11.16) 258
(11.17) 260
(11.18) 262
(11.19) 262
(11.20) 262
(11.21) 262
(11.22) 263
(12.1) 267
(12.2) 268
(12.3) 268
(12.4) 269
(12.5) 270
(12.6) 271
(12.7) 272
(12.8) 273
(12.9) 273
(12.10) 274
(12.11) 274
(12.12) 274
(12.13) 276
(12.14) 276
(12.15) 276
(12.16) 277
(12.17) 278
(12.18) 278